

目 录

第 1 章 绪论

第 2 章 知识表示与知识图谱

第 3 章 确定性推理方法

第 4 章 不确定性推理方法

第 5 章 搜索求解策略

第 6 章 智能计算及其应用

第 7 章 专家系统与机器学习

第 8 章 人工神经网络及其应用

第 9 章 智能体与多智能体系统

第 10 章 自然语言处理及其应用

第 11 章 人工智能在游戏设计中的应用

附录：参考例题及解答

第 1 章 绪论

- ◆ 2024 年诺贝尔物理学奖：【基于人工神经网络实现机器学习的基础性发现和发明】

—— 约翰·霍普菲尔德 (John J. Hopfield);

杰弗里·辛顿 (Geoffrey E. Hinton)

- ◆ 1956 年正式提出人工智能这个术语，并把它作为一门新兴学科。

- ◆ 何为智能？

三种观点：思维理论、知识阈值理论、进化理论等。

综合上述各种观点，可以认为：智能是知识与智力的总和。其中，知识是一切智能行为的基础，而智力是获取知识并应用知识求解问题的能力。

- ◆ 智能的特征

1. 具有感知能力（视听触嗅味）

2. 具有记忆与思维能力

思维可分为：逻辑思维（抽象思维）、形象思维（直感思维）、顿悟思维（灵感思维）等。

3. 具有学习能力

4. 具有行为能力

- ◆ 人工智能发展简史

1956 年以前——孕育

①亚里士多德：三段论（前 384-前 322）

②培根：归纳法、“知识就是力量”

③莱布尼茨：万能符号、推理计算

④布尔：布尔代数

⑤图灵：图灵机（1936）

⑥麦克洛奇&匹兹：第一个神经网络模型（M-P 模型）（1943）

⑦阿塔纳索夫&贝瑞：第一台电子计算机（Atanasoff-Berry Computer, ABC）（1937-1941）

第一台计算机不是由美国的莫克利和埃柯特在 1946 年发明。（美国著名公案，课本 P24）

1956-1969——形成 人工智能之父——麦卡锡（本书不是图灵）

这个阶段主要是指 1956—1969 年。1956 年夏季，由当时达特茅斯学院（Dartmouth College）的年轻数学助教、现任斯坦福大学教授麦卡锡（J. McCarthy）联合哈佛大学年轻数学和神经学家、麻省理工学院教授明斯基（M. L. Minsky），IBM 公司信息研究中心负责人洛切斯特（N. Rochester），贝尔实验室信息部数学研究员香农（C. E. Shannon）共同发起，邀请普林斯顿大学的莫尔（T. Moore）和 IBM 公司的塞缪尔（A. L. Samuel）、麻省理工学院的塞尔夫里奇（O. Selfridge）和索罗莫夫（R. Solomonoff）以及兰德（RAND）公司和卡内基梅隆大学的纽厄尔（A. Newell）、西蒙（H. A. Simon）等在美国达特茅斯学院召开了一次为时两个月的学术研讨会，讨论关于机器智能的问题。会上经麦卡锡提议正式采用了“人工智能”这一术语。麦卡锡因此被称为人工智能之父。这是一次具有历史意义的重要会议，它标志着人工智能作为一门新兴学科正式诞生了。此

1970 以后——发展

2011 以后——大数据驱动人工智能发展期

- ◆ 人工智能研究的基本内容

1. 知识表示：将人类知识形式化/模型化（详见下章），方法：符号表示法、连接机制表示法

2. 机器感知：以机器视觉和机器听觉为主

3. 机器思维

4. 机器学习：研究如何使计算机具有类似于人的学习能力，使它能通过学习自动地获取知识。

5. 机器行为

- ◆ 模式识别

模式识别(pattern recognition)是一门研究对象描述和分类方法的学科。

模式：对一个物体或者某些其他感兴趣实体定量的或者结构的描述。

模式类：具有某些共同属性的模式集合。

第2章 知识表示与知识图谱

- ◆ 知识：把有关信息关联在一起所形成的信息结构。
- ◆ 知识表示：将人类知识形式化或者模型化。
- ◆ 逻辑：①经典命题逻辑和一阶谓词逻辑 ②泛指经典逻辑之外的：三值、多值、模糊等
命题逻辑与谓词逻辑是最先应用于人工智能的两种逻辑。命题逻辑可看作是谓词逻辑的一种特殊形式。
- ◆ 命题(proposition)：一个非真即假的陈述句。一个命题不能同时既为真又为假，但可以在一种条件下为真，在另一种条件下为假。
- ◆ 谓词(predicate)逻辑：基于命题中谓词分析的一种逻辑。一个谓词可分为谓词名与个体两个部分。个体表示某个独立存在的事物或者某个抽象的概念；谓词名用于刻画个体的性质、状态或个体间的关系。
谓词的一般形式： $P(x_1, x_2, \dots, x_n)$ ，其中， P 是谓词名， x_1, x_2, \dots, x_n 是个体。
谓词中包含的个体数目称为谓词的元数。 $P(x)$ 是一元谓词， $P(x, y)$ 是二元谓词 $P(x_1, x_2, \dots, x_n)$ 是 n 元谓词。
在谓词 $P(x_1, x_2, \dots, x_n)$ 中,若 $x(i=1, \dots, n)$ 都是个体常量、变元或函数，称它为一阶谓词。如果某个 x_i 本身又是一个一阶谓词，则称它为二阶谓词，余者可依此类推。
- ◆ 谓词公式

连接词（优先级顺序）：否定（非）、合取、析取、蕴涵（条件）、等价（双条件） $\neg, \wedge, \vee, \rightarrow, \leftrightarrow$

谓词公式：由谓词符号、常量符号、变量符号、函数符号以及括号、逗号等按一定语法规则组成的字符串的表达式。

- ◆ 原子谓词公式
单个谓词是谓词公式，称为原子谓词公式。
- ◆ 量词的辖域
位于量词后面的单个谓词或者用括弧括起来的谓词公式称为量词的辖域，辖域内与量词中同名的变元称为约束变元，不受约束的变元称为自由变元。
- ◆ 谓词公式的永真蕴涵

定义 2.7 对于谓词公式 P 与 Q ,如果 $P \rightarrow Q$ 永真,则称公式 P 永真蕴涵 Q ,记作 $P \Rightarrow Q$,且称 Q 为 P 的逻辑结论, P 为 Q 的前提。

- ◆ 产生式

1. 确定性规则知识的产生式表示

确定性规则知识的产生式表示的基本形式如下：

IF P THEN Q

或者

$P \rightarrow Q$

2. 不确定性规则知识的产生式表示

不确定性规则知识的产生式表示的基本形式如下：

IF P THEN Q (置信度)

或者

$P \rightarrow Q$ (置信度)

3. 确定性事实性知识的产生式表示

确定性事实一般用三元组表示：

(对象,属性,值)

或者

(关系,对象1,对象2)

4. 不确定性事实性知识的产生式表示

不确定性事实一般用四元组表示：

(对象,属性,值,置信度)

或者

(关系,对象1,对象2,置信度)

- ◆ 知识图谱（详见参考例题）（第五版教材新内容！）

第3章 确定性推理方法

◆ 自然演绎推理

从一组已知为真的事实出发,直接运用经典逻辑的推理规则推出结论的过程称为自然演绎推理。其中,基本的推理是 P 规则、 T 规则、假言推理、拒取式推理等。

假言推理的一般形式是

$$P, P \rightarrow Q \Rightarrow Q$$

它表示:由 $P \rightarrow Q$ 及 P 为真,可推出 Q 为真。

例如,由“如果 x 是金属,则 x 能导电”及“铜是金属”可推出“铜能导电”的结论。

拒取式推理的一般形式是

$$P \rightarrow Q, \neg Q \Rightarrow \neg P$$

它表示:由 $P \rightarrow Q$ 为真及 Q 为假,可推出 P 为假。

例如,由“如果下雨,则地上就湿”及“地上不湿”可推出“没有下雨”的结论。

例 3.1 设已知如下事实:

① 凡是容易的课程小王 ($Wang$) 都喜欢。

② C 班的课程都是容易的。

③ ds 是 C 班的一门课程。

求证:小王喜欢 ds 这门课程。

证明 首先定义谓词:

$EASY(x)$: x 是容易的;

$LIKE(x, y)$: x 喜欢 y ;

$C(x)$: x 是 C 班的一门课程。

把上述已知事实及待求证的问题用谓词公式表示出来:

$(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$	凡是容易的课程小王都是喜欢的;
$(\forall x)(C(x) \rightarrow EASY(x))$	C 班的课程都是容易的;
$C(ds)$	ds 是 C 班的课程;
$LIKE(Wang, ds)$	小王喜欢的 ds 这门课程,这是待求证的问题。

应用推理规则进行推理:

因为

$$(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$$

所以由全称固化得

$$EASY(z) \rightarrow LIKE(Wang, z)$$

因为

$$(\forall x)(C(x) \rightarrow EASY(x))$$

所以由全称固化得

$$C(y) \rightarrow EASY(y)$$

由 P 规则及假言推理得

$$C(ds), C(y) \rightarrow EASY(y) \Rightarrow EASY(ds)$$

$$EASY(ds), EASY(z) \rightarrow LIKE(Wang, z)$$

由 T 规则及假言推理得

$$LIKE(Wang, ds)$$

即小王喜欢 ds 这门课程。

◆ 子句

任何文字的析取式称为子句 (clause)。

第4章 不确定性推理方法

◆ 可信度方法 (C-F 模型)

可信度方法是肖特里菲 (E. H. Shortliffe) 等人在确定性理论 (Theory of Confirmation) 的基础上, 结合概率论等提出的一种不确定性推理方法。它首先在专家系统 MYCIN 中得到了成功的应用。由于该方法比较直观、简单, 而且效果也比较好, 因而受到人们的重视。目前, 许多专家系统都是基于这一方法建造起来的。

人们在长期的实践活动中, 对客观世界的认识积累了大量的经验, 当面临一个新事物或新情况时, 往往可用这些经验对问题的真、假或为真的程度作出判断。这种根据经验对一个事物或现象为真的相信程度称为可信度 (certainty)。

5. 结论不确定性的合成算法

若由多条不同知识推出了相同的结论, 但可信度不同, 则可用合成算法求出综合可信度。

由于对多条知识的综合可通过两两的合成实现, 所以下面只考虑两条知识的情况。

设有如下知识

$$\begin{array}{llllll} \text{IF} & E_1 & \text{THEN} & H & (CF(H, E_1)) \\ \text{IF} & E_2 & \text{THEN} & H & (CF(H, E_2)) \end{array}$$

则结论 H 的综合可信度可分为如下两步算出:

(1) 分别对每一条知识求出 $CF(H)$

$$CF_1(H) = CF(H, E_1) \times \max\{0, CF(E_1)\}$$

$$CF_2(H) = CF(H, E_2) \times \max\{0, CF(E_2)\}$$

(2) 用下述公式求出 E_1 与 E_2 对 H 的综合影响所形成的可信度 $CF_{1,2}(H)$

$$CF_{1,2}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & \text{若 } CF_1(H) \geq 0, \quad CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & \text{若 } CF_1(H) < 0, \quad CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & \text{若 } CF_1(H)CF_2(H) < 0 \end{cases}$$

【重要例题】例 4.1 (解析见课本)

例 4.1 设有如下一组知识:

$$\begin{array}{llllll} r_1: & \text{IF} & E_1 & \text{THEN} & H & (0.8) \\ r_2: & \text{IF} & E_2 & \text{THEN} & H & (0.6) \\ r_3: & \text{IF} & E_3 & \text{THEN} & H & (-0.5) \\ r_4: & \text{IF} & E_4 & \text{AND} & (E_5 \text{ OR } E_6) & \text{THEN } E_1 & (0.7) \\ r_5: & \text{IF} & E_7 & \text{AND} & E_8 & \text{THEN } E_3 & (0.9) \end{array}$$

已知: $CF(E_2) = 0.8, CF(E_4) = 0.5, CF(E_5) = 0.6, CF(E_6) = 0.7, CF(E_7) = 0.6, CF(E_8) = 0.9$ 。求 $CF(H)$ 。

◆ 证据理论 (D-S 理论)

证据理论 (Theory of Evidence) 由德普斯特 (A. P. Dempster) 于 20 世纪 60 年代首先提出, 并由沙佛 (G. Shafer) 在 20 世纪 70 年代中期进一步发展起来的一种处理不确定性的理论, 所以, 又称为 D-S 理论。

1. 概率分配函数

定义 4.1 设函数 $M: 2^D \rightarrow [0, 1]$, 即对任何一个属于 D 的子集 A , 命它对应一个数 $M \in [0, 1]$, 且满足

$$M(\emptyset) = 0$$

$$\sum_{A \subseteq D} M(A) = 1$$

则称 M 是 2^D 上的基本概率分配函数, $M(A)$ 称为 A 的基本概率数。

2. 信任函数

定义 4.2 命题的信任函数 (Belief Function) $Bel: 2^D \rightarrow [0, 1]$, 且

$$Bel(A) = \sum_{B \subseteq A} M(B) \quad \forall A \subseteq D \quad (4.5)$$

其中 2^D 表示 D 的所有子集。

Bel 函数又称为下限函数, $Bel(A)$ 表示对命题 A 为真的总的信任程度。

3. 似然函数

定义 4.3 似然函数 $Pl: 2^D \rightarrow [0, 1]$, 且

$$Pl(A) = 1 - Bel(\neg A) \quad \forall A \subseteq D \quad (4.6)$$

4. 概率分配函数的正交和 (证据的组合) 【重要, 对应习题 4.4】

定义 4.4 设 M_1 和 M_2 是两个概率分配函数, 则其正交和 $M = M_1 \oplus M_2$ 为

$$\begin{aligned} M(\emptyset) &= 0 \\ M(A) &= K^{-1} \sum_{x \cap y = A} M_1(x) M_2(y) \end{aligned} \quad (4.7a)$$

其中, K 由下式计算

$$K = 1 - \sum_{x \cap y = \emptyset} M_1(x) M_2(y) = \sum_{x \cap y \neq \emptyset} M_1(x) M_2(y) \quad (4.7b)$$

◆ 模糊集合的运算

设 A, B 是论域 U 中的两个模糊集。

① 交运算 (intersection) $A \cap B$:

$$\mu_{A \cap B}(x) = \min \{ \mu_A(x), \mu_B(x) \} = \mu_A(x) \wedge \mu_B(x) \quad (4.14)$$

② 并运算 (union) $A \cup B$:

$$\mu_{A \cup B}(x) = \max \{ \mu_A(x), \mu_B(x) \} = \mu_A(x) \vee \mu_B(x) \quad (4.15)$$

③ 补运算 (complement) \bar{A} 或者 A^c :

$$\mu_{\bar{A}}(x) = 1 - \mu_A(x) \quad (4.16)$$

其中, \wedge 表示取小运算; \vee 表示取大运算。

【重要例题】例 4.4 (解析见课本)

例 4.4 设论域 $U = \{x_1, x_2, x_3, x_4\}$, A 及 B 是论域 U 上的两个模糊集合, 已知

$$A = 0.3/x_1 + 0.5/x_2 + 0.7/x_3 + 0.4/x_4$$

$$B = 0.5/x_1 + 1/x_2 + 0.8/x_3$$

求 $\bar{A}, \bar{B}, A \cap B, A \cup B$ 。

◆ 模糊推理

在模糊逻辑中, 给集合中每一个元素赋予一个介于 0 和 1 之间的实数, 描述其属于一个集合的程度, 该实数称为元素属于一个集合的隶属度。集合中所有元素的隶属度全体构成集合的隶属函数。

模糊关系描述两个模糊集合中的元素之间关联程度的多少。当论域为有限时, 模糊关系的合成可用模糊矩阵的合成表示。模糊矩阵的合成可以由多种计算方法得到。常用的几种计算方法: 最大-最小合成法、最大-代数积合成法。

通过条件模糊向量与模糊关系 R 的合成进行模糊推理, 得到结论的模糊向量, 然后采用模糊决策将模糊结论转换为精确量。

模糊决策方法有最大隶属度法、加权平均判决法、中位数法等。

第 5 章 搜索求解策略

◆ 搜索方法

根据搜索过程中是否运用与问题有关的信息,可以将搜索方法分为启发式搜索和盲目搜索。

所谓盲目搜索(Blind Search)是指在对特定问题不具有任何有关信息的条件下,按固定的步骤(依次或随机调用操作算子)进行的搜索,它能快速地调用一个操作算子。

所谓启发式搜索(Heuristic Search)则是考虑特定问题领域可应用的知识,动态地确定调用操作算子的步骤,优先选择较适合的操作算子,尽量减少不必要的搜索,以求尽快地到达结束状态,提高搜索效率。

◆ 估价函数

一般来说,估计一个结点的价值,必须综合考虑两方面的因素:已经付出的代价和将要付出的代价。因此,估价函数 $f(n)$ 定义为从初始结点经过 n 结点到达目的结点的路径的最小代价估计值,其一般形式是

$$f(n) = g(n) + h(n) \quad (5.3)$$

其中, $g(n)$ 是从初始结点到 n 结点的实际代价,而 $h(n)$ 是从 n 结点到目的结点的最佳路径的估计代价。

◆ A 搜索算法

A 算法是基于估价函数的一种 加权启发式 图搜索 算法,步骤略。

◆ A*搜索算法

A* 搜索算法是由著名的人工智能学者 Nilsson 提出的,它是目前最有影响的启发式图搜索算法,也称为最佳图搜索算法。

定义 $h^*(n)$ 为状态 n 到目的状态的最优路径的代价,则当 A 搜索算法的启发函数 $h(n)$ 小于等于 $h^*(n)$,即满足

$$h(n) \leq h^*(n), \quad \text{对所有结点 } n \quad (5.4)$$

时,被称为 A* 搜索算法。

第 6 章 智能计算及其应用

◆ 引言

受自然界和生物界规律的启迪,人们根据其原理模仿设计了许多求解问题的算法,包括人工神经网络、模糊逻辑、遗传算法、DNA 计算、模拟退火算法、禁忌搜索算法、免疫算法、膜计算、量子计算、粒子群优化算法、蚁群算法、人工蜂群算法、人工鱼群算法以及细菌群体优化算法等,这些算法称为智能计算,也称为计算智能(Computational Intelligence, CI)。智能优化方法通常包括进化计算和群智能等两大类方法,是一种典型的元启发式随机优化方法,已经广泛应用于组合优化、机器学习、智能控制、模式识别、规划设计、网络安全等领域,是 21 世纪有关智能计算中的重要技术之一。

◆ 进化算法

进化算法(Evolutionary Algorithms, EA)是基于自然选择和自然遗传等生物进化机制的一种搜索算法。进化算法是以达尔文的进化论思想为基础,通过模拟生物进化过程与机制的求解问题的自组织、自适应的人工智能技术,是一类借鉴生物界自然选择和自然遗传机制的随机搜索算法,这些方法本质上从不同的角度对达尔文的进化原理进行了不同的运用和阐述,非常适用于处理传统搜索方法难以解决的复杂和非线性优化问题。生物进化是通过繁殖、变异、竞争和选择实现的;而进化算法则主要通过选择、重组和变异这三种操作实现优化问题的求解。

进化算法是一个“算法簇”,包括遗传算法(Genetic Algorithms, GA)、遗传规划(Genetic Programming)、进化策略(Evolution Strategies)和进化规划(evolution programming)等。

◆ 粒子群优化算法(详见参考例题)

第 7 章 专家系统与机器学习

◆ 专家系统的特点

1. 具有专家水平的专业知识
2. 能进行有效的推理
3. 具有启发性
4. 具有灵活性
5. 具有透明性
6. 具有交互性

第 9 章 智能体与多智能体系统

◆ 智能体

在人工智能领域中,Agent 可以看作是一个程序或者一个实体,它嵌入在环境中,通过传感器 (sensor) 感知环境,通过效应器 (effector) 自治地作用于环境并满足设计要求。Agent 与环境的交互作用如图 9.1 所示。




图 9.1 Agent 与环境的交互作用

◆ 智能体的特性: 自主性、反应性、社会性、进化性

◆ 智能体的结构: Agent=体系结构+程序

◆ 多智能体系统 (详见参考例题)

◆ 多智能体系统的类别及解释 (详见参考例题)

第 11 章 人工智能在游戏设计中的应用

◆ 概念区分——人工智能游戏(AI game)/游戏人工智能(game AI)

前者是应用人工智能技术设计的游戏,

后者是适合于游戏开发的人工智能技术。

◆ 游戏人工智能的概念与分类 (详见参考例题)

附录：参考例题及解答

【课本 P47，知识图谱】

- 什么是知识图谱？如何用主谓宾 SPO 三元组表示知识图谱？

知识图谱 (knowledge graph/vault)，又称科学知识图谱，用各种不同的图形等可视化技术描述知识资源及其载体，挖掘、分析、构建、绘制和显示知识及它们之间的相互联系。

表示：(1) (实体 1-关系-实体 2) (2) (实体-属性-属性值)

【课本 P263，多智能体系统】

- 什么是多智能体系统？写出其类别并具体解释。

对于现实中复杂的大规模问题，只靠单个的智能体往往无法描述和解决。因此，一个应用系统中往往包含多个智能体，这些智能体不仅具备自身的问题求解能力和行为目标，而且能够相互协作，达到共同的整体目标，这样的系统称为多智能体系统 (Multi-Agent System, MAS)。

反应式 Agent 是一种具备对当时处境的实时反应能力的 Agent。

慎思式 Agent 是一种基于知识的系统，包括环境描述和丰富的智能行为的逻辑推理能力。

复合式 Agent 综合了反应式 Agent 和慎思式 Agent 的优点，具有较强的灵活性和快速的响应性。复合式 Agent 是在一个 Agent 内组合多种相对独立和并行执行的智能形态，其结构包括感知、动作、反应、建模、规划、通信和决策等模块，如图 9.4 所示。

【课本 P163，粒子群 (PSO) 算法】

- 简述粒子群优化算法的基本原理（指出右边各部分含义，各参数的意义）。

在粒子群优化算法中，在 n 维连续搜索空间中，对粒子群中的第 i ($i=1, 2, \dots, m$) 个粒子，定义 n 维当前位置向量 $x^i(k) = [x_1^i \ x_2^i \ \dots \ x_n^i]^T$ 表示搜索空间中粒子的当前位置， n 维最优位置向量 $p^i(k) = [p_1^i \ p_2^i \ \dots \ p_n^i]^T$ 表示该粒子至今所获得的具有最优适应度 $f_p^i(k)$ 的位置， n 维速度向量 $v^i(k) = [v_1^i \ v_2^i \ \dots \ v_n^i]^T$ 表示该粒子的搜索方向。

每个粒子经历过的最优位置 (pbest) 记为 $p^i(k) = [p_1^i \ p_2^i \ \dots \ p_n^i]^T$ ，群体经历过的最优位置 (gbest) 记为 $p^g(k) = [p_1^g \ p_2^g \ \dots \ p_n^g]^T$ ，则基本的 PSO 算法为

$$v_j^i(k+1) = \omega(k) v_j^i(k) + \varphi_1 \text{rand}(0, a_1) (p_j^i(k) - x_j^i(k)) + \varphi_2 \text{rand}(0, a_2) (p_j^g(k) - x_j^i(k)) \quad (6.20a)$$

$$x_j^i(k+1) = x_j^i(k) + v_j^i(k+1) \quad (6.20b)$$

$$i = 1, 2, \dots, m; \quad j = 1, 2, \dots, n$$

其中， ω 是惯性权重因子。 φ_1, φ_2 是加速度常数，均为非负值。 $\text{rand}(0, a_1)$ 和 $\text{rand}(0, a_2)$ 为 $[0, a_1]$ 、 $[0, a_2]$ 范围内的具有均匀分布的随机数， a_1 与 a_2 为相应的控制参数。

式 (6.20a) 右边的第一部分是粒子在前一时刻的速度；第二部分为个体“认知 (cognition)”分量，表示粒子本身的思考，将现有的位置和曾经经历过的最优位置相比。第三部分是群体“社会 (social)”分量，表示粒子间的信息共享与相互合作。 φ_1 和 φ_2 分别控制个体认知分量和群体社会分量相对贡献的学习率。引入 $\text{rand}(0, a_1)$ 和 $\text{rand}(0, a_2)$ 将增加认知和社会搜索方向的随机性和算法多样性。

【课本 P295，游戏人工智能】

- 什么是游戏人工智能，分哪两类，有什么含义？

适合于游戏开发的人工智能技术称为游戏人工智能(Game AI)。

游戏人工智能分为**定性**(deterministic)和**非定性**(nondeterministic)两类。

定性技术是游戏人工智能的**基础**。用定性技术设计的角色行为是**特定的、可预测的**。非定性技术是定性技术的一种**提高**。用非定性技术设计的角色行为具有**某种程度的不确定性和不可预测性**。

未来的游戏人工智能越来越注重非定性技术的研究与应用。成功的游戏软件应该采用定性技术和非定性技术相结合的方法。用定性技术解决软件的部分调试和测试问题，用非定性技术增强软件的智能性，赋予软件更强的生命力和挑战性。

【课本 P77，归结反演】

- 例 3.10 已知如下信息。

规则 1: 任何人的兄弟不是女性。

规则 2: 任何人的姐妹必是女性。

事实: Mary 是 Bill 的姐妹。

求证: Mary 不是 Tom 的兄弟。

解 定义谓词:

$brother(x, y)$: x 是 y 的兄弟

$sister(x, y)$: x 是 y 的姐妹

$woman(x)$: x 是女性

把已知规则与事实表示成谓词公式,得

规则 1: $\forall x \forall y (brother(x, y) \rightarrow \neg woman(x))$

规则 2: $\forall x \forall y (sister(x, y) \rightarrow woman(x))$

事实: $sister(Mary, Bill)$

把要求证的结论表示成谓词公式,得

求证: $\neg brother(Mary, Tom)$

化规则 1 为子句

$$\forall x \forall y (\neg brother(x, y) \vee \neg woman(x))$$

$$C_1 = \neg brother(x, y) \vee \neg woman(x)$$

化规则 2 为子句

$$\forall x \forall y (\neg sister(x, y) \vee woman(x))$$

$$C_2 = \neg sister(u, v) \vee woman(u)$$

事实原来就是子句形式

$$C_3 = sister(Mary, Bill)$$

C_2 与 C_3 归结为

$$C_{23} = woman(Mary)$$

C_{23} 与 C_1 归结为

$$C_{123} = \neg brother(Mary, y)$$

设 $C_4 = brother(Mary, Tom)$, 则

$$C_{1234} = NIL$$

所以,得证。

【课本 P111, D-S 证据理论】

• 习题 4.4

设样本空间 $D = \{a, b, c, d\}$, M_1, M_2 为定义在 2^D 上的概率分布函数:
 $M_1: M_1(\{b, c, d\}) = 0.7, M_1(\{a, b, c, d\}) = 0.3, M_1$ 的其余基本概率数均为 0;
 $M_2: M_2(\{a, b\}) = 0.6, M_2(\{a, b, c, d\}) = 0.4, M_2$ 的其余基本概率数均为 0。

- (1) 求它们的正交和 $M = M_1 \oplus M_2$;
- (2) 求出 M 的似然函数和信任函数。

$$\begin{aligned} (1) \text{ 因为 } K &= \sum_{X \cap Y \neq \emptyset} M_1(X) M_2(Y) \\ &= M_1(\{b, c, d\}) M_2(\{a, b\}) + M_1(\{b, c, d\}) M_2(\{a, b, c, d\}) \\ &\quad + M_1(\{a, b, c, d\}) M_2(\{a, b\}) + M_1(\{a, b, c, d\}) M_2(\{a, b, c, d\}) \\ &= 0.7 \times 0.6 + 0.7 \times 0.4 + 0.3 \times 0.6 + 0.3 \times 0.4 = 1 \end{aligned}$$

$$\text{所以 } M(A) = K^{-1} \times \sum_{X \cap Y = A} M_1(X) M_2(Y) = \sum_{X \cap Y = A} M_1(X) M_2(Y)$$

$$\text{所以 } M(b) = M_1(\{b, c, d\}) \times M_2(\{a, b\}) = 0.7 \times 0.6 = 0.42$$

$$M(b, c, d) = M_1(\{b, c, d\}) \times M_2(\{a, b, c, d\}) = 0.7 \times 0.4 = 0.28$$

$$M(a, b) = M_1(\{a, b, c, d\}) \times M_2(\{a, b\}) = 0.3 \times 0.6 = 0.18$$

$$M(a, b, c, d) = M_1(\{a, b, c, d\}) \times M_2(\{a, b, c, d\}) = 0.3 \times 0.4 = 0.12$$

M 的其余基本概率分配函数为 0。

(2)

似然函数 $Bel(A)$ 是所有 A 的子集的基本概率分配之和, 即:

$$Bel(A) = \sum_{B \subseteq A} M(B)$$

计算各个集合的似然函数:

- $Bel(\{b\})$:

$$Bel(\{b\}) = M(\{b\}) = 0.42$$

- $Bel(\{b, c, d\})$:

$$Bel(\{b, c, d\}) = M(\{b\}) + M(\{b, c, d\}) = 0.42 + 0.28 = 0.70$$

- $Bel(\{a, b\})$:

$$Bel(\{a, b\}) = M(\{b\}) + M(\{a, b\}) = 0.42 + 0.18 = 0.60$$

- $Bel(\{a, b, c, d\})$:

$$Bel(\{a, b, c, d\}) = M(\{b\}) + M(\{b, c, d\}) + M(\{a, b\}) + M(\{a, b, c, d\}) = 0.42 + 0.28 + 0.18 + 0.12 = 1.00$$

信任函数 $Pl(A)$ 是所有与 A 有非空交集的基本概率分配之和, 即:

$$Pl(A) = \sum_{B \cap A \neq \emptyset} M(B)$$

计算各个集合的信任函数:

- $Pl(\{b\})$:

$$Pl(\{b\}) = M(\{b\}) + M(\{b, c, d\}) + M(\{a, b\}) + M(\{a, b, c, d\}) = 0.42 + 0.28 + 0.18 + 0.12 = 1.00$$

- $Pl(\{b, c, d\})$:

$$Pl(\{b, c, d\}) = M(\{b\}) + M(\{b, c, d\}) + M(\{a, b, c, d\}) = 0.42 + 0.28 + 0.12 = 0.82$$

- $Pl(\{a, b\})$:

$$Pl(\{a, b\}) = M(\{b\}) + M(\{a, b\}) + M(\{b, c, d\}) + M(\{a, b, c, d\}) = 0.42 + 0.18 + 0.28 + 0.12 = 1.00$$

- $Pl(\{a, b, c, d\})$:

$$Pl(\{a, b, c, d\}) = M(\{a, b, c, d\}) + M(\{b\}) + M(\{b, c, d\}) + M(\{a, b\}) = 1.00$$