

---

# 第六章：支持向量机

---

---

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数


□ 软间隔与正则化

□ 支持向量回归

□ 核方法


# 引子

线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开。




# 引子

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



# 引子

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



-A: 应选择“**正中间**”, 容忍性好, 鲁棒性高, 泛化能力最强.

# 间隔与支持向量

超平面 $H$ 方程:  $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = 0$


$g(\mathbf{x})$ 是点 $\mathbf{x}$ 到决策面 $H$ 的距离的一种代数度量

函数间隔: 量化分类的正确性、确信度

$$\hat{r}_i = y_i (\mathbf{w}^\top \mathbf{x}_i + b)$$

几何间隔

$$r_i = y_i \frac{(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|} = \frac{\hat{r}_i}{\|\mathbf{w}\|}$$



$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|}, \quad g(\mathbf{x}) = r \|\mathbf{w}\|$$


$r$ 是 $\mathbf{x}$ 到 $H$ 的垂直距离

$\mathbf{x}_p$ 是 $\mathbf{x}$ 在 $H$ 上的投影向量

$$r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}, \quad r_0 = \frac{b}{\|\mathbf{w}\|}$$

# 间隔与支持向量

超平面方程:  $w^\top x + b = 0$



# 支持向量机基本型

□ 最大间隔：寻找参数  $\mathbf{w}$  和  $b$ , 使得  $\gamma$  最大.

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数

□ 软间隔与正则化

□ 支持向量回归

□ 核方法

# 对偶问题

## □ 拉格朗日乘子法

- 第一步：引入拉格朗日乘子  $\alpha_i \geq 0$  得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令  $L(\mathbf{w}, b, \boldsymbol{\alpha})$  对  $\mathbf{w}$  和  $b$  的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$$

$$\min_{\boldsymbol{\alpha}} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$

# 对偶问题

$$\theta_P(\mathbf{x}) = \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta) \quad P \text{表示原始问题}$$

$$\theta_D(\alpha, \beta) = \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \quad D \text{表示对偶问题}$$

$$\min_{\mathbf{x}} \theta_P(\mathbf{x}) = \min_{\mathbf{x}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta)$$

广义拉格朗日函数的极大小问题


$$\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta)$$

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \leq \min_{\mathbf{x}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta) = p^*$$


强对偶定理: 等号成立

充要条件: 优化变量满足  
Karush-Kuhn-Tucker(KKT)条件

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \leq b_i, \quad i = 1, 2, \dots, k \\ & h_j(\mathbf{x}) = c_j, \quad j = 1, 2, \dots, l \end{aligned}$$



定理1: 若原始问题和对偶问题都有最优值, 则式成立



# 对偶问题

$$\begin{aligned}L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \\&= \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m (\alpha_i - \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \alpha_i y_i b) \\&= \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i b\end{aligned}$$

$$\frac{\partial L}{\partial \mathbf{w}} = \frac{1}{2} \times 2 \times \mathbf{w} + 0 - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i - 0 = 0 \implies \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0 + 0 - 0 - \sum_{i=1}^m \alpha_i y_i = 0 \implies \sum_{i=1}^m \alpha_i y_i = 0$$

# 对偶问题

$$\begin{aligned}\inf_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i b \\&= \frac{1}{2} \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i - \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i - b \sum_{i=1}^m \alpha_i y_i \\&= -\frac{1}{2} \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i - b \sum_{i=1}^m \alpha_i y_i\end{aligned}$$

$$\begin{aligned}\inf_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= -\frac{1}{2} \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i \\&= -\frac{1}{2} \left( \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \left( \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right) + \sum_{i=1}^m \alpha_i \\&= -\frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i \\&= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j\end{aligned}$$


# 解的稀疏性

□ 最终模型:  $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \boxed{\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}} + b$

□ KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$



支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

# 求解方法 - SMO

□ 基本思路：不断执行如下两个步骤直至收敛。

- 第一步：选取一对需更新的变量  $\alpha_i$  和  $\alpha_j$ 。
- 第二步：固定  $\alpha_i$  和  $\alpha_j$  以外的参数，求解对偶问题更新  $\alpha_i$  和  $\alpha_j$ 。

□ 仅考虑  $\alpha_i$  和  $\alpha_j$  时，对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

用一个变量表示另一个变量，回代入对偶问题可得一个单变量的二次规划，该问题具有闭式解。

□ 偏移项  $b$ ：通过支持向量来确定。

$$y_s \left( \sum_{i \in S} \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_s + b \right) = 1$$

例：对于由正类样本点 (3,2)和反类样本点 (1,1)、(2,1) 组成的训练集，利用求解对偶问题的方法求出最优超平面，并判断哪些样本是支持向量。

$$\min \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^3 \alpha_i$$

代入数据后展开为：

$$\frac{1}{2} (13\alpha_1^2 + 2\alpha_2^2 + 5\alpha_3^2 - 10\alpha_1\alpha_2 - 16\alpha_1\alpha_3 + 6\alpha_2\alpha_3) - (\alpha_1 + \alpha_2 + \alpha_3)$$

约束条件为：

$$\alpha_1 - \alpha_2 - \alpha_3 = 0, \quad \alpha_i \geq 0 \quad (i = 1, 2, 3).$$

由  $\alpha_1 = \alpha_2 + \alpha_3$ ，代入目标函数化简为：

$$s(\alpha_2, \alpha_3) = \frac{5}{2}\alpha_2^2 + \alpha_3^2 + 3\alpha_2\alpha_3 - 2\alpha_2 - 2\alpha_3.$$



对  $\alpha_2$  和  $\alpha_3$  求偏导并令其为0，解得  $\alpha_2 = -2$ ,  $\alpha_3 = 4$ ，不满足非负约束。

检查边界条件：

- 当  $\alpha_2 = 0$  时，目标函数为  $\alpha_3^2 - 2\alpha_3$ ，极小值在  $\alpha_3 = 1$ ，对应  $\alpha_1 = 1$ ，目标值为  $-1$ 。
- 当  $\alpha_3 = 0$  时，目标函数为  $\frac{5}{2}\alpha_2^2 - 2\alpha_2$ ，极小值在  $\alpha_2 = \frac{2}{5}$ ，对应目标值为  $-0.4$ 。

最优解为  $\alpha_1 = 1, \alpha_2 = 0, \alpha_3 = 1$

- **权重向量**  $w = \sum \alpha_i y_i x_i = (1)(+1)(3, 2) + (1)(-1)(2, 1) = (1, 1)$
- **偏置项**  $b = -4$

支持向量判断：

$$\alpha_1 > 0 \text{ (对应点(3,2)) 和 } \alpha_3 > 0 \text{ (对应点(2,1))}$$

最优超平面：

$$x^{(1)} + x^{(2)} - 4 = 0$$

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数

□ 软间隔与正则化

□ 支持向量回归

□ 核方法

# 线性不可分


-Q: 若不存在一个能正确划分两类样本的超平面, 怎么办?

-A: 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.

□ 广义线性判别函数

如果  $\begin{cases} x < b \text{ 或 } x > a & \text{则决策 } x \in \omega_1 \\ b \leq x \leq a & \text{则决策 } x \in \omega_2 \end{cases}$

$$g(x) = (x - a)(x - b)$$



# 广义线性判别函数


## □ 二次函数的一般形式

$$g(x) = c_0 + c_1x + c_2x^2$$

映射 $X \rightarrow Y$

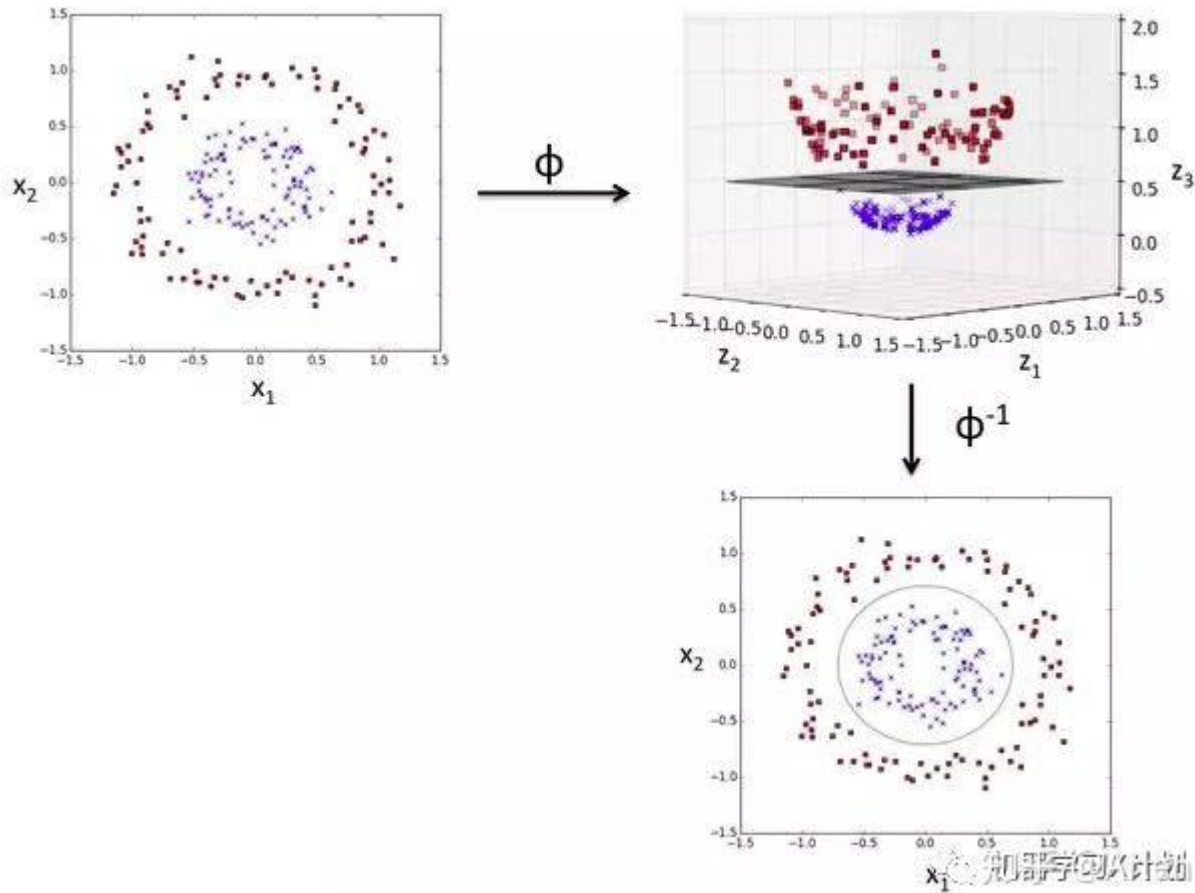
$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix}$$

广义权向量




- 按照上述原理，任何非线性函数 $g(x)$ 用级数展开成高次多项式后，都可转化成线性来处理；“维数灾难”

# 线性不可分



# 线性不可分

## □ 异或问题



# 核支持向量机

□ 设样本  $\mathbf{x}$  映射后的向量为  $\phi(\mathbf{x})$ , 划分超平面为  $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$ .

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)} - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \text{只以内积的形式出现} \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x})} + b$$

# 核函数

□ 基本想法：不显式地设计核映射，而是设计核函数。

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

□ Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定，则它就能作为核函数来使用。

(1) 交换性：

$$\kappa(x_i, x_j) = \kappa(x_j, x_i)$$

(2) 半正定性：

$$\forall \alpha_i \in R, \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \kappa(x_i, x_j) \geq 0$$



# 核函数

## □ 常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数


□ 软间隔与正则化

□ 支持向量回归

□ 核方法

# 软间隔

- Q: 现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是有过拟合造成的.
- A: 引入“软间隔”的概念, 允许支持向量机在一些样本上不满足约束.



# 0/1损失函数

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少。


$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} (y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$

其中  $l_{0/1}$  是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

- 存在的问题：0/1损失函数非凸、非连续，不易优化！

# 替代损失



替代损失函数数学性质较好，一般是0/1损失函数的上界

# 软间隔支持向量机


原始问题  $\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$

引入松弛变量 (Slack variables)  $\xi_i > 0$

$$\min_{\mathbf{w}, b, \xi_i} \left( \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \right)$$

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, (i = 1, 2, \dots, m)$$



# 软间隔支持向量机

原始问题  $\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$

$$\min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(\mathbf{w}^\top \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)) + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i \xi_i - \sum_{i=1}^m \mu_i \xi_i$$

$$0 = \sum_{i=1}^m \alpha_i y_i \quad = -\frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i + \sum_{i=1}^m C \xi_i - \sum_{i=1}^m \alpha_i \xi_i - \sum_{i=1}^m \mu_i \xi_i$$

$$C = \alpha_i + \mu_i \quad = -\frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i + \boxed{\sum_{i=1}^m (C - \alpha_i - \mu_i) \xi_i}$$
$$= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

# 软间隔支持向量机

原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

对偶问题


$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \\ \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \end{aligned}$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性.



# 软间隔支持向量机

$$\begin{cases} \alpha_i \geq 0, & \mu_i \geq 0 \\ y_i f(\mathbf{x}_i) - 1 + \xi_i \geq 0 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1 + \xi_i) = 0 \\ \xi_i \geq 0, \mu_i \xi_i = 0 \end{cases}$$



# 正则化

- 支持向量机学习模型的更一般形式

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$



结构风险, 描述模型的某些性质



经验风险, 描述模型与训练数据的契合程度

- 通过替换上面两个部分, 可以得到许多其他学习模型
  - 对数几率回归(Logistic Regression)
  - 最小绝对收缩选择算子(LASSO)
  - .....

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数


□ 软间隔与正则化

□ 支持向量回归

□ 核方法


# 支持向量回归

特点：允许模型输出和实际输出间存在  $2\epsilon$  的偏差。



# 损失函数

落入中间  $2\epsilon$  间隔带的样本不计算损失, 从而使得模型获得稀疏性.



# 形式化

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \leq \epsilon + \xi_i, \quad \text{超平面上} \\ & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \geq -\epsilon - \hat{\xi}_i, \quad \text{超平面下} \\ & \xi_i \geq 0, \hat{\xi}_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha, \hat{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^m (\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^m (\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \leq \alpha_i \leq C, \quad 0 \leq \hat{\alpha}_i \leq C. \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数

□ 软间隔与正则化

□ 支持向量回归

□ 核方法

# 表示定理

支持向量机  $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$

支持向量回归  $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$

结论：无论是支持向量机还是支持向量回归，学得模型总可以表示成核函数的线性组合。

更一般的结论(表示定理)：对于任意单调增函数 $\Omega$ 和任意非负损失函数 $l$ ，优化问题

$$\min_{h \in \mathbb{H}} F(h) = \Omega(\|h\|_{\mathbb{H}}) + l(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m))$$

的解总可以写为  $h^* = \sum_{i=1}^m \alpha_i \kappa(\cdot, \mathbf{x}_i)$ 。



# 核线性判别分析

□ 通过表示定理可以得到很多线性模型的“核化”版本

- 核SVM
- 核LDA
- 核PCA
- .....

□ 核LDA: 先将样本映射到高维特征空间, 然后在此特征空间中做线性判别分析

$$\begin{array}{l} \max_{\mathbf{w}} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w^\phi \mathbf{w}} \\ \quad \downarrow \\ h(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}_i, \mathbf{x}) \\ \max_{\boldsymbol{\alpha}} J(\boldsymbol{\alpha}) = \frac{\boldsymbol{\alpha}^\top \mathbf{M} \boldsymbol{\alpha}}{\boldsymbol{\alpha}^\top \mathbf{N} \boldsymbol{\alpha}} \end{array}$$