

《神经网络与深度学习》


注意力机制与外部记忆

周晓飞

xiaofei-zhou.com

自动化学院


网络能力



例子：阅读理解

Facebook bAbi tasks

- 1 John moved to the bedroom.
- 2 Mary grabbed the football there.
- 3 Sandra journeyed to the bedroom.
- 4 Sandra went back to the hallway.
- 5 Mary moved to the garden.
- 6 Mary journeyed to the office.
- 7 Where is the football? office



通用近似定理

- ▶ 由于优化算法和计算能力的限制，神经网络在实践中很难达到通用近似的能力。
 - ▶ 网络不能太复杂（参数太多）
- ▶ 如何提高网络能力
 - ▶ 局部连接
 - ▶ 权重共享
 - ▶ 汇聚操作
 - ▶ ?



本章主要内容包括：

- ▶ 认知神经学中的注意力
- ▶ 注意力机制
- ▶ 自注意力模型
- ▶ 人脑中的记忆
- ▶ 记忆增强网络
- ▶ 基于神经动力学的联想记忆

1 认知神经学中的注意力

大脑中的注意力 Attention

- ▶ 人脑每个时刻接收的外界输入信息非常多，包括来源于视觉、听觉、触觉的各种各样的信息。
- ▶ 但就视觉来说，眼睛每秒钟都会发送千万比特的信息给视觉神经系统。
- ▶ 人脑可以有意无意的从这些大量输入信息中选择小部分有用信息来重点处理，并忽略其他信息，这种能力就叫做注意力
- ▶ 人脑通过注意力来解决信息超载问题。

注意力示例







Fig. 1. General architecture of the model.

Itti L, Koch C, Niebur E. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on pattern analysis and machine intelligence, 1998, 20(11): 1254-1259.

大脑中的注意力 Attention

- ▶ 自上而下有意识的注意力，**聚焦式注意力 Focus Attention**
 - ▶ 指主动有意识地聚焦于某一对象的注意力 Top-down
- ▶ 自下而上无意识的注意力，**基于显著性的注意力 Saliency-based Attention bottom-up**
 - ▶ 由外界刺激驱动的注意，无需主动干预，和任务无关
 - ▶ 赢者通吃 winner-take-all, 聚焦在有显著不同刺激的对象上

注意力示例

- ▶ 当一个人在吵闹的鸡尾酒会上和朋友聊天时，尽管周围噪音干扰很多，他还是可以听到朋友的谈话内容，而忽略其他人的声音（**聚焦式注意力**）。
- ▶ 同时，如果未注意到的背景声中有重要的词（比如他的名字），他会马上注意到（**显著性注意力**）。

鸡尾酒会效应

2 人工神经网络中的注意力机制

例子：阅读理解 SQuAD

The first recorded travels by Europeans to China and back date from this time. The most famous traveler of the period was the Venetian Marco Polo, whose account of his trip to "Cambaluc," the capital of the Great Khan, and of life there astounded the people of Europe. The account of his travels, *Il milione* (or, *The Million*, known in English as the *Travels of Marco Polo*), appeared about the year 1299. Some argue over the accuracy of Marco Polo's accounts due to the lack of mentioning the Great Wall of China, tea houses, which would have been a prominent sight since Europeans had yet to adopt a tea culture, as well the practice of foot binding by the women in capital of the Great Khan. Some suggest that Marco Polo acquired much of his knowledge through contact with Persian traders since many of the places he named were in Persian.

How did some suspect that Polo learned about China instead of by actually visiting it?

Answer: through contact with Persian traders

注意力模型

▶ 软性注意力机制 (soft attention mechanism)

▶ 注意力机制可以分为两步 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbb{R}^{D \times N}$

▶ 计算注意力分布 α

▶ 引入查询向量 $\mathbf{q}$, 以 $z \in [1, N]$ 表示被选择信息的索引位置 ($z=n$),

▶ “软性”信息选择机制: 在给定 $\mathbf{q}$ 和 $\mathbf{X}$ 的情况下, 选择第 i 个输入向量的概率

$$\begin{aligned}\alpha_n &= p(z = n | \mathbf{X}, \mathbf{q}) \\ &= \text{soft max}(s(\mathbf{x}_n, \mathbf{q})) \\ &= \frac{\exp(s(\mathbf{x}_n, \mathbf{q}))}{\sum_{j=1}^N \exp(s(\mathbf{x}_j, \mathbf{q}))}\end{aligned}$$

▶ 其中, α_n 称为注意力分布, $s(\mathbf{x}, \mathbf{q})$ 为注意力打分函数

注意力打分函数 $s(x_i, q)$

加性模型

$$s(\mathbf{x}_i, \mathbf{q}) = \mathbf{v}^T \tanh(W\mathbf{x}_i + U\mathbf{q}),$$

点积模型

$$s(\mathbf{x}_i, \mathbf{q}) = \mathbf{x}_i^T \mathbf{q},$$

缩放点积模型

$$s(\mathbf{x}_i, \mathbf{q}) = \frac{\mathbf{x}_i^T \mathbf{q}}{\sqrt{d}},$$

双线性模型

$$s(\mathbf{x}_i, \mathbf{q}) = \mathbf{x}_i^T W \mathbf{q},$$

注意力模型


► 软性注意力机制 (soft attention mechanism)

► 注意力机制可以分为两步 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbb{R}^{D \times N}$

► 加权平均 α_n ，可以解释为给定任务相关的查询 q 时，第 n 个输入向量受关注的程度，这里采用“软性”信息选择机制对输入信息进行汇总，即

$$\text{att}(\mathbf{X}, \mathbf{q}) = \sum_{n=1}^N \alpha_n \mathbf{x}_n = \mathbb{E}_{z \sim p(z|\mathbf{X}, \mathbf{q})} [\mathbf{x}_z]$$

► 此式即为软性注意力机制。下图为示例



注意力机制的变体

► 硬性注意力 (hard attention)

- 最大采样，即选取概率最大值对应的输入向量
- 随机采样


$$\text{att}(\mathbf{X}, \mathbf{q}) = \mathbf{x}_{\hat{n}} \quad \hat{n} = \arg \max_{n=1}^N \alpha_n$$

► 键值对注意力 (key-value pair attention)

- $(\mathbf{K}, \mathbf{N}) = [(\mathbf{k}_1, \mathbf{v}_1), \dots, (\mathbf{k}_N, \mathbf{v}_N)]$ 表示N个输入信息，给定

$$\begin{aligned} \text{att}((\mathbf{K}, \mathbf{V}), \mathbf{q}) &= \sum_{n=1}^N \alpha_n \mathbf{v}_n \\ &= \sum_{n=1}^N \frac{\exp(s(\mathbf{k}_n, \mathbf{q}))}{\sum_j \exp(s(\mathbf{k}_j, \mathbf{q}))} \mathbf{v}_n \end{aligned}$$

《神经网络与深度学习》



注意力机制的变体

▶ 多头注意力 (multi-head attention)

- ▶ 利用多个查询 $\mathbf{Q}=[\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M]$ ，并行的从输入信息中选取多组信息
- ▶ 每个注意力关注输入信息的不同部分

$$\text{att}((\mathbf{K}, \mathbf{V}), \mathbf{Q}) = \text{att}((\mathbf{K}, \mathbf{V}), \mathbf{q}_1) \oplus \dots \oplus \text{att}((\mathbf{K}, \mathbf{V}), \mathbf{q}_M)$$


▶ 结构化注意力 (structural attention)

- ▶ 输入信息本身具有层次结构 (Hierarchical)，如文本的词、句子、段落等

注意力机制的变体

► 指针网络（pointer network）


- 只利用注意力机制中的第一步，计算**注意力分布**作为一个软性的**指针（pointer）**来指出相关信息的位置。




3 自注意力模型

自注意力模型

- 当使用神经网络来处理一个变长的向量序列时，我们通常可以使用 **卷积网络** 或 **循环网络** 进行编码来得到一个相同长度的输出向量序列。



(a) 卷积网络




(b) 双向循环网络

只建模了输入信息的局部依赖关系

自注意力模型


► 如何建立非局部 (Non-local) 的依赖关系

► 全连接?



(a) 全连接模型

无法处理变长问题



连接权重 α_{ij} 由注意力机制动态生成

自注意力模型

▶ 输入序列为 $X = [\mathbf{x}_1, \dots, \mathbf{x}_N] \in \mathbb{R}^{D_x \times N}$

▶ 首先生成三个向量序列

▶ 对每个输入 $\mathbf{x}_i$, 计算得到查询向量 $\mathbf{q}_i$, 键向量 $\mathbf{k}_i$ 和值向量 $\mathbf{v}_i$

$$\mathbf{Q} = \mathbf{W}_q \mathbf{X} \in \mathbb{R}^{D_k \times N} \quad \mathbf{K} = \mathbf{W}_k \mathbf{X} \in \mathbb{R}^{D_k \times N} \quad \mathbf{V} = \mathbf{W}_v \mathbf{X} \in \mathbb{R}^{D_v \times N}$$

$$\mathbf{Q} = [\mathbf{q}_1, \dots, \mathbf{q}_N] \quad \mathbf{K} = [\mathbf{k}_1, \dots, \mathbf{k}_N] \quad \mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_N]$$

▶ 计算 $\mathbf{h}_i$

$$\mathbf{h}_n = \text{att}((\mathbf{K}, \mathbf{V}), \mathbf{q}_n)$$

$$= \sum_{j=1}^N \alpha_{nj} \mathbf{v}_j$$

$$= \sum_{j=1}^N \text{soft max} \left(s(\mathbf{k}_j, \mathbf{q}_n) \right) \mathbf{v}_j$$

$$\mathbf{H} = [\mathbf{h}_1, \dots, \mathbf{h}_N]$$

$$\mathbf{H} = \mathbf{V} \text{soft max} \left(\frac{\mathbf{K}^T \mathbf{Q}}{\sqrt{D_k}} \right)$$

QKV模式 (Query-Key-Value)

$$\begin{matrix} & \mathbf{X} & & \mathbf{W}^Q & & \mathbf{Q} \\ \text{Thinks} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & \times & \begin{bmatrix} \square & \square & \square & \square \\ \square & \square & \square & \square \end{bmatrix} & = & \begin{bmatrix} \square & \square & \square \end{bmatrix} \\ \text{Machines} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & & & & \begin{bmatrix} \square & \square & \square \end{bmatrix} \end{matrix}$$

$$\begin{matrix} & \mathbf{X} & & \mathbf{W}^K & & \mathbf{K} \\ \text{Thinks} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & \times & \begin{bmatrix} \square & \square & \square & \square \\ \square & \square & \square & \square \end{bmatrix} & = & \begin{bmatrix} \square & \square & \square \end{bmatrix} \\ \text{Machines} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & & & & \begin{bmatrix} \square & \square & \square \end{bmatrix} \end{matrix}$$

$$\begin{matrix} & \mathbf{X} & & \mathbf{W}^V & & \mathbf{V} \\ \text{Thinks} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & \times & \begin{bmatrix} \square & \square & \square & \square \\ \square & \square & \square & \square \end{bmatrix} & = & \begin{bmatrix} \square & \square & \square \end{bmatrix} \\ \text{Machines} & \begin{bmatrix} \square & \square & \square & \square \end{bmatrix} & & & & \begin{bmatrix} \square & \square & \square \end{bmatrix} \end{matrix}$$

$$\text{softmax}\left(\frac{\mathbf{Q} \times \mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V}$$
$$= \mathbf{Z}$$


图片来源: <http://jalammar.github.io/illustrated-transformer/>

多头 (multi-head) 自注意力模型


1) This is our input sentence*

Thinking
Machines

2) We embed each word*




3) Split into 8 heads.
We multiply X or R with weight matrices









4) Calculate attention using the resulting $Q/K/V$ matrices



5) Concatenate the resulting Z matrices, then multiply with weight matrix W^O to produce the output of the layer



* In all encoders other than #0, we don't need embedding. We start directly with the output of the encoder right below this one




图片来源: <http://jalammar.github.io/illustrated-transformer/>

Transformer Encoder

▶ 仅仅自注意力还不够

▶ 其它操作

- ▶ 位置编码
- ▶ 层归一化
- ▶ 直连边
- ▶ 逐位的FNN



图片来源: <http://jalammar.github.io/illustrated-transformer/>




Figure 2: An overview of the Dual Attention Network. (Best viewed in color)

Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 3146-3154.




Figure 2. Overview of the proposed CCNet for semantic segmentation.




Figure 3. The details of criss-cross attention module.

Huang Z, Wang X, Huang L, et al. Ccnet: Criss-cross attention for semantic segmentation[C]//Proceedings of the IEEE International Conference on Computer Vision. 2019: 603-612.

4 外部记忆

大脑中的记忆

- ▶ 记忆：外界信息在人脑中的内部表示
- ▶ 记忆过程 演化
 - ▶ 工作记忆（短期记忆）神经元活动更新较快 隐状态
 - ▶ 结构记忆（长期记忆）神经元之间的链接形态更新速度慢 权重参数
- ▶ 特点：联想记忆（Associative Memory）
 - ▶ 不同对象之间关系
 - ▶ 基于内容寻址的存储CAM
- ▶ 提高网络容量
 - ▶ 结构化的记忆
 - ▶ 基于神经动力学的联想记忆


不严格的类比

记忆周期	计算机	人脑	神经网络
短期	寄存器	短期记忆	状态（神经元活性）
中期	内存	工作记忆	外部记忆
长期	外存	长期记忆	可学习参数
存储方式	随机寻址	内容寻址	内容寻址为主

5 结构化的外部记忆 记忆增强神经网络

记忆网络 (Memory Network)

- ▶ 记忆增强神经网络 (Memory Augmented Neural Network, MANNN)
 - ▶ 主网络C 负责信息处理和与外界交互 (读写操作)
 - ▶ 外部记忆M 可分为很多记忆片段 $M=[m_1, m_2, \dots, m_N]$
 - ▶ 读写操作 R 根据C生成的查询向量 q_w 和 q_r , 分别将要写入的信息a更新记忆模块M和从外部记忆单元读取信息



外部记忆

▶ 外部记忆定义为矩阵 $M \in \mathbb{R}^{d \times k}$

- ▶ k 是记忆片段的数量, d 是每个记忆片段的大小
- ▶ 按内容寻址的方式进行定位, 然后读写

▶ 如何读? **注意力机制**

- ▶ 按内容寻址, 常用注意力机制 以读模块 R 为例

$$\mathbf{r} = \sum_{n=1}^N \alpha_n \mathbf{m}_n$$

$$\alpha_n = \text{soft max} \left(s(\mathbf{m}_n, \mathbf{q}_r) \right)$$

- ▶ 可看作一个接口, 将信息的存储与计算分离

端到端记忆网络

▶ 端到端记忆网络 End-To-End Memory Network, MemN2N

- ▶ 多次从外部记忆中读取信息
- ▶ 给定待存储信息 $m_{1:N} = \{m_1, \dots, m_N\}$ ，转换为两组记忆片段（键值对）A寻址，C输出


$$\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_N] \quad \mathbf{C} = [\mathbf{c}_1, \dots, \mathbf{c}_N]$$

- ▶ 主网络根据输入 $\mathbf{x}$ 得到查询向量 $\mathbf{q}$,使用键值对注意力机制来从外部记忆读取相关信息 $\mathbf{r}$,并产生输出 $\mathbf{y}$

$$\mathbf{r} = \sum_{n=1}^N \text{soft max}(\mathbf{a}_n^T \mathbf{q}) \mathbf{c}_n$$
$$\mathbf{y} = f(\mathbf{q} + \mathbf{r})$$

记忆网络

Sukhbaatar, S., Szlam, A., Weston, J., & Fergus, R. (2015). End-To-End Memory Networks, 1–11. <http://arxiv.org/abs/1503.08895>



多跳操作 Multi-Hop

▶ 主网络和外部记忆进行多轮交互

- ▶ 第k-1次的结果得到第k次的输出

$$\mathbf{q}^{(k)} = \mathbf{q}^{(k-1)} + \mathbf{r}^{(k-1)}$$


- ▶ 第k轮交互的外部记忆A(k)和C(k)，主网络从外部记忆读取信息为

$$\mathbf{r}^{(k)} = \sum_{n=1}^N \text{soft max} \left(\left(\mathbf{a}_n^{(k)} \right)^T \mathbf{q}^{(k)} \right) \mathbf{c}_n^{(k)}$$
$$\mathbf{y} = f \left(\mathbf{q}^{(K)} + \mathbf{r}^{(K)} \right)$$

神经图灵机

▶ 图灵机 Turing Machine


- ▶ 图灵于1936年提出的一种抽象数学模型，可以用来模拟任何可计算问题。
- ▶ 构成：无限长纸带、符号表、读写头、状态寄存器控制规则



神经图灵机 NTM

► 组件

- 控制器 前馈 or 循环神经网络
- 外部记忆 $\mathbf{M} \in \mathbb{R}^{D \times N}$ N 个记忆片段 每个 D 维
- 读写操作



图片来源: <http://cpmarkchang.logdown.com/posts/279710-neural-network-neural-turing-machine>

Graves, A., Wayne, G., & Danihelka, I. (2014). Neural Turing Machines. Arxiv, 1–26. <http://arxiv.org/abs/1410.5401>

神经图灵机示例

► t 时刻，外部记忆 $\mathbf{M}_t = [\mathbf{m}_{t,1}, \dots, \mathbf{m}_{t,N}]$

► **读操作** 从 $\mathbf{M}_t$ 读取信息 $\mathbf{r}$

$$\alpha_{t,n} = \text{soft max} (s(\mathbf{m}_{t,n}, \mathbf{q}_t))$$


$$\mathbf{r}_t = \sum_{n=1}^N \alpha_{t,n} \mathbf{m}_{t,n}$$

► **写操作**

► 删除 $\mathbf{e}_t$ 和增加 $\mathbf{a}_t$

$$\mathbf{m}_{t+1,n} = \mathbf{m}_{t,n} (1 - \alpha_{t,n} \mathbf{e}_t) + \alpha_{t,n} \mathbf{a}_t$$

► 得到下一时刻的外部记忆 $\mathbf{M}_{t+1}$




6 基于神经动力学的联想记忆

联想记忆


▶ 自联想 Auto-associative model

- 输入输出在同一空间
- 前馈神经网络或RNN来实现
- 自编码器Auto-encoder AE




▶ 异联想 Hetero-associative model

- 输入输出不在同一空间
- 分类器



如何实现联想记忆?



Classical Conditioning

Hopfield网络

► 神经网络作为一种记忆的存储和检索模型。

► 所有神经元互相连接（自身不连接）

► 更新规则


$$s_i = \begin{cases} +1 & \sum_{j=1}^M w_{ij}s_j + b_i \geq 0 \\ -1 & \text{else} \end{cases}$$

$$w_{ii} = 0 \quad \forall i \in [1, M]$$

$$w_{ij} = w_{ji} \quad \forall i, j \in [1, M]$$

↓ 同步更新

$$\mathbf{s}_t = f(\mathbf{W}\mathbf{s}_{t-1} + \mathbf{b})$$



能量函数


- ▶ 在Hopfield网络中，我们给每个不同的网络状态定义一个标量属性，称为“能量”。

$$\begin{aligned} E &= -\frac{1}{2} \sum_{i,j} w_{ij} s_i s_j - \sum_i b_i s_i \\ &= -\frac{1}{2} \mathbf{s}^T \mathbf{W} \mathbf{s} - \mathbf{b}^T \mathbf{s}. \end{aligned}$$

- ▶ Hopfield网络是稳定的，即能量函数经过多次迭代后会达到收敛状态。

检索过程（联想记忆）

- ▶ 给定一个外部输入，网络经过演化，会达到某个稳定状态（吸引点）。



检索过程（联想记忆）

- ▶ 每个吸引点 u 都对应一个“管辖”区域 R_u 。如果输入向量 x 落入这个区域，网络最终会收敛到 u 。
- ▶ 吸引点可以看作是网络中存储的**模式**。

存储过程

▶ 信息存储是指将一组向量 $X = [\mathbf{x}_1, \dots, \mathbf{x}_N]$ 存储在网络中的过程。

▶ 存储过程主要是调整神经元之间的连接权重，因此可以看做是一种学习过程。

▶ 神经元 i 和 j 之间的连接权重

$$w_{ij} = \frac{1}{N} \sum_{n=1}^N x_i^{(n)} x_j^{(n)},$$

▶ 如果两个神经元经常同时激活，则它们之间的连接加强；如果经常不同时激活，则连接消失。类似于人脑的 **Hebbian 法则**

使用联想记忆增加网络容量

- ▶ 通过改进网络结构、学习方式以及引入更复杂的运算，可以有效地改善联想记忆网络的容量
- ▶ 联想记忆具有存储和检索功能，可以利用联想记忆来增加网络容量。
- ▶ 和结构化的外部记忆相比，联想记忆具有更好的生物学解释性。

总结

- ▶ 注意力机制
- ▶ 自注意力
- ▶ 联想记忆→记忆增强神经网络

谢 谢