

《神经网络与深度学习》豆包押题卷 2026.01


考试时间：120 分钟 满分：100 分

一、填空题（共 10 题，每题 3 分，满分 30 分）

1. 人工智能发展历史分为三个阶段，分别是推理期、_____和学习期。
2. 前馈神经网络中，用记号 L 表示神经网络的_____， $a^{(l)}$ 表示第 l 层神经元的_____。
3. Sigmoid 型函数中，Logistic 函数将输入“挤压”到_____区间，Tanh 函数将输入映射到_____区间。
4. 卷积层的两个核心性质是_____和_____，其目的是减少网络参数数量。
5. 简单循环网络（SRN）的隐藏层状态更新公式为 $h_t = f(Uh_{t-1} + Wx_t + b)$ ，其中 U 表示_____权重矩阵。
6. LSTM 通过_____、_____和输出门三个门结构来解决长序列依赖问题。
7. 自适应学习率优化算法中，_____算法结合了动量和 RMSprop 的优点，被认为是较好的选择。
8. 无监督学习的主要任务类型包括聚类、_____和密度估计等。
9. 自注意力模型中，输入序列通过权重矩阵生成三个向量，分别是查询向量（Q）、_____和值向量（V）。
10. 迁移学习根据迁移方式可分为归纳迁移学习和_____迁移学习两类。


二、简答题（共 6 题，每题 5 分，满分 30 分）

1. 根据下图推导 LSTM 的核心公式（包括各个门结构、候选状态、细胞状态和隐藏状态的更新公式）。



2. 简述多任务学习的概念及其核心思想。

3. 根据下图，推导自注意力（Self-Attention）模型的核心公式（包括 Q、K、V 的生成及最终输出公式）。



4. 简述端到端神经网络和神经图灵机的异同点。

5. 分析 ReLU 激活函数的优缺点。

6. 分别列举至少 5 种网络优化方法和 5 种正则化方法。

三、计算题（共 2 题，每题 20 分，满分 40 分）

1. 已知卷积层的输入为双通道特征映射 $X^1 \in \mathbb{R}^{3 \times 3}$ 和 $X^2 \in \mathbb{R}^{3 \times 3}$ ，具体数值如下：

$$X^1 = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}, X^2 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

使用 2 个三维卷积核 $W^{1,1} \in \mathbb{R}^{2 \times 2}$ 、 $W^{1,2} \in \mathbb{R}^{2 \times 2}$ （对应第一个输出特征映射）和 $W^{2,1} \in \mathbb{R}^{2 \times 2}$ 、 $W^{2,2} \in \mathbb{R}^{2 \times 2}$ （对应第二个输出特征映射），偏置 $b^1 = 1$ ， $b^2 = 0$ ，步长为 1，无零填充。

卷积核数值：

$$W^{1,1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, W^{1,2} = \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix}$$
$$W^{2,1} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, W^{2,2} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

计算该卷积层的两个输出特征映射 Y^1 和 Y^2 （激活函数忽略，仅计算净输入）。

2. 根据反向传播算法中误差项的递推公式 $\delta^{(l)} = f'_l(z^{(l)}) \odot (W^{(l+1)\top} \delta^{(l+1)})$ ，结合常用激活函数的特性，简述梯度消失现象的产生原理。

参考答案

一、填空题

1. 知识期
2. 层数；输出（活性值）
3. $(0, 1)$ ； $(-1, 1)$
4. 局部连接；权重共享
5. 状态-状态
6. 输入门；遗忘门
7. Adam
8. 特征学习
9. 键向量（K）
10. 转导

二、简答题

1. LSTM 核心公式推导：

- 输入门： $i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$
- 遗忘门： $f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$
- 输出门： $o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$
- 候选状态： $\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$
- 细胞状态更新： $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
- 隐藏状态更新： $h_t = o_t \odot \tanh(c_t)$

其中， σ 为 Sigmoid 激活函数， $\odot$ 为向量元素乘， x_t 为时刻 t 输入， h_{t-1} 为上一时刻隐藏状态， c_{t-1} 为上一时刻细胞状态。

2. 多任务学习：指同时学习多个相关任务，让这些任务在学习过程中共享知识，利用多个任务之间的相关性来改进模型在每个任务上的性能和泛化能力。其核心思想是将多个任务的学习过程结合起来，通过共享特征或参数，挖掘任务间的潜在关联，实现知识迁移，从而提升单个任务的泛化能力，属于归纳迁移学习的一种。

3. 自注意力模型核心公式推导：

- 输入序列： $X = [x_1, x_2, \dots, x_N] \in \mathbb{R}^{D_x \times N}$

- 生成 Q、K、V 向量：

$$Q = W_q X \in \mathbb{R}^{D_k \times N} \text{ (查询向量矩阵)}$$

$$K = W_k X \in \mathbb{R}^{D_k \times N} \text{ (键向量矩阵)}$$

$$V = W_v X \in \mathbb{R}^{D_v \times N} \text{ (值向量矩阵)}$$

- 采用缩放点积作为评分函数，输出序列：

$$H = V \odot \text{softmax}\left(\frac{K^{\top} Q}{\sqrt{D_k}}\right)$$

- 单个位置输出： $h_n = \text{att}((K, V), q_n)$ ，即第 n 个查询向量对应的注意力加权结果。

4. 端到端神经网络与神经图灵机的异同：

- 相同点：均属于神经网络模型，依赖参数学习实现任务建模，核心均包含特征表示学习和任务决策过程。
- 不同点：① 结构差异：端到端神经网络无独立外部记忆模块，依赖网络自身参数存储信息；神经图灵机包含显式外部记忆库和读写头，可动态读写记忆；② 能力差异：端到端网络擅长直接映射输入到输出，处理固定维度或序列任务，但长程依赖和复杂推理能力有限；神经图灵机通过记忆机制增强了复杂推理和长序列处理能力，可处理需要外部知识存储的任务；③ 适用场景：端到端网络适用于图像分类、语音识别等常规任务；神经图灵机适用于逻辑推理、算法执行等需要记忆交互的复杂任务。

5. ReLU 激活函数的优缺点：

- 优点：① 梯度计算简单，导数为 0 或 1，避免了复杂的指数运算；② 缓解梯度消失问题，在输入为正的区域内梯度恒为 1，利于深层网络训练；③ 稀疏激活特性，输入小于 0 时输出为 0，减少神经元间的冗余依赖，提升模型泛化能力。
- 缺点：① 存在“死亡 ReLU”问题，当输入长期为负时，神经元永久失活，参数无法更新；② 输出不具有均值为 0 的特性，可能导致后续层输入分布偏移；③ 对异常值敏感，输入过大时输出无边界约束，可能影响模型稳定性。

6. 网络优化方法与正则化方法：

- 优化方法：① 随机梯度下降（SGD）；② 动量（Momentum）；③ AdaGrad；④ AdaDelta；⑤ RMSprop；⑥ Adam。
- 正则化方法：① 提前停止（Early Stop）；② 权重衰减（Weight Decay）；③ Dropout；④ 数据增强（Data Augmentation）；⑤ L1/L2 正则化。

三、计算题

1. 卷积双通道计算：

卷积层净输入公式为 $Z^p = \sum_{d=1}^2 W^{p,d} \otimes X^d + b^p$ （ $d = 1, 2$ 为输入通道），步长 1，无零填充，输出特征映射尺寸为 $3 - 2 + 1 = 2 \times 2$ 。

（1）计算第一个输出特征映射 Y^1 （对应 $p = 1$ ）：

- 区域 1（左上角 2×2 ）：

$$W^{1,1} \otimes X^1 \text{ 部分: } 1 \times 1 + 0 \times 2 + 0 \times 4 + 1 \times 5 = 6$$

$$W^{1,2} \otimes X^2 \text{ 部分: } (-1) \times 0 + (-1) \times 1 + (-1) \times 1 + (-1) \times 0 = -2$$

$$\text{净输入: } 6 + (-2) + 1 = 5$$

- 区域 2（右上角 2×2 ）：

$$W^{1,1} \otimes X^1: 1 \times 2 + 0 \times 3 + 0 \times 5 + 1 \times 6 = 8$$

$$W^{1,2} \otimes X^2: (-1) \times 1 + (-1) \times 0 + (-1) \times 0 + (-1) \times 1 = -2$$

$$\text{净输入: } 8 + (-2) + 1 = 7$$

- 区域 3（左下角 2×2 ）：

$$W^{1,1} \otimes X^1: 1 \times 4 + 0 \times 5 + 0 \times 7 + 1 \times 8 = 12$$

$$W^{1,2} \otimes X^2: (-1) \times 1 + (-1) \times 0 + (-1) \times 0 + (-1) \times 1 = -2$$

$$\text{净输入: } 12 + (-2) + 1 = 11$$

- 区域 4 (右下角 2×2):

$$W^{1,1} \otimes X^1: 1 \times 5 + 0 \times 6 + 0 \times 8 + 1 \times 9 = 14$$

$$W^{1,2} \otimes X^2: (-1) \times 0 + (-1) \times 1 + (-1) \times 1 + (-1) \times 0 = -2$$

$$\text{净输入: } 14 + (-2) + 1 = 13$$

$$\text{因此, } Y^1 = \begin{bmatrix} 5 & 7 \\ 11 & 13 \end{bmatrix}$$

(2) 计算第二个输出特征映射 Y^2 (对应 $p = 2$):

- 区域 1:

$$W^{2,1} \otimes X^1: 1 \times 1 + 1 \times 2 + 1 \times 4 + 1 \times 5 = 12$$

$$W^{2,2} \otimes X^2: 0 \times 0 + 1 \times 1 + 1 \times 1 + 0 \times 0 = 2$$

$$\text{净输入: } 12 + 2 + 0 = 14$$

- 区域 2:

$$W^{2,1} \otimes X^1: 1 \times 2 + 1 \times 3 + 1 \times 5 + 1 \times 6 = 16$$

$$W^{2,2} \otimes X^2: 0 \times 1 + 1 \times 0 + 1 \times 0 + 0 \times 1 = 0$$

$$\text{净输入: } 16 + 0 + 0 = 16$$

- 区域 3:

$$W^{2,1} \otimes X^1: 1 \times 4 + 1 \times 5 + 1 \times 7 + 1 \times 8 = 24$$

$$W^{2,2} \otimes X^2: 0 \times 1 + 1 \times 0 + 1 \times 0 + 0 \times 1 = 0$$

$$\text{净输入: } 24 + 0 + 0 = 24$$

- 区域 4:

$$W^{2,1} \otimes X^1: 1 \times 5 + 1 \times 6 + 1 \times 8 + 1 \times 9 = 28$$

$$W^{2,2} \otimes X^2: 0 \times 0 + 1 \times 1 + 1 \times 1 + 0 \times 0 = 2$$

$$\text{净输入: } 28 + 2 + 0 = 30$$

$$\text{因此, } Y^2 = \begin{bmatrix} 14 & 16 \\ 24 & 30 \end{bmatrix}$$

2. 梯度消失原理分析:

反向传播中, 损失函数对第 l 层权重的梯度计算依赖于第 l 层的误差项 $\delta^{(l)}$, 而 $\delta^{(l)}$ 通过递推公式 $\delta^{(l)} = f_l'(z^{(l)}) \odot (W^{(l+1)^T} \delta^{(l+1)})$ 计算, 即深层误差由浅层误差传递而来。

- 对于 Sigmoid 等传统激活函数, 其导数 $f_l'(z^{(l)})$ 的取值范围为 $(0, 0.25]$, 始终小于 1。
- 当网络层数较深时, 第 l 层的误差项 $\delta^{(l)}$ 需要乘以 $(l+1)$ 到输出层所有层的激活函数导数和权重矩阵转置。由于每个激活函数导数都小于 1, 多次乘积后, 误差项会呈指数级衰减。
- 损失函数对浅层权重的梯度与 $\delta^{(l)}$ 成正比, 当 $\delta^{(l)}$ 衰减到接近 0 时, 浅层权重的梯度也趋近于 0, 导致浅层参数无法有效更新, 即出现梯度消失。