

《神经网络与深度学习》

第五章 卷积神经网络

Convolutional Neural Network, CNN


周晓飞

xiaofei-zhou.com

自动化学院

全连接前馈神经网络

- ▶ 权重矩阵的参数非常多
- ▶ 导致训练效率低，易出现过拟合



▶ 局部不变性特征

- ▶ 自然图像中的物体都具有局部不变性特征，比如尺度缩放、平移、旋转等操作不影响其语义信息。
- ▶ 而全连接前馈网络很难提取这些局部不变特征。

卷积神经网络

- ▶ 卷积神经网络（Convolutional Neural Networks, CNN）是一种前馈神经网络。
 - ▶ 卷积神经网络是受生物学上感受野（Receptive Field）的机制而提出的。
 - ▶ 在视觉神经系统中，一个神经元的感受野是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元。
- ▶ 目前的卷积神经网络一般是由卷积层、汇聚层和全连接层交叉堆叠而成的前馈神经网络
- ▶ 卷积神经网络结构上的三个特性：
 - ▶ 局部连接
 - ▶ 权重共享
 - ▶ 汇聚：空间或时间上的次采样

1 卷积

卷积 (Convolution)

- ▶ 卷积经常用在信号处理中，用于计算信号的延迟累积。
- ▶ 假设一个**信号发生器**每个时刻 t 产生一个信号 x_t ，其信息的衰减率为 w_k ，即在 $k-1$ 个时间步长后，信息为原来的 w_k 倍

▶ 假设 $w_1 = 1, w_2 = 1/2, w_3 = 1/4$

- ▶ 时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加。

$$y_t = 1 \times x_t + (1/2) \times x_{t-1} + (1/4) \times x_{t-2}$$

$$= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2}$$

$$= \sum_{k=1}^3 w_k x_{t-k+1}$$

- ▶ 我们把 $w_1, w_2, \dots$ 称为滤波器Filter或卷积核 (Convolution Kernel)。设滤波器长度为 K ，它和信号序列 $x_1, x_2, \dots$ 的卷积为：

- ▶ 为简单起见，这里假设卷积的输出 y_t 的下标 t 从 K 开始

$$y_t = \sum_{k=1}^K w_k x_{t-k+1}$$

卷积 (Convolution)

- ▶ 信号序列X和滤波器W的卷积定义为

$$y = w * x$$

- ▶ 其中*表示卷积运算。一般情况下，滤波器的长度K远小于信号序列x的长度
- ▶ 我们可以设计不同的滤波器来提取信号序列的不同特征。比如，当滤波器 $w=[1/K, \dots, 1/K]$ 时，卷积相当于信号序列的简单移动平均MA-Moving Average（窗口大小为K）；当滤波器 $w=[1, -2, 1]$ 时，可以近似实现对信号序列的二阶微分，即 $x''(t) = x(t+1) + x(t-1) - 2x(t)$

- ▶ 下图给出了滤波器的一维卷积示例。

- ▶ $w=[-1, 0, 1]$






图 5.1 一维卷积示例(滤波器为 $[-1, 0, 1]$)

卷积的变种

- ▶ **步长stride**: 卷积核在滑动时的时间间隔，图a给出了步长为2的卷积示例。
- ▶ **零填充zero padding**: 在输入向量两端进行补零。图b给出了输入的两端各补一个零后的卷积示例
- ▶ 假设卷积层的输入神经元个数为M，卷积大小为K，步长为S，在输入两端各填补P个0，那么该卷积层的神经元数量为 $(M-K+2P)/S+1$



(a) 步长 $s = 2$



(b) 零填充 $p = 1$

引入滤波器的滑动步长 s 和零填充 p $w=[-1,0,1]$

卷积的变种

► 卷积的结果按输出长度不同可以分为三类：

- 窄卷积(narrow convolution)：步长 $s = 1$ ，两端不补零 $p = 0$ ，卷积后输出长度为 $M - K + 1$ 。
- 宽卷积(wide convolution)：步长 $s = 1$ ，两端补零 $p = K - 1$ ，卷积后输出长度 $M + K - 1$ 。
- 等宽卷积(equal-width convolution)：步长 $s = 1$ ，两端补零 $p = (K - 1)/2$ ，卷积后输出长度 M 。

- 在早期的文献中，卷积一般默认为窄卷积。
- 而目前的文献中，卷积一般默认为等宽卷积。

二维卷积

- ▶ 在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积。
- ▶ 给定图像 $\mathbf{X} \in \mathbb{R}^{M \times N}$ 和一个滤波器 $\mathbf{W} \in \mathbb{R}^{U \times V}$ ，一般 $U \ll M, V \ll N$ 对应卷积操作：

$$y_{ij} = \sum_{u=1}^m \sum_{v=1}^n w_{uv} \cdot x_{i-u+1, j-v+1}.$$

- ▶ 这里为了简单起见，卷积输出 y_{ij} 的下标 (i,j) 从 (U,V) 开始

二维卷积

► 输入信息 X 和滤波 W 的二维卷积定义为

$$Y = W * X$$

► 其中 $*$ 表示二维卷积运算。

► 下图为卷积示例（卷积核旋转 180° ）


1	1	1	1	1
-1	0	-3	0	1
2	1	1	-1	0
0	-1	1	2	1
1	2	1	1	1

 $\otimes$


1	0	0
0	0	0
0	0	-1

 $=$


0	-2	-1
2	2	4
-1	0	0




二维卷积




步长1，零填充0



步长2，零填充0



步长1，零填充1




步长2，零填充1

两维卷积

- ▶ 在图像处理中常用的均值滤波器（Mean Filter）就是一种二维卷积，将当前位置的像素值设置为滤波器窗口中所有像素的平均值，即 $w_{uv} = 1/UV$
- ▶ 在图像处理中，卷积经常作为特征提取的有效方法。一幅图像在经过卷积操作后得到的结果称为特征映射（Feature Map）。下图给出了几种常见的滤波器，以及其对应的特征映射。

卷积作为特征提取器

- ▶ 图中最上面的滤波器是高斯滤波器，可以用来对图像进行平滑去噪；中间和最下面的滤波器可以用来提取边缘特征



互相关

- ▶ 在机器学习和图像处理领域，卷积的主要功能是在一个图像（或某种特征）上滑动一个卷积核（滤波器），通过卷积操作**提取特征**。
- ▶ 在计算卷积的过程中，需要进行卷积核**翻转**。但在具体实现上，一般会以互相关操作来代替卷积，从而减少一些不必要的操作或开销。
- ▶ **互相关**是一个衡量两个序列相关性的函数，通常是用滑动窗口的点积计算来实现。给定一个图像 $\mathbf{X} \in \mathbb{R}^{M \times N}$ 和卷积核 $\mathbf{W} \in \mathbb{R}^{U \times V}$ 它们的相关性为：

$$y_{ij} = \sum_{u=1}^m \sum_{v=1}^n w_{uv} \cdot x_{i+u-1, j+v-1}$$

互相关

- ▶ 和卷积公式相比，互相关和卷积的区别仅仅在于卷积核是否进行翻转，因此，互相关也可以称为不翻转卷积。互相关公式亦可以表述为

$$\mathbf{Y} = \mathbf{W} \otimes \mathbf{X} = \text{rot180}(\mathbf{W}) * \mathbf{X}$$

- ▶ 其中 $\otimes$ 表示互相关运算， $\text{rot180}(\cdot)$ 表示旋转180度， $\mathbf{Y} \in \mathbb{R}^{M-U+1, N-V+1}$ 为输出矩阵
- ▶ 在神经网络中使用卷积是为了进行特征抽取，卷积核是否进行翻转和其特征抽取的能力无关。特别是当卷积核是可学习的参数时，卷积和互相关在能力上是等价的。因此，除非特别声明，卷积一般指“互相关”。

卷积的数学性质-交换性

▶ 真正的翻转卷积是具有交换性的，即 $\mathbf{x} * \mathbf{y} = \mathbf{y} * \mathbf{x}$ 。对于互相关的“卷积”，也同样具有一定的“交换性”

▶ 宽卷积（wide convolution）：给定二维图像 $\mathbf{X} \in \mathbb{R}^{M \times N}$ 和一个二维卷积核 $\mathbf{W} \in \mathbb{R}^{U \times V}$ ，对 $\mathbf{X}$ 进行零填充，两端各补 $U-1$ 和 $V-1$ 个零，得到全填充的图像 $\tilde{\mathbf{X}} \in \mathbb{R}^{(M+2U-2) \times (N+2V-2)}$ 。图像 $\mathbf{X}$ 和卷积核 $\mathbf{W}$ 的宽卷积定义为：

$$\mathbf{W} \tilde{\otimes} \tilde{\mathbf{X}} = \text{rot180}(\tilde{\mathbf{X}}) \tilde{\otimes} \mathbf{W}$$

▶ 其中， $\tilde{\otimes}$ 表示宽卷积运算。

▶ 当输入信息和卷积核有固定长度时，它们的宽卷积依然具有交换性，即 $\text{rot}(\mathbf{W}) \tilde{\otimes} \tilde{\mathbf{X}} = \text{rot180}(\tilde{\mathbf{X}}) \tilde{\otimes} \mathbf{W}$

卷积的数学性质-导数

► 假设 $\mathbf{Y} = \mathbf{W} \otimes \mathbf{X}$, 其中 $\mathbf{X} \in \mathbb{R}^{M \times N}$, $\mathbf{W} \in \mathbb{R}^{U \times V}$, $\mathbf{Y} \in \mathbb{R}^{M-U+1, N-V+1}$, 函数 $f(\mathbf{Y}) \in \mathbb{R}$ 为一个标量函数, 则

$$\begin{aligned}\frac{\partial f(\mathbf{Y})}{\partial w_{uv}} &= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial y_{ij}}{\partial w_{uv}} \frac{\partial f(\mathbf{Y})}{\partial y_{ij}} \\ &= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} x_{i+u-1, j+v-1} \frac{\partial f(\mathbf{Y})}{\partial y_{ij}} \\ &= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial f(\mathbf{Y})}{\partial y_{ij}} x_{u+i-1, v+j-1}\end{aligned}$$

► 由此可以推出 $f(\mathbf{Y})$ 关于 $\mathbf{W}$ 的偏导数为 $\mathbf{X}$ 和 $\partial f(\mathbf{Y})/\partial \mathbf{Y}$ 的卷积, 即

$$\frac{\partial f(\mathbf{Y})}{\partial \mathbf{W}} = \frac{\partial f(\mathbf{Y})}{\partial \mathbf{Y}} \otimes \mathbf{X}$$

卷积的数学性质-导数

► 同理，可以得到

$$\begin{aligned}\frac{\partial f(Y)}{\partial x_{st}} &= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} \frac{\partial y_{ij}}{\partial x_{st}} \frac{\partial f(Y)}{\partial y_{ij}} \\ &= \sum_{i=1}^{M-m+1} \sum_{j=1}^{N-n+1} w_{s-i+1, t-j+1} \frac{\partial f(Y)}{\partial y_{ij}},\end{aligned}$$

► 从上式可看出 $f(Y)$ 关于 X 的偏导数为 W 和 $\partial f(Y)/\partial Y$ 的宽卷积。
上式中的卷积是真正的卷积而不是互相关。为了一致性，我们用互相关的“卷积”，即：

$$\begin{aligned}\frac{\partial f(\mathbf{Y})}{\partial \mathbf{X}} &= \text{rot180}\left(\frac{\partial f(\mathbf{Y})}{\partial \mathbf{Y}}\right) \tilde{\otimes} \mathbf{W} \\ &= \text{rot180}(\mathbf{W}) \tilde{\otimes} \frac{\partial f(\mathbf{Y})}{\partial \mathbf{Y}}\end{aligned}$$

2 卷积神经网络


卷积神经网络-用卷积来代替全连接

▶ 用卷积层代替全连接层，第 l 层的净输入 $z^{(l)}$ 为第 $l-1$ 层活性值 $a^{(l-1)}$ 和卷积核 $w^{(l)} \in \mathbb{R}^k$ 的卷积，即
$$z^{(l)} = w^{(l)} \otimes a^{(l-1)} + b^{(l)}$$


▶ 其中卷积核 $w^{(l)} \in \mathbb{R}^k$ 为可学习的权重向量， $b^{(l)} \in \mathbb{R}$ 为可学习的偏置。

▶ 根据卷积的性质，卷积有两个很重要的性质：

▶ 局部连接：第 l 层的每一个神经元仅和第 $l-1$ 层的某个局部窗口内的神经元相连，构成一个局部连接网络。如图b所示，这样连接个数由 $M_l \times M_{l-1}$ 变为 $M_l \times K$ ， K 为卷积核大小



(a) 全连接层



(b) 卷积层

卷积神经网络-用卷积来代替全连接

- ▶ 权重共享：由前式可以看出，作为参数的卷积核 $w^{(1)}$ 对于1层的所有神经元都是相同的。如上图所示，所有同颜色的连接上权重是相同的。因此，权重共享可以理解为一个卷积核只捕捉输入数据中一种特定的局部特征。也导致提取不同特征需要不同的卷积核。
- ▶ 两条性质导致卷积层的参数有一个K维的权重 $w^{(1)}$ 和1维的偏置 $b^{(1)}$ ，共K+1个参数。参数个数和神经元的数量无关。此外，第1层的神经元个数不是任意选择的，而是满足


$$M_1 = M_{l-1} - K + 1$$

卷积神经网络-卷积层

- ▶ **特征映射 Feature Map** 为一幅图像经过卷积提取到的特征，每个特征映射可以作为一类抽取的图像特征。为了提高卷积网络的表示能力，可以在每一层使用多个不同的特征映射，以更好地表示图像的特征。
- ▶ 假设一个卷积层的结构如下：
 - ▶ 输入特征映射组: $\chi \in \mathbb{R}^{M \times N \times D}$ ，每个切片 Slice 矩阵 $\mathbf{X}^d \in \mathbb{R}^{M \times N}$ 表示一个输入特征映射 $1 \leq d \leq D$ ；
 - ▶ 输出特征映射组: $y \in \mathbb{R}^{M' \times N' \times P}$ ，每个切片 $\mathbf{Y}^p \in \mathbb{R}^{M' \times N'}$ 为一个输出特征映射， $1 \leq p \leq P$
 - ▶ 卷积核: $\mathbf{W} \in \mathbb{R}^{U \times V \times P \times D}$ ，每个切片 $\mathbf{W}^{p,d} \in \mathbb{R}^{U \times V}$ 为一个二维卷积核 $1 \leq d \leq D, 1 \leq p \leq P$

卷积神经网络-卷积层

► 典型的卷积层为3维结构



卷积神经网络-卷积层

- 为了计算输出特征 $\mathbf{Y}^p$ ，用卷积核 $\mathbf{W}^{p,1}, \mathbf{W}^{p,2}, \dots, \mathbf{W}^{p,D}$ 分别对输入特征 $\mathbf{X}^1, \mathbf{X}^2, \dots, \mathbf{X}^D$ 进行卷积，然后将卷积结果相加，并加上一个标量偏置 b ，得到卷积层的净输入 $\mathbf{Z}^p$ ，再经过非线性激活函数 $f(\cdot)$ 后得到输出特征映射 $\mathbf{Y}^p$ 。

$$\mathbf{Z}^p = \mathbf{W}^p \otimes \mathbf{X} + b^p = \sum_{d=1}^D \mathbf{W}^{p,d} \otimes \mathbf{X}^d + b^p,$$

$$\mathbf{Y}^p = f(\mathbf{Z}^p).$$

- 其中 $\mathbf{W}^p \in \mathbb{R}^{U \times V \times D}$ 为三维卷积核

卷积神经网络-卷积层


整个计算过程如图所示

在输入为 $\chi \in \mathbb{R}^{M \times N \times D}$ ，输出为 $y \in \mathbb{R}^{M' \times N' \times P}$ 的卷积层中，每一个输出特征映射都需要D个卷积核以及一个偏置。假设每个卷积核的大小为 $U \times V$ ，那么共需要：


$P \times D \times (U \times V) + P$ 个参数

$$Z^p = \mathbf{W}^p \otimes \mathbf{X} + b^p = \sum_{d=1}^D W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$



步长2 filter个数3 3*3 填充



卷积神经网络-汇聚层

- ▶ **汇聚层 (pooling layer)** 也叫子采样层 (subsampling layer)，其作用是进行特征选择，降低特征数量，从而减少参数数量
- ▶ 假设汇聚层的输入特征 $\chi \in \mathbb{R}^{M \times N \times D}$ ，对于其中每个特征映射 $\mathbf{X}^d \in \mathbb{R}^{M \times N}$ 将其划分为很多区域 $R_{m,n}^d, 1 \leq m \leq M', 1 \leq n \leq N'$ ，这些区域可以重叠，也可以不重叠。汇聚是对每个区域进行下采样得到一个值，作为这个区域的概括。
- ▶ 常见的汇聚有两种：
 - ▶ **最大汇聚 Max Pooling**, 对一个区域 $R_{m,n}^d$ ，选择这个区域内所有神经元的最大活性值作为这个区域的表示，即 $y_{m,n}^d = \max_{i \in R_{m,n}^d} x_i$

卷积神经网络-汇聚层

► 平均汇聚 (Mean Pooling) 一般取区域内所有神经元的活性值的平均值，即

$$y_{m,n}^d = \frac{1}{|R_{m,n}^d|} \sum_{i \in R_{m,n}^d} x_i$$

► 对每一个输入特征映射 X^d 的 $M' \times N'$ 个区域进行子采样，得到汇聚层输入输出特征映射 $Y^d = \{y_{m,n}^d\}, 1 \leq m \leq M', 1 \leq n \leq N'$

卷积神经网络-汇聚层

- ▶ 下图给出了采样最大汇聚进行子采样操作的示例。可以看到汇聚层不仅可以有效减少神经元的数量，还可以使得网络对一些小的局部形态改变保持不变性，并拥有更大的感受野。
- ▶ 汇聚层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。




图 5.8 汇聚层中最大汇聚过程示例

卷积神经网络-汇聚层


- ▶ 目前主流的卷积网络中，汇聚层仅包含下采样操作，但在早期的卷积网络中，有时也会在汇聚层使用非线性激活函数：

$$\mathbf{Y}'^d = f(\mathbf{w}^d \mathbf{Y}^d + \mathbf{b}^d)$$

- ▶ 其中 $\mathbf{Y}'^d$ 为汇聚层的输出， $f(\cdot)$ 为非线性激活函数， $\mathbf{w}^d$ 和 $\mathbf{b}^d$ 为可学习的标量权重和偏置。
- ▶ 典型的汇聚层是将每个特征映射划分为 2×2 大小的不重叠区域，然后使用最大汇聚的方式进行下采样。汇聚层也可以看作一个特殊的卷积层，卷积核大小为 $K \times K$ ，步长为 $S \times S$ ，卷积核为 max 或 mean 函数。过大的采样区域会急剧减少神经元的数量，也会造成过多的信息损失。

卷积神经网络-卷积网络的整体结构

- ▶ 卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。
 - ▶ 趋向于小卷积 (1×1 、 3×3)、大深度 (层数大于50)
 - ▶ 趋向于全卷积 (不同步长, 汇聚层作用减弱)
- ▶ 典型结构



- ▶ 一个卷积块为连续M个卷积层和b个汇聚层 (M通常设置为2~5, b为0或1)。一个卷积网络中可以堆叠N个连续的卷积块, 然后在接着K个全连接层 (N的取值区间比较大, 比如1~100或者更大; K一般为0~2)。

3 参数学习

参数学习

- ▶ 在卷积神经网络中，主要有两种不同的神经层：卷积层和汇聚层。而参数为卷积核及偏置，因此只需要计算卷积层中参数的梯度。
- ▶ 假设，第 l 层为卷积层，第 $l-1$ 层的输入特征映射为 $\chi^{(l-1)} \in \mathbb{R}^{M \times N \times D}$ 通过卷积计算得到第 l 层的特映射净输入 $Z^{(l)} \in \mathbb{R}^{M' \times N' \times P}$ 。第 l 层的第 p 个特征映射景输入：

$$Z^{(l,p)} = \sum_{d=1}^D W^{(l,p,d)} \otimes X^{(l-1,d)} + b^{(l,p)}$$

- ▶ 其中 $W^{(l,p,d)}$ 和 $b^{(l,p)}$ 为卷积核以及偏置。第 l 层中共有 $P \times D$ 个卷积核和 P 个偏置，可分别用链式法则计算梯度

参数学习

- ▶ 根据卷积性质及上式，损失函数L关于第l层的卷积核 $\mathbf{W}^{(l,p,d)}$ 的偏导数为：

$$\frac{\partial f(\mathbf{Y})}{\partial \mathbf{W}} = \frac{\partial f(\mathbf{Y})}{\partial \mathbf{Y}} \otimes \mathbf{X} \quad \Rightarrow \quad \begin{aligned} \frac{\partial L}{\partial \mathbf{W}^{(l,p,d)}} &= \frac{\partial L}{\partial \mathbf{Z}^{(l,p)}} \otimes \mathbf{X}^{(l-1,d)} \\ &= \delta^{(l,p)} \otimes \mathbf{X}^{(l-1,d)} \end{aligned}$$

- ▶ 其中 $\delta^{(l,p)}$ 为损失函数关于第l层的第p个特征映射净输入 $\mathbf{Z}^{(l,p)}$ 的偏导数。
- ▶ 同理可得，损失函数关于第l层第p个偏置 $b^{(l,p)}$ 的偏导数：

$$\frac{\partial L}{\partial b^{(l,p)}} = \sum_{i,j} \left[\delta^{(l,p)} \right]_{i,j}$$

在卷积网络中，每层参数的梯度依赖其所在层的误差项 $\delta^{(l,p)}$

参数学习-卷积神经网络中的反向传播算法

- **汇聚层**：根据链式法则，第 l 层一个特征映射的误差项 $\delta^{(l,p)}$ ，只需要将 $l+1$ 层对应特征映射的误差项 $\delta^{(l+1,p)}$ 进行**上采样**操作，再和 l 层特征映射的激活值偏导数逐元素相乘，就得到了 $\delta^{(l,p)}$

$$\begin{aligned}\delta^{(l,p)} &\stackrel{\Delta}{=} \frac{\partial L}{\partial \mathbf{Z}^{(l,p)}} \\ &= \frac{\partial \mathbf{X}^{(l,p)}}{\partial \mathbf{Z}^{(l,p)}} \frac{\partial \mathbf{Z}^{(l+1,p)}}{\partial \mathbf{X}^{(l,p)}} \frac{\partial L}{\partial \mathbf{Z}^{(l+1,p)}} \\ &= \mathbf{f}'_l(\mathbf{Z}^{(l,p)}) \odot \text{up}(\delta^{(l+1,p)})\end{aligned}$$

- 其中 $\mathbf{f}'_l$ 为第 l 层的激活函数，up为上采样函数。

参数学习-卷积神经网络中的反向传播算法

► **卷积层**：假设第 $l+1$ 层是卷积层，特征映射净输入 $Z^{(l+1,p)} \in \mathbb{R}^{M' \times N' \times P}$ ，第 p 个特征映射净输入 $Z^{(l+1,p)} = \sum_{d=1}^D W^{(l+1,p,d)} \otimes X^{(l,d)} + b^{(l+1,p)}$

► 第 l 层的第 d 特征映射的误差项 $\delta^{(l,d)}$ 的具体推导过程如下：

$$\begin{aligned} \delta^{(l,d)} &\stackrel{\Delta}{=} \frac{\partial L}{\partial Z^{(l,d)}} = \frac{\partial X^{(l,d)}}{\partial Z^{(l,d)}} \frac{\partial L}{\partial X^{(l,p)}} \\ &= f'_1(Z^{(l,d)}) \odot \sum_{p=1}^P \left(\text{rot}180(W^{(l+1,p,d)}) \tilde{\otimes} \frac{\partial L}{\partial Z^{(l+1,p)}} \right) \\ &= f'_1(Z^{(l,d)}) \odot \sum_{p=1}^P \left(\text{rot}180(W^{(l+1,p,d)}) \tilde{\otimes} \delta^{(l+1,p)} \right) \end{aligned}$$

$$\begin{aligned} \frac{\partial f(Y)}{\partial X} &= \text{rot}180 \left(\frac{\partial f(Y)}{\partial Y} \right) \tilde{\otimes} W \\ &= \text{rot}180(W) \tilde{\otimes} \frac{\partial f(Y)}{\partial Y} \end{aligned}$$

4 其它卷积种类

转置卷积

- ▶ 我们一般通过卷积操作实现高位特征到低维特征的转换。比如，在一维卷积中，经过大小为3的卷积核，其输出为3维特征。如果设置步长大于1，可以进一步降低输出特征的维度。在一些任务中，我们需要将低维特征映射到高维特征。
- ▶ 假设高维向量 $\mathbf{x} \in \mathbb{R}^d$ 和低维向量 $\mathbf{z} \in \mathbb{R}^p$, $p < d$ 。如果用仿射变换来实现高维到低维的映射， $\mathbf{z} = \mathbf{W}\mathbf{x}$
- ▶ 其中 $\mathbf{W} \in \mathbb{R}^{p \times d}$ 为转换矩阵。我们可以通过转置 $\mathbf{W}$ 来实现低维到高维的反向映射 $\mathbf{x} = \mathbf{W}^T \mathbf{z}$

转置卷积

- ▶ 卷积操作也可以写成仿射变换。假设一个5维向量 $\mathbf{x}$ ，经过大小为3的卷积核 $\mathbf{w}=[w_1, w_2, w_3]^T$ 进行卷积，得到3维向量 $\mathbf{z}$ ，
- ▶ 同时，要实现 $\mathbf{z}$ 到 $\mathbf{x}$ 的映射，可转置仿射矩阵 $\mathbf{C}$

$$\mathbf{z} = \mathbf{w} \otimes \mathbf{x}$$

$$= \begin{bmatrix} w_1 & w_2 & w_3 & 0 & 0 \\ 0 & w_1 & w_2 & w_3 & 0 \\ 0 & 0 & w_1 & w_2 & w_3 \end{bmatrix} \mathbf{x}$$

$$= \mathbf{C} \mathbf{x}$$

$$\mathbf{x} = \mathbf{C}^T \mathbf{z}$$

$$= \begin{bmatrix} w_1 & 0 & 0 \\ w_2 & w_1 & 0 \\ w_3 & w_2 & w_1 \\ 0 & w_3 & w_2 \\ 0 & 0 & w_3 \end{bmatrix} \mathbf{z} = \text{rot180}(\mathbf{w}) \tilde{\otimes} \mathbf{z}$$

转置卷积

- ▶ 从上述两式可以看出，从仿射变换的角度来看两个卷积操作也是形式上的转置关系 $\mathbf{z} = \mathbf{w} \otimes \mathbf{x}$ 和 $\mathbf{x} = \text{rot180}(\mathbf{w}) \otimes \mathbf{z}$ ；因此，将低维特征映射到高维特征的卷积操作称为**转置卷积**（**Transposed Convolution**），或**反卷积**（**Deconvolution**）
- ▶ 在卷积网络中，卷积层的前向计算和反向传播也是一种转置关系。对于M维向量z和大小为K的卷积核，如果希望通过卷积操作来映射到更高维的向量，只需要对向量z进行两端补零 $P=K-1$ ，然后进行卷积，可以得到 $M+K-1$ 维的向量。

转置卷积

转置卷积同样适用于二维卷积






图 5.16 步长 $s = 1$, 无零填充 $p = 0$ 的两维卷积和其对应的转置卷积

转置卷积

- ▶ **微步卷积**：通过减少转置卷积步长 $S < 1$ 来实现上采样，大幅提高特征维数。此种步长 $S < 1$ 的转置卷积称为微步卷积。为了实现此种卷积，可以在输入特征之间插入0来间接地使步长变小
- ▶ 若卷积操作步长 $S > 1$ ，则其对应转置卷积步长 $1/S$ ，由此需要在输入特征之间插入 $S-1$ 个0来使得其移动速度变慢
- ▶ 一维卷积：M维的向量Z和大小为K的卷积核，通过对向量Z进行两端补零 $P=K-1$ ，并且在每两个向量元素之间插入D个0，然后进行步长 $S=1$ 的卷积，得到 $(D+1) \times (M-1) + K$ 维的向量



(a) 卷积, $s = 2, p = 0$



(b) 转置卷积, $s = 1, p = 2, d = 1$

图 5.17 步长 $s = 2$, 无零填充 $p = 0$ 的两维卷积和其对应的转置卷积


空洞卷积

▶ 如何增加输出单元的感受野


- ▶ 增加卷积核的大小
- ▶ 增加层数来实现
- ▶ 在卷积之前进行汇聚操作

▶ 空洞卷积

- ▶ 通过给卷积核插入“空洞”来变相地增加其大小。



D=2



D=3

空洞卷积

- ▶ **空洞卷积** (Atrous convolution) : 是一种不增加参数数量, 同时增加输出单元感受野的方法, 也称为膨胀卷积 (Dilated convolution)
- ▶ 空洞卷积通过给卷积核插入“空洞”来变相的增加其大小, 如果在卷积核的每两个元素之间插入D-1个空洞, 卷积核有效大小为:

$$K' = K + (K - 1) \times (D - 1)$$


- ▶ 其中D为膨胀率 (Dilation Rate) 。当D=1时, 卷积核为普通卷积核。

5 典型的卷积网络

LeNet-5

► LeNet-5 是一个非常成功的神经网络模型。


- ▶ 基于 LeNet-5 的手写数字识别系统在 90 年代被美国很多银行使用，用来识别支票上面的手写数字。
- ▶ LeNet-5 共有 7 层。



AlexNet


► 2012 ILSVRC winner

- (top 5 error of 16% compared to runner-up with 26% error)
- 第一个现代深度卷积网络模型，首次使用了很多现代深度卷积网络的一些技术方法，
 - 比如使用GPU进行并行训练，采用了ReLU作为非线性激活函数，使用Dropout防止过拟合，使用数据增强
- 5个卷积层、3个汇聚层和3个全连接层



Inception模块 v1


- ▶ 在卷积网络中，如何设置卷积层的卷积核大小是一个十分关键的问题。在Inception网络中，一个卷积层包含多个不同大小的卷积操作，称为Inception模块。
- ▶ Inception模块同时使用 1×1 、 3×3 、 5×5 等不同大小的卷积核，并将得到的特征映射在深度上拼接（堆叠）起来作为输出特征映射。



Inception网络

► 2014 ILSVRC winner (22层)

- 参数: GoogLeNet: 4M VS AlexNet: 60M
- 错误率: 6.7%
- Inception网络是由有多个inception模块和少量的汇聚层堆叠而成。



Inception模块 v3

- ▶ 用多层的小卷积核来替换大的卷积核，以减少计算量和参数量。
 - ▶ 使用两层 3×3 的卷积来替换v1中的 5×5 的卷积
 - ▶ 使用连续的 $n \times 1$ 和 $1 \times n$ 来替换 $n \times n$ 的卷积。




Figure 5. Inception modules where each 5×5 convolution is replaced by two 3×3 convolution, as suggested by principle 3 of Section 2.

<http://blog.csdn.net/xbinworld>







Figure 6. Inception modules after the factorization of the $n \times n$ convolutions. In our proposed architecture, we chose $n = 7$ for the 17×17 grid. (The filter sizes are picked using principle 3)

残差网络

- ▶ **残差网络** (Residual Network, ResNet) 是通过给非线性的卷积层增加**直连边**的方式来提高信息的传播效率。
- ▶ 假设在一个深度网络中，我们期望一个非线性单元（可以为一层或多层的卷积层） $f(\mathbf{x}, \theta)$ 去逼近一个目标函数为 $h(\mathbf{x})$ 。
- ▶ 将目标函数拆分成两部分：**恒等函数**和**残差函数**

$$h(\mathbf{x}) = \underbrace{\mathbf{x}}_{\text{恒等函数}} + \underbrace{(h(\mathbf{x}) - \mathbf{x})}_{\text{残差函数}} \rightarrow f(\mathbf{x}, \theta)$$


残差单元



ResNet


► 2015 ILSVRC winner (152层)

► 错误率: 3.57%




6 卷积的应用


文本序列的卷积模型




表示学习



表示学习



AlphaGo



The input to the policy network is a $19 \times 19 \times 48$ image stack consisting of 48 feature planes. The first hidden layer zero pads the input into a 23×23 image, then convolves k filters of kernel size 5×5 with stride 1 with the input image and applies a rectifier nonlinearity. Each of the subsequent hidden layers 2 to 12 zero pads the respective previous hidden layer into a 21×21 image, then convolves k filters of kernel size 3×3 with stride 1, again followed by a rectifier nonlinearity. The final layer convolves 1 filter of kernel size 1×1 with stride 1, with a different bias for each position, and applies a softmax function. The match version of AlphaGo used $k = 192$ filters; Fig. 2b and Extended Data Table 3 additionally show the results of training with $k = 128, 256$ and 384 filters.

policy network:

[19x19x48] Input


CONV1: 192 5x5 filters , stride 1, pad 2 => [19x19x192]

CONV2..12: 192 3x3 filters, stride 1, pad 1 => [19x19x192]

CONV: 1 1x1 filter, stride 1, pad 0 => [19x19] (*probability map of promising moves*)

- ▶ 分布式系统: 1202 个CPU 和176 块GPU
- ▶ 单机版: 48 个CPU 和8 块GPU
- ▶ 走子速度: 3 毫秒-2 微秒

目标检测 (Object Detection)



Mask RCNN





Figure 4. More results of **Mask R-CNN** on COCO test images, using ResNet-101-FPN and running at 5 fps, with 35.7 mask AP (Table 1).

OCR 光学字符识别



图像生成




Deep Dream




画风迁移



对抗样本



(a)



(b)

总结

- ▶ 卷积神经网络是受生物学上感受野机制启发而提出的。
- ▶ AlexNet是第一个现代深度卷积网络模型，是深度学习技术在图像分类上的真正突破的开端（ReLU/Dropout/GPU）；VGG、InceptionV1/V2/V4等
- ▶ 随着卷积网络层数的增多，卷积层越来越多的使用 1×1 和 3×3 大小的小卷积核，也出现了一些不规则卷积操作，如空洞卷积等
- ▶ 网络结构趋向全卷积网络(Fully convolutional network,FCN),减少汇聚层和全连接层的作用。

谢 谢