

《神经网络与深度学习》

无监督学习

周晓飞

xiaofei-zhou.com

自动化学院

为什么要无监督学习？


大脑有大约 10^{14} 个突触，我们只能活大约 10^9 秒。所以我们有比数据更多的参数。这启发了我们必须进行大量无监督学习的想法，因为感知输入（包括本体感受）是我们可以获得每秒 10^5 维约束的唯一途径。

-- Geoffrey Hinton, 2014 AMA on Reddit


无监督学习 (Unsupervised Learning)

- ▶ 无监督学习是指从无标签的数据中学习出一些有用的模式。
 - ▶ 一般直接从原始数据中学习 (无需人工标签或反馈等指导信息)
- ▶ 监督学习
 - ▶ 建立映射关系 $f: x \rightarrow y$, 寻找输入输出之间的映射关系
- ▶ 无监督学习分类
 - ▶ 无监督特征学习
 - ▶ 从无标签的训练数据中挖掘有效的特征或表示
 - ▶ 概率密度估计 $p(x)$
 - ▶ 根据一组训练数据来估计样本空间的概率密度
 - ▶ 参数和非参数
 - ▶ 聚类
 - ▶ 将数据分到不同的簇, 组内相似性高于组间相似性, K-mean


典型的无监督学习问题



无监督特征学习



密度估计




聚类

1 无监督特征学习

主成份分析 (Principal Component Analysis, PCA)

- ▶ 一种最常用的数据降维方法，令在转换后的空间中数据的方差最大



主成份分析 (Principal Component Analysis, PCA)

▶ 一组D维样本 $\{\mathbf{x}^{(n)} \in \mathbb{R}^D\}_{n=1}^N$ ，投影向量为 $\mathbf{w} \in \mathbb{R}^D$ 。每个样本投影之后

$$\mathbf{z}^{(n)} = \mathbf{w}^T \mathbf{x}^{(n)}$$

▶ 投影方差

$$\mathbf{X} = [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(n)}] \quad \bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \quad \bar{\mathbf{X}} = \bar{\mathbf{x}} \mathbf{1}_D^T$$

$$\begin{aligned} \sigma(\mathbf{X}; \mathbf{w}) &= \frac{1}{N} \sum_{n=1}^N \left(\mathbf{w}^T \mathbf{x}^{(n)} - \mathbf{w}^T \bar{\mathbf{x}} \right)^2 \\ &= \frac{1}{N} \left(\mathbf{w}^T \mathbf{X} - \mathbf{w}^T \bar{\mathbf{X}} \right) \left(\mathbf{w}^T \mathbf{X} - \mathbf{w}^T \bar{\mathbf{X}} \right)^T \\ &= \mathbf{w}^T \Sigma \mathbf{w} \end{aligned}$$

主成份分析 (Principal Component Analysis, PCA)

▶ 最大化投影方差 $\sigma(\mathbf{X}; \mathbf{w})$

$$\max_{\mathbf{w}} \mathbf{w}^T \Sigma \mathbf{w} + \lambda (1 - \mathbf{w}^T \mathbf{w})$$

$$\Rightarrow \Sigma \mathbf{w} = \lambda \mathbf{w}$$

$$\Rightarrow \sigma(\mathbf{X}; \mathbf{w}) = \mathbf{w}^T \Sigma \mathbf{w} = \mathbf{w}^T \lambda \mathbf{w} = \lambda$$

▶ λ 是特征值, $\mathbf{w}$ 是 Σ 的最大特征值对应的特征向量

▶ 投影阵 $\mathbf{W} \in \mathbb{R}^{D \times D'}$: 将 Σ 的特征值从大到小排列, 保留前 D' 个特征向量, 其对应的特征向量即是最优投影矩阵 $\Sigma \mathbf{W} = \mathbf{W} \text{diag}(\lambda)$

▶ 其中 $\lambda = [\lambda_1, \dots, \lambda_{D'}]$

稀疏编码 (Sparse Coding)

► (线性) 编码

- 给定一组基向量 $A = [\mathbf{a}_1, \dots, \mathbf{a}_p]$, 将输入样本 $\mathbf{x}$ 表示为这些基向量的线性组合

$$\mathbf{x} = \sum_{i=1}^p z_i \mathbf{a}_i$$

$$= \mathbf{A}\mathbf{z},$$

字典 (dictionary)

编码 (encoding)

- 基向量系数 $\mathbf{z} = [z_1, z_2, \dots, z_M]$ 为输入样本 $\mathbf{x}$ 的编码, $\mathbf{A}$ 为字典

完备性

- ▶ 如果 M 个基向量刚好可以支撑 D 维的欧氏空间，则这 M 个基向量是**完备**的。
- ▶ 如果 M 个基向量可以支撑 D 维的欧氏空间，并且 $M > D$ ，则这 M 个基向量是**过完备**的，冗余的。
- ▶ 稀疏编码
 - ▶ 找到一组“超完备”的基向量（即 $M > D$ ）来进行编码。
 - ▶ 结合稀疏性限制，减少解空间大小，得到稀疏编码

稀疏编码

▶ 给定一组 N 个输入向量 $\{\mathbf{x}^{(n)} \in \mathbf{R}^D\}_{n=1}^N$ ，其稀疏编码的目标函数定义为

$$L(\mathbf{A}, \mathbf{Z}) = \sum_{n=1}^N \left(\left\| \mathbf{x}^{(n)} - \mathbf{A} \mathbf{z}^{(n)} \right\| + \eta \rho(\mathbf{z}^{(n)}) \right) \quad \mathbf{Z} = \left[\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \dots, \mathbf{z}^{(n)} \right]$$

▶ $\rho(\cdot)$ 是一个稀疏性衡量函数， η 是一个超参数，用来控制稀疏性的强度。

$$\rho(\mathbf{z}) = \sum_{m=1}^M \mathbf{I}(|z_m| > 0)$$

$$\rho(\mathbf{z}) = \sum_{m=1}^M |z_m|$$

$$\rho(\mathbf{z}) = \sum_{m=1}^M \log(1 + z_m^2)$$

$$\rho(\mathbf{z}) = \sum_{m=1}^M -\exp(-z_m^2)$$

稀疏编码-训练过程

- ▶ 稀疏编码的训练过程一般用交替优化的方法进行。
- ▶ 给定N个样本 $\{\mathbf{x}^{(n)} \in \mathbb{R}^D\}_{n=1}^N$ ，同时学习基向量A以及每个输入样本对应的稀疏编码 $\{\mathbf{z}^{(n)}\}_{n=1}^N$

1) 固定基向量 A，对每个输入 $\mathbf{x}^{(n)}$ ，计算其对应的最优编码

$$\min_{\mathbf{z}^{(n)}} \left\| \mathbf{x}^{(n)} - A\mathbf{z}^{(n)} \right\|^2 - \eta \rho(\mathbf{z}^{(n)}), \quad \forall n \in [1, N].$$

2) 固定上一步得到的编码 $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(N)}$ ，计算其最优的基向量

$$\min_A \sum_{n=1}^N \left(\left\| \mathbf{x}^{(n)} - A\mathbf{z}^{(n)} \right\|^2 \right) + \lambda \frac{1}{2} \|A\|^2,$$

稀疏编码的优点

▶ 计算量

- ▶ 稀疏性带来的最大好处就是可以极大地降低计算量。

▶ 可解释性

- ▶ 因为稀疏编码只有少数的非零元素，相当于将一个输入样本表示为少数几个相关的特征。这样我们可以更好地描述其特征，并易于理解。

▶ 特征选择


- ▶ 稀疏性带来的另外一个好处是可以实现特征的自动选择，只选择和输入样本相关的最少特征，从而可以更好地表示输入样本，降低噪声并减轻过拟合。

自编码器 (Auto-Encoder)

- ▶ 编码器 (Encoder) $f: \mathbb{R}^D \rightarrow \mathbb{R}^M$
- ▶ 解码器 (Decoder) $g: \mathbb{R}^M \rightarrow \mathbb{R}^D$

- ▶ 自编码器的学习目标是**最小化重构错误**:

$$\begin{aligned} L &= \sum_{n=1}^N \left\| \mathbf{x}^{(n)} - g\left(f\left(\mathbf{x}^{(n)}\right)\right) \right\|^2 \\ &= \sum_{n=1}^N \left\| \mathbf{x}^{(n)} - f \circ g\left(\mathbf{x}^{(n)}\right) \right\|^2 \end{aligned}$$



$$\mathbf{z} = f\left(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}\right)$$

$$\mathbf{x}' = f\left(\mathbf{W}^{(2)}\mathbf{z} + \mathbf{b}^{(2)}\right)$$

自编码器

- ▶ 给定一组样本 $\mathbf{x}^{(n)} \in [0,1]^D$, $1 < n < N$, 其重构误差为

$$L = \sum_{n=1}^N \left\| \mathbf{x}^{(n)} - \mathbf{x}'^{(n)} \right\|^2 + \lambda \left\| \mathbf{W} \right\|_F^2$$

- ▶ 通过重构误差可以有效的学习网络的参数
- ▶ 训练结束后，一般去掉解码器，保留编码器。编码器的输出可以直接作为后续机器学习模型的输入

稀疏自编码器

- ▶ $M > D$, $\mathbf{z}$ 尽量稀疏, 是为稀疏自编码器 Sparse Auto-Encoder
- ▶ 优点: 可解释性, 隐式的进行特征选择
- ▶ 通过给自编码器中隐藏层单元 $\mathbf{z}$ 加上 稀疏性限制, 自编码器可以学习到数据中一些有用的结构。


$$L = \sum_{n=1}^N \left\| \mathbf{x}^{(n)} - \mathbf{x}'^{(n)} \right\|^2 + \boxed{\eta \rho(\mathbf{Z})} + \lambda \left\| \mathbf{W} \right\|_F^2$$

堆叠自编码器 stacked auto-encoder SAE

- ▶ 采用更深层的神经网络作为自编码器来提取特征，能得到更有力的语义信息表征
- ▶ 实践中，采用逐层堆叠的方式来训练一个更深层的自编码器
- ▶ SAE一般采用逐层训练的方式Layer-wise training

降噪自编码器 Denoising auto-encoder

- ▶ 通过引入噪声来增加编码鲁棒性的自编码器
 - ▶ 对于一个向量 $\mathbf{x}$ ，首先根据一个比例 μ 随机将 $\mathbf{x}$ 的一些维度的值设置为0，得到一个被损坏的向量 $\tilde{\mathbf{x}}$ 。
 - ▶ 然后将被损坏的向量 $\tilde{\mathbf{x}}$ 输入给自编码器得到编码 $\mathbf{z}$ ，并重构出原始的无损输入 $\mathbf{x}$
- ▶ 通过引入噪声来学习更鲁棒性的数据编码，并提高模型的编码能力



2 概率密度估计

Probabilistic density estimation

密度估计

▶ 密度估计方法可以分为两类

- ▶ 参数密度估计 (Parametric Density Estimation) 是根据先验知识假设随机变量服从某种分布，然后通过训练样本来估计分布的参数。
- ▶ 非参数密度估计 (Nonparametric Density Estimation) 是不假设数据服从某种分布，通过将样本空间划分为不同的区域并估计每个区域的概率来近似数据的概率密度函数。

参数密度估计

- ▶ 令 $D = \{\mathbf{x}^{(n)}\}_{i=1}^N$ 为从某个未知分布中独立抽取的 N 个训练样本，假设这些样本服从一个概率分布函数 $p(\mathbf{x}|\theta)$ ，其对数似然函数为

$$\log p(D; \theta) = \sum_{n=1}^N \log p(\mathbf{x}^{(n)}; \theta)$$

- ▶ 如何计算 θ ?

- ▶ 最大似然估计 Maximum likelihood estimation, MLE

$$\theta^{\text{ML}} = \arg \max_{\theta} \sum_{n=1}^N \log p(\mathbf{x}^{(n)}; \theta)$$

参数密度估计一般存在以下问题

▶ 模型选择问题

- ▶ 如何选择数据分布的密度函数？
- ▶ 实际数据的分布往往是非常复杂的，而不是简单的正态分布或多项分布。

▶ 不可观测变量问题

- ▶ 即我们用来训练的样本只包含部分的可观测变量，还有一些非常关键的变量是无法观测的，这导致我们很难准确估计数据的真实分布。

▶ 维度灾难问题

- ▶ 高维数据的参数估计十分困难
- ▶ 随着维度的增加，估计参数所需要的样本数量指数增加。在样本不足时会出现过拟合。

非参密度估计

- ▶ 非参数密度估计 (Nonparametric Density Estimation) 是不假设数据服从某种分布，通过将样本空间划分为不同的区域并估计每个区域的概率来近似数据的概率密度函数。

非参密度估计

- ▶ 对于高维空间中的一个随机向量 $\mathbf{x}$ ，假设其服从一个未知分布 $p(\mathbf{x})$ ，则 $\mathbf{x}$ 落入空间中的小区域 $\mathcal{R}$ 的概率为

$$P = \int_{\mathcal{R}} p(\mathbf{x}) d\mathbf{x}$$

- ▶ 给定 N 个训练样本 $D = \{\mathbf{x}^{(n)}\}_{i=1}^N$ ，落入区域 $\mathcal{R}$ 的样本数量 K 服从二项分布

$$P_K = \binom{N}{K} P^K (1 - P)^{1-K}$$

非参密度估计

- ▶ 当N 非常大时，我们可以近似认为

$$P \approx \frac{K}{N}$$

- ▶ 假设区域R足够小，其内部的概率密度是相同的，则有

$$P \approx p(\mathbf{x})V$$


- ▶ 结合上述两个公式，得到

$$p(\mathbf{x}) \approx \frac{K}{NV}$$


直方图方法 (Histogram Method)

- ▶ 一种非常直观的估计连续变量密度函数的方法，可以表示为一种柱状图。
- ▶ 以1维变量为例，首先将取值范围分为M个连续的、不重叠的区间bin，每个区间的宽度为 Δ_m 。给定训练样本 $D = \{\mathbf{x}^{(n)}\}_{n=1}^N$ ，统计样本落入区间的数量 K_m ，然后将其归一化为密度函数

$$p_m = \frac{K_m}{N\Delta_m}, 1 \leq m \leq M$$



(a) 10 个区间 (bin)



(b) 30 个区间 (bin)

核密度估计 (Kernel Density Estimation)

- ▶ 核密度估计是一种直方图方法的改进。
 - ▶ 也叫Parzen窗方法
- ▶ 假设 $\mathcal{R}$ 为d维空间中的一个以点 $\mathbf{x}$ 为中心的“超立方体”，并定义核函数来表示一个样本 $\mathbf{z}$ 是否落入该超立方体中

$$\phi\left(\frac{\mathbf{z}-\mathbf{x}}{H}\right)=\begin{cases} 1 & \text{if } |\mathbf{z}_i-\mathbf{x}_i|<\frac{H}{2}, 1\leq i\leq D \\ 0 & \text{else} \end{cases}$$

核密度估计 (Kernel Density Estimation)

- ▶ 给定训练样本 $D = \{\mathbf{x}^{(n)}\}_{n=1}^N$ ，落入区域 R 的样本数量为 K

$$K = \sum_{n=1}^N \phi\left(\frac{\mathbf{x}^{(n)} - \mathbf{x}}{H}\right)$$

- ▶ 点 $\mathbf{x}$ 的密度估计为

$$p(\mathbf{x}) = \frac{K}{NH^D} = \frac{1}{NH^D} \sum_{n=1}^N \phi\left(\frac{\mathbf{x}^{(n)} - \mathbf{x}}{H}\right)$$

- ▶ 核函数亦可采用更加平滑的，如高斯核函数

K近邻方法

- ▶ 核密度估计方法中的核宽度是固定的，因此同一个宽度可能对高密度的区域过大，而对低密度区域过小。
- ▶ 一种更灵活的方式是设置一种可变宽度的区域，并使得落入每个区域中样本数量为固定的K。
- ▶ 要估计点x的密度，首先找到一个以x为中心的球体，使得落入球体的样本数量为K，就可以计算出点x的密度。

$$p(x) = \frac{K}{NV}$$

总结

- ▶ 无监督学习主要包括无监督特征学习、概率密度估计和聚类
- ▶ 无监督特征学习：PCA/Sparse coding/ AE/ SAE
- ▶ 概率密度估计：参数密度估计/非参数密度估计，其中
 - ▶ 参数密度估计一般采用最大似然估计来计算参数
 - ▶ 非参数密度估计常采用直方图方法、核方法以及K近邻方法

谢 谢