

实践中的真实知识：视频恶劣天气去除的扩散测试时自适应

杨一军，吴红涛，Angelica I. Aviles-Rivero，张宇伦，秦静，朱雷

1 香港科技大学（广州） 2 剑桥大学 3 苏黎世联邦理工学院

4 香港理工大学 5 香港科技大学 项目页面：<https://github.com/scott-yjyang/DiffTTA>

摘要

真实世界的视觉任务经常受到意外恶劣天气条件的影响，包括雨、雾、雪和雨滴。在过去十年中，卷积神经网络和视觉Transformer 在单天气视频去噪方面取得了出色的成果。然而，由于缺乏适当的适应，它们大多无法泛化到其他天气条件。尽管 ViWS-Net 被提出用于使用同一组预训练权重去除视频中的恶劣天气条件，但在训练时看到过的天气使其严重受限，在测试时遇到未见过的天气时退化。在这项工作中，我们将测试时适应引入视频的恶劣天气去除中，并提出了第一个将测试时适应集成到迭代扩散逆过程中的框架。具体来说，我们设计了一个基于扩散的网络，并提出了一个新颖的时间噪声模型，以在训练阶段有效地探索退化视频片段中的帧相关信息。在推理阶段，我们引入了一个名为“扩散管自校准”的代理任务，以学习测试视频流的起始分布，并通过近似时间噪声模型进行在线适应来优化模型。在基准数据集上的实验结果表明，我们的基于扩散网络的测试时适应方法（Diff-TTA）在恢复由已知天气条件退化的视频方面优于最先进的方法。其泛化能力也在合成和真实世界视频中未见过的天气条件下得到了验证。




图 1. 现有的一体化恶劣天气去除方法的概述。我们的方法不仅可以在已知的天气条件下实现优异的性能，还可以通过扩散测试时适应，使用一套预训练权重在未知的天气条件下实现优异的性能。特别是，我们的 Diff-TTA 比 WeatherDiffusion 效率高 90 倍。

处理过度的视频会显著影响后续高级视觉应用的性能，如目标检测、语义分割和自动驾驶。为了减轻这些负面影响，卷积神经网络（CNN）和 Transformer 经常在文献中使用。此外，扩散模型已成为图像合成的实际生成模型[14, 16, 37]，并已用于单图像恶劣天气去除[34]。虽然深度神经网络在分布内的测试点可以实现不错的结果，但实际应用通常需要鲁棒性。当面对未知输入扰动、天气条件变化或其他分布偏移源时，这一点尤其重要。现有的单天气去除方法[4, 20, 61]需要对特定领域进行后续训练。这导致在不同参数集之间切换，这可能使流程变得繁琐。

最近，一体化恶劣天气去除引起了社区的注意，它旨在用通用模型处理各种天气条件[11, 21,

1. 引言

不良天气如雨、雪和雾在许多现有的户外视频中非常常见。不良天气的存在通常会降低帽状物的可见性

*刘珠（leizhu@ust.hk）是通讯作者。




图 2。我们的 Diff-TTA 使天气去除模型能够克服未见过的天气损坏。我们使用 t-SNE [40]来可视化每个数据集最后一个特征提取器层的特征。显然，在适应后，未见过的数据点倾向于近似已见过的数据点，这意味着 Diff-TTA 可以将未知退化分类到已知分布中。（“现实世界”包含同时被雾和雪损坏的视频片段。）39, 52]。然而，由于训练数据的有限性和缺乏测试数据适应机制，频繁无法从分布外条件中恢复的潜在问题在很大程度上仍未得到解决。如图 1 所示，通用模型在处理其训练数据范围之外的所有可能天气条件时都会遭受严重退化。此外，许多现实世界应用的一个共同方面是需要有限数据在线适应。这在自动驾驶汽车或无人机等场景中尤其相关，其中视觉模型必须持续处理视频流并调整其预测。为了实现有效的自适应，关键在于利用输入数据的方式要有益且不引入有害的偏差，即使训练数据和测试数据之间存在分布偏移。因此，类似于人类通过实践更新知识的方式，使用单个预训练权重通过在线自适应去除任何天气条件，这一任务既实用又充满前景，尽管具有挑战性。在本文中，我们构建了基于扩散的视频不良天气去除框架。然而，扩散模型通常涉及显著的训练开销，阻碍了该技术在视频任务研究社区中的更广泛采用。我们不是引入大量参数用于时间编码，而是基于 DDIM [38] 设计了一种高效策略来保留时间相关性，特别是时间噪声模型，以减轻其训练负担。与独立地从标准高斯分布为每帧采样噪声的朴素噪声模型不同，我们的时间噪声模型通过时间序列模型考虑了帧间关系。更重要的是，为了迅速应对意外的天气状况，我们引入了测试时适应技术，通过仅使用退化测试数据重新校准模型的参数。主流的测试时适应方法[18, 41

60]通过在测试阶段使用特定的代理任务来操作和迭代更新 CNN 和视觉转换器的归一化统计信息。然而，这些方法在迁移到低级任务时往往失败。此外，将这些迭代适应集成到这些模型中会显著增加推理成本，与原始模型相比，成本会随着迭代次数成倍增加。

相比之下，我们强调了结合扩散反向过程和测试时适应的优势，基于它们迭代共同特征。据我们所知，还没有工作提出扩散模型和测试时适应的可能性。基于我们的扩散框架，我们设计了一个代理任务，并在反转时间扩散过程时有效地将其结合到每个去噪迭代中。具体来说，我们开发了一个名为扩散管自校准（Diff-TSC）的代理任务，该任务由时间噪声模型监督。这是设计为任务无关的，并且不需要对训练过程进行任何更改。我们不是直接遍历所有细粒度细节，而是提取几个管状物来品尝未知天气下退化的帧的分布。这种方法促进了扩散模型的快速优化，同时降低了计算成本。如图 2 所示，测试时适应通过减轻已见和未见天气损坏之间的差距，帮助提高模型在实际场景中的鲁棒性。我们的贡献可以总结为：• 我们首次提出了一种基于扩散模型的集成式恶劣天气去除视频框架。该框架通过新颖的时间噪声模型高效地利用时间冗余信息。• 为了提高模型对未知天气的鲁棒性，我们首次在扩散逆过程中引入测试时适应，通过将代理任务结合进来学习测试数据的先验分布。• 我们在已知的天气（如雨、雾、雪）和未知的天气（如雨痕+雨滴、雪+雾）上广泛评估了我们的方法。在合成视频和真实世界视频上始终表现出的优越性能验证了其有效性和泛化能力。

2. 相关工作

一体化恶劣天气去除。在过去的十年中，低层视觉社区非常关注单一天气去除，例如去雨[5, 20, 24, 43, 48, 50, 51, 55]、去雾[28, 36, 47, 61]、除雪[4, 7–9, 58]，既在图像层面也在视频层面。由于现有模型在适应不同天气条件方面的局限性，研究人员最近一直在研究使用单个模型实例来处理多个恶劣天气去除任务。在图像层面，在开创性工作 All-in-one[21]之后，TransWeather[39]和 TKL[11]被引入来处理许多天气

7-9 条件使用单个编码器和解码器。Zhu 等人[64]详细阐述了一种两阶段训练策略，以探索天气通用和天气特定信息，以实现多种天气条件的复杂去除。Ye 等人[54]引入了由预训练的 VQGAN 学习的高质量码本先验，以从恶劣天气退化中恢复纹理细节。上述方法未能从时间空间中捕获冗余信息。虽然它们可以适应逐帧恶劣天气去除，但在视频级方法中结合时间数据为处理视频中多种恶劣天气条件提供了一种更稳健的解决方案。最近，Yang[52]引入了“ViWS-Net”，这是第一个视频级方法。该方法使用天气信使标记来跨帧传递天气知识。它还采用对抗学习来区分天气类型，从而强调天气不变信息。然而，他们没有考虑深度模型的在线适应，导致在未知天气下导致未见场景退化的潜在崩溃。

扩散模型。扩散模型是一种生成模型方法，以其在图像合成和生成任务中的卓越成就而闻名[14, 16, 27, 37, 53, 59]。本质上，去噪扩散概率模型（DDPM）[16]采用了参数化马尔可夫链来优化似然函数的下变分界，可以模拟扩散过程以迭代提高目标分布的质量，优于其他生成模型。在修复任务中，Luo 等人[30]在扩散模型中应用了具有均值回归特性的随机微分方程来提高低质量图像。DiffIR [46]通过估计紧凑的 IR 先验表示，为图像修复提供了一个强大的扩散基线。Zhang 等人[62]提出了一种基于扩散模型的统一条件框架，通过轻量级 U-Net 的多源引导进行图像修复。Ozdenizci 等人[34]设计了一种基于块的扩散建模方法，称为 WeatherDiffusion，使网络大小无关。虽然这种技术利用扩散模型进行图像天气去除，但其非常慢的推理速度限制了实际应用。然而，目前还没有工作将扩散模型应用于视频恶劣天气去除。

测试时适应。最近，人们越来越关注使用纯序列的未标记测试数据来适应深度模型。这与传统的无监督域适应形成对比，后者需要访问训练数据和足够多的未标记测试数据。测试时适应技术允许使用单个实例或一批未标记测试数据的分布统计数据来更新模型。通常，TENT [41] 侧重于最小化模型在目标数据上的预测熵。

T3A [18] 通过使用未标记的测试数据计算不同类别的伪原型表示来调整训练源模型的分类器。MEMO [60] 旨在最小化边缘熵，迫使深度模型在各种增强下持续预测。这种方法强制执行这些增强的不变性，并确保预测置信度。Chen 等人 [3] 提出应用自监督对比学习进行目标特征学习，该学习与伪标签联合训练。尽管测试时自适应方法越来越多地用于图像分类 [1, 32, 33, 42, 57] 和分割 [17, 25, 49] 任务，但它们在恶劣天气去除任务中的潜力尚未被探索。在我们的工作中，扩散模型中迭代采样过程的本质显著促进了适应目标分布。视频场景进一步允许积累适应知识以供后续帧使用。

3. 前提：扩散模型

扩散模型由正向过程和反向过程组成。正向过程定义为一个长度为 T 的离散马尔可夫链： $q(x_t|x) = \prod_{t=1}^T q(x_t|x)$ 。在正向过程的每一步 $t \in [1, T]$ 中，扩散模型向数据 x 添加从高斯分布 $N(0, I)$ 中采样的噪声 ϵ_t ，并得到扰动数据 x_t ， $q(x_t|x) = N(x_t; \sqrt{1 - \beta_t}x, \beta_t I)$ 。 β_t 决定了 t 时刻噪声的比例。值得注意的是，我们不仅可以在马尔可夫链上顺序采样，还可以通过闭合形式在任何时间步 t 采样 x_t ， $q(x_t|x) = N(x_t; \sqrt{1 - \alpha_t}x, (1 - \alpha_t)I)$ ，其中 $\alpha_t = \prod_{s=1}^t (1 - \beta_s)$ 。为了参数化高斯分布，引入了神经网络 ϵ_θ ，它通过 DDPM [16] 的目标进行优化：

$$L = \mathbb{E} \|\epsilon - \epsilon_\theta(\sqrt{1 - \alpha_t}x + \sqrt{\beta_t}\epsilon, t)\|^2. \quad (1)$$

在反向过程中，扩散模型通过训练良好的 ϵ_θ 预测的噪声，逐渐将随机采样的高斯噪声去噪到高质量输出 x_0 。这个过程也定义为一个马尔可夫链： $p(x_t) = p(x_0) \prod_{t=1}^T p(x_t|x)$ ， $p(x_t|x) = N(x_t; \mu(x_t, t), \sigma_t^2 I)$ 。均值和方差分别为 $\mu(x_t, t) = \sqrt{1 - \beta_t}(x_0 - \beta_t \epsilon_\theta(x_t, t))$ ， $\sigma_t^2 = 1\beta_t$ 。

4. 方法

在这项工作中，我们设计了一个基于扩散的模型，该模型使用一套模型参数来去除视频中任意的不良天气。我们遵循视频不良天气去除的端到端公式，其公式如下：

$$\hat{V} = \phi(V), V = \{I\}_i, \quad (2)$$

其中 V 是第 k 个被任意天气类型降级的包含 N 帧的视频片段， $\hat{V}$ 是恢复后的片段。 ϕ 是




图 3. 我们的视频恶劣天气去除 Diff-TTA 框架概述。在训练阶段，通过时间扩散过程，我们随机在干净的训练视频片段 V 上添加时间噪声。然后，通过估计所应用的噪声，训练去噪 NAFNet ϵ ，该噪声由看到的天气类型的退化对应物 V 条件化。在测试阶段，将裁剪的管状片段 $[V, \hat{V}]$ 最后恢复对用于学习引子分布的代理任务 Diff-TSC 结合到去噪每个时间步的随机采样时间噪声 V 的迭代在线适应中。

从 DDIM [38]派生的去噪函数。去噪函数中的去噪网络 ϵ 由一个编码器和解码器组成。

在训练阶段，我们遵循 DDIM 的公式，将扩散正向过程扩展到时间对应物，以进行帧相关性建模。使用 NAFNet[6]作为主干网络的去噪网络 ϵ 用于噪声估计，这强制模型的输出逼近所提出的时间噪声模型。在推理阶段，我们提出了一个代理任务 Diff-TSC，基于扩散反向过程，使扩散模型适应由未知天气退化的目标测试数据。我们迭代优化裁剪管状物的噪声估计，并校准模型参数的权重集，以实现更鲁棒的天气去除。接下来，我们详细阐述了我们基于扩散的视频不良天气去除解决方案以及我们的扩散测试时适应，这些也显示在图 3 中。

在训练图像扩散模型并将其用于将视频帧逐个反向转换到噪声空间时，可以很容易地观察到这些帧的噪声图之间的显著相关性。我们不是将大量参数引入去噪网络，而是通过基于 ARMA 的时间噪声模型将原始扩散过程扩展到时间对应物，以有效地保留帧之间的相关性。时间噪声模型。ARMA（自回归滑动平均）[2]是一种广泛用于时间序列数据的统计模型，它结合了自回归（AR）部分和滑动平均（MA）部分。通常，ARMA 可以表示为：

$$X = c + \epsilon + \sum_{i=1}^p \phi_i X_i + \sum_{j=1}^q \tau_j \epsilon_j, \quad (3)$$

其中 X 是值项， ϵ 是误差项， c 是常数项， p 、 q 是自回归阶数和移动平均阶数，而 ϕ 、 τ 分别是它们的系数。受自回归移动平均模型（ARMA）的启发，我们将原始的高斯噪声模型 $N(0, I)$ 开发为时间噪声模型 $T(0, I)$ 。具体来说，令 $\{\epsilon_t\}$ 表示视频片段中连续帧对应的噪声序列。我们首先分别从 $N(0, I)$ 中采样噪声序列 $\{\epsilon_t\}$ 和相应的误差序列 $\{\epsilon_t\}$ 。常数项 c 应与高斯分布的均值一致，即零。为了同时考虑过去和未来的信息，我们强制要求当前帧的噪声不仅受前一个帧的噪声和误差项的影响，还受下一个帧的影响，相应

4.1. 时间扩散过程

传统的扩散模型被训练以从扰动图像中去除独立噪声。方程(1)中的噪声 ϵ 从独立同分布的高斯分布 $\epsilon \sim N(0, I)$ 中采样

为了同时考虑过去和未来的信息，我们强制要求当前帧的噪声不仅受前一个帧的噪声和误差项的影响，还受下一个帧的影响，相应地，自回归阶数和移动平均阶数 p 、 $q=1$ 。因此，公式（3）中的表达式演变为噪声项和误差项的凸组合：

$$\tilde{\epsilon}=(1-\phi-\tau)\epsilon+\phi\tilde{\epsilon}+\tau\epsilon_2+\tau\epsilon+\epsilon_2,(4)$$

其中 ϕ, τ 分别经验设置为 0.6, 0.3。算法 1 进一步说明了我们的时序噪声模型，其中每个视频片段的噪声序列通过独立的先序和后序步骤构建。

算法 1: 时序噪声模型 $T(0, l)$ 输入: K 个片段 $\{V, V, \dots, V\}$ 在一批中; 系数 ϕ, τ

1 对于片段 $k=1, 2, \dots, K$ 并行地做
对于帧 $i=1, 2, \dots, N$ ，并行地执行
3 样本 $\tilde{\epsilon}, \epsilon \in R$ 从 $N(0, l)$
4 结束
对于帧 $i=2, 3, \dots, N$ ，顺序地执行
6 $\tilde{\epsilon}_i=(1-\phi-\tau)\epsilon_i+\phi\tilde{\epsilon}_{i-1}+\tau\epsilon_{i-1}$
7 结束
8 对于帧 $i=N-1, \dots, 2, 1$ 依次进行
9 $\tilde{\epsilon}_i=(1-\phi-\tau)\epsilon_i+\phi\tilde{\epsilon}_{i+1}+\tau\epsilon_{i+1}$
10 结束
11 $\tilde{\epsilon}=\text{normalize}(\tilde{\epsilon}) \Rightarrow \tilde{\epsilon} \sim T(0, l)$
12 结束
13 返回 $\{\{\tilde{\epsilon}|\tilde{\epsilon} \in R\}i\}$ 为了增强我们的去噪网络捕获时间依赖性的能力，我们通过用三维卷积层替换去噪 NAFNet 的第一层和最后一层来特别修改了架构。这个定制的网络，表示为 ϵ ，然后被优化为：

$$L=\|\tilde{\epsilon}-\epsilon(\sqrt{\alpha}V+\sqrt{1-\alpha}\epsilon,V,t)\|,(5)$$

其中我们利用时间噪声模型作为监督，并且 $\|\cdot\|$ 表示 L 范数。

4.2. 扩散测试时自适应

一旦通过所提出的时间噪声模型训练，网络 ϵ 就能生成高质量的图像。这是通过采样一个噪声状态 V 并在反向过程中迭代去噪来实现的。Yang 等人 [52] 引入了对抗学习用于天气条件

在训练阶段需要天气类型标注。此外，他们的方法可能无法处理分布外数据，因为将所有现实世界条件都包含在训练中，考虑天气类型和图像统计，是不切实际的。相比之下，我们引入了测试时适应和通过实践更新知识来去除任意的天气条件。我们设计并集成了扩散管小自校准（Diff-TSC），这是一个代理任务，将其纳入扩散逆过程的迭代去噪中，以学习由未知天气退化的帧的初始分布。

算法 2: 扩散测试时适应未知天气。 θ 是训练前训练网络的权重集， δ 是在线适应的学习率。

输入: K 个重叠片段: $\{V, V, \dots, V\}$ 在一个视频流中

1 对于片段 $k=1, 2, \dots, K$ 顺序执行
2 初始化网络 ϵ 以 θ
3 使用算法 1 初始化 $\hat{V}$
4 如果 $k=1$ 则
5 按顺序依次对步长 $t=T, \dots, 2, 1$ 进行循环
6 $\hat{V}=\text{ddim}(V, \hat{V}, \epsilon, t)$
7 结束
8 否则
9 $A, \hat{A}=\text{TubeletCrop}(V, \hat{V}, N)$
对于步长 $t=T, \dots, 2, 1$ 依次执行 10
11 根据 (5) 式计算 $L(A, \hat{A}, \tilde{\epsilon}, t)$
12 $\hat{\theta}=\hat{\theta}-\delta \nabla_{\hat{\theta}} L$
13 $\hat{\epsilon}=\epsilon(\hat{V}, \hat{A}, \hat{\theta})$ $V=$ 按 $\text{ddim}(V, \hat{V}, \epsilon, t)$
14 结束
15 $\hat{V}=\text{整合}(\hat{V}, \hat{V})$
16 结束
17 结束
18 返回恢复的片段 $\{\hat{V}, \hat{V}, \dots, \hat{V}\}$

扩散管自校准。我们设计了一个自监督学习的代理任务，以将扩散模型迁移到特定的天气条件。具体来说，对于视频流中的每个片段，我们首先使用源数据训练的 θ 初始化 ϵ 的权重集。在推断当前片段 V 时，我们利用前一个片段 V 及其恢复结果 $\hat{V}$ 作为在线优化的条件和输入。我们不是直接遍历所有细粒度细节，而是从 V 中随机裁剪 N 个管状物作为起始分布，以避免高分辨率引起的内存开销和巨大的计算成本。按照第 4.1 节中的过程，我们对恢复的管状物 $\hat{A}$ 进行时间扩散，并将它们与退化的管状物 A 一起输入去噪 NAFNet 进行噪声估计。如[41]中所述，它



图 4. 我们的方法与最先进算法在看到天气条件方面的定性比较。竞争性算法被选择在示例帧上展示被雨、雾、雪降级的结果。颜色框表示细节的比较。请放大图像以改善可视化效果。

PyTorch 平台。我们采用了 Lion 优化器[12] ($\beta=0.9$, $\beta=0.99$), 初始学习率为 2×10^{-5} , 通过余弦调度器衰减到 2×10^{-6} 。我们随机裁剪视频帧到 256×256 用于训练。我们的框架以端到端的方式经验性地训练了 600k 次迭代, 批大小为 4。每个批次包含 4 个视频片段, 每个片段有 5 帧。方法特定细节。在训练过程中, 我们使用了从 $\beta=0.0001$ 线性增加到 $\beta=0.02$ 的扩散过程, $T=1000$ 个时间步。在测试过程中, 推理步骤减少到 25, 通过确定性隐式采样。我们使用相同优化器, 但学习率更小, 为 1×10^{-5} , 用于测试时适应。裁剪的管状数 N 经验性地设置为 5, 裁剪大小为 128×128 。尽管加入了适应, 我们的 Diff-TTA 比 WeatherDiffusion 效率高 90 倍。处理一个包含 5 帧、补丁大小为 256×256 的视频片段, DiffTTA 的平均运行时间为 6.01 秒, 而 WeatherDiffusion 为 542.76 秒。

5.3. 性能评估

比较方法。如表 1 所示, 我们按照[52]中的做法, 将我们提出的方法与五种当前最先进的方法在三种已见天气条件下进行了比较, 即去雨、去雾、除雪、恢复、一体化恶劣天气去除。对于一体化恶劣天气去除, 我们将其与六种代表性的单图像方法 All-in-one [21]、UVRNet [19]、TransWeather [39]、TKL [11]、WeatherDiffusion [34]、WGWS-Net [64] 以及视频级方法 ViWS-Net [52] 进行了比较。

定量比较。为了对恢复结果进行定量评估, 我们应用峰值信噪比 (PSNR) 和结构相似性 (SSIM) 作为指标。遵循之前的实验设置, 仅报告所有一体化恶劣天气去除模型在混合训练集上训练的结果。为了确保比较的公平性

我们基于我们的训练数据集对官方代码实现的每个比较模型进行重新训练, 并报告最佳结果。从表 1 可以看出, 我们的方法在雨、雾和雪条件下, 在所有方法中实现了最佳的平均性能, 分别比第二好的方法 ViWS-Net [52] 在 PSNR 和 SSIM 上高出 0.46 和 0.0059。尽管像 DDMSNET [58] 和 SMGARN [13] 这样的单气象方法在其自身气象条件下取得了令人印象深刻的结果, 但它们经常无法去除其他气象条件, 例如雾。我们的方法在雨和雪条件下显著超越了他所有恶劣天气方法, 并在雾条件下获得了具有竞争力的结果。值得注意的是, 对于这类方法来说, 泛化能力至关重要, 这可以从平均性能中观察到。为了进一步验证它们的泛化能力, 我们在表 2 中对所有恶劣天气去除方法在未见过的天气条件下进行了评估, 即雨迹+雨滴和雪+雾。当面对这些未见过的天气条件时, 我们的 Diff-TTA 在当前最先进方法中表现出卓越的优势。在合成视频上的视觉比较。为了生动地展示我们方法的有效性, 图 4 展示了我们的方法与五种当前最先进方法在雨、雾和雪条件下的定性比较。我们的方法在各种天气类型下都表现出良好的视觉效果。具体来说, 在雨雪场景中, 我们的方法显著减少了雨痕和雪花粒的存在, 优于其他方法。在雾天场景中, 我们的方法有效地去除了残留的雾气, 并保留了干净的背景, 效果令人印象深刻。更多已见和未见天气的视觉结果显示在补充文件中。在真实世界视频上的视觉比较。为了评估我们 Diff-TTA 在真实世界应用中的普适性, 我们从 Youtube 网站收集了几个由雨、雾、雪造成的真实世界退化视频, 并进一步将我们的方法与其他一体化恶劣天气去除方法进行比较。

表 3. 所提出框架中每个关键组件在已见天气条件下的消融研究。最高值以粗体字标记。“Diff-TTA” 表示扩散测试时适应。

组合组件数据集扩散过程时间噪声 Diff-TTA 雨雾雪平均											
M1 --- 29.07 0.9514 22.64 0.8930 28.79 0.9350 26.83 0.9264 M2 ✓ - - 31.55 0.9466 23.58 0.9041 30.48 0.9520 28.52 0.9342 M3 ✓ ✓ - 32.10 0.9530 24.31 0.9124 31.04 0.9621 29.15 0.9425											
我们的 ✓ ✓ ✓ 32.43 0.9573 24.56 0.9148 31.86 0.9640 29.63 0.9453											




图 5. 在由雨、雾、雪污染的选定真实世界视频序列上，对一体化恶劣天气去除方法进行的视觉比较。显然，我们的网络比现有技术更有效地去除输入视频帧中的雨痕、雾和雪花。请放大图像以改善可视化效果。




图 6. 我们提出的 Diff-TTA 对 VRDS 和 RVSD 的每个案例的详细结果。所提出的 Diff-TTA 在各种情况下都带来了持续的性能提升。方法。图 5 显示了我们网络和比较方法在真实世界视频帧上产生的视觉结果，清晰地展示了我们的卓越性能。消融研究。我们评估了每个组件的有效性，包括扩散过程、时间噪声模型和扩散测试时自适应（Diff-TTA），如表 3 所示。我们在混合训练集上训练并在三个特定天气的测试集（雨、雾、雪）上进行测试，从 PSNR 和 SSIM 的角度来看。基线模型 M1，即普通的 NAFNet，在三个恶劣天气数据集上的平均性能分别为 26.83 和 0.9264（PSNR 和 SSIM）。M2 配备了扩散过程，并通过噪声估计进行训练，平均性能分别提高了 1.69 和 0.0078（PSNR 和 SSIM）。

M3 引入了提出的时序噪声模型，取代了香草噪声模型，并带来了平均 PSNR、SSIM 分别提高了 0.63、0.0083 的改进。最后，我们的完整模型采用了扩散测试时自适应（Diff-TTA），与 M3 相比，PSNR、SSIM 分别获得了 0.48、0.0028 的显著提升。图 6 进一步消融了我们在两个未见数据集上的迭代自适应，展示了持续改进的效果。

6. 结论

本文介绍了一种名为 Diff-TTA 的基于扩散模型的测试时自适应方法，能够恢复由各种甚至未知天气条件造成的视频退化。该方法涉及构建基于扩散的网络，并利用一种新的时序噪声模型来建立视频帧之间的相关性。更重要的是，将代理任务 Diff-TSC 结合到扩散反向过程中，以迭代更新深度模型。这使得视觉系统能够在现实场景中高效地自适应，而无需修改源训练过程，使其易于应用于各种现成的基于扩散的模型，以增强天气去除效果。在包含多种天气条件的合成和真实世界数据上的实验结果，证实了该方法的有效性和泛化能力。我们相信 Diff-TTA 可以成为一个有吸引力的基线，将社区的关注点从复杂的训练过程转移到在线测试时自适应。

参考文献

[1] Malik Boudiaf, Romain Mueller, Ismail Ben Ayed, and Luca Bertinetto. 无参数的在线测试时适应. 在 IEEE/CVF 计算机视觉和模式识别会议论文集, 第 8344–8353 页, 2022 年. 3 [2] George Box. Box and jenkins: 时间序列分析、预测和控制. 在 《一个非常英国的事务：六位英国人与 20 世纪时间序列分析的发展》, 第 161–215 页. Springer, 2013 年. 4 [3] Dian Chen, Dequan Wang, Trevor Darrell, and Sayna Ebrahimi. 对比测试时适应. 在 IEEE/CVF 计算机视觉和模式识别会议论文集, 第 295–305 页, 2022 年. 3 [4] Haoyu Chen, Jingjing Ren, Jinjin Gu, Hongtao Wu, Xuequan Lu, Haoming Cai, and Lei Zhu. 视频除雪：一个新数据集和一个新方法. 在 IEEE/CVF 国际计算机视觉会议论文集, 第 13211–13222 页, 2023 年. 1, 2, 6 [5] Jie Chen, Cheen-Hau Tan, Junhui Hou, Lap-Pui Chau, and He Li. 在 CNN 框架中鲁棒的视频内容对齐和补偿用于雨除法. 在 IEEE 计算机视觉和模式识别会议论文集, 第 6286–6295 页, 2018 年. 2 [6] 陈亮宇,褚晓杰,张祥宇,孙健.图像修复的简单基线.在计算机视觉欧洲会议,第 17-33 页.斯普林格,2022. 4, 1 [7] 陈思祥,叶天,刘云,白金斌,陈皓宇,林云龙,石军,陈 erkang. Cplformer:用于图像除雪的跨尺度原型学习 Transformer.在 ACM 国际多媒体会议第 31 届,第 4228-4239 页,2023. 2 [8] 陈思祥,叶天,薛成浩,陈皓宇,刘云,陈 erkang,朱雷.基于不确定性驱动的动态退化感知和背景建模的高效单图像除雪.在 ACM 国际多媒体会议第 31 届,第 4269-4280 页,2023. [9] 陈伟婷,方浩宇,丁建钧,蔡成哲,郭思延. Jstasr:基于改进部分卷积和遮蔽效应去除的联合尺寸和透明度感知除雪算法.在计算机视觉欧洲会议,第 754-770 页.斯普林格,2020. 2

[10] 魏婷婷, 方浩宇, 谢成林, 蔡成哲, 陈建钧, 丁建军, 郭思延, 等. 全部积雪清除：基于分层双树复小波表示和矛盾通道损失的图像去雪算法. IEEE/CVF 国际计算机视觉会议论文集, 第 4196–4205 页, 2021. 6 [11] 魏婷婷, 黄志凯, 蔡成哲, 杨浩翔, 丁建军, 郭思延. 通过两阶段知识学习和多对比正则化学习多种恶劣天气去除：迈向统一模型. IEEE/CVF 计算机视觉与模式识别会议论文集, 第 17653–17662 页, 2022. 1, 2, 6, 7

[12] 邱宁, 李昌, 黄达, Esteban Real, 王凯源, 刘瑶, Pham Hieu, 董宣毅, Luong Thang, Cho-Jui Hsieh, 等. 优化算法的符号发现. arXiv 预印本 arXiv:2302.06675, 2023. 7 [13] 程波东, 李军成, 陈颖, 张舒怡, 曾铁勇. 雪掩引导的自适应残差网络用于图像除雪. arXiv 预印本 arXiv:2207.04754, 2022. 6, 7 [14] Prafulla Dhariwal 和 Alexander Nichol. 扩散模型在图像合成上击败了 GAN. 神经信息处理系统进展, 34:8780–8794, 2021. 1, 3 [15] 董杭, 潘金山, 向雷, 胡哲, 张新怡, 王飞, 和杨明轩. 多尺度增强去雾网络与密集特征融合. 在 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 2157–2167 页, 2020. 6 [16] Jonathan Ho, Ajay Jain, 和 Pieter Abbeel. 去噪扩散概率模型. 神经信息处理系统进展, 33:6840–6851, 2020. 1, 3 [17] 胡明浩, 宋涛, 顾宇君, 罗向德, 陈继能, 陈一南, 张亚, 和张少挺. 图像分割的全测试时自适应. 在医学图像计算与计算机辅助干预——MICCAI 2021：第 24 届国际会议, 斯特拉斯堡, 法国, 2021 年 9 月 27 日至 10 月 1 日, 论文集, 第三部分 24, 第 251-260 页. Springer, 2021. 3 [18] Yusuke Iwasawa 和 Yutaka Matsuo. 用于模型无关领域泛化的测试时分类器调整模块. 神经信息处理系统进展, 34:2427-2440, 2021. 2, 3 [19] Ashutosh Kulkarni、Prashant W Patil、Subrahmanyam Murala 和 Sunil Gupta. 统一多天气能见度恢复. IEEE 多媒体汇刊, 2022. 6, 7 [20] Minghan Li、Qi Xie、Qian Zhao、Wei Wei、Shuhang Gu、Jing Tao 和 Deyu Meng. 基于多尺度卷积稀疏编码的视频雨迹去除. IEEE 计算机视觉与模式识别会议论文集, 第 6644-6653 页, 2018. 1, 2 [21] Ruoteng Li、Robby T Tan 和 Loong-Fah Cheong. 使用架构搜索的一站式恶劣天气去除. IEEE/CVF 计算机视觉与模式识别会议论文集, 第 3175-3185 页, 2020. 1, 2, 6, 7 [22] Jian Liang、Dapeng Hu 和 Jiashi Feng. 我们真的需要访问源数据吗？无监督域适应的源假设迁移. 在机器学习国际会议, 第 6028-6039 页. PMLR, 2020. 6 [23] 景云李, 范宇晨, 向晓宇, 拉基什·兰坎, 艾迪·伊尔格, 西蒙·格林, 曹继章, 张凯, 拉杜·蒂莫夫特, 和卢克·范戈尔. 带引导可变形注意力的循环视频修复 Transformer. arXiv 预印本 arXiv:2206.02146, 2022. 6 [24] 刘佳颖, 杨文涵, 杨帅, 和郭宗明. 擦除还是填充？视频中深度联合循环雨去除和重建. 在 IEEE 计算机视觉和模式识别会议论文集, 第 3233-3242 页, 2018. 2

2 [25] 刘泉, 陈成, 窦奇, 和彭安·亨。基于形状字典的医学图像分割单域泛化。在 AAAI 人工智能会议论文集, 第 1756-1764 页, 2022 年。3 [26] 刘晓红, 马永瑞, 石志浩, 和陈俊。基于注意力的多尺度网络 Griddehazenet 用于图像去雾。在 IEEE/CVF 国际计算机视觉会议论文集, 第 7314-7323 页, 2019 年。6 [27] 刘希惠, 朴东旭, 阿扎迪·萨曼, 张公, 乔皮扬·阿尔曼, 胡雨晓, 石汉普里, 罗伯巴赫·安娜, 和达雷尔·特伦多尔。免费更多控制! 基于语义扩散引导的图像合成。在 IEEE/CVF 计算机视觉应用冬季会议论文集, 第 289-299 页, 2023 年。3 [28] 刘叶, 万良, 付华珠, 秦静, 和朱雷。基于相位的记忆网络用于视频去雾。在 ACM 国际多媒体会议第 30 次会议论文集, 第 5427-5435 页, 2022 年。2, 6 [29] 刘云福, 赵大卫, 黄世超, 和黄建年。Desnownet: 用于雪去除的上下文感知深度网络。IEEE 图像处理汇刊, 第 27 卷第 6 期, 第 3064-3073 页, 2018 年。6 [30] 罗子伟, Fredrik K Gustafsson, 赵铮, Sjölund Jens, 和 Thomas B Schöon. 使用均值回归随机微分方程进行图像恢复. arXiv 预印本 arXiv:2301.11699, 2023. 3, 1 [31] 罗子伟, Fredrik K Gustafsson, 赵铮, Sjölund Jens, 和 Thomas B Schöon. Refusion: 使用潜在空间扩散模型实现大尺寸逼真图像恢复. 在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 页面 1680–1691, 2023. 1 [32] 阮秋安, 阮天祥, Lim Ser-Nam, 和 Torr Philip HS. Tipi: 具有变换不变性的测试时适应. 在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 页面 24162–24171, 2023. 3 [33] 牛树成, 吴嘉祥, 张一帆, 陈瑶佛, 郑时健, 赵培林, 和谭明奎. 无遗忘的高效测试时模型适应. 在机器学习国际会议, 页面 16888–16905. PMLR, 2022. 3 [34] Ozan Özdenizci 和 Robert Legenstein. 使用基于块的降噪扩散模型在恶劣天气条件下恢复视力. IEEE 模式分析和机器智能汇刊, 2023. 1, 3, 6, 7 [35] 董伟仁, 左万明, 胡清华, 朱鹏飞, 孟德宇。渐进式图像去雨网络: 更好更简单的基线。在 IEEE/CVF 计算机视觉与模式识别会议论文集, 第 3937–3946 页, 2019 年。6 [36] 任文琪, 张景刚, 徐祥宇, 马林, 曹晓春, 孟高峰, 刘伟。基于语义分割的深度视频去雾。IEEE 图像处理汇刊, 第 28 卷第 4 期: 1895–1908, 2018 年。2, 6 [37] Jaskirat Singh, Stephen Gould, 郑亮。基于潜在扩散模型的超保真引导图像合成。arXiv 预印本 arXiv:2211.17084, 2022 年。1, 3

[38] 宋佳明, 孟晨林, 和斯特凡诺·埃尔蒙。去噪扩散隐式模型。arXiv 预印本 arXiv:2010.02502, 2020。2, 4 [39] 杰亚·玛丽亚·约瑟夫·瓦拉纳苏, 拉杰夫·亚萨尔拉, 和维什阿尔·M·帕特尔。Transweather: 基于 Transformer 的恶劣天气条件下图像恢复。在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 第 2353–2363 页, 2022。2, 6, 7 [40] 劳伦斯·范德马滕和杰弗里·H·希顿。使用 t-sne 可视化数据。机器学习研究杂志, 9 (11), 2008。2 [41] 王德权, 伊万·谢尔哈默, 刘少腾, 布鲁诺·奥尔沙文, 和特雷弗·达雷尔。Tent: 通过熵最小化实现完全测试时适应。arXiv 预印本 arXiv:2006.10726, 2020。2, 3, 5 [42] 王勤, 奥莉加·芬克, 卢克·范戈尔, 和邓新戴。持续测试时域适应。在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 第 7201–7211 页, 2022。3 [43] 王帅, 朱雷, 付华珠, 秦静, 卡拉-比安妮谢恩利布, 冯伟, 和王松。重新思考视频雨痕去除: 一个新的合成模型和具有视频雨先验的去雨网络。在 European Conference on Computer Vision, 第 565–582 页。Springer, 2022 年。2, 6 [44] 王馨涛, Chan Kelvin CK, 余克, 董超, 和 Chen Change Loy。Edvr: 使用增强可变形卷积网络的视频修复。在 IEEE/CVF 计算机视觉与模式识别研讨会论文集, 第 0–0 页, 2019 年。6 [45] 吴鸿涛, 杨一军, 陈浩宇, 任晶晶, 和朱雷。Mask-guided 渐进网络用于视频中雨滴和雨痕的联合去除。在 31st ACM International Conference on Multimedia, 第 7216–7225 页, 2023 年。6 [46] 夏斌, 张宇伦, 王世银, 王奕通, 吴兴龙, 田亚鹏, 杨文明, 和 Luc Van Gool。Diffir: 用于图像修复的高效扩散模型。arXiv 预印本 arXiv:2303.09472, 2023 年。3 [47] 许嘉琪, 胡晓伟, 朱雷, 窦琪, 戴继锋, 乔宇, 和 Pheng-Ann Heng。通过多范围时间对齐网络与物理先验的视频去雾。在 IEEE/CVF 计算机视觉与模式识别会议, 第 18053–18062 页, 2023 年。2 [48] 颜文定, Tan Robby T, 杨文汉, 和戴登新。自对准视频去雨, 具有传输深度一致性。在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 第 11966-11976 页, 2021 年。2 [49] 杨红铮, 陈成, 蒋美瑞, 刘全德, 曹建峰, 黄炳安, 和窦琪。Dlta: 跨域医学图像测试时自适应的动态学习率。IEEE 医学成像汇刊, 41 (12):3575-3586, 2022 年。3 [50] 杨文涵, 刘佳颖, 冯嘉石。双流框架一致性循环视频去雨。在 IEEE/CVF 计算机视觉与模式识别会议论文集中, 第 1661-1670 页, 2019 年。2

2 [51] 杨文瀚、谭罗比、王世奇、刘佳颖。自学习视频雨迹去除：当循环一致性遇到时间对应。在 IEEE/CVF 计算机视觉与模式识别会议论文集，第 1720-1729 页，2020 年。2, 6 [52] 杨一军、阿维莱斯-里韦罗·安杰莉卡 I、付华珠、刘叶、王伟明、朱雷。通过天气信使和对抗反向传播的视频恶劣天气成分抑制网络。在 IEEE/CVF 国际计算机视觉会议论文集，第 13200-13210 页，2023 年。2, 3, 5, 6, 7 [53] 杨一军、付华珠、阿维莱斯-里韦罗·安杰莉卡 I、施奥拉比亚·比安妮卡、朱雷。Diffmic：用于医学图像分类的双引导扩散网络。在医学图像计算与计算机辅助干预国际会议，第 95-105 页。斯普林格，2023 年。3 [54] 叶天、陈思祥、白金斌、石军、薛成浩、蒋静霞、尹俊杰、陈尔康、刘云。带码本先验的恶劣天气去除。在 IEEE/CVF 国际计算机视觉会议论文集，第 12653-12664 页，2023 年。3 [55] 岳宗胜、谢建文、赵倩、孟德宇。半监督视频去雨，使用动态雨生成器。在 IEEE/CVF 计算机视觉与模式识别会议论文集，第 642-652 页，2021 年。2, 6 [56] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang, 和 Ling Shao。多阶段渐进式图像恢复。在 IEEE/CVF 计算机视觉与模式识别会议论文集，第 14821-14831 页，2021 年。6 [57] Jian Zhang, Lei Qi, Yinghuan Shi, 和 Yang Gao。Domainadaptor：一种新的测试时适应方法。在 IEEE/CVF 国际计算机视觉会议论文集，第 18971-18981 页，2023 年。3 [58] Kaihao Zhang, Rongqing Li, Yanjiang Yu, Wenhan Luo, 和 Changsheng Li。用于雪去除的深度密集多尺度网络，使用语义和深度先验。IEEE 图像处理汇刊，第 30 卷，第 7419-7431 页，2021 年。2, 6, 7 [59] Lvmin Zhang, Anyi Rao, 和 Maneesh Agrawala。为文本到图像扩散模型添加条件控制。在 IEEE/CVF 国际计算机视觉会议论文集，第 3836-3847 页，2023 年。3 [60] Marvin Zhang, Sergey Levine, 和 Chelsea Finn。备忘：通过适应和增强测试时间鲁棒性。神经信息处理系统进展，35：38629–38642，2022。2, 3 [61] 张新怡，董航，潘金山，朱超，台英，王成杰，李吉林，黄飞月，和王飞。

[63] 周坤，李文波，陆丽英，韩晓光，和陆建波。重新审视视频恢复的时间对齐。在 IEEE/CVF 计算机视觉与模式识别会议论文集中，第 6053-6062 页，2022 年。6 [64] 朱宇瑞，王天宇，付雪阳，杨轩宇，郭欣，戴继峰，乔宇，和胡晓伟。学习在多种恶劣天气条件下进行图像恢复的天气通用和天气特定特征。在 IEEE/CVF 计算机视觉与模式识别会议论文集中，第 21747-21758 页，2023 年。3, 6, 7

学习恢复模糊视频：一个新的真实世界数据集和一种新方法。在 IEEE/CVF 计算机视觉与模式识别会议论文集中，第 9239-9248 页，2021 年。1, 2, 6

[62] 张毅，石晓宇，李大松，王晓刚，王健，和李红生。基于扩散模型的图像恢复的统一条件框架。arXiv 预印本 arXiv:2305.20049，2023 年。3

实践中的真实知识：视频恶劣天气去除的扩散测试时自适应

补充材料

这是一份关于《实践中的真实知识：视频恶劣天气去除的扩散测试时序自适应》的补充材料。我们在本文中提供了以下材料：

- 第 7 节我们设计的方法的更多细节。
- 第 8 节计算成本比较。
- 第 9 节可视化结果
- 第 10 节未来工作

7. 更多细节

在我们提出的方法中，我们采用 NAFNet [6] 作为去噪网络的主干。NAFNet 是一个非常简单但高效的基础模型，用于图像恢复任务。我们基于其原始设置将其应用于视频恢复任务。具体来说，通过将宽度增加到 64，NAFNet 的块数增加到 44 来对其进行扩展。每个块中均集成了由 SimpleGate 和一个线性层组成的额外 MLP 层，用于时间嵌入，如图 7 所示。

8. 计算成本比较

在本节中，我们展示了我们的速度优势相对于基于扩散的恢复方法。我们在 RTX4090 GPU 上执行所有推理阶段以确保公平比较。在 5 帧、 256×256 块大小的视频片段上显示 FLOPs 和运行时间的结果在表 4 中。这表明我们的方法在加入自适应机制后实现了更优的模型复杂度和运行时间性能，同时获得了有前景的恢复性能。

9. 更多可视化结果

我们在合成数据集和真实数据集上与最先进方法进行了更多的视觉比较，以展示 Diff-TTA 在去除任意恶劣天气条件方面的出色视觉性能和泛化能力。连续帧的恢复结果也显示在补充视频中。在已见数据集上的视觉比较。我们提供了 Diff-TTA 与 SOTA 方法之间的更多定性比较。结果如图 8 所示。Diff-TTA 通过去除不良成分和恢复更多背景细节实现了最佳视觉质量。在未见数据集上的视觉比较。我们提供了 Diff-TTA 与 SOTA 方法之间的定性比较。结果如图 9、10 所示。




图 7。去噪 NAFNet 模块的详细结构。

表 4。在 5 帧视频片段（ 256×256 块大小）上的 FLOPs 和运行时间比较。

方法	IR-SDE [30]	Refusion [31]	WeatherDiffusion [34]	Diff-TTA(我们)	FLOPs/G	1896.67 $\times$ 100 步	372.38 $\times$ 100 步
	1242.01 $\times$ 1000 步	385.14 $\times$ 25 步	运行时间/s 23.42	12.55	542.76	6.01	

我们的 Diff-TTA 通过移除未知的不良成分和恢复更多背景细节，实现了最佳视觉效果。在真实世界数据上的可视化比较。我们提供了我们 Diff-TTA 与 SOTA 方法之间的更多定性比较。结果如图 11 所示。我们的 Diff-TTA 通过移除未知的不良成分和恢复更多背景细节，进一步验证了其泛化能力。

10. 未来工作

在未来，我们计划进一步加速 Diff-TTA 的推理速度，以用于实时应用。此外，我们将测试时适应应用于其他恢复任务。








图 8。更多关于已见天气状况的视觉比较。




TransWeather TKL WeatherDiffusion





ViWS-Net 我们 GT




TransWeather TKL WeatherDiffusion





ViWS-Net Ours GT




TransWeather TKL WeatherDiffusion



ViWS-Net Ours GT 图 9。更多关于未见过天气状况的可视化比较。



TransWeather TKL WeatherDiffusion



ViWS-Net 我们 GT




TransWeather TKL WeatherDiffusion





ViWS-Net 我们 GT




TransWeather TKL WeatherDiffusion





ViWS-Net 我们 GT 图 10。更多关于未见天气条件的视觉比较。



转换天气 TKL
ViWS-Net 我们



转换天气 TKL
ViWS-Net 我们



转换天气 TKL
ViWS-Net 我们

ViWS-Net 我们 图 11。更多关于真实场景的视觉比较。