

基于天气信使和对抗反向传播的视频恶劣天气成分抑制网络

Yijun Yang^{1,2}, Angelica I. Aviles-Rivero³, Huazhu Fu⁴, Ye Liu⁵, Weiming Wang⁶, Lei Zhu^{1,2†}

¹香港科技大学 (广州)

²香港科技大学 ³剑桥大学

⁴新加坡科技研究局高性能计算研究所

⁵天津大学 ⁶香港都会大学

摘要

尽管卷积神经网络(CNN)已被提出用于使用一组预训练权重去除单张图像中的恶劣天气条件,但由于缺乏时间信息,它们无法恢复恶劣天气视频。此外,现有的从视频中去除恶劣天气条件(例如雨、雾和雪)的方法只能处理一种恶劣天气。在本工作中,我们提出了首个通过开发视频恶劣天气成分抑制网络(ViWS-Net)来从所有恶劣天气条件下恢复视频的框架。为实现这一目标,我们首先设计了一个具有多个转换器阶段的与天气无关的视频转换器编码器。此外,我们设计了一种长短期时间建模机制作为天气信使,以早期融合输入的相邻视频帧并学习特定天气的信息。我们还引入了一个带有梯度反转的天气判别器,通过对抗性预测天气类型来保持天气不变的通用信息并抑制像素特征中的特定天气信息。最后,我们开发了一种基于消息传递的视频转换器解码器,用于检索残差天气特定特征,该特征与分层像素特征进行时空聚合,并加以细化以预测输入视频的清晰目标帧。在基准数据集和真实世界的天气视频上的实验结果表明,我们的 ViWS-Net 在恢复受任何天气条件影响而退化的视频方面优于当前最先进的方

例如自动驾驶和交通监控等系统,会因环境能见度降低以及图像/视频内容受损而受到影响。消除这些恶劣天气的影响是一项具有挑战性但前景广阔的任务。尽管已经提出了许多视频去雾/去雨/去雪的方法,但它们主要针对一种天气退化情况。由于需要针对所有恶劣天气条件使用多个模型和权重集,导致内存和计算成本高昂,因此不适合实时系统。此外,系统还必须在一系列天气消除算法之间切换,这使得处理流程更加复杂,对于实时系统来说实用性更低。

最近,李等人[18]提出了一种“万能”恶劣天气去除网络,能够从图像中去除任何天气状况,这是首个为恶劣天气去除提供通用解决方案的算法。在此问题设定的基础上,已开发出几种单图像多恶劣天气去除方法[8, 38],通过单个编码器和单个解码器的一个模型实例来消除退化效应。尽管单图像多恶劣天气去除任务已取得显著进展,但我们认为,利用相邻帧的时间冗余来减少恢复任务中固有的不稳定性,视频级算法能够取得更好的效果。

因此,能够将图像级算法转换为视频级算法的通用框架具有极高的价值。然而,有两个瓶颈需要解决: 1) 如何有效地保持视频帧间背景细节的时序一致性; 2) 如何防止多种天气因素在视频帧间造成干扰。

为解决上述瓶颈问题,我们提出了视频逆天气成分抑制网络(ViWS-Net),这是首个仅通过一组参数就能消除所有恶劣天气状况的视频级算法。

1. 简介

恶劣天气状况(包括雨、雾和雪)常常会降低户外视觉系统的性能。

† Lei Zhu (leizhu@ust.hk) is the corresponding author.

预训练权重。具体而言，我们引入了“时间活跃天气信使”标记，以学习视频帧间特定天气的信息，并在我们基于信使的视频转换器解码器中检索这些信息。我们还设计了一种长短期时间建模机制，用于天气信使标记，以实现帧间的早期融合，并支持不同时间跨度的时间依赖关系的恢复。为了抑制多种恶劣天气条件对背景恢复的负面影响，我们通过引入天气判别器开发了一种天气抑制对抗学习方法。在视频转换器编码器和判别器之间采用对抗反向传播，通过梯度反转来保持共同的背景信息，同时抑制分层像素特征中的特定天气信息。由于目前没有公开的视频去雪数据集，我们基于 KITTI [22] 合成了首个视频级雪数据集，命名为 KITTI-snow。我们在视频去雨、去雾和去雪的基准数据集上进行了大量实验，包括 RainMotion [39]、REVIDE [49] 和 KITTI-snow，以及一些真实世界的天气视频，以验证我们框架在视频多类恶劣天气去除方面的有效性和泛化能力。我们的贡献可总结如下：

我们提出了一种新颖的统一框架 ViWS-Net，它能够利用一组预训练的权重解决从多种不良天气退化中恢复视频帧的问题。

我们引入了具有时间活跃性的天气信使令牌，它能够实现早期的时间融合，并有助于提取特定天气的残余信息，从而实现对天气干扰的一致性去除。

我们设计了一种天气抑制对抗学习方法，该方法能保留不受天气影响的背景信息，同时抑制特定天气的信息，从而防止因各种天气类型造成的干扰而恢复信息。

为了在多种恶劣天气条件下评估我们的框架，我们合成了一套视频级别的雪天数据集 KITTI-snow。我们在三个基准数据集和真实世界视频上进行的大量实验表明，ViWS-Net 具有有效性和泛化能力。我们的代码可在 <https://github.com/scott-yjyang/ViWS-Net> 公开获取。

2. 相关工作

视频单天气去除。我们简要介绍不同的视频单天气去除方法。对于视频去雨，Garg 和 Nayar 首先对视频雨进行了建模，并基于雨条纹的光度外观开发了

一种雨检测器[12, 13]。受这些开创性工作的启发，在过去几十年中提出了许多专注于手工制作的先验知识的方法[1-4, 25, 34, 50]。最近，深度神经网络也被用于这一研究方向[5, 17, 23, 39, 42-45]。杨等人[43]构建了一个两阶段循环网络，利用双层正则化进行视频去雨。王等人[39]设计了一种新的视频雨模型，考虑了雨条纹的运动，从而更准确地对视频中的雨条纹层进行建模。对于视频去雾，引入了各种方法[15, 20, 47]以生成更准确的去雾结果。例如，随着深度学习的发展，任等人[33]提出了一个合成视频去雾数据集，并开发了一种深度学习解决方案，以跨帧累积信息进行透射率估计。为突破现实世界中雾霾场景表现不佳的局限，张等人[49]开发了一套视频采集系统，能够从现实场景中获取有雾视频及其对应的无雾视频。在此基础上，刘等人[27]提出了一种基于相位的记忆网络，该网络将当前帧的颜色和相位信息与过去连续帧的信息进行整合。对于除雪，尽管大多数现有的基于学习的方法[6, 7, 48]专注于单幅图像的除雪，但尚未有研究利用时间信息探索视频除雪的更好解决方案。我们提出了一种新颖的方法来应对视频中不良天气影响去除的挑战。与以往的方法不同，我们采用了一个统一的单编码器单解码器网络，能够使用单个模型实例处理各种不良天气状况。

单幅图像多不良天气去除。最近，一批研究人员对单模型实例完成单幅图像多不良天气去除任务进行了研究。李等人[18]开发了一种基于单个网络的方法All-in-One，该方法具有多个针对特定任务的编码器和基于神经架构搜索（NAS）架构的通用解码器。它仅根据退化类型将损失反向传播到相应的特征编码器。TransWeather [38] 提出了一种基于变压器的端到端网络，仅包含一个编码器和一个解码器。它在变压器编码器中引入了块内补丁变压器块，以实现较小的天气去除效果。它还利用了带有从头开始学习的天气类型嵌入的变压器解码器，以适应不同的天气类型。陈等人[8]提出了一种两阶段知识蒸馏机制，将针对多种不良天气类型训练良好的多个教师模型的特定天气知识转移到一个学生模型中。我们的研究关注视频中的多不良天气去除问题。然而，上述所有方法都未能从时间空间中捕获互补信息。尽管我们可以对其进行概括，以逐帧消除不利的天气影响




图 1. 我们用于视频多类恶劣天气去除的 ViWS-Net 框架概述。对于给定的一系列视频帧，我们将帧划分为补丁标记，并将其与相应的天气信使标记连接起来作为输入。天气信使在时间上收集特定天气的信息，而与天气无关的视频转换器编码器执行特征提取并生成分层像素特征。同时，通过梯度反转层对抗性地学习天气判别器，以保持天气不变的信息并抑制特定天气的信息。对于每一帧，由信使驱动的视频转换器解码器利用最后一个像素特征 f^{N_s} 作为键和值，将学习良好的天气信使标记 m^{N_s} 作为查询来检索特定天气的特征 r 。最后，将特定天气的特征 r 与分层像素特征 $\{f_i\}_{N_s}$ 聚合在一起。

1 等于 1

在空间和时间轴上进行处理，然后通过一个细化网络来获取最终的清晰目标帧 $\hat{I}_t$ 。

视频帧之间的动作方式和时间信息使我们的方法比那些基于图像的方法表现得更好。

对抗学习。近年来，深度学习因其能够学习非线性特征而广受欢迎，这使得学习适用于多种任务的不变特征变得更加容易。受生成对抗网络[14]的启发，对抗学习已被应用于自然语言处理，以学习多任务学习的通用特征表示，如[24, 28, 36]所示。这些对抗多任务模型由三个网络组成：特征编码器网络、解码器网络和领域网络。解码器网络基于特征编码器网络最小化所有任务的训练损失，而领域网络则区分给定数据实例所属的任务。这种学习范式也被用于解决领域偏移问题[11, 19, 30, 35, 37]，以学习领域不变的信息。受这些工作的启发，我们进一步通过对抗学习范式探索视频中多种恶劣天气的通用特征表示。

3. 方法

在这项工作中，我们的目标是设计出首个视频级别的统一模型，仅使用一组模型参数就能消除帧中多种类型的恶劣天气。我们将恶劣天气消除的端到端公式化表述为：

$$\hat{I}_t = \mathcal{D}(\mathcal{E}(\mathbf{V}_i^q)), \quad \mathbf{V} = \{I_{t-n}, \dots, I_{t-1}, I_t, I_{t+1}, \dots, I_{t+n}\}, \quad (1)$$

其中， $\mathbf{V}_i^q$ 是受第 q 种天气类型影响而退化的第 i 个视频片段，包含 $T = 2n + 1$ 帧， $\hat{I}_t$ 表示恢复的目标帧。与标准的图像级方法 All-in-One [18] 不同，我们的 ViWS-Net 通过一个视频变换编码器 $\mathcal{E}(\cdot)$ 和一个视频变换解码器 $\mathcal{D}(\cdot)$ 更高效地解决了多种恶劣天气问题。接下来，我们将详细阐述我们针对视频多种恶劣天气去除任务的解决方案。

3.1. 总体架构

我们的 ViWS-Net 的整体架构如图 1 所示，它由一个与天气无关的视频转换模块组成。




图 2. 我们长短期时间建模机制的示意图。此机制在变压器编码器的每个阶段都会反复应用。

ViWS-Net 由一个前编码器、一个基于消息传递的视频转换器解码器和一个天气判别器组成。不失一般性，我们基于分流变压器 [32] 构建 ViWS-Net，该变压器由分流自注意力（SSA）和细节特定前馈层（DSF）组成。SSA 将 PVT [40] 中的空间缩减注意力扩展到通过多尺度标记聚合在单个自注意力层内统一多尺度特征提取。DSF 通过在前馈层的两个全连接层之间插入一个深度卷积层来增强局部细节。

给定一个由 $T = 2n + 1$ 帧组成的视频片段序列 $\{I_{t-n}, \dots, I_{t-1}, I_t, I_{t+1}, \dots, I_{t+n}\}$ ，其受到 q 级恶劣天气的影响，我们的变压器编码器执行特征提取并生成分层像素特征，同时天气信使标记在时间轴上进行早期融合的长短期时间建模。带有梯度反转层的天气判别器通过预测视频片段的天气类型进行对抗学习，以保持天气不变的背景信息并抑制像素特征中的天气特定信息。由信使驱动的视频变压器解码器使用在编码过程中良好学习到的时间活跃天气信使初始化天气类型查询，从被抑制的像素特征中检索残余的天气特定信息。最后，分层像素特征和天气特定特征在时空上进行整合和细化，以重建干净的目标帧。在实践中，我们设置 $n = 2$ ，以在性能和计算成本之间取得良好的平衡。

3.2. 时效性天气信息推送使者

先前的单幅图像多不良天气去除工作 [38] 在解码器的变换器中采用固定数量的可学习嵌入来从像素特征中查询特定天气特征，称为天气类型查询。然而，由于随机初始化的限制，它们在解码过程中难以提取出稳健的特定天气信息。此外，这些查询嵌入在各帧之间独立学习，导致在视频场景中缺乏时间信息。为了解决这些局限性，我们在视频变换器编码器中引入了天气信使，并将学习良好的天气信使用作天气类型查询。

具体而言，为每一帧引入一组大小为 $M \times C$ 的可学习嵌入作为天气信使标记，记为 $\{m_i^0\}_{Ti=1} \in \mathbb{R}^T \times M \times C$ 。将分辨率为 $H \times W$ 的视频片段划分并投影为 $T \times HW$ 。

$\bigwedge_p$ 乘以 $2 \times C$ 的重叠补丁嵌入逐帧进行，其中 P 和 C 分别表示补丁大小和通道维度。然后，我们将每一帧的补丁嵌入与相应的天气信使标记进行拼接，再输入到视频变换器编码器中：

$$\{[f_i^0, m_i^0]\}_{i=1}^T \in \mathbb{R}^{T \times (\frac{HW}{P^2} + M) \times C}. \quad (2)$$

联合标记 $\{[f_i^0, m_i^0]\}_{Ti=1}$ 作为变压器编码器第一阶段的输入。我们的视频变压器编码器有 $N_s = 4$ 个阶段，每个阶段由若干个 SSA 和 DSF 块组成。第 1 阶段的联合标记学习为：

$$\{[f_i^l, m_i^l]\}_{i=1}^T = \{DSF^l(SSA^l([f_i^{l-1}, m_i^{l-1}]))\}_{i=1}^T. \quad (3)$$

我们的天气信使在每个阶段的帧块之间临时活跃，以从像素特征中收集特定天气信息。为了进一步探索目标帧不同跨度的时间依赖性，我们采用了一种长短期时间建模机制，如图 2 所示。将一帧的天气信使标记分为 6 组，并沿时间轴以不同的时间步长（0 - 2）和方向（向前或向后）进行移位，随后进行逆操作（移位回）。对于目标帧 I_t ，前 3 组通过将相邻帧 $\{I_{t-1}, I_{t+1}\}$ 的信使标记移位一个时间步长来建模短期依赖性，而后 3 组通过将相邻帧 $\{I_{t-2}, I_{t+2}\}$ 的信使标记移位两个时间步长来建模长期依赖性。不同跨度的时间依赖性使目标帧的恢复能够从过去和未来的帧中获得全面的特定天气信息参考。

3.3. 天气抑制对抗学习

为了构建一个不受天气影响的变压器编码器，受领域适应 [11] 的启发，我们设计了天气抑制对抗学习，以学习一个优秀的特征空间，该空间能保持与天气无关的背景信息，并抑制特定天气的信息。为此，我们通过对抗反向传播优化了一个天气判别器，用于对天气类型进行分类。

值得注意的是，在视频转换器编码器和天气判别器之间插入了一个梯度反转层（GRL）。在反向传播过程中，GRL 从天气判别器获取梯度，将其乘以 $-\lambda$ 并传递给转换器编码器。为了预测视频片段的天气类型，我们通过计算注意力机制来整合一个视频片段中所有帧的信息。

我们对其向量表示进行加权平均。通过使用 S 型函数应用门控注意力机制，提供一种可学习的非线性，从而增加模型的灵活性。对每一帧计算一个注意力得分 α_i ，计算方式如下：

$$\alpha_i = \frac{\exp\{\mathbf{w}_1^T(\tanh(\mathbf{w}_2\mathbf{v}_i^T) \cdot \text{sigm}(\mathbf{w}_3\mathbf{v}_i^T))\}}{\sum_{k=1}^T \exp\{\mathbf{w}_1^T(\tanh(\mathbf{w}_2\mathbf{v}_k^T) \cdot \text{sigm}(\mathbf{w}_3\mathbf{v}_k^T))\}}, \quad (4)$$

其中 $\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3$ 是可学习的参数。此过程会产生一个加权融合的向量表示，其形式为：

$$\mathbf{v} = \sum_{i=1}^T \alpha_i \mathbf{v}_i, \quad (5)$$

其中 $\mathbf{v}_i$ 是来自第 i 帧特征嵌入的向量表示。最终通过一个全连接层从融合向量中获得天气类型。虽然天气判别器 $\mathbf{w}(\cdot)$ 力求对天气类型做出准确预测，但视频变换器编码器则致力于生成与天气无关的像素特征。因此，可以通过最小-最大优化来实现对抗损失，如下所示：

$$\mathcal{L}_{adv} = \min_{\theta_w} \left(\lambda \max_{\theta_\varepsilon} \left(\sum_{q=1}^Q \sum_{i=1}^{N_q} q \log[\mathcal{W}(\mathcal{E}(\mathbf{V}_i^q))] \right) \right). \quad (6)$$

我们的天气抑制对抗学习基于这样一个基本理念：在转换器编码器的分层像素特征中，通过弱化天气类型的区分来抑制特定天气的信息。这保护了目标帧不受不同天气类型的干扰，从而使模型专注于与天气无关的背景信息。在训练阶段，应用天气抑制对抗学习，使视频转换器编码器具备不受天气影响的特性。在推理阶段，仅将视频帧输入到视频转换器编码器和解码器中以去除天气影响。

3.4. 基于 Messenger 的视频转换器解码器

直观来看，尽管天气抑制对抗学习在很大程度上阻碍了特定天气信息的出现，但当对抗损失达到鞍点时，像素特征中仍可能存在残余的特定天气信息。为了定位来自残余特定天气信息的干扰，我们设计了由信使驱动的视频变换器解码器，以检索此类信息，并利用第 3.2 节中描述的时序活跃天气信使从分层特征中恢复帧。首先，我们采用训练良好的天气信使 $\{\mathbf{mNS}_i\}_{i=1}^T$ 进行查询。残余的特定天气信息。在经过基于长短时序的 Transformer 编码器建模后，天气信使能够利用丰富的时序信息，在像素特征中定位出更多真实的恶劣天气情况，这比独立学习的查询嵌入要更有效。

表 1. 这是我们的视频多类恶劣天气去除算法在 RainMotion、REVIDE 和 KITTI-snow 数据集上的统计数据。混合训练集由这三个数据集的训练集组成。

天气	数据集	分裂	视频编号	视频长度	视频帧数
雨	雨动	火车	40	50	2000
		测试	40	20	800
霾	REVIDE 无准确标注的中文词汇，原词输出	火车	42	7-34	928
		测试	6	20-31	154
雪	KITTI-雪地数据集	火车	35	50	1750
		测试	15	50	750

[38]. 以像素特征 $\{\mathbf{f}_i^{N_s}\}_{i=1}^T$ 作为键值，Transformer 解码器生成特定天气特征 $\{\mathbf{r}_i\}_{i=1}^T$ 。请注意，此处的 Transformer 解码器仅运行在一个阶段，但包含多个块，这些块与 Transformer 编码器的阶段类似。如图 1 所示，特定天气特征在卷积投影块中逐帧与分层像素特征进行空间整合，该块由上采样层和 2D 卷积残差层成对组成。为了恢复背景细节，我们从原始帧中减去输出。之后，我们将帧的输出进行拼接，并将其输入到由三个连续的 3D 卷积层组成的时域融合块中，以实现时域整合。最后，我们通过应用一个精炼网络（这是我们的 ViWS-Net 的一个简单且小得多的版本）来处理初始恢复结果中存在细微瑕疵的部分，从而获得干净的目标帧 $\hat{\mathbf{I}}_t$ 。

监督目标函数由平滑的 L1 损失和感知损失组成，具体如下：

$$\mathcal{L}_S = \mathcal{L}_{smoothL_1} + \gamma_1 \mathcal{L}_{perceptual}, \text{ with} \quad (7)$$

$$\mathcal{L}_{smoothL_1} = \begin{cases} 0.5(\hat{I}_t - B_t)^2, & \text{if } |\hat{I}_t - B_t| < 1 \\ |\hat{I}_t - B_t| - 0.5, & \text{otherwise,} \end{cases} \quad (8)$$

$$\mathcal{L}_{perceptual} = \mathcal{L}_{mse}(VGG_{3,8,15}(\hat{I}_t), VGG_{3,8,15}(B_t)), \quad (9)$$

其中 $\hat{\mathbf{I}}_t$ 和 B_t 分别表示目标帧的预测值和真实值。整体目标函数由监督损失和对抗损失组成，可定义如下：

$$\mathcal{L}_{total} = \mathcal{L}_S + \gamma_2 \mathcal{L}_{adv}, \quad (10)$$

其中， γ_1 和 γ_2 是平衡超参数，分别经验性地设置为 0.04 和 0.001。

4. 实验

在本节中，我们将详细描述为验证我们所提出的方法而开展的一系列实验。

4.1. 数据集

在我们的实验中使用了多种视频恶劣天气数据集。表 1 总结了我们的视频多类恶劣天气数据集的信息。RainMotion [39]

表 2. 视频多种恶劣天气去除的定量评估。对于“原天气”，这些方法在特定天气的训练集上进行训练，并在特定天气的测试集上进行测试。对于“雨”、“雾”和“雪”，这些方法在混合训练集上进行训练，并在特定天气的测试集上进行测试。在“雨”、“雾”和“雪”上计算平均性能。采用峰值信噪比（PSNR）和结构相似性指数（SSIM）作为我们的评估指标。最高值以红色标注。

方法		类型	来源	数据集							
				原天气	雨		雾		雪		平均的
德雷恩	PReNet [31]	图像	CVPR'19 (计算机视觉与模式识别会议 2019)	26.80	0.8814	17.64	0.8030	28.57	0.9401	24.34	0.8748
	SLDNet [44]	视频	CVPR 2020	20.31	0.6272	21.24	0.7129	16.21	0.7561	22.01	0.8550
	S2VD [45]	视频	CVPR'21	24.09	0.7944	28.39	0.9006	19.65	0.8607	26.23	0.9190
	RDD-Net [39]	视频	ECCV 202	31.82	0.9423	30.34	0.9300	18.36	0.8432	30.40	0.9560
去雾	GDN [26]	图像	ICCV'19 (国际计算机视觉大会 2019)	29.96	0.9370	19.01	0.8805	31.02	0.9518	26.66	0.9231
	MSBDN [10]	图像	CVPR 2020	22.01	0.8759	26.70	0.9146	22.24	0.9047	27.07	0.9340
	VDHNet [33]	视频	TIP'19	16.64	0.8133	29.87	0.9272	16.85	0.8214	29.53	0.9395
	PM-Net [27]	视频	MM'2	23.83	0.8950	25.79	0.8880	23.57	0.9143	18.71	0.7881
除雪	DesnowNet [29]	图像	TIP'18	28.30	0.9530	25.19	0.8786	16.43	0.7902	27.56	0.9181
	DDMSNET [48]	图像	TIP'21	32.55	0.9613	29.01	0.9188	19.50	0.8615	32.43	0.9694
	HDCW-Net [7]	图像	ICCV'21 (国际计算机视觉大会 2021)	28.10	0.9055	28.10	0.9055	17.36	0.7921	31.05	0.9482
	SMGARN [9]	图像	TCSVT'2	33.24	0.9721	27.78	0.9100	17.85	0.8075	32.34	0.9668
修复	MPRNet [46]	图像	CVPR'21	—	—	28.22	0.9165	20.25	0.8934	30.95	0.9482
	EDVR [41]	视频	CVPR'19 (计算机视觉与模式识别会议 2019)	31.10	0.9371	31.10	0.9371	19.67	0.8724	30.27	0.9440
	RVRT [21]	视频	NIPS'2	—	—	30.11	0.9132	21.16	0.8949	26.78	0.8834
	RTA [51]	视频	CVPR 202	—	—	30.12	0.9186	20.75	0.8915	29.79	0.9367
一体化 [18]		图像	CVPR 2020	—	—	26.62	0.8948	20.88	0.9010	30.09	0.9431
UVRNet [16]		图像	TMM'2	—	—	22.31	0.7678	20.82	0.8575	24.71	0.8873
TransWeather [38]		图像	CVPR 202	—	—	26.82	0.9118	22.17	0.9025	28.87	0.9313
TKL [8]		图像	CVPR'2	—	—	26.73	0.8935	22.08	0.9044	31.35	0.9515
我们的		视频	—	—	—	31.52	0.9433	24.51	0.9187	31.49	0.9562
										29.17	0.9394

这是基于 NTURain [5] 合成的最新视频去雨数据集，它包含五个大的雨痕掩码，使得去除雨痕更具挑战性。REVIDE [49] 是首个具有高保真度真实雾天条件的室内场景真实世界视频去雾数据集。据我们所知，目前还没有公开的视频级雪数据集。因此，我们构建了自己的视频去雪数据集，名为 KITTI-snow。KITTI-snow 的详情如下。在训练阶段，我们将这三个数据集的训练集合并，以学习一个统一的模型。在测试阶段，我们分别在三个测试集上评估我们的模型。

KITTI-snow：我们创建了一个名为 KITTI-snow 的合成户外数据集，其中包含 50 个视频，总计 2500 帧，所有视频均呈现雪景。具体而言，我们从 KITTI [22] 中随机选取了两组视频。第一组包含 35 个视频，用作训练集；第二组包含 15 个视频，用作测试集。对于每个原始视频，我们根据 Photoshop 的雪花合成教程，合成具有不同属性（即透明度、大小和位置）的雪花。为了更好地模拟真实的雪景，对雪花颗粒应用了高斯模糊。为了模拟时间一致性，我们在同一视频的不同帧中，从相同的分布中采样雪花的位置、大小和模糊程度。视频帧的空间分辨率为 1000×300。图 3 展示了我们合成数据集中五个具有不同分布的视频的示例帧。



图 3. KITTI-snow 中五个合成视频的示例帧。每个视频中的雪花均从不同的分布中采样。

4.2. 实施细节

关于训练细节，所提出的框架在两块 NVIDIA RTX 3090 GPU 上进行训练，并在 Pytorch 平台上实现。我们的框架以端到端的方式进行了 500 轮的实验性训练，并应用了 Adam 优化器。初始学习率设为 2×10^{-4} ，每 100 轮衰减 50%。我们将视频帧随机裁剪为 224×224。我们实验性地将 n 设为 2，这意味着我们的网络为每个视频片段接收 5 帧。每次将由三种天气类型（即雨、雾、雪）均匀组成的 12 个视频片段批次输入网络。

关于方法细节，每帧的天气信使标记数 M 设定为 48。为了在早期抑制来自天气判别器的噪声信号




图 4.针对不同任务设计的最佳算法之间的定性比较。分别选取了在雨、雾、雪等恶劣天气影响下的示例帧，展示其处理结果。颜色框内显示了对恶劣天气去除效果的详细对比。




图 5. 不同多重恶劣天气去除方法在分别受雨、雾、雪影响的三个真实世界视频序列上的视觉对比。彩色方框显示了放大视图，突出了天气去除效果的详细对比。显然，我们的网络比最先进的方法能更有效地去除输入视频帧中的雨痕、雾气和雪花。

在训练过程的各个阶段，我们按照以下时间表将适应因子 λ 从 0 逐渐增加到 1:

$$\lambda = \frac{2}{1 + \exp(-10 \cdot p)} - 1, \quad (11)$$

其中 p 是当前迭代次数除以总迭代次数。

表 3.所选模型与 ViWS-Net 之间计算复杂度的定量比较。最优值以粗体显示。

方法	参数 (M)	每秒浮点运算次数 (百万次/秒)	推理时间 (秒)
TransWeather [38]	24.01	37.68	0.49
TKL [8]	28.71	94.05	0.51
EDVR [41]	20.70	335.27	0.63
ViWS-Net (我们的成果)	57.82	68.72	0.46

4.3. 定量评估

比较方法。如表 2 所示，我们在混合数据集上将所提出的方法与五种最先进的方法进行了比较。对于去雨，我们将我们的方法与一种单图像方法 PReNet [31] 以及三种视频方法 SLDNet [44]、S2VD [45]、RDD-Net [39] 进行了比较。对于去雾，我们与两种单图像方法 GDN [26]、MSBDN [10] 以及两种视频方法 VDHNet [33]、PM-Net [27] 进行了比较。对于去雪，我们与四种单图像方法 DesnowNet [29]、DDMSNET [48]、HDCW-Net [7]、SMGARN [9] 进行了比较。对于图像修复，我们将我们的方法与一种单图像方法 MPRNet [46] 以及三种视频方法 EDVR [41]、RVRT [21]、RTA [51] 进行了比较。对于多种恶劣天气去除，我们与最新的四种单图像方法 All-in-one [18]、UVRNet [16]、TransWeather [38]、TKL [8] 进行了比较。

多恶劣天气去除分析。为了对恢复结果进行定量评估，我们采用峰值信噪比 (PSNR) 和结构相似性 (SSIM) 作为衡量标准。对于单恶劣天气去除模型 (去雨、去雾、去雪)，报告了两种类型的结果: (i) 在各自原始天气条件下训练的模型 (即单恶劣天气训练集); (ii) 在多种恶劣天气条件下训练的模型。

表 4.在所提出的框架中，针对三种天气类型对每个关键模块进行消融研究。最大值以粗体字标出。“WS. Adv.” 表示天气抑制对抗学习。

组合	模块			数据集							
	天气信使	视频解码器	WS. 高级版	雨		霾		雪		平均的	
M1	-	-	-	26.92	0.9273	22.77	0.9052	29.94	0.9462	26.54	0.9262
M2	✓	-	-	30.03	0.9327	23.92	0.9149	30.54	0.9520	28.16	0.9332
M3	-	✓	-	29.33	0.9365	22.84	0.9085	30.89	0.9554	27.69	0.9335
M4	-	-	✓	29.70	0.9316	23.87	0.9152	30.82	0.9521	28.13	0.9330
M5	✓	✓	-	31.00	0.9419	24.13	0.9164	30.93	0.9552	28.69	0.9378
我们的	✓	✓	✓	31.52	0.9433	24.51	0.9187	31.49	0.9562	29.17	0.9394

表 5. 所提出的信使驱动视频变压器解码器的消融研究。最大值以粗体显示。

模块		平均的	
时间融合	RefineNet	峰值信噪比	SSIM
-	-	28.37	0.9305
✓	-	28.80	0.9357
✓	✓	29.17	0.9394

在所有天气类型的数据上（即混合训练集）进行训练。对于恢复和多不良天气去除模型，仅报告在混合训练集上训练的模型的结果。为了公平比较，我们基于我们的训练数据集重新训练了每个由官方代码实现的对比模型，并报告了最佳结果。可以看出，当在多种天气类型上进行训练时，我们的方法在 PSNR 和 SSIM 上分别以 2.16 和 0.0216 的显著优势取得了最佳平均性能，优于第二好的方法 EDVR [41]。尽管在单种天气数据上训练时，我们的方法可能不如单种天气去除方法，但这些方法在面对多种不良天气条件时通常会失效。例如，去雨方法 RDD-Net [39] 无法去除雾的退化，而去雾方法 PM-Net [27] 和去雪方法 DDMSNET [48] 在雪和雾去除方面表现不佳。此外，还可以观察到，DDMSNET [48] 和 SMGARN [9] 在融合了雪的专用模块后，在多种天气类型上训练时仍能取得不错的去雪效果。然而，这些方法难以应对诸如雾霾之类的其他退化现象，导致在多天气环境下的图像修复平均性能较低。与现有方法不同，我们的方法仅依靠统一的架构和一组预训练的权重，就能在所有天气类型中实现一致的性能。

计算复杂度分析。我们通过将一段 5 帧、分辨率为 224×224 的视频片段输入到我们的模型和其他代表性模型中，来评估计算复杂度（训练参数数量、浮点运算次数、推理时间）。我们的 ViWS-Net 在保持与其他方法相当的计算复杂度的同

时，在多恶劣天气去除方面取得了最佳效果。

4.4. 定性评估

在我们的数据集上的结果。为了更好地说明我们 ViWS-Net 的有效性，图 4 展示了在雨、雾和雪这三种天气场景下，我们的方法与 5 种最先进的方法的视觉对比，这 5 种方法分别是各自方法组中平均性能最佳的方法。显然，可以注意到我们的方法在每种天气类型下的视觉质量都能取得令人满意的效果。对于雨和雪场景，我们的方法恢复的结果中包含的雨条纹和雪粒比其他方法少。对于雾天场景，我们的方法能去除更多的残留雾气，并且能更好地保留清晰的背景。

真实世界中受损视频的结果。为了评估我们视频多重恶劣天气去除网络的通用性，我们收集了三段真实世界中的受损视频，即一段来自 NTURain* 的雨天视频、一段来自 YouTube 网站的雾天视频和一段雪天视频，并进一步将我们的网络与最先进的多恶劣天气去除方法进行了比较。图 5 展示了我们的网络和两种选定方法在真实世界视频帧上产生的视觉结果。从详细对比中可以明显看出，在所有天气类型中，我们的方法都优于其他方法，能够有效去除恶劣天气并保留背景细节。

4.5. 消融研究

ViWS-Net 中每个模块的有效性。我们评估了所提出的每个模块的有效性，包括时间活跃天气信使、视频解码器和天气抑制对抗学习（WS. Adv.），如表 4 所示。我们报告了在天气特定测试集上测试的结果，该测试集是在混合训练集上训练的。基准模型 M1 由分流变压器编码器和卷积投影解码器组成，在三个恶劣天气数据集上的平均性能分别为 26.54 和 0.9262（PSNR 和 SSIM）。M2 引入了时间活跃天气信使标记

* <https://github.com/hotndy/SPAC-SupplementaryMaterials/>

基于 M1 的 Transformer 编码器使 PSNR 和 SSIM 的平均性能分别提升了 1.62 和 0.0070，这证明了我们提出的长短期时间建模策略的有效性。M3 引入了由天气类型查询驱动的视频 Transformer 解码器（天气类型查询随机初始化），而 M4 则在 M1 的基础上引入了基于天气抑制的对抗学习。M3 和 M4 均显著提升了平均性能。M5 则是在 M2 和 M3 的基础上开发的，其中天气类型查询由训练良好的天气消息标记初始化，从而在 PSNR 和 SSIM 上分别取得了 28.69 和 0.9378 的更好平均性能。我们的完整模型进一步应用了天气抑制对抗学习策略，与 M5 相比，PSNR 和 SSIM 分别提高了 0.48 和 0.0016。

视频解码器中视频转换器的有效性。我们在表 5 中进一步验证了我们精心设计的视频转换器解码器中的时间融合模块和 RefineNet 模块的有效性。我们报告的结果是在混合测试集上测试我们的方法，并在混合训练集上对其进行训练所获得的。值得注意的是，这两个模块都对平均性能有益。

5. 结论

本文提出了 ViWS-Net，这是一种创新方法，采用统一架构和一组预训练权重，同时解决视频帧中多种不利天气条件的问题。我们的方法融合了天气抑制对抗学习，以减轻不同天气状况的不利影响，并采用天气信使来利用丰富的时序信息实现一致的恢复。我们在基准数据集和真实世界视频上对所提出的方法进行了评估，实验结果表明，ViWS-Net 的性能优于最先进的方法。我们还进行了消融研究，以验证每个模块的有效性。

致谢

本研究得到了广州市科技计划项目（项目编号：2023A03J0671）、国家自然科学基金（项目编号：61902275）以及香港都会大学研究资助（编号：RD/2021/09）的支持。

参考文献

- [1] Peter C. Barnum, Srinivasa Narasimhan, and Takeo Kanade. Analysis of rain and snow in frequency space. *International journal of computer vision*, 86(2):256–274, 2010. [2](#)
- [2] Jérémie Bossu, Nicolas Hautiere, and Jean-Philippe Tarel. Rain or snow detection in image sequences through use of a histogram of orientation of streaks. *International journal of computer vision*, 93(3):348–367, 2011.
- [3] Nathan Brewer and Nianjun Liu. Using the shape characteristics of rain to identify and remove rain from video. In *Joint IAPR International Workshops on Statistical Techniques in Pattern Recognition (SPR) and Structural and Syntactic Pattern Recognition (SSPR)*, pages 451–458. Springer, 2008.
- [4] Jie Chen and Lap-Pui Chau. A rain pixel recovery algorithm for videos with highly dynamic scenes. *IEEE transactions on image processing*, 23(3):1097–1104, 2013. [2](#)
- [5] Jie Chen, Cheen-Hau Tan, Junhui Hou, Lap-Pui Chau, and He Li. Robust video content alignment and compensation for rain removal in a cnn framework. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6286–6295, 2018. [2](#), [6](#)
- [6] Wei-Ting Chen, Hao-Yu Fang, Jian-Jiun Ding, Cheng-Che Tsai, and Sy-Yen Kuo. Jstasr: Joint size and transparency-aware snow removal algorithm based on modified partial convolution and veiling effect removal. In *European Conference on Computer Vision*, pages 754–770. Springer, 2020. [2](#)
- [7] Wei-Ting Chen, Hao-Yu Fang, Cheng-Lin Hsieh, Cheng-Che Tsai, I Chen, Jian-Jiun Ding, Sy-Yen Kuo, et al. All snow removed: Single image desnowing algorithm using hierarchical dual-tree complex wavelet representation and contradict channel loss. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4196–4205, 2021. [2](#), [6](#), [7](#)
- [8] Wei-Ting Chen, Zhi-Kai Huang, Cheng-Che Tsai, Hao-Hsiang Yang, Jian-Jiun Ding, and Sy-Yen Kuo. Learning multiple adverse weather removal via two-stage knowledge learning and multi-contrastive regularization: Toward a uni-fied model. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17653–17662, 2022. [1](#), [2](#), [6](#), [7](#)
- [9] Bodong Cheng, Juncheng Li, Ying Chen, Shuyi Zhang, and Tiejiong Zeng. Snow mask guided adaptive residual network for image snow removal. *arXiv preprint arXiv:2207.04754*, 2022. [6](#), [7](#), [8](#)
- [10] Hang Dong, Jinshan Pan, Lei Xiang, Zhe Hu, Xinyi Zhang, Fei Wang, and Ming-Hsuan Yang. Multi-scale boosted dehazing network with dense feature fusion. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 2157–2167, 2020. [6](#), [7](#)
- [11] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation. In *International conference on machine learning*, pages 1180–1189. PMLR, 2015. [3](#), [4](#)
- [12] Kshitiz Garg and Shree K Nayar. Detection and removal of rain from videos. In *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004. CVPR 2004.*, volume 1, pages I–I. IEEE, 2004. [2](#)
- [13] Kshitiz Garg and Shree K Nayar. Photorealistic rendering of rain streaks. *ACM Transactions on Graphics (TOG)*, 25(3):996–1002, 2006. [2](#)
- [14] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks. *Communications of the ACM*, 63(11):139–144, 2020. [3](#)

- [15] Jin-Hwan Kim, Won-Dong Jang, Yongsup Park, Dong-Hahk Lee, Jae-Young Sim, and Chang-Su Kim. Temporally x real-time video dehazing. In *2012 19th IEEE International Conference on Image Processing*, pages 969–972. IEEE, 2012. 2
- [16] Ashutosh Kulkarni, Prashant W Patil, Subrahmanyam Murala, and Sunil Gupta. Unified multi-weather visibility restoration. *IEEE Transactions on Multimedia*, 2022. 6, 7
- [17] Minghan Li, Qi Xie, Qian Zhao, Wei Wei, Shuhang Gu, Jing Tao, and Deyu Meng. Video rain streak removal by mul-tiscale convolutional sparse coding. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6644–6653, 2018. 2
- [18] Ruoteng Li, Robby T Tan, and Loong-Fah Cheong. All in one bad weather removal using architectural search. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 3175–3185, 2020. 1, 2, 3, 6, 7
- [19] Ya Li, Xinmei Tian, Mingming Gong, Yajing Liu, Tongliang Liu, Kun Zhang, and Dacheng Tao. Deep domain generalization via conditional invariant adversarial networks. In *Proceedings of the European Conference on Computer Vi-sion (ECCV)*, pages 624–639, 2018. 3
- [20] Zhuwen Li, Ping Tan, Robby T Tan, Danping Zou, Steven Zhiying Zhou, and Loong-Fah Cheong. Simultaneous video defogging and stereo reconstruction. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4988–4997, 2015. 2
- [21] Jingyun Liang, Yuchen Fan, Xiaoyu Xiang, Rakesh Ranjan, Eddy Ilg, Simon Green, Jiezhong Cao, Kai Zhang, Radu Timofte, and Luc Van Gool. Recurrent video restoration transformer with guided deformable attention. *arXiv preprint arXiv:2206.02146*, 2022. 6, 7
- [22] Yiyi Liao, Jun Xie, and Andreas Geiger. Kitti-360: A novel dataset and benchmarks for urban scene understanding in 2d and 3d. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022. 2, 6
- [23] Jiaying Liu, Wenhan Yang, Shuai Yang, and Zongming Guo. Erase or fill? deep joint recurrent rain removal and recon-struction in videos. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3233–3242, 2018. 2
- [24] Pengfei Liu, Xipeng Qiu, and Xuanjing Huang. Adversarial multi-task learning for text classification. *arXiv preprint arXiv:1704.05742*, 2017. 3
- [25] Peng Liu, Jing Xu, Jiafeng Liu, and Xianglong Tang. Pixel based temporal analysis using chromatic property for removing rain from videos. *Comput. Inf. Sci.*, 2(1):53–60, 2009. 2
- [26] Xiaohong Liu, Yongrui Ma, Zhihao Shi, and Jun Chen. Grid-dehazenet: Attention-based multi-scale network for image dehazing. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 7314–7323, 2019. 6, 7
- [27] Ye Liu, Liang Wan, Huazhu Fu, Jing Qin, and Lei Zhu. Phase-based memory network for video dehazing. In *Proceedings of the 30th ACM International Conference on Multimedia*, pages 5427–5435, 2022. 2, 6, 7, 8
- [28] Yang Liu, Zhaowen Wang, Hailin Jin, and Ian Was-sell. Multi-task adversarial network for disentangled feature learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3743–3751, 2018. 3
- [29] Yun-Fu Liu, Da-Wei Jaw, Shih-Chia Huang, and Jenq-Neng Hwang. Desnownet: Context-aware deep network for snow removal. *IEEE Transactions on Image Processing*, 27(6): 3064–3073, 2018. 6, 7
- [30] Mohammad Mahfujur Rahman, Clinton Fookes, Mahsa Bak-tashmotlagh, and Sridha Sridharan. Correlation-aware adversarial domain adaptation and generalization. *Pattern Recognition*, 100:107124, 2020. 3
- [31] Dongwei Ren, Wangmeng Zuo, Qinghua Hu, Pengfei Zhu, and Deyu Meng. Progressive image deraining networks: A better and simpler baseline. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 3937–3946, 2019. 6, 7
- [32] Sucheng Ren, Daquan Zhou, Shengfeng He, Jiashi Feng, and Xinchao Wang. Shunted self-attention via multi-scale token aggregation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10853–10862, 2022. 4
- [33] Wenqi Ren, Jingang Zhang, Xiangyu Xu, Lin Ma, Xiaochun Cao, Gaofeng Meng, and Wei Liu. Deep video dehazing with semantic segmentation. *IEEE transactions on image processing*, 28(4):1895–1908, 2018. 2, 6, 7
- [34] Varun Santhaseelan and Vijayan K Asari. Utilizing local phase information to remove rain from video. *International Journal of Computer Vision*, 112(1):71–89, 2015. 2
- [35] Rui Shao, Xiangyuan Lan, Jiawei Li, and Pong C Yuen. Multi-adversarial discriminative deep domain generalization for face presentation attack detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10023–10031, 2019. 3
- [36] Yusuke Shinohara. Adversarial multi-task learning of deep neural networks for robust speech recognition. In *Inter-speech*, pages 2369–2372. San Francisco, CA, USA, 2016. 3
- [37] Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial discriminative domain adaptation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7167–7176, 2017. 3
- [38] Jeya Maria Jose Valanarasu, Rajeev Yasarla, and Vishal M Patel. Transweather: Transformer-based restoration of images degraded by adverse weather conditions. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2353–2363, 2022. 1, 2, 4, 5, 6, 7
- [39] Shuai Wang, Lei Zhu, Huazhu Fu, Jing Qin, Carola-Bibiane Sch'onlieb, Wei Feng, and Song Wang. Rethinking video rain streak removal: A new synthesis model and a deraining network with video rain prior. In *European Conference on Computer Vision*, pages 565–582. Springer, 2022. 2, 5, 6, 7, 8
- [40] Wenhai Wang, Enze Xie, Xiang Li, Deng-Ping Fan, Kaitao Song, Ding Liang, Tong Lu, Ping Luo, and Ling Shao. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 568–578, 2021. 4
- [41] Xintao Wang, Kelvin CK Chan, Ke Yu, Chao Dong, and

- Chen Change Loy. Edvr: Video restoration with enhanced deformable convolutional networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 0–0, 2019. 6, 7, 8
- [42] Wending Yan, Robby T Tan, Wenhan Yang, and Dengxin Dai. Self-aligned video deraining with transmission-depth consistency. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11966–11976, 2021. 2
- [43] Wenhan Yang, Jiaying Liu, and Jiashi Feng. Frame-consistent recurrent video deraining with dual-level flow. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1661–1670, 2019. 2
- [44] Wenhan Yang, Robby T Tan, Shiqi Wang, and Jiaying Liu. Self-learning video rain streak removal: When cyclic consistency meets temporal correspondence. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1720–1729, 2020. 6, 7
- [45] Zongsheng Yue, Jianwen Xie, Qian Zhao, and Deyu Meng. Semi-supervised video deraining with dynamical rain generator. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 642–652, 2021. 2, 6, 7
- [46] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang, and Ling Shao. Multi-stage progressive image restoration. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 14821–14831, 2021. 6, 7
- [47] Jiawan Zhang, Liang Li, Yi Zhang, Guoqiang Yang, Xiaochun Cao, and Jizhou Sun. Video dehazing with spatial and temporal coherence. *The Visual Computer*, 27(6):749–757, 2011. 2
- [48] Kaihao Zhang, Rongqing Li, Yanjiang Yu, Wenhan Luo, and Changsheng Li. Deep dense multi-scale network for snow removal using semantic and depth priors. *IEEE Transactions on Image Processing*, 30:7419–7431, 2021. 2, 6, 7, 8
- [49] Xinyi Zhang, Hang Dong, Jinshan Pan, Chao Zhu, Ying Tai, Chengjie Wang, Jilin Li, Feiyue Huang, and Fei Wang. Learning to restore hazy video: A new real-world dataset and a new method. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9239–9248, 2021. 2, 6
- [50] Xiaopeng Zhang, Hao Li, Yingyi Qi, Wee Kheng Leow, and Teck Khim Ng. Rain removal in video by combining temporal and chromatic properties. In *2006 IEEE international conference on multimedia and expo*, pages 461–464. IEEE, 2006. 2
- [51] Kun Zhou, Wenbo Li, Liying Lu, Xiaoguang Han, and Jiangbo Lu. Revisiting temporal alignment for video restoration. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 6053–6062, 2022. 6, 7