

ICCV
2023

International Conference on Computer Vision
October 2 - 6, 2023 Paris, France

ICCV23
PARIS

未经制作者许可盗用属于剽窃！仅供参考！

Video Adverse-Weather-Component Suppression Network via Weather Messenger and Adversarial Backpropagation

ViWS-Net: 基于天气信使与对抗反向传播的视频多恶劣天气去除网络

Yijun Yang^{1,2}, Angelica I. Aviles-Rivero³, Huazhu Fu⁴, Ye Liu⁵, Weiming Wang⁶, Lei Zhu^{1,2†}

¹The Hong Kong University of Science and Technology (Guangzhou)

²The Hong Kong University of Science and Technology ³University of Cambridge

⁴Institute of High Performance Computing, Agency for Science, Technology and Research, Singapore

⁵Tianjin University ⁶Hong Kong Metropolitan University

未经制作者许可禁止盗用！！

时间：2025/5/23



ViWS-Net



恶劣天气的影响

- 雨、雾、雪降低户外视觉系统（如自动驾驶）性能
- 现有方法（CNN等）需**多模型处理单一天气**，**计算成本高、实时性差**

现有挑战

- 缺乏时间信息，单图方法无法直接应用
- 单一模型处理多种天气的通用框架缺失

关键问题

现有方法多为“逐帧处理”，忽略相邻帧

- 如何利用时间信息保持背景一致性？
- 如何抑制多天气干扰，保留通用特征？




研究目标


- 构建首个**单模型统一处理视频多恶劣天气**的框架

三大创新



- 时间活跃天气信使**：捕捉跨帧天气特征，实现长短期时间建模
- 天气抑制对抗学习**：通过对抗训练分离天气无关背景与天气特定信息
- 首个视频雪数据集**：合成 KITTI-snow，填补领域空白




天气不可知视频 Transformer 编码器




天气判别器 (对抗学习)



信使驱动视频 Transformer 解码器



输入：视频帧序列 + 天气信使令牌
功能：提取层次化像素特征，通过
长短期时间建模融合相邻帧信息




天气不可知视频
Transformer 编码器


天气判别器（对抗学习）

目标：通过梯度反转层（GRL）
迫使编码器抑制天气特定信息

信使驱动视频
Transformer 解码器



输入：编码器输出特征 + 学习好的天气信使
功能：检索残差天气特征，时空融合后生成清晰帧



Temporally-Active Weather Messenger

时间活跃天气信使

机制设计

- 令牌初始化：可学习嵌入，与图像块嵌入拼接输入编码器
- 长短期时间建模 (Fig.2)
 - 分 6 组移位信使令牌：
 - 3 组建模短期依赖 (± 1 帧)
 - 3 组建模长期依赖 (± 2 帧)
 - 优势：融合多时间跨度信息，提升天气特征捕捉能力




Figure 2. An illustration of our Long Short-term Temporal Modeling mechanism. This mechanism is repeatedly applied at each stage of the transformer encoder.

Long Short-term Temporal Modeling
长短期时序建模

Temporally-Active Weather Messenger

时间活跃天气信使

在视频时间建模中，传统方法常使用LSTM等循环神经网络。但本文选择了Transformer架构结合移位操作，这是为什么呢？

LSTM 的固有局限性（问题本质）

• 长程依赖建模不足

LSTM 的**梯度消失问题**使其难以捕捉超过 5-10 帧的长程依赖（如持续数秒的大雾变化），而 ViWS-Net 的移位操作**可显式建模 ± 2 帧（共 5 帧）的长期依赖**，且通过多层 Transformer 堆叠可扩展至更长序列。

• 并行计算能力差

LSTM 需按时间顺序递推计算，无法并行处理多帧，导致推理速度慢（如处理 5 帧序列需 5 次迭代），而 Transformer 的**自注意力机制**可并行计算所有帧的交互，推理时间仅 0.46s/5 帧，满足实时性需求。

• 多尺度特征融合不足

LSTM 的隐藏状态仅输出单一尺度特征，难以融合图像块的多尺度信息（如细雨的局部细节 vs 暴雨的全局模式），而 ViWS-Net 的 Shunted Transformer 通过**多尺度令牌聚合 (SSA)**，可同时提取不同分辨率特征。

Transformer + 移位操作的优势（方案合理性）

• 显式时间建模与灵活移位

通过**分组移位信使令牌**（短期 ± 1 帧、长期 ± 2 帧），强制模型学习不同时间跨度的依赖关系，避免 LSTM 隐式建模的模糊性。


• 天气特征与背景的解耦能力

Transformer 的**自注意力机制**可显式计算天气信使与图像块的关联度，例如通过注意力权重判断哪些区域属于天气干扰（如雪花区域权重高），而 LSTM 的门控机制难以实现这种细粒度分离。

• 与对抗学习的兼容性

天气抑制对抗学习需要编码器输出“天气不可知”的通用特征，Transformer 的深层特征空间更易通过对抗训练实现**域不变性**，而 LSTM 的循环结构导致特征空间复杂，对抗信号难以有效传递。

长程时间建模能力
多尺度特征融合能力
实时推理效率



Weather-Suppression Adversarial Learning

天气抑制对抗学习

对抗训练流程

- **判别器**：预测天气类型（雨 / 雾 / 雪）
- **编码器**：通过 **GRL 反向梯度**，使判别器无法区分输入天气类型
- **损失函数**：**最小化 - 最大化博弈**，分离天气无关背景

$$\mathcal{L}_{adv} = \min_{\theta_w} \left(\lambda \max_{\theta_\epsilon} \left(\sum_{q=1}^Q \sum_{i=1}^{N_q} q \log[\mathcal{W}(\mathcal{E}(\mathbf{V}_i^q))] \right) \right).$$

为了预测视频片段的天气类型，我们通过计算**注意力机制**来整合一个视频片段中所有帧的信息。我们对其向量表示进行加权平均。通过使用 S 型函数应用门控注意力机制，提供一种可学习的非线性，从而增加模型的灵活性。

对每一帧计算一个**注意力得分** a_i ，计算方式如下：

$$\alpha_i = \frac{\exp \{ \mathbf{w}_1^T (\tanh(\mathbf{w}_2 \mathbf{v}_i^T) \cdot \text{sigm}(\mathbf{w}_3 \mathbf{v}_i^T)) \}}{\sum_{k=1}^T \exp \{ \mathbf{w}_1^T (\tanh(\mathbf{w}_2 \mathbf{v}_k^T) \cdot \text{sigm}(\mathbf{w}_3 \mathbf{v}_k^T)) \}},$$

其中 w_1, w_2, w_3 是可学习的参数。

此过程会产生一个**加权融合的向量表示**，其形式为：

$$\mathbf{v} = \sum_{i=1}^T \alpha_i \mathbf{v}_i,$$

其中 V_i 是来自第 i 帧特征嵌入的向量表示。最终通过一个**全连接层**从融合向量中获得天气类型。

Messenger-driven Video Transformer Decoder

信使驱动视频
Transformer 解码器

解码器工作流程

- 天气特征检索：以**编码器深层特征**为**键/值**，**天气信使**为**查询**，生成残差天气特征
- 时空融合：**卷积投影块（上采样 + 卷积）**修复空间细节，3D 卷积实现时间平滑
- 细节细化：**轻量级细化网络**去除伪影

监督目标函数由**平滑的 L1 损失**和**感知损失**组成，具体如下：

$$\mathcal{L}_S = \mathcal{L}_{smoothL_1} + \gamma_1 \mathcal{L}_{perceptual}, \text{ with}$$
$$\mathcal{L}_{smoothL_1} = \begin{cases} 0.5(\hat{I}_t - B_t)^2, & \text{if } |\hat{I}_t - B_t| < 1 \\ |\hat{I}_t - B_t| - 0.5, & \text{otherwise,} \end{cases}$$
$$\mathcal{L}_{perceptual} = \mathcal{L}_{mse}(VGG_{3,8,15}(\hat{I}_t), VGG_{3,8,15}(B_t)),$$

其中 I_t 和 B_t 分别表示目标帧的预测值和真实值。
整体目标函数由**监督损失**和**对抗损失**组成，定义：

$$\mathcal{L}_{total} = \mathcal{L}_S + \gamma_2 \mathcal{L}_{adv},$$

其中， γ_1 和 γ_2 是平衡超参数，分别经验性地设置为 0.04 和 0.001。



数据集与训练配置

在训练阶段，我们将这三个数据集的训练集合并，以学习一个统一的模型。

在测试阶段，我们分别在三个测试集上评估我们的模型。

天气类型	数据集	数据规模	特点
雨	RainMotion	80 视频 (2800 帧)	合成多雨场景
雾	REVIDE	48 视频 (1082 帧)	真实室内雾场景
雪	KITTI-snow	50 视频 (2500 帧)	首个视频雪数据集 (合成)

数据集与训练配置

天气类型	数据集	数据规模	特点
雪	KITTI-snow	50 视频 (2500 帧)	首个视频雪数据集 (合成)

KITTI-snow (合成户外数据集)

包含50个视频，总计2500帧，所有视频均呈现雪景。
具体而言，从KITTI中随机选取了两组视频。
第一组包含 35 个视频，用作**训练集**；
第二组包含 15 个视频，用作**测试集**。

为了模拟时间一致性，在同一视频的不同帧中，从相同的分布中采样雪花的位置、大小和模糊程度。
视频帧的空间分辨率为 1000×300 。
图3展示了合成数据集中五个具有不同分布的视频的示例帧。



Figure 3. Example frames of five synthesized videos in KITTI-snow. The snowflakes in each video are sampled from different distributions.



定量评估


采用 **峰值信噪比 (PSNR)** 和 **结构相似性指数 (SSIM)** 作为评估指标。

Methods		Type	Source	Datasets										
				Original Weather		Rain		Haze		Snow		Average		
去雨	Derain	PReNet [31]	Image	CVPR'19	27.06	0.9077	26.80	0.8814	17.64	0.8030	28.57	0.9401	24.34	0.8748
		SLDNet [44]	Video	CVPR'20	20.31	0.6272	21.24	0.7129	16.21	0.7561	22.01	0.8550	19.82	0.7747
		S2VD [45]	Video	CVPR'21	24.09	0.7944	28.39	0.9006	19.65	0.8607	26.23	0.9190	24.76	0.8934
		RDD-Net [39]	Video	ECCV'22	31.82	0.9423	30.34	0.9300	18.36	0.8432	30.40	0.9560	26.37	0.9097
去雾	Dehaze	GDN [26]	Image	ICCV'19	19.69	0.8545	29.96	0.9370	19.01	0.8805	31.02	0.9518	26.66	0.9231
		MSBDN [10]	Image	CVPR'20	22.01	0.8759	26.70	0.9146	22.24	0.9047	27.07	0.9340	25.34	0.9178
		VDHNet [33]	Video	TIP'19	16.64	0.8133	29.87	0.9272	16.85	0.8214	29.53	0.9395	25.42	0.8960
		PM-Net [27]	Video	MM'22	23.83	0.8950	25.79	0.8880	23.57	0.9143	18.71	0.7881	22.69	0.8635
去雪	Desnow	DesnowNet [29]	Image	TIP'18	28.30	0.9530	25.19	0.8786	16.43	0.7902	27.56	0.9181	23.06	0.8623
		DDMSNET [48]	Image	TIP'21	32.55	0.9613	29.01	0.9188	19.50	0.8615	32.43	0.9694	26.98	0.9166
		HDCW-Net [7]	Image	ICCV'21	31.77	0.9542	28.10	0.9055	17.36	0.7921	31.05	0.9482	25.50	0.8819
		SMGARN [9]	Image	TCSVT'22	33.24	0.9721	27.78	0.9100	17.85	0.8075	32.34	0.9668	25.99	0.8948
修复	Restoration	MPRNet [46]	Image	CVPR'21	— —	— —	28.22	0.9165	20.25	0.8934	30.95	0.9482	26.47	0.9194
		EDVR [41]	Video	CVPR'19	— —	— —	31.10	0.9371	19.67	0.8724	30.27	0.9440	27.01	0.9178
		RVRT [21]	Video	NIPS'22	— —	— —	30.11	0.9132	21.16	0.8949	26.78	0.8834	26.02	0.8972
		RTA [51]	Video	CVPR'22	— —	— —	30.12	0.9186	20.75	0.8915	29.79	0.9367	26.89	0.9156
All-in-one [18]		Image	CVPR'20	— —	— —	26.62	0.8948	20.88	0.9010	30.09	0.9431	25.86	0.9130	
UVRNet [16]		Image	TMM'22	— —	— —	22.31	0.7678	20.82	0.8575	24.71	0.8873	22.61	0.8375	
TransWeather [38]		Image	CVPR'22	— —	— —	26.82	0.9118	22.17	0.9025	28.87	0.9313	25.95	0.9152	
TKL [8]		Image	CVPR'22	— —	— —	26.73	0.8935	22.08	0.9044	31.35	0.9515	26.72	0.9165	
Ours		Video	— —	— —	— —	31.52	0.9433	24.51	0.9187	31.49	0.9562	29.17	0.9394	



定性评估

视觉对比 —— 输入帧 vs 各方法输出 vs 真实清晰帧







- 雨：ViWS-Net 去除条纹更彻底，背景更清晰



- 雾：残留雾气更少，色彩还原更自然



- 雪：雪花去除干净，无伪影残留



Input Frame

RDD-Net

GDN

DDMSNET

EDVR

TKL

Ours

GT

Figure 4. **Qualitative Comparison between adverse weather removal algorithms.** The best algorithms designed for different tasks are selected to present the results on the example frames degraded by rain, haze, snow, respectively. The color box indicates the detailed comparison of weather removal.



消融研究

Table 4. Ablation study of each critical module in the proposed framework on three weather types. The top values are marked in bold font. “WS. Adv.” denote weather-suppression adversarial learning.

Combination	Module			Datasets							
	WeatherMessenger	VideoDecoder	WS. Adv.	Rain		Haze		Snow		Average	
M1	-	-	-	26.92	0.9273	22.77	0.9052	29.94	0.9462	26.54	0.9262
M2	✓	-	-	30.03	0.9327	23.92	0.9149	30.54	0.9520	28.16	0.9332
M3	-	✓	-	29.33	0.9365	22.84	0.9085	30.89	0.9554	27.69	0.9335
M4	-	-	✓	29.70	0.9316	23.87	0.9152	30.82	0.9521	28.13	0.9330
M5	✓	✓	-	31.00	0.9419	24.13	0.9164	30.93	0.9552	28.69	0.9378
Ours	✓	✓	✓	31.52	0.9433	24.51	0.9187	31.49	0.9562	29.17	0.9394

模块有效性

单一模块（天气信使 / 对抗学习 / 解码器）均提升性能
全模块组合（Ours）比基线（M1）PSNR 提升 2.63 dB

解码器组件

时间融合 + 细化网络进一步提升细节恢复

Table 5. Ablation study of the proposed messenger-driven video transformer decoder. The top values are denoted in bold.

Module		Average	
TemporalFusion	RefineNet	PSNR	SSIM
-	-	28.37	0.9305
✓	-	28.80	0.9357
✓	✓	29.17	0.9394



模型效果对比

Video Adverse-Weather-Component Suppression Network via Weather Messenger and Adversarial Backpropagation

Supplementary Video 2:
Visual comparisons on real-world videos between our network and state-of-the-art methods

Anonymous
Paper ID #2799

核心贡献

首个单模型统一处理视频多恶劣天气的框架 ViWS-Net

天气信使与对抗学习结合，有效分离天气特征与背景

合成 KITTI-snow 数据集，推动视频去雪研究

性能总结


在定量 / 定性评估中**显著优于 SOTA**，计算效率均衡

未来方向

扩展至更复杂天气（如混合天气、沙尘）

优化模型结构，提升实时性（如轻量化 Transformer）

探索无监督 / 半监督训练，减少对标注数据的依赖



* 彩色方框显示了放大视图，突出了天气去除效果的详细对比。

ICCV
2023

International Conference on Computer Vision
October 2 - 6, 2023 Paris, France

ICCV23
PARIS

T H A N K Y O U

谢谢观看

Video Adverse-Weather-Component Suppression Network
via Weather Messenger and Adversarial Backpropagation

汇报人：

时间：2025/5/23