

NLP 简答终极二页纸

1. 概念？与 AI 关系？

让计算机**模拟人类**对**自然语言**进行智能化处理的技术。

NLP、机器学习、机器视觉共同构成 AI 的核心技术体系。

2. 研究内容、层次、具体？

基础研究：语言模型、语料库/语言知识库建设、字符集编码体系等

应用基础研究：词法/句法/语义/篇章分析等

应用层研究：机器翻译、信息检索、自动文摘、问答系统、文档分类、信息抽取、对话系统等

3. 主要困难？

歧义（一词多义）：分词/短语/词义/语用歧义

病构（未知语言现象）：新词汇/新词义/新句子结构

4. 基本方法、特点？

理性主义：基于**规则**的分析方法建立符号处理系统

经验主义：基于**大规模真实语料**(语言数据)建立计算方法

5. 请简要说明 WordNet？【2025T1】

WordNet 是由普林斯顿大学团队开发的英语语义数据库，基于认知语言学理论构建词汇网络，将词语按语义而非字母顺序关联。其核心结构以**同义词集(synset)**为基本单元，涵盖名词、动词、形容词和副词，通过上下位、整体部分等九类语义关系连接概念。

6. 知网(HowNet)构建原则？

以**义原(semantic prime)**为基本构建单位的汉语词汇知识库(中科院计算所研发)。义原是最基本的、不易再分割的最小意义单位。词语通过其所包含的义原集合来定义，义原之间通过 6 种关系互连。

7. 简述语言模型、N-gram？为什么要平滑？【2025T2】

语言模型(NLP 的核心)用于预测文本中下一个词的概率。基于大量文本数据学习语言的统计规律，能生成连贯文本或评估文本合理性。**N-gram** 是语言模型的一种，通过统计 n 个连续词的出现频率来预测下一个词。

原因：**避免零概率问题**。训练数据中未出现的 **N-gram** 的概率会被计算为 0，处理未知序列时表现不佳。平滑技术为**未出现的 N-gram 分配小概率**，使 **N-gram** 模型能更合理地处理未知序列，提高泛化能力和准确性。

8. 几种减值平滑法的原理和区别。

①绝对减值：固定数值减值，与原计数无关；

②线性减值：按比例减值，与原计数正相关；

③Good-Turing 法：通过频次分布动态修正计数，无固定减值参数；

④Katz 后退法：仅对高频项做同阶减值，低频项不做。

[1] 前三种均将腾出的概率在同阶所有未出现 **N-gram** 中平均分配，仅依赖同阶 N-gram 的计数统计，无需低阶模型；

[2] Katz 后退法对于未出现/低频事件不做同阶均分，直接**退回到低阶模型估算概率**，其需要结合低阶($n-1$)gram 的统计结果，属于**跨阶平滑**。

9. 向量空间模型 VSM 三个关键点？

索引项的选择、索引项的权重、相似度评价

10. LSI 模型相对于 VSM 应用于信息检索的优势？

可用奇异值过滤次要的“语义维度”，滤除噪声；

分解出语义层作为中介后，可将同义词用语义层联系起来；分解出语义层的过程中，多义词重要性自动下降（到几乎不起作用的程度）。

11. LSI 模型中 C 、 U 、 V^T 、 Σ 四个矩阵的含义？【2025T6】

奇异值分解： $C = U\Sigma V^T$

C ：“**词项-文档**”原始矩阵。

U ：“**词项**”**表征**矩阵，表示词项与各语义维度间的关系。

V^T ：“**文档**”**标引**矩阵，表示文档与各语义维度间的关系。

Σ ：**奇异值对角**矩阵，对角线上的奇异值模拟了各“语义维度”的重要性程度。

12. 问答系统的概念、实现类型？

允许用户以**自然语言方式询问**，能从大量异构数据中查找并总结用户问题**答案(准确而简洁)**的新型信息检索系统。

基于**大规模真实文本、Web、知识库、语言模型**

13. 字分类法原理？【2025T3】

将分词过程看作是字的分类问题。认为每个字在构特定的词时都占据着一个确定的构词位置(**词位**)。假定每个字只有 4 个词位：**词首(B)、词中(M)、词尾(E)和单独成词(S)**，那么，每个字归属一特定的词位。

14. 命名实体识别(NER)概念？

识别文本中对实体的命名性指称(人名、地名、机构名、时间名等专有名词)

15. 如何利用 HMM 建立词性标注器？

模型设计：将词性序列作为**隐藏状态序列**，单词序列作为**观测序列**。

模型训练：利用大规模已标注语料库，统计并计算出初始状态概率 π 、词性间状态转移概率 A 、词汇的发射概率 B 。

标注解码：给定新的待标注文本序列，利用 **Viterbi 算法**动态规划求解出全局概率最大的隐藏词性状态序列。

16. 句法结构分析、浅层句法分析、依存句法分析概念？

①句法结构分析（=完全句法分析）：判断输入的整体句子是否合乎语法规则，并确定出宏观的、完整的树状句法层级结构，输出句法分析树。

②浅层句法分析：不关注整体的长距离关联特征，仅关注局部区域内的语法属性，把句子拆解切分为多个相互独立的、底层的基本语块（如 Base NP、PP 等）。

③依存句法分析：以**动词**为句子的绝对中心，直接利用词汇与词汇之间的二元连边（**支配者→被支配者**的依存关系）来表达结构，突出词汇直接的关联特性。

17. 术语含义：S、VP、NP、PP；SBV、VOB、ATT、DE【2025T4】

句子、动词短语、名词短语、介词短语、主谓依存关系、动宾依存关系、定语修饰关系、“的”字结构依存关系

18. PCFG 特点、优势？

PCFG 为文法中的每条产生式规则赋予了一个概率，一棵完整句法树的发生概率由推导出该树的所有节点规则概率连乘计算得到。

优势：①大幅降低人工编制规则的工作量、主观性；②从真实训练数据中学习，更贴合客观实际；③结合动态规划，精准寻找到概率最大（全局最优）的句法树，有效解决了一句多树的切分歧义难题。

19. 词义消歧概念、方法？

确定一个多义词在给定上下文语境中的具体含义。

基于**规则**、基于**有监督学习**、基于**词典**。

20. 基于词典的消歧类型、原理？【2025T5】

①基于词典中**语义定义**：将词典中词条本身的定义作为判断其语义的条件。

②基于**义类辞典**：确定多义词上下文词语的语义类状况，统计共现的语义类规律来确定多义词在此语境中的词义。

③基于**双语词典**：利用第二种语言的语料库，统计对应不同词义的翻译词与上下文词的同现频次，同现频次显著高者即为消歧结果。

21. 语义角色标注概念？常用语义角色？

以句子的谓词为中心，研究句子中各成分与谓词之间的关系，并用语义角色来描述区分它们之间的关系。

体词（名词、代词等）和**谓词**（动词）之间的**及物性关系**，如动作和施事者、动作和受事者、动作和结果、动作和工具等关系。

22. 基于短语结构树与基于依存关系树的语义角色标注方法之间的核心差异？

①标注对象为**短语**，特征信息主要从**句法结构树**中抽取。

②标注对象为**词语**，特征信息主要从**依存句法树**中抽取。

23. NLP 发展过程、各阶段核心特征？

①小规模专家系统（1950~1990）：依赖人工制定的专家规则系统。

②语料库统计模型（1990~2010）：使用离散的语言符号（如 One-hot 等高维稀疏向量）来表示词，通过大量统计方法进行学习。

③深度学习模型（2010~2017）：把词语表示成**低维的稠密连续向量**，能够较好地提取特征。

④大规模预训练模型（2018~）：确立了“预训练(Pre-train)+精调(Fine-tune)”的新范式。

24. 词表示模型的发展过程、代表性模型？

①**离散表示**：为每个词分配唯一的索引数字身份证，表现为高维、稀疏的向量。**One-hot**。

②**分布表示**：基于分布语义假设，利用词在语料库中的上下文共现信息来统计表示词义。**LSA、HAL**。

③**嵌入表示（分布式表示）**：使用低维、稠密、连续的向量表示词，通过自监督学习获得。预训练静态词向量 **NNLM、RNNLM、Word2vec(含 CBOW、Skip-gram)**和 **GloVe**；预训练动态词向量 **ELMo、BERT、GPT** 等。

25. 静态、动态词向量差异、优劣势？

• 核心差异：静态词向量是“**一词一向量**”，向量固定且与上下文无关；动态词向量是“**一词多向量**”，词向量会根据其所处的上下文语境动态生成并改变。

• 静态词向量：

（优）模型浅层、轻量高效，训练和推理速度极快；

（劣）无法处理“一词多义”现象，同一词在不同语境下的向量完全相同，语义表达单一。

• 动态词向量：

（优）具备强大的上下文感知能力，完美解决“一词多义”难题，捕捉语境对词义的微妙影响，语义理解更透彻；

（劣）基于深层复杂神经网络（如 LSTM/Transformer），模型庞大，计算开销与推理成本更高。

26. 在 Word2vec 模型中为什么需要采用负采样技术？

在利用 Softmax 对目标词进行预测时，如果词汇表非常大且计算资源有限，每一次迭代都需要在**整个词表**上计算概率（归一化），计算效率会极其低下。

负采样技术将复杂的“**多分类预测**”转化为对(词，上下文)是否共现的“**二分类问题**”（1 表示共现，0 表示不共现），并通过“**换词**”构造**少量负例**。这样每次只需要更新正负样本对应的少量参数，**极大提升了训练速度**。