

NLP Notes for Final Exams

自然语言处理

期末通关讲义

■ 编者: Kureha Shiro



第一讲 绪论

1.1 本讲重点

- 1. 掌握自然语言的概念定义、特点；
- 2. 掌握自然语言处理的概念定义；
- 3. 熟悉自然语言处理的主要研究内容及层次划分；
- 4. 理解自然语言处理的主要困难；
- 5. 了解自然语言处理的两类方法的特点与核心区别。

1.2 自然语言与 NLP 的定义

自然语言：随着社会发展进程自然产生并发展演化的用于人类日常交流与思考的符号系统。

其特点是：规则无法完全覆盖现象、内容不断发展变化、形式灵活多变。

自然语言处理（NLP）：让计算机模拟人类对自然语言进行智能化处理的技术。

NLP 与 AI 的关系：NLP、机器学习、机器视觉共同构成人工智能的核心技术体系。

1.3 NLP 的研究内容（层次划分）——【2025·真题选择 T2】

- 基础研究：语言模型、语料库建设、语言知识库建设、字符集编码体系等
- 应用基础研究：词法分析、句法分析、语义分析、篇章分析等
- 应用层研究：机器翻译、信息检索、自动文摘、问答系统、文档分类、信息抽取、对话系统等

1.4 NLP 面临的主要困难——【2025·真题选择 T3、T7】

（1）歧义——同一语言形式对应多种含义

分词歧义	短语歧义	词义歧义	语用歧义
研究所取得的成就	喜欢乡下的孩子	打乒乓球	剩女产生的原因有两个，
研究所/取得/的/成就	【喜欢乡下】的孩子	打电话	一是谁都看不上，
研究/所/取得/的/成就	喜欢【乡下的孩子】	打毛衣 打酱油	二是谁都看不上。

（2）病构——未知的语言现象

新词汇	新词义	新句子结构
非典、网红、新冠、C 位、YYDS……	打 call、小鲜肉、很丧、卷……	他非常男人。眼看他楼塌了。

1.5 NLP 的两类研究方法（规则 vs 统计）

- **理性主义（1950s—1990）**：通过一些特殊的语句或语言现象的研究来得到对人的语言能力的认识，而这些语句和语言现象在实际的应用中并不常见。
 - 问题求解的基本思路：**基于规则的分析方法建立符号处理系统**
 - * 规则库开发： $N + N \rightarrow NP$
 - * 词典标注： $\#$ 工作， $N(uc)$ ； V ；
 - * 推导算法设计：归约、推导、歧义消解方法…
 - 知识库 + 推理系统 $\rightarrow$ **NLP 系统**
 - 理论基础：Chomsky 的文法理论
- **经验主义（1990—今天）**：偏重于对大规模语言数据中人们所实际使用的普通语句的统计。
 - 求解问题的思路：**基于大规模真实语料 (语言数据) 建立计算方法**
 - * 大规模真实数据的收集、标注：真实性、代表性、标注信息……
 - * 模型训练：模型的复杂性、有效性、参数训练方法……
 - 语料库 + 模型 $\rightarrow$ **NLP 系统**
 - 理论基础：统计学、信息论、机器学习

1.6 课后习题

1. 什么是自然语言处理？NLP 与人工智能的关系如何？
2. NLP 的研究内容可分为哪些层次？各层次包含哪些具体方向？
3. NLP 面临的主要困难有哪些？请举例说明。
4. NLP 的基本方法分为哪几类？各自有何特点？

（注：本节答案已清晰呈现在上文，略）

第二讲 熵及最大熵模型

2.1 熵的概念——【2025 · 真题选择 T14】

熵 (entropy): 信息论的核心概念，由香农 (Claude Shannon) 在 1948 年提出。设离散型随机变量 X 的取值空间为 $\mathcal{R}$ ，概率分布 $p(x) = P(X = x)$ ，则 X 的熵定义为：

$$H(X) = - \sum_{x \in \mathcal{R}} p(x) \log p(x)$$

约定 $0 \log 0 = 0$ 。对数底数为 2/e/10 时，熵的单位为**比特 (bit)** / 奈特 (nat) / 哈脱特 (hat)。

熵又称**自信息 (self-information)**，是随机变量不确定性的量化指标，代表信源 X 每发送一个符号所提供的平均信息量。**熵越大，不确定性越强，正确预测其值的可能性就越小。**

例题 2-1: 假设 a, b, c, d, e, f 六个字符随机出现，概率分别为 $\frac{1}{8}, \frac{1}{4}, \frac{1}{8}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}$ ，计算该分布的熵。

解析：

$$H(P) = - \sum p \log_2 p = - \left(4 \times \frac{1}{8} \log_2 \frac{1}{8} + 2 \times \frac{1}{4} \log_2 \frac{1}{4} \right) = 2.5 \text{ 比特}$$

结果表明，传输一个字符平均需要 2.5 比特，可设计出如下最优编码方案：

字符	a	b	c	d	e	f
编码	100	00	101	01	110	111

例题 2-2: 计算下列两种情况下英文 (26 个字母和 1 个空格，共 27 个字符) 信息源的熵。

(1) 假设 27 个字符等概率出现；(2) 假设英文字母的概率分布如下：

字母	空格	E	T	O	A	N	I	R	S
概率	0.1956	0.105	0.072	0.0654	0.063	0.059	0.055	0.054	0.052
字母	H	D	L	C	F	U	M	P	Y
概率	0.047	0.035	0.029	0.023	0.0225	0.0225	0.021	0.0175	0.012
字母	W	G	B	V	K	X	J	Q	Z
概率	0.012	0.011	0.0105	0.008	0.003	0.002	0.001	0.001	0.001

解析：(1) 等概率出现情况：

$$H(X) = - \sum_{x \in X} p(x) \log_2 p(x) = 27 \times \left\{ -\frac{1}{27} \log_2 \frac{1}{27} \right\} = \log_2 27 \approx 4.75 \text{ (比特)}$$

(2) 实际情况：

$$H(X) = - \sum_{i=1}^{27} p(x_i) \log_2 p(x_i) \approx 4.02 \text{ (比特)}$$

说明：考虑了英文字母和空格实际出现的概率后，英文信源的平均不确定性，比把字母和空格看作等概率出现时英文信源的平均不确定性要小。

2.2 最大熵模型——【2025 · 真题选择 T15】

仅掌握未知分布的部分信息时，满足已知条件的分布有无数种。

熵最大的分布最能反映事件真实分布，因为熵定义了随机变量的不确定性，当熵最大时，随机变量最不确定，最难准确预测其行为。

最大熵原理：学习概率模型时，在所有可能的概率分布中，熵最大的模型是最优模型。

离散随机变量 X 的熵满足 $0 \leq H(P) \leq \log |X|$ ，其中 $|X|$ 为取值个数。当且仅当 X 服从均匀分布时，熵取最大值。

模型要求：

1. 必须满足所有已知事实（约束条件）
2. 不做任何未知假设，按等可能处理，通过最大化熵来实现（剩下的等概率）

最大熵概念在 NLP 中应用广泛，通常做法是根据已知样本设计特征函数，假设存在 k 个特征函数 $f_i (i = 1, 2, \dots, k)$ ，所建模型应满足所有这些特征的约束。在约束条件确定的模型集合中，选取熵最大的模型。

例题 2-3（概率分布估计）：设随机变量 X 有 5 个取值 $\{x_1, x_2, x_3, x_4, x_5\}$ ，估计各取值的概率。

1. 仅有归一化约束时，求各取值的概率？
2. 增加约束 $p(x_1) + p(x_2) = \frac{3}{10}$ ，求各取值的概率？

解析：

1. 等概率： $p(x_i) = \frac{1}{5}$
2. 前两个平分 $\frac{3}{10}$ ，后三个平分剩余概率：

$$p_1 = p_2 = \frac{3}{20}, \quad p_3 = p_4 = p_5 = \frac{7}{30}$$

例题 2-4 (最大熵模型求解): 用例 2 的约束条件构造最优化问题, 用拉格朗日对偶性求解。

解析: 以 $y_1, \dots, y_5$ 表示 $A, \dots, E$, 最优化问题为:

$$\min -H(P) = \sum_{i=1}^5 P(y_i) \log P(y_i)$$

约束条件:

$$P(y_1) + P(y_2) = \frac{3}{10}, \quad \sum_{i=1}^5 P(y_i) = 1$$

引入拉格朗日乘子 w_0, w_1 , 定义拉格朗日函数:

$$L(P, w) = \sum_{i=1}^5 P(y_i) \log P(y_i) + w_1 \left(P(y_1) + P(y_2) - \frac{3}{10} \right) + w_0 \left(\sum_{i=1}^5 P(y_i) - 1 \right)$$

由拉格朗日对偶性, 先固定 w 求 $L(P, w)$ 对 P 的最小化, 再对 w 最大化。对各 $P(y_i)$ 求偏导并令为零, 解得:

$$P(y_1) = P(y_2) = e^{-w_1 - w_0 - 1}, \quad P(y_3) = P(y_4) = P(y_5) = e^{-w_0 - 1}$$

代入约束条件求得 $e^{-w_1 - w_0 - 1} = \frac{3}{20}$, $e^{-w_0 - 1} = \frac{7}{30}$, 故:

$$P(y_1) = P(y_2) = \frac{3}{20}, \quad P(y_3) = P(y_4) = P(y_5) = \frac{7}{30}$$

2.3 联合熵与条件熵

联合熵 (joint entropy): 描述一对随机变量平均所需的信息量。

$$H(X, Y) = - \sum_x \sum_y p(x, y) \log p(x, y)$$

条件熵 (conditional entropy): 给定 X 的情况下 Y 的不确定性。

$$H(Y | X) = - \sum_x \sum_y p(x, y) \log p(y | x)$$

熵的连锁规则 (chain rule):

$$H(X, Y) = H(X) + H(Y | X) = H(Y) + H(X | Y)$$

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1})$$

例题 2-5: 某语言字符分为元音 (V) 和辅音 (C) 两类。元音集合 $\{a, i, u\}$, 辅音集合 $\{p, t, k\}$ 。若所有单词由 C-V 音节序列组成, 联合概率分布 $P(C, V)$ 如下表:

元音\辅音	p	t	k
a	1/16	3/8	1/16
i	1/16	3/16	0
u	0	3/16	1/16

求 $H(C)$ 、 $H(V | C)$ 和 $H(C, V)$ 。

解析：先计算辅音边缘概率 $P(p) = 1/8$ ， $P(t) = 3/4$ ， $P(k) = 1/8$ 。

(1) $H(C) = -\sum p(c) \log_2 p(c) = -(2 \times \frac{1}{8} \log_2 \frac{1}{8} + \frac{3}{4} \log_2 \frac{3}{4}) \approx 1.061$ 比特

(2) 计算条件概率，如 $P(a | p) = \frac{1/16}{1/8} = \frac{1}{2}$ ， $P(i | p) = \frac{1}{2}$ ， $P(u | p) = 0$ 。则：

$$H(V | C) = \frac{1}{8} H\left(\frac{1}{2}, \frac{1}{2}, 0\right) + \frac{3}{4} H\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right) + \frac{1}{8} H\left(\frac{1}{2}, 0, \frac{1}{2}\right) = 1.375 \text{ 比特}$$

(3) $H(C, V) = H(C) + H(V | C) \approx 1.061 + 1.375 = 2.436$ 比特

熵率 (entropy rate)：对长度为 n 的信息，每个字符的平均熵为：

$$H_{\text{rate}} = \frac{1}{n} H(X_1, \dots, X_n)$$

语言 L 的熵率定义为：

$$H_{\text{rate}}(L) = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, \dots, X_n)$$


2.4 互信息

互信息 (mutual information)：反映知道 Y 的值后 X 不确定性的减少量，即 Y 透露了多少关于 X 的信息量（如下图）。

$$I(X; Y) = H(X) - H(X | Y) = \sum_{x, y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

互信息体现了两个变量间的依赖程度： $I(X; Y) \gg 0$ 表示高度相关， $I(X; Y) = 0$ 表示相互独立。由于 $H(X | X) = 0$ ，有 $H(X) = I(X; X)$ ，因此熵也称为自信息。

应用：互信息在词汇聚类、汉语自动分词、词义消歧等问题中有重要用途。



2.5 补充：贝叶斯定理

贝叶斯定理 (Bayes' Theorem): 关于随机事件 A 和 B 的条件概率的定理。

$$P(a | b) = \frac{P(b | a)P(a)}{P(b)}$$

其中 $P(a)$ 是 a 的先验概率, 不考虑任何 b 方面的因素; $P(b)$ 是 b 的先验概率;

$P(a | b)$ 是已知 b 发生后 a 的条件概率, 称为 a 的后验概率;

$P(b | a)$ 是已知 a 发生后 b 的条件概率, 称为 b 的后验概率。

2.6 课后习题

1. 文本 A 平均每 10000 篇才出现一次。某文本分类系统: 若文本确为 A, 判定为 A 的概率为 0.9; 若非 A, 误判为 A 的概率为 0.1。当系统判定结果为 A 时, 正确的概率是?

解析: 由贝叶斯定理,

$$P(A | \text{判 } A) = \frac{0.0001 \times 0.9}{0.0001 \times 0.9 + 0.9999 \times 0.1} \approx 0.0009$$

2. 离散随机变量 X 取值 0, 1, 2, 概率分布 $p(0) = p(1) = p(2) = \frac{1}{3}$, 其熵是多少?

解析: $H(X) = -\sum p(x) \log_2 p(x) = -3 \times \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 \approx 1.585$ 比特

3. 离散随机变量 X 的熵定义为?

解析:

$$H(X) = -\sum_{x \in X} p(x) \log_2 p(x)$$

4. 简述最大熵原理。

解析: 最大熵原理指出, 对一个随机事件的概率分布进行预测时, **预测应当满足全部已知的约束, 而对未知的情况不要做任何主观假设**。在这种情况下, **概率分布最均匀**, 预测的风险最小, 因此得到的概率分布的熵是最大。

5. 计算如下联合概率分布的 $H(X)$ 和 $H(Y | X)$:

$X \backslash Y$	1	2	3	4
1	1/8	1/16	1/16	1/4
2	1/16	1/8	1/16	0
3	1/32	1/32	1/16	0
4	1/32	1/32	1/16	0

解析: 先计算 X 的边缘概率:

$$P(X=1) = \frac{1}{8} + \frac{1}{16} + \frac{1}{16} + \frac{1}{4} = \frac{1}{2}$$

$$P(X=3) = \frac{1}{32} + \frac{1}{32} + \frac{1}{16} + 0 = \frac{1}{8}$$

$$P(X=2) = \frac{1}{16} + \frac{1}{8} + \frac{1}{16} + 0 = \frac{1}{4}$$

$$P(X=4) = \frac{1}{32} + \frac{1}{32} + \frac{1}{16} + 0 = \frac{1}{8}$$

$$H(X) = -\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{4}\log_2 \frac{1}{4} + 2 \times \frac{1}{8}\log_2 \frac{1}{8}\right) = \frac{1}{2} + \frac{1}{2} + \frac{3}{4} = \frac{7}{4} \text{ 比特}$$

然后对每个 x 计算 $H(Y | X = x)$:

$$H(Y | X = 1) = -\left(\frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{8}\log_2 \frac{1}{8} + \frac{1}{8}\log_2 \frac{1}{8} + \frac{1}{2}\log_2 \frac{1}{2}\right) = \frac{7}{4}$$

$$H(Y | X = 2) = -\left(\frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{4}\log_2 \frac{1}{4}\right) = \frac{3}{2}$$

$$H(Y | X = 3) = -\left(\frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{2}\log_2 \frac{1}{2}\right) = \frac{3}{2}$$

$$H(Y | X = 4) = H(Y | X = 3) = \frac{3}{2}$$

$$H(Y | X) = \sum_x p(x)H(Y | X = x) = \frac{1}{2} \times \frac{7}{4} + \frac{1}{4} \times \frac{3}{2} + \frac{1}{8} \times \frac{3}{2} + \frac{1}{8} \times \frac{3}{2} = \frac{13}{8} \text{ 比特}$$

6. **【2025 · 真题计算 T1】** 计算如下离散随机变量 X 和 Y 的联合熵 $H(X, Y)$ 和条件熵 $H(Y|X)$ 、 $H(X|Y)$ 。

	y_1	y_2
x_1	0.1	0.4
x_2	0.1	0.4

解析：第一步：计算边缘概率

X 的边缘概率： $p(x_1) = 0.1 + 0.4 = 0.5$ $p(x_2) = 0.1 + 0.4 = 0.5$

Y 的边缘概率： $p(y_1) = 0.1 + 0.1 = 0.2$ $p(y_2) = 0.4 + 0.4 = 0.8$

第二步：计算联合熵 $H(X, Y)$

$$\begin{aligned} H(X, Y) &= -\sum_i \sum_j p(x_i, y_j) \log_2 p(x_i, y_j) \\ &= -0.1 \log_2 0.1 - 0.4 \log_2 0.4 - 0.1 \log_2 0.1 - 0.4 \log_2 0.4 \\ &= 2 \times (-0.1 \log_2 0.1 - 0.4 \log_2 0.4) \approx 1.722 \text{ bit} \end{aligned}$$

第三步：计算条件熵 $H(Y|X)$ 和 $H(X|Y)$

条件熵公式： $H(Y|X) = \sum_i p(x_i)H(Y|x_i)$

$$- H(Y|x_1) = -0.2 \log_2 0.2 - 0.8 \log_2 0.8 \approx 0.722 \text{ bit}$$

$$- H(Y|x_2) = -0.2 \log_2 0.2 - 0.8 \log_2 0.8 \approx 0.722 \text{ bit}$$

$$H(Y|X) = 0.5 \times 0.722 + 0.5 \times 0.722 = 0.722 \text{ bit}$$

$$- H(X|y_1) = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1 \text{ bit}$$

$$- H(X|y_2) = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1 \text{ bit}$$

$$H(X|Y) = 0.2 \times 1 + 0.8 \times 1 = 1 \text{ bit}$$

第三讲 形式语言与自动机

形式语言与自动机是 NLP 的核心基础：形式语言理论用于语言描述与分析，自动机理论用于词法分析、拼写检查、短语识别等任务。两者为计算机处理自然语言提供形式化工具。

3.1 基本概念

无向图：二元组 $G = (N, E)$ ， N 为顶点非空有限集， E 为边有限集。

有向图：二元组 $D = (N, E)$ ，边 $(n_i, n_j) \neq (n_j, n_i)$ ， n_i 为出边、 n_j 为入边。

连通图：任意两顶点间均存在路径（顶点构成的序列 P ）。

回路：起点与终点重合的路径。 $k = 0$ 为自回路；无回路的图为无回路图。

树：无回路的连通无向图。标记根结点的树称为**根树**，满足：仅有一个根结点，无直接前驱；除根外每个结点仅有唯一直接前驱；任意结点存在从根到自身的路径。

结点分类：根结点、叶结点、内结点；存在父子、兄弟关系。

字符串：字符表 Σ 上的每个元素（字符）组成的有限序列；空串记为 ε ； Σ^* 表示所有字符串（含空串）的集合。“连接”和“闭包”是字符串基本运算。

连接：串 x 与 y 连接为 xy ； $x^n = \overbrace{xx \cdots x}^n$ ， $x^0 = \varepsilon$ 。

集合乘积： $AB = \{xy \mid x \in A, y \in B\}$ ， $A^0 = \{\varepsilon\}$ 。

闭包： $V^* = V^0 \cup V^1 \cup V^2 \cup \cdots$ ， $V^+ = V^1 \cup V^2 \cup \cdots = V^* - \{\varepsilon\}$ 。

3.2 形式语言

语言是按规则构成的句子或符号串的有限或无限集合。描述语言的方式有三种：

1. **穷举法**（只适合句子数目有限的语言）
2. **文法描述**（生成语言中合格的句子）
3. **自动机法**（对输入的句子进行检验，区别哪些是/不是语言中的句子）

形式语言是用来精确地描述语言（包括人工语言和自然语言）及其结构的手段。**形式语言学**也称**代数语言学**。以重写规则 $\alpha \rightarrow \beta$ 的形式表示（ α, β 均为字符串）。

形式语法：四元组 $G = (N, \Sigma, P, S)$ 。

- N ：非终结符有限集； Σ ：终结符有限集； $N \cap \Sigma = \emptyset$
- $V = N \cup \Sigma$ ：总词汇表
- P ：重写规则 $\alpha \rightarrow \beta$ 的有限集， α 至少含一个非终结符
- $S \in N$ ：初始符（句子符）

推导（直接派生）：设 $G = (N, \Sigma, P, S)$ 是一个文法，在 $(N \cup \Sigma)^*$ 上定义关系 $\xRightarrow{G}$ 如下：

如果 $\alpha\beta\gamma$ 是 $(N \cup \Sigma)^*$ 中的符号串, 且 $\beta \rightarrow \delta$ 是 P 的产生式, 那么

$$\alpha\beta\gamma \xRightarrow[G]{\quad} \alpha\delta\gamma$$

最左推导每次只改写最左边的非终结符;

最右推导每次只改写最右边的非终结符, 又叫**规范推导**。

句子: S 是初始句子形式; 经推导得到的新串仍为句子形式; 不含非终结符的句子形式称为句子。文法 G 生成的语言为:

$$L(G) = \{x \mid x \in \Sigma^*, S \xRightarrow[G]{*} x\}$$

例题 3-1: $G = (\{E, T, F\}, \{a, +, *, (,)\}, P, E)$

$$\begin{aligned} P: \quad E &\rightarrow E + T \mid T & T &\rightarrow T * F \mid F \\ F &\rightarrow (E) \mid a \end{aligned}$$

字符串 $a + a * a$ 的两种推导过程:

$$\begin{aligned} E &\Rightarrow E + T \Rightarrow T + T \Rightarrow F + T \Rightarrow a + T \Rightarrow a + T * F \\ &\Rightarrow a + F * F \Rightarrow a + a * F \Rightarrow a + a * a \quad (\text{最左推导}) \end{aligned}$$

$$\begin{aligned} E &\Rightarrow E + T \Rightarrow E + T * F \Rightarrow E + T * a \Rightarrow E + F * a \Rightarrow E + a * a \\ &\Rightarrow T + a * a \Rightarrow F + a * a \Rightarrow a + a * a \quad (\text{最右推导}) \end{aligned}$$

例题 3-2: 给定文法 $G(S)$ 的一组规则:

$S \rightarrow P NP$ (S 表示文法的初始符, 而不是句子)

$NP \rightarrow NN \mid NP Aux NP$

$P \rightarrow \text{关于}; NN \rightarrow \text{鲁迅} \mid \text{文章}; Aux \rightarrow \text{的}$

分别用最左推导和最右推导生成句子”关于鲁迅的文章”。

解析:

最左推导:

$$\begin{aligned} S &\Rightarrow PNP \Rightarrow \text{关于}NP \Rightarrow \text{关于}NP Aux NP \Rightarrow \text{关于}NN Aux NP \\ &\Rightarrow \text{关于}鲁迅 Aux NP \Rightarrow \text{关于}鲁迅的 NP \\ &\Rightarrow \text{关于}鲁迅的 NN \Rightarrow \text{关于}鲁迅的文章 \end{aligned}$$

最右推导 (规范推导):

$$\begin{aligned} S &\Rightarrow PNP \Rightarrow PNP Aux NP \Rightarrow PNP Aux NN \Rightarrow PNP Aux 文章 \\ &\Rightarrow PNP 的文章 \Rightarrow PNN 的文章 \Rightarrow P 鲁迅的文章 \Rightarrow \text{关于}鲁迅的文章 \end{aligned}$$

3.2.1 乔姆斯基层级——【2025·真题选择 T17】

乔姆斯基层级：文法按约束从弱到强分四类，包含关系为 $L(G_0) \supseteq L(G_1) \supseteq L(G_2) \supseteq L(G_3)$ 。

- 3 型（正则文法）： $A \rightarrow xB$ （右线性）或 $A \rightarrow Bx$ （左线性）， $A, B \in N, x \in \Sigma$
- 2 型（上下文无关文法 CFG）： $A \rightarrow \alpha$ ， $A \in N$ ， $\alpha \in (N \cup \Sigma)^*$ （* 指任意字符串）
- 1 型（上下文有关文法 CSG）： $\alpha A \beta \rightarrow \alpha \gamma \beta$ ， $|\gamma| \geq |\alpha A \beta|$
- 0 型（无约束文法）： $\alpha \rightarrow \beta$ ， $\alpha \in (N \cup \Sigma)^+$ （+ 指非空字符串），无额外限制

* 此处符号表示较难理解，判断方式的文字表述详见下页。

例题 3-3：判断文法类型并写出生成的语言：

$G = (N, \Sigma, P, S)$ ，其中， $N = \{S, A, B\}$ ， $\Sigma = \{a, b\}$ ，

产生式 P ：(1) $S \rightarrow aA$ (2) $A \rightarrow aA$ (3) $A \rightarrow bbB$ (4) $B \rightarrow bB$ (5) $B \rightarrow b$

解析：规则 (3) 似乎不满足正则文法定义的条件，但可改写成：

$$(6) A \rightarrow bX \quad (7) X \rightarrow bB$$

因此，该文法修改后为右线性正则文法（3 型），生成的语言为：

$$L(G) = \{a^n b^m \mid n \geq 1, m \geq 3\}$$

（推导示例：对 $a^2 b^3$ ： $S \Rightarrow aA \Rightarrow aaA \Rightarrow aabB \Rightarrow aabbB \Rightarrow aabbb$ ）

例题 3-4：已知文法 $G = (N, \Sigma, P, S)$ ，其中， $N = \{S, A, B, C\}$ ， $\Sigma = \{a, b, c\}$ ，产生式 P ：

(1) $S \rightarrow ABC$ (2) $A \rightarrow aA \mid a$ (3) $B \rightarrow bB \mid b$ (4) $C \rightarrow BA \mid c$ 。试求生成的语言。

解析：该文法所识别的语言为：

$$L(G) = \{a^n b^m a^k c^\alpha, n \geq 1, m \geq 1, k \geq 0, \alpha \in \{0, 1\}\}$$

（若 $k > 0$ ， $\alpha = 0$ ，否则 $\alpha = 1$ ）

补充例：以下文法分别描述什么？判断其类型。

1. $S \rightarrow aS \mid \varepsilon$ ：

生成 a^* ，为 3 型正则文法。

2. $S \rightarrow aSb \mid \varepsilon$ ：

生成 $\{a^n b^n \mid n \geq 0\}$ ，包含嵌套结构，无法用正则文法描述，为 2 型 CFG。

3. $S \rightarrow aSBC \mid abc$ ， $CB \rightarrow BC$ ， $aB \rightarrow ab$ ， $bB \rightarrow bb$ ， $bC \rightarrow bc$ ， $cC \rightarrow cc$ ：

生成 $\{a^n b^n c^n \mid n \geq 1\}$ ，包含上下文约束，为 1 型 CSG。

★★★ 【总结】那我问你？如何判断文法类型！

在具体判定文法类型时，推荐采用自底向上（从严到宽）的顺序开始判断，依次尝试是否满足：3型 $\rightarrow$ 2型 $\rightarrow$ 1型 $\rightarrow$ 0型。

3 型文法（正则文法）

1. **左边要求：**左边有且仅有一个字符，并且该字符必须为非终结符。
2. **右边长度与类型：**右边最多只能有两个字符。
 - 当右边有两个字符时，必须一个为终结符，一个为非终结符。
 - 当右边只有一个字符时，此字符必须为终结符。
 - **特例：**有时可引入新增非终结符 X ，如可将 $A \rightarrow bbB$ 改写为 $A \rightarrow bX$ ； $X \rightarrow bB$ 。
3. **线性限制：**所有右边为两个字符的产生式，终结符和非终结符的位置固定为 终结符 + 非终结符（右线性）或者 非终结符 + 终结符（左线性）。且在同一个文法中，所有产生式的这种相对位置必须保持相同，不可混用。

2 型文法（上下文无关文法 CFG）

1. **左边要求：**同 3 型文法第一条（左边有且仅有一个非终结符）。
2. **右边要求：**所有产生式的右边可以含有有限个终结符和非终结符。也就是说，右侧对终结符和非终结符的数量、顺序均没有任何限制，只要长度有限即可。

1 型文法（上下文有关文法 CSG）

1. **左边要求：**所有产生式左边至少包含一个非终结符。
2. **右边要求：**同 2 型文法第二条（右边为有限个符号串），且通常满足绝大多数产生式左侧长度不超过右侧长度（ $|\alpha| \leq |\beta|$ ，除包含起始符号产生空串的特殊情况外）。

0 型文法（无约束文法）

1. **判定规则：**当文法与前面的所有类型（3 型、2 型、1 型）都不符合时，则归为 0 型文法。

3.2.2 派生树与二义性

★★★ CFG 派生树：上下文无关文法 $G = (N, \Sigma, P, S)$ 产生句子的派生树满足以下条件：

1. **根节点与标记：**树的根节点标记为开始符号 S ，其余所有节点标记均属于 $N \cup \Sigma$ 。
2. **内节点属性：**若某个节点具有子节点，则该节点必为非终结符（ $A \in N$ ）。
3. **分支与产生式映射：**若某个标记为 A 的节点拥有 k 个直接子节点（从左到右依次标记为 $A_1, A_2, \dots, A_k$ ），则 $A \rightarrow A_1 A_2 \dots A_k$ 必须是 P 中的一条产生式规则。

例题 3-5: 已知文法 $G = (\{S, A\}, \{a, b\}, P, S)$, 产生式 P 为: $S \rightarrow bA, A \rightarrow bAA, A \rightarrow a$


解析: 文法 G 所产生的句子 $bbaa$ 可以由以下最左推导过程与对应的派生树表示:

$S \Rightarrow bA$

$\Rightarrow bbAA$

$\Rightarrow bbaA$

$\Rightarrow bbaa$




CFG 的二义性: 一个文法 G , 存在某个句子有不只一棵分析树与之对应。

例题 3-6: 试证明对于句子 $i + i * i$, 文法 $G(E)$ 是二义性的。其产生式规则如下:

$$E \rightarrow E + E \mid E * E \mid (E) \mid E - E \mid i$$


解析: 对于句子 $i + i * i$, 根据不同的优先级理解, 构造出以下两棵完全不同的分析树:

1. 右结合/先乘后加: 先将后两个 i 通过 $E \rightarrow E * E$ 结合, 再与第一个 i 进行加法结合。
2. 左结合/先加后乘: 先将前两个 i 通过 $E \rightarrow E + E$ 结合, 再与第三个 i 进行乘法结合。



例题 3-7: 绘制例题 3-2 的 CFG 派生树。

解析:



3.3 自动机理论 ★★★

自动机分为四类：有限自动机（FA）、下推自动机（PDA）、线性界限自动机（LBA）和图灵机（TM）。每种自动机对应一类文法。


文法类型	文法名称	等价自动机
3 型	正则文法	有限自动机（FA）
2 型	上下文无关（CFG）	下推自动机（PDA）
1 型	上下文有关（CSG）	线性界限自动机（LBA）
0 型	无约束文法	图灵机（TM）

3.3.1 有限自动机（FA）——【2025 · 真题选择 T16】


★★ 确定有限自动机（DFA）：五元组 $M = (\sum, Q, \delta, q_0, F)$ ，其中 $\delta : Q \times \sum \rightarrow Q$ 为单值转移函数。接受语言：

$$T(M) = \{x \mid \delta(q_0, x) \in F\}$$

状态变换图：映射 $\delta(q, a) = q'$ 可以由状态变换图描述。



为了明确起见，终止状态用双圈表示，起始状态用有“开始”标记的箭头表示。如：



DFA 定义的语言：如果一个句子 x 使得有限自动机 M 有 $\delta(q_0, x) = p, p \in F$ ，那么，称句子 x 被 M 接受。由 M 定义的语言 $T(M)$ 就是被 M 接受的句子的全集。即：

$$T(M) = \{x \mid \delta(q_0, x) \in F\}$$

例题 3-8：设 M 是一个有限自动机， M 的状态变换图如下所示。

问：链 $x = 110101$ 能否被 M 接受？写出该自动机的状态语义？

```
graph TD; start(( )) -- 开始 --> q0((q0)); q0 -- 1 --> q1(((q1))); q1 -- 1 --> q0; q0 -- 0 --> q2((q2)); q2 -- 0 --> q0; q1 -- 0 --> q3((q3)); q3 -- 0 --> q1; q2 -- 1 --> q3; q3 -- 1 --> q2
```

解析：链 $x = 110101$ 能被 M 接受。 $T(M) = \{\text{含偶数个0和偶数个1的链}\}$

非确定有限自动机 (NFA): 五元组 $M = (\Sigma, Q, \delta, q_0, F)$, 其中 $\delta: Q \times \Sigma \rightarrow 2^Q$ 为多值转移函数。接受语言:

$$T(M) = \{x \mid \exists p \in \delta(q_0, x), p \in F\}$$

定理: NFA 与 DFA 等价, 任意 NFA 均可转化为等价的 DFA。此外, 正则文法与有限自动机等价, 即任意正则文法 G 存在等价的 FA 满足 $L(G) = L(M)$, 反之亦然。

NFA 与 DFA 的唯一区别:

- 在 NFA 中 $\delta(q, a)$ 是一个状态集合;
- 而在 DFA 中 $\delta(q, a)$ 是一个状态。

3.3.2 下推自动机、图灵机、线性界限自动机

下推自动机 (PDA): 七元组 $M = (\Sigma, Q, \Gamma, \delta, q_0, Z_0, F)$, 在 FA 基础上增加下推存储器 (栈)。PDA 与 CFG 等价, 可识别上下文无关语言。

图灵机 (TM): 六元组 $T = (\Sigma, Q, \Gamma, \delta, q_0, F)$, 可改写输入带、左右移动, 与 0 型文法等价。

线性界限自动机 (LBA): 受限图灵机, 读写头不超出输入串范围, 与 1 型文法等价。

3.4 课后习题

1. 下列形式语言是哪种文法系统 ()

$$N = \{S, A, B, C\}, \Sigma = \{a, b, c\},$$

$$P: S \rightarrow ABC$$

$$A \rightarrow aA \mid a$$

$$B \rightarrow bB \mid b$$

$$C \rightarrow BA \mid c$$

- A. 上下文有关文法 B. 上下文无关文法 C. 正则文法 D. 无约束文法

解析: B。根据文法产生式, 所有规则的左部都仅包含一个非终结符 (S, A, B, C), 这符合上下文无关文法 (2 型文法) 的定义。此外, 存在形如 $S \rightarrow ABC$ 和 $C \rightarrow BA$ 这样右部包含多个非终结符的规则, 因此它不符合正则文法 (3 型文法, 要求右端最多一个非终结符且在最右或最左) 的严格限制。故该系统属于上下文无关文法。

2. 确定的有限自动机 M 是一个五元组 $(\Sigma, Q, \delta, q_0, F)$, 其中 Σ 代表的含义是 ()

- A. 状态的有限集合 B. 初始状态 C. 输入符号的有穷集合 D. 终止状态集合


解析: C。在确定的有限自动机 (DFA) 的五元组定义中, 各符号含义如下: Q 是状态的有穷集合, Σ 是输入字母表 (即输入符号的有穷集合), δ 是状态转移函数, q_0 是唯一的初始状态, F 是终止 (接受) 状态集合。

3. 设文法 G 由如下规则定义： $S \rightarrow AB$; $A \rightarrow Aa \mid bB$; $B \rightarrow a \mid Sb$


给出下列句子形式的派生树：(1) baabaab (2) bBABb

解析：

(1) 句子 baabaab 的派生树如下：



(2) 句子形式 bBABb 的派生树如下：



4. 请将右线性正则文法 G ($S \rightarrow aA$; $A \rightarrow bB$; $B \rightarrow a \mid bB$) 转换对应自动机的状态转换图。

解析：根据右线性文法构造有穷自动机 (NFA) 的规则：文法非终结符 S, A, B 作为自动机的状态， S 为初始状态；并额外增加一个终止状态 f 。


对于 $S \rightarrow aA$ ，构造从 S 到 A 标记为 a 的转移；

对于 $A \rightarrow bB$ ，构造从 A 到 B 标记为 b 的转移；

对于 $B \rightarrow bB$ ，构造 B 上标记为 b 的自环；

对于 $B \rightarrow a$ (相当于 $B \rightarrow a\epsilon$)，构造从 B 到终态 f 标记为 a 的转移。

对应的状态转换图如下：



第四讲 隐马尔可夫模型

4.1 HMM 的基本概念 ★★★

隐马尔可夫模型（Hidden Markov Model, HMM）：时序概率模型，描述由一个隐藏的马尔可夫链随机生成不可观测的状态序列，再由各状态生成观测序列的过程。属于生成模型。
三要素 $\lambda = (A, B, \pi)$ ：设 $Q = \{q_1, \dots, q_N\}$ 为状态集合， $V = \{v_1, \dots, v_M\}$ 为观测集合。

- $A = [a_{ij}]_{N \times N}$ ：状态转移矩阵， $a_{ij} = P(i_{t+1} = q_j \mid i_t = q_i)$
- $B = [b_j(k)]_{N \times M}$ ：观测概率矩阵， $b_j(k) = P(o_t = v_k \mid i_t = q_j)$
- $\pi = (\pi_i)$ ：初始状态概率向量， $\pi_i = P(i_1 = q_i)$

两个基本假设：

1. 齐次马尔可夫性：当前时刻状态只依赖于前一时刻的状态，与更早状态和观测无关。

$$P(i_t \mid i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t \mid i_{t-1})$$

2. 观测独立性：当前时刻的观测只依赖于该时刻的状态，与其他时刻的状态和观测无关。

$$P(o_t \mid i_T, o_T, i_{T-1}, o_{T-1}, \dots, i_1, o_1) = P(o_t \mid i_t)$$

引例（盒子和球模型）：4 个盒子，均装有红、白两种球。初始时等概率选择盒子（ $\pi_i = 0.25$ ），从该盒中随机抽一个球记录颜色后放回，再按给定概率转移到下一个盒子。重复 5 次。
分析：状态（盒子编号）：1/2/3/4；观测（球的颜色）：红/白；观测序列 $O = (\text{红}, \text{红}, \text{白}, \text{白}, \text{红})$

状态转移矩阵 $A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}$ ，观测概率矩阵 $B = \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}$

注：该模型可用三个基本问题求解：给定 O 和 λ ，求概率 $P(O \mid \lambda)$ ；给定 O 学习参数 λ ；给定 O 和 λ 求最优状态序列。

4.2 三个基本问题——【2025 · 真题选择 T18】

问题	解决方法	方法本质	解决了什么	描述	已知	求解
识别问题	前向后向	递推计算	给定 λ 和 O 计算下一个观测序列 O 出现的概率 $P(O \lambda)$	如何评估模型与观测序列之间的匹配程度	$\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$	$P(O \lambda)$
学习问题	BW算法	极大似然估计	给定观测序列 O ，估计模型 λ 参数，使得模型观测序列的条件概率 $P(O \lambda)$ 最大	如何训练模型使其最好地描述观测数据	$O = (o_1, o_2, \dots, o_T)$	$\lambda = (A, B, \pi)$ 使得 $P(O \lambda)$ 最大
解码问题	维特比算法	动态规划求解最优路径	给定 O 和 λ ，求给定观测序列条件下，最可能出现的对应的状态序列	如何根据观测序列推断出隐藏的模型状态	$\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$	使 $P(O \lambda)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$

4.3 前向算法 ★★★

前向概率： $\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i \mid \lambda)$ ，表示到时刻 t 观测序列为 $o_1, \dots, o_t$ 且状态为 q_i 的联合概率。

递推公式：

$$\alpha_1(i) = \pi_i b_i(o_1), \quad \alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1})$$

终止： $P(O \mid \lambda) = \sum_{i=1}^N \alpha_T(i)$ 。

计算量为 $O(N^2T)$ ，远优于直接枚举法的 $O(TN^T)$ 。

例题 4-1（前向算法）： 设 HMM 参数为：

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

观测序列 $O = (\text{红}, \text{白}, \text{红})$ ，用前向算法求 $P(O \mid \lambda)$ 。

解析：

步骤 1 ($t = 1, o_1 = \text{红}$):

$$\alpha_1(1) = \pi_1 b_1(\text{红}) = 0.2 \times 0.5 = 0.10$$

$$\alpha_1(2) = \pi_2 b_2(\text{红}) = 0.4 \times 0.4 = 0.16$$

$$\alpha_1(3) = \pi_3 b_3(\text{红}) = 0.4 \times 0.7 = 0.28$$

步骤 2 ($t = 2, o_2 = \text{白}$):

$$\alpha_2(1) = [0.1 \times 0.5 + 0.16 \times 0.3 + 0.28 \times 0.2] \times 0.5 = 0.077$$

$$\alpha_2(2) = [0.1 \times 0.2 + 0.16 \times 0.5 + 0.28 \times 0.3] \times 0.6 = 0.1104$$

$$\alpha_2(3) = [0.1 \times 0.3 + 0.16 \times 0.2 + 0.28 \times 0.5] \times 0.3 = 0.0606$$

步骤 3 ($t = 3, o_3 = \text{红}$):

$$\alpha_3(1) = [0.077 \times 0.5 + 0.1104 \times 0.3 + 0.0606 \times 0.2] \times 0.5 = 0.04187$$

$$\alpha_3(2) = [0.077 \times 0.2 + 0.1104 \times 0.5 + 0.0606 \times 0.3] \times 0.4 = 0.03551$$

$$\alpha_3(3) = [0.077 \times 0.3 + 0.1104 \times 0.2 + 0.0606 \times 0.5] \times 0.7 = 0.11523$$

步骤 4 (终止):

$$P(O \mid \lambda) = 0.04187 + 0.03551 + 0.11523 = 0.19261$$

4.4 后向算法 ★★★

后向概率: $\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T \mid i_t = q_i, \lambda)$, 表示在时刻 t 状态为 q_i 的条件下, 未来观测序列为 $o_{t+1}, \dots, o_T$ 的条件概率。

递推公式:

$$\beta_T(i) = 1, \quad \beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)$$

终止: $P(O \mid \lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$

例题 4-2 (后向算法): 设 HMM 参数为:

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

观测序列 $O = (\text{红}, \text{白}, \text{红}, \text{白})$, 用后向算法求 $P(O \mid \lambda)$ 。

解析:

初始化 ($t = 4$): $\beta_4(1) = \beta_4(2) = \beta_4(3) = 1$

$t = 3$ ($o_4 = \text{白}$):

$$\beta_3(1) = \sum_{j=1}^3 a_{1j} b_j(\text{白}) \beta_4(j) = 0.5 \times 0.5 + 0.2 \times 0.6 + 0.3 \times 0.3 = 0.46$$

$$\beta_3(2) = \sum_{j=1}^3 a_{2j} b_j(\text{白}) \beta_4(j) = 0.3 \times 0.5 + 0.5 \times 0.6 + 0.2 \times 0.3 = 0.51$$

$$\beta_3(3) = \sum_{j=1}^3 a_{3j} b_j(\text{白}) \beta_4(j) = 0.2 \times 0.5 + 0.3 \times 0.6 + 0.5 \times 0.3 = 0.43$$

$t = 2$ ($o_3 = \text{红}$):

$$\begin{aligned} \beta_2(1) &= \sum_{j=1}^3 a_{1j} b_j(\text{红}) \beta_3(j) = 0.5 \times 0.5 \times 0.46 + 0.2 \times 0.4 \times 0.51 + 0.3 \times 0.7 \times 0.43 \\ &= 0.115 + 0.0408 + 0.0903 = 0.2461 \end{aligned}$$

$$\begin{aligned} \beta_2(2) &= \sum_{j=1}^3 a_{2j} b_j(\text{红}) \beta_3(j) = 0.3 \times 0.5 \times 0.46 + 0.5 \times 0.4 \times 0.51 + 0.2 \times 0.7 \times 0.43 \\ &= 0.069 + 0.102 + 0.0602 = 0.2312 \end{aligned}$$

$$\begin{aligned} \beta_2(3) &= \sum_{j=1}^3 a_{3j} b_j(\text{红}) \beta_3(j) = 0.2 \times 0.5 \times 0.46 + 0.3 \times 0.4 \times 0.51 + 0.5 \times 0.7 \times 0.43 \\ &= 0.046 + 0.0612 + 0.1505 = 0.2577 \end{aligned}$$

$t = 1$ ($o_2 = \text{白}$):

$$\begin{aligned}\beta_1(1) &= \sum_{j=1}^3 a_{1j} b_j(\text{白}) \beta_2(j) = 0.5 \times 0.5 \times 0.2461 + 0.2 \times 0.6 \times 0.2312 + 0.3 \times 0.3 \times 0.2577 \\ &= 0.061525 + 0.027744 + 0.023193 = 0.112462 \\ \beta_1(2) &= 0.3 \times 0.5 \times 0.2461 + 0.5 \times 0.6 \times 0.2312 + 0.2 \times 0.3 \times 0.2577 \\ &= 0.036915 + 0.06936 + 0.015462 = 0.121737 \\ \beta_1(3) &= 0.2 \times 0.5 \times 0.2461 + 0.3 \times 0.6 \times 0.2312 + 0.5 \times 0.3 \times 0.2577 \\ &= 0.02461 + 0.041616 + 0.038655 = 0.104881\end{aligned}$$

终止:

$$\begin{aligned}P(O | \lambda) &= \sum_{i=1}^3 \pi_i b_i(o_1) \beta_1(i) \\ &= 0.2 \times 0.5 \times 0.112462 + 0.4 \times 0.4 \times 0.121737 + 0.4 \times 0.7 \times 0.104881 \\ &= 0.011246 + 0.019478 + 0.029367 = 0.060091\end{aligned}$$

4.5 Baum-Welch 算法 (EM 算法)

Baum-Welch 算法用于 HMM 的参数学习。观测序列 O 为观测数据, 状态序列 I 为隐数据, 属于含隐变量的参数估计问题, 用 EM 算法求解。

4.6 维特比算法 ★★★

维特比算法 (Viterbi Algorithm): 用动态规划求解概率最大的路径 (最优状态序列)。

$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda)$: 时刻 t 到状态 q_i 的所有路径中的最大概率。

$\psi_t(i) = \arg \max_j [\delta_{t-1}(j) a_{ji}]$: 达到该最大概率的前一状态。

算法步骤:

1. 初始化: $\delta_1(i) = \pi_i b_i(o_1)$, $\psi_1(i) = 0$
2. 递推: $\delta_t(i) = \max_j [\delta_{t-1}(j) a_{ji}] b_i(o_t)$, $\psi_t(i) = \arg \max_j [\delta_{t-1}(j) a_{ji}]$
3. 终止: $P^* = \max_i \delta_T(i)$, $i_T^* = \arg \max_i \delta_T(i)$
4. 回溯: $i_t^* = \psi_{t+1}(i_{t+1}^*)$, $t = T - 1, \dots, 1$

例题 4-3 (维特比算法): 设 HMM 参数为:

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

观测序列 $O = (\text{红}, \text{白}, \text{红})$, 求最优状态序列 I^* 。

解析:

步骤 1 ($t = 1$):

$$\begin{aligned} \delta_1(1) &= 0.2 \times 0.5 = 0.10, \\ \delta_1(2) &= 0.4 \times 0.4 = 0.16, \\ \delta_1(3) &= 0.4 \times 0.7 = 0.28, \quad \psi_1(i) = 0 \end{aligned}$$

步骤 2 ($t = 2, o_2 = \text{白}$):

$$\begin{aligned} \delta_2(1) &= \max\{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5 \\ &= \max(0.05, 0.048, 0.056) \times 0.5 = 0.028 & \psi_2(1) &= 3 \\ \delta_2(2) &= \max\{0.10 \times 0.2, 0.16 \times 0.5, 0.28 \times 0.3\} \times 0.6 \\ &= \max(0.02, 0.08, 0.084) \times 0.6 = 0.0504 & \psi_2(2) &= 3 \\ \delta_2(3) &= \max\{0.10 \times 0.3, 0.16 \times 0.2, 0.28 \times 0.5\} \times 0.3 \\ &= \max(0.03, 0.032, 0.14) \times 0.3 = 0.042 & \psi_2(3) &= 3 \end{aligned}$$

步骤 3 ($t = 3, o_3 = \text{红}$):

$$\begin{aligned} \delta_3(1) &= \max\{0.028 \times 0.5, 0.0504 \times 0.3, 0.042 \times 0.2\} \times 0.5 \\ &= \max(0.014, 0.01512, 0.0084) \times 0.5 = 0.00756 & \psi_3(1) &= 2 \\ \delta_3(2) &= \max\{0.028 \times 0.2, 0.0504 \times 0.5, 0.042 \times 0.3\} \times 0.4 \\ &= \max(0.0056, 0.0252, 0.0126) \times 0.4 = 0.01008 & \psi_3(2) &= 2 \\ \delta_3(3) &= \max\{0.028 \times 0.3, 0.0504 \times 0.2, 0.042 \times 0.5\} \times 0.7 \\ &= \max(0.0084, 0.01008, 0.021) \times 0.7 = 0.0147 & \psi_3(3) &= 3 \end{aligned}$$

步骤 4 (终止与回溯):

$$\begin{aligned} P^* &= \max_i \delta_3(i) = 0.0147, \quad i_3^* = 3 \\ i_2^* &= \psi_3(3) = 3, \quad i_1^* = \psi_2(3) = 3 \end{aligned}$$

故最优状态序列 $I^* = (3, 3, 3)$, 即三个时刻都最可能处于状态 3。

4.7 课后习题

1. 解释 HMM 中 Q, V, A, B, π 的含义；前向变量和后向变量 $\alpha_t(i), \beta_t(i)$ 的定义；Baum Welch 算法中 $\gamma_t(i), \xi_t(i, j)$ 的含义；维特比算法中 $\delta_t(i), \psi_t(i)$ 的含义。

解析：

- Q 是所有可能的状态的集合， V 是所有可能的观测的集合， A 是状态转移概率矩阵， B 是观测概率矩阵， π 是初始状态概率向量。
- 前向变量 $\alpha_t(i)$ 定义为在时刻 t 部分观测序列为 $o_1, o_2, \dots, o_t$ 且状态为 q_i 的概率。
- 后向变量 $\beta_t(i)$ 定义为在时刻 t 状态为 q_i 的条件下，从 $t+1$ 到 T 的部分观测序列为 $o_{t+1}, o_{t+2}, \dots, o_T$ 的概率。
- $\gamma_t(i)$ 表示在时刻 t 处于状态 q_i 的概率， $\xi_t(i, j)$ 表示在时刻 t 处于状态 q_i 且在时刻 $t+1$ 处于状态 q_j 的联合概率。
- $\delta_t(i)$ 定义为在时刻 t 状态为 i 的所有单个路径 $(i_1, i_2, \dots, i_t)$ 中概率最大值； $\psi_t(i)$ 为维特比算法的回溯指针，定义为使时刻 t 状态 i 的路径概率取最大值时，对应的第 $t-1$ 时刻的状态索引，用于最终反向回溯还原全局最优隐状态序列。

2. 给定盒子和球组成的隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，其中，

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \pi = (0.2, 0.4, 0.4)^T$$

设 $T = 3$ ， $O = (\text{红}, \text{白}, \text{红})$ ，试用后向算法计算 $P(O|\lambda)$ 。

(1) 初始化: $\beta_3(1) = 1, \beta_3(2) = 1, \beta_3(3) = 1.$

(2) $\beta_2(1) = 0.5 \times 0.5 \times 1 + 0.2 \times 0.4 \times 1 + 0.3 \times 0.7 \times 1 = 0.54.$

$\beta_2(2) = 0.3 \times 0.5 \times 1 + 0.5 \times 0.4 \times 1 + 0.2 \times 0.7 \times 1 = 0.49.$

$\beta_2(3) = 0.2 \times 0.5 \times 1 + 0.3 \times 0.4 \times 1 + 0.5 \times 0.7 \times 1 = 0.57.$

$\beta_1(1) = 0.5 \times 0.5 \times 0.54 + 0.2 \times 0.6 \times 0.49 + 0.3 \times 0.3 \times 0.57 = 0.2457$

$\beta_1(2) = 0.3 \times 0.5 \times 0.54 + 0.5 \times 0.6 \times 0.49 + 0.2 \times 0.3 \times 0.57 = 0.2622$

$\beta_1(3) = 0.2 \times 0.5 \times 0.54 + 0.3 \times 0.6 \times 0.49 + 0.5 \times 0.3 \times 0.57 = 0.2277$

(3) $P(O|\lambda) = 0.2 \times 0.5 \times 0.2457 + 0.4 \times 0.4 \times 0.2622 + 0.4 \times 0.7 \times 0.2277$
 $= 0.02457 + 0.041952 + 0.063756$

$= 0.13028.$

3. 给定盒子和球组成的隐马尔可夫模型 $\lambda = (A, B, \pi)$, 其中,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \pi = (0.2, 0.4, 0.4)^T$$

设 $T = 4$, $O = (\text{红}, \text{白}, \text{红}, \text{白})$, 试用维特比算法求最优路径 $I^* = (i_1^*, i_2^*, i_3^*, i_4^*)$ 。

(1) 初始化: $\delta_1(1) = 0.2 \times 0.5 = 0.1$ $\psi_1(1) = \psi_1(2) = \psi_1(3) = 0$
 $\delta_1(2) = 0.4 \times 0.4 = 0.16$
 $\delta_1(3) = 0.4 \times 0.7 = 0.28$

(2) 递推计算:

$\delta_2(1) = \max \{0.1 \times 0.5, 0.16 \times 0.3, \underline{0.28 \times 0.2}\} \times 0.5 = 0.028$ $\psi_2(1) = 3$
 $\delta_2(2) = \max \{0.1 \times 0.2, 0.16 \times 0.5, \underline{0.28 \times 0.5}\} \times 0.6 = 0.0504$ $\psi_2(2) = 3$
 $\delta_2(3) = \max \{0.1 \times 0.3, 0.16 \times 0.2, \underline{0.28 \times 0.5}\} \times 0.3 = 0.042$ $\psi_2(3) = 3$

$\delta_3(1) = \max \{0.028 \times 0.5, \underline{0.0504 \times 0.3}, 0.042 \times 0.2\} \times 0.5 = 0.00756$ $\psi_3(1) = 2$
 $\delta_3(2) = \max \{0.028 \times 0.2, \underline{0.0504 \times 0.5}, 0.042 \times 0.3\} \times 0.4 = 0.01008$ $\psi_3(2) = 2$
 $\delta_3(3) = \max \{0.028 \times 0.3, 0.0504 \times 0.2, \underline{0.042 \times 0.5}\} \times 0.7 = 0.014$ $\psi_3(3) = 3$

$\delta_4(1) = \max \{\underline{0.00756 \times 0.5}, 0.01008 \times 0.3, 0.014 \times 0.2\} \times 0.5 = 0.00189$ $\psi_4(1) = 1$
 $\delta_4(2) = \max \{0.00756 \times 0.2, \underline{0.01008 \times 0.5}, 0.014 \times 0.3\} \times 0.6 = 0.003024$ $\psi_4(2) = 2$
 $\delta_4(3) = \max \{0.00756 \times 0.3, 0.01008 \times 0.2, \underline{0.014 \times 0.5}\} \times 0.3 = 0.002205$ $\psi_4(3) = 3$

(3) 终止: $\max \{\delta_4(1), \delta_4(2), \delta_4(3)\} = 0.003024$ $i_4^* = 2$

回溯: $i_3^* = 2, i_2^* = 2, i_1^* = 3$ 故 $I^* = (3, 2, 2, 2)$

第五讲 条件随机场

5.1 概率无向图模型（马尔可夫随机场）

概率无向图模型，亦称**马尔可夫随机场**：由无向图 $G = (V, E)$ 表示联合概率分布，图中结点 $v \in V$ 表示随机变量 Y_v ，边 $e \in E$ 表示变量间的直接依赖关系。

三种等价的马尔可夫性：

- **成对马尔可夫性**：设 u, v 是无向图 G 中任意两个没有边直接连接的结点，对应的随机变量为 Y_u 与 Y_v 。在给定其余所有结点变量 Y_O 的条件下， Y_u 与 Y_v 条件独立，即：

$$P(Y_u, Y_v | Y_O) = P(Y_u | Y_O)P(Y_v | Y_O)$$

- **局部马尔可夫性**：设 $v \in V$ 是无向图 G 中的任意一个结点， W 是与 v 有边连接的所有邻接结点的集合。在给定邻接结点变量 Y_W 的条件下， Y_v 与其余所有独立结点变量 Y_O 条件独立，即：

$$P(Y_v, Y_O | Y_W) = P(Y_v | Y_W)P(Y_O | Y_W)$$

- **全局马尔可夫性**：设结点集合 C 是分离开结点集合 A 与 B 的分割集。在给定分割集变量 Y_C 的条件下，集合 A 与 B 对应的随机变量组 Y_A 与 Y_B 条件独立，即：

$$P(Y_A, Y_B | Y_C) = P(Y_A | Y_C)P(Y_B | Y_C)$$

★★★**团** (clique)：无向图 G 中任意两个结点均有边连接的结点子集。若在一个团中无法再添加任何一个结点使其仍保持为团，则称该子集为**最大团** (maximal clique)。

5.2 条件随机场


线性链条件随机场 (Linear-Chain CRF)：

设 $X = (X_1, \dots, X_n)$ 为输入观测序列， $Y = (Y_1, \dots, Y_n)$ 为对应的输出标记（状态）序列。在给定观测序列 X 的条件下，若随机变量序列 Y 构成的条件概率分布 $P(Y | X)$ 满足**图结构的条件马尔可夫性**，即：


$$P(Y_i | X, Y_1, \dots, Y_{i-1}, Y_{i+1}, \dots, Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$

对任意位置 $i = 1, 2, \dots, n$ 均成立（在边界 $i = 1$ 或 $i = n$ 时只考虑单侧）

则称该条件概率分布为**线性链条件随机场**。



(a) 线性链条件随机场

(b) X 和 Y 有相同的图结构的线性链条件随机场

★★★ 参数化形式：线性链 CRF 在给定观测序列 x 时，某个特定标记序列 y 的条件概率：

$$P(y | x) = \frac{1}{Z(x)} \exp \left(\underbrace{\sum_{i=1}^{n+1} \sum_{k=1}^K \lambda_k t_k(y_{i-1}, y_i, x, i)}_{\text{转移特征加权和}} + \underbrace{\sum_{i=1}^n \sum_{l=1}^L \mu_l s_l(y_i, x, i)}_{\text{状态特征加权和}} \right)$$

转移特征加权和

状态特征加权和

$$Z(x) = \sum_y \exp \left(\sum_{i=1}^{n+1} \sum_{k=1}^K \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i=1}^n \sum_{l=1}^L \mu_l s_l(y_i, x, i) \right)$$

其中：

- $t_k(y_{i-1}, y_i, x, i)$: 定义在边上的**转移特征函数**，建模相邻标记间的转移行为，权重为 λ_k 。
- $s_l(y_i, x, i)$: 定义在结点上的**状态特征函数**，建模当前位置的标记行为，权重为 μ_l 。
- 特征函数通常取二值函数形式（满足条件取 1，否则取 0）。为统一边界，通常设定隐式辅助标记 $y_0 = \text{start}$ 和 $y_{n+1} = \text{stop}$ 。

5.3 学习算法与预测

CRF 作为判别式模型，通常在训练集上采用极大似然估计（MLE）加正则化项进行参数学习，其目标函数具有全局凹性，能保证收敛到全局最优解。常见优化算法包括改进的迭代缩放法（IIS）、梯度下降法以及拟牛顿法（如 L-BFGS）。

在概率计算中，为了高效求解状态的边缘概率分布，需要引入**前向—后向算法**。定义前向向量 $\alpha_i(x)$ 和后向向量 $\beta_i(x)$ 递推关系为：

$$\alpha_i^\top(x) = \alpha_{i-1}^\top(x) M_i(x), \quad \alpha_0(y) = \begin{cases} 1, & y = \text{start} \\ 0, & \text{other} \end{cases}$$

$$\beta_i(x) = M_{i+1}(x) \beta_{i+1}(x), \quad \beta_{n+1}(y) = \begin{cases} 1, & y = \text{stop} \\ 0, & \text{other} \end{cases}$$

配分函数可直接由端点表达为： $Z(x) = \alpha_n^\top(x) \cdot 1 = \beta_1(\text{start})$ 。

预测算法（维特比解码算法）：CRF 的预测任务旨在寻找给定观测下非规范化条件概率最大的最优状态序列 y^* 。类似于隐马尔可夫模型，其核心算法为动态规划维特比算法：

★★★线性链 CRF 维特比算法步骤:

1. 初始化 (位置 $i = 1$): 对各候选状态 $j = 1, 2, \dots, m$, 计算其非规范化起点概率:

$$\delta_1(j) = \sum_{k=1}^K w_k f_k(y_0 = \text{start}, y_1 = j, x, 1), \quad j = 1, 2, \dots, m$$

2. 递推循环 (对各个位置 $i = 2, 3, \dots, n$): 对于当前位置的各候选标记状态 $l = 1, 2, \dots, m$, 分别计算局部最大对数概率并记录最佳前驱路径指针:

$$\delta_i(l) = \max_{1 \leq j \leq m} \left\{ \delta_{i-1}(j) + \sum_{k=1}^K w_k f_k(y_{i-1} = j, y_i = l, x, i) \right\}, \quad l = 1, 2, \dots, m$$

$$\Psi_i(l) = \arg \max_{1 \leq j \leq m} \left\{ \delta_{i-1}(j) + \sum_{k=1}^K w_k f_k(y_{i-1} = j, y_i = l, x, i) \right\}, \quad l = 1, 2, \dots, m$$

3. 终止条件 (终点位置 $i = n + 1$): 引入结束状态 stop , 求得全局最优路径的最高对数非规范化分值及终点状态指针:

$$\max_y \sum_{k=1}^K w_k f_k(y, x) = \max_{1 \leq j \leq m} \left\{ \delta_n(j) + \sum_{k=1}^K w_k f_k(y_n = j, y_{n+1} = \text{stop}, x, n + 1) \right\}$$

$$y_n^* = \arg \max_{1 \leq j \leq m} \left\{ \delta_n(j) + \sum_{k=1}^K w_k f_k(y_n = j, y_{n+1} = \text{stop}, x, n + 1) \right\}$$

4. 路径回溯 (倒序反推 $i = n - 1, n - 2, \dots, 1$):

$$y_i^* = \Psi_{i+1}(y_{i+1}^*)$$


最终得到的序列 $y^* = (y_1^*, y_2^*, \dots, y_n^*)$ 即为全局最优最优标记序列。

5.4 CRF 与 HMM 的关系

- 判别式对决生成式: CRF 是判别模型, 直接对条件概率 $P(Y | X)$ 建模, 不对观测数据 X 的分布进行刻画; HMM 是生成模型, 对联合概率 $P(X, Y) = P(Y)P(X|Y)$ 建模, 必须显式估计观测的发射概率。
- 打破独立性假设限制: HMM 为了简化求解, 强制做出了极其严苛的“观测独立性假设”(即当前位置的观测仅与当前状态独立相关)。而 CRF 彻底避免了这一假设, 能够灵活、任意地加入重叠特征、丰富的前后长距离上下文特征。
- 全局归一化与标注偏置: HMM 在每个状态节点上进行局部归一化, 容易带来标注偏置问题 (Label Bias Problem); 而 CRF 采用全局配分函数 $Z(x)$ 进行全局范围内的概率归一化, 克服了局部的短视性, 因而序列标注性能更强。

5.5 课后习题

1. 列举图中的最大团_____



解析：在无向图中，**团**（Clique）是指图中任意两个节点都相连的子图。**最大团**（Maximal Clique）是指不能再向其中加入任何一个相邻节点构成更大团的团。

观察图可知，包含 3 个节点的完全子图有两个，分别是由 Y_1, Y_2, Y_3 构成的三角形，以及由 Y_2, Y_3, Y_4 构成的三角形。不存在包含 4 个节点的完全子图（因为 Y_1 和 Y_4 不相连）。

因此，图中的最大团为： $\{Y_1, Y_2, Y_3\}$ 和 $\{Y_2, Y_3, Y_4\}$ 。

2. 关于 HMM（隐马尔可夫模型）和 CRF（条件随机场）的区别，下列说法中**错误**的是？

- A. HMM 是有向图，CRF 是无向图。
- B. CRF 是描述两个序列联合分布 $P(I, O)$ 的概率模型；HMM 是给定观测状态 O 的条件下预测状态序列 I 的 $P(I|O)$ 的条件概率模型。
- C. HMM 是生成模型，CRF 是判别模型。
- D. HMM 只使用了局部特征（齐次马尔可夫假设和观测独立性假设），只能找到局部最优解；CRF 使用了全局特征（在所有特征进行全局归一化），可以得到全局的最优值。

解析：B


- **A 项正确：**从概率图模型分类来看，HMM 属于有向图模型（贝叶斯网络），存在由状态到观测的生成方向；CRF 属于无向图模型（马尔可夫随机场），通过定义在团上的特征函数进行计算。
- **B 项错误：**该选项将两者的定义完全颠倒。HMM 作为生成模型，对其状态序列 I 和观测序列 O 的**联合概率分布** $P(I, O)$ 进行建模；而 CRF 作为判别模型，直接对给定观测序列 O 时状态序列 I 的**条件概率分布** $P(I|O)$ 进行建模。
- **C 项正确：**这是 HMM 和 CRF 最本质的类别区分。HMM 属于生成模型，CRF 属于判别模型。
- **D 项正确：**HMM 强依赖于“齐次马尔可夫假设”与“观测独立性假设”，这使得它只能利用局部信息；而 CRF 可以定义任意复杂的全局特征函数，且通过配分函数（Partition Function） $Z(x)$ 进行全局归一化，克服了诸如 MEMM 等模型中的标注偏置（Label Bias）问题，从而更有效地求得全局最优解。

3. 参考下面的状态路径图，假设随机矩阵：

$$M_1(x) = \begin{bmatrix} 0 & 0 \\ 0.5 & 0.5 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} 0.3 & 0.7 \\ 0.7 & 0.3 \end{bmatrix},$$

$$M_3(x) = \begin{bmatrix} 0.5 & 0.5 \\ 0.6 & 0.4 \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$$

求起点 $\text{start} = 2$ ，终点 $\text{stop} = 2$ 的所有路径的状态序列 y 的概率及概率最大的状态序列。



解析：此题本质是计算条件随机场（CRF）/隐马尔可夫模型中的路径概率。

设状态序列为 $y = (y_1, y_2, y_3)$ ，路径非规范化概率：

$$P(y) = M_1(\text{start}, y_1) \cdot M_2(y_1, y_2) \cdot M_3(y_2, y_3) \cdot M_4(y_3, \text{stop})$$

已知起点 $\text{start} = 2$ （对应 M_1 的第 2 行），终点 $\text{stop} = 2$ （对应 M_4 的第 2 列）。

我们穷举所有 8 种可能的状态序列计算概率：

（注意：本题中各路径概率之和恰好为 1，因此非规范化概率即为最终概率）

- $y = (1, 1, 1)$: $P = 0.5 \times 0.3 \times 0.5 \times 1 = 0.075$
- $y = (1, 1, 2)$: $P = 0.5 \times 0.3 \times 0.5 \times 1 = 0.075$
- $y = (1, 2, 1)$: $P = 0.5 \times 0.7 \times 0.6 \times 1 = \mathbf{0.210}$
- $y = (1, 2, 2)$: $P = 0.5 \times 0.7 \times 0.4 \times 1 = 0.140$
- $y = (2, 1, 1)$: $P = 0.5 \times 0.7 \times 0.5 \times 1 = 0.175$
- $y = (2, 1, 2)$: $P = 0.5 \times 0.7 \times 0.5 \times 1 = 0.175$
- $y = (2, 2, 1)$: $P = 0.5 \times 0.3 \times 0.6 \times 1 = 0.090$
- $y = (2, 2, 2)$: $P = 0.5 \times 0.3 \times 0.4 \times 1 = 0.060$

综上所述，概率最大的状态序列为 $y = (1, 2, 1)$ ，其最大概率为 **0.21**。

4. 设有一标注问题：输入观测序列为 $X = (X_1, X_2, X_3)$ ，输出标记序列为 $Y = (Y_1, Y_2, Y_3)$ ， Y_1, Y_2, Y_3 取值于 $y = \{1, 2\}$ 。假设特征 t_k, s_l 和对应的权值 λ_k, μ_l 如下（这里只注明特征取值为 1 的条件，取值为 0 的条件省略）：

$t_1 = t_1(y_{i-1} = 1, y_i = 2, x, i), i = 2, 3$	$\lambda_1 = 1$
$t_2 = t_2(y_1 = 1, y_2 = 1, x, 2)$	$\lambda_2 = 0.6$
$t_3 = t_3(y_2 = 2, y_3 = 1, x, 3)$	$\lambda_3 = 1$
$t_4 = t_4(y_1 = 2, y_2 = 1, x, 2)$	$\lambda_4 = 1$
$t_5 = t_5(y_2 = 2, y_3 = 2, x, 3)$	$\lambda_5 = 0.2$
$s_1 = s_1(y_1 = 1, x, 1)$	$\mu_1 = 1$
$s_2 = s_2(y_i = 2, x, i), i = 1, 2$	$\mu_2 = 0.5$
$s_3 = s_3(y_i = 1, x, i), i = 2, 3$	$\mu_3 = 0.8$
$s_4 = s_4(y_3 = 2, x, 3)$	$\mu_4 = 0.5$

对给定的观测序列 x ，求标记序列为 $y = (y_1, y_2, y_3) = (1, 2, 2)$ 的非规范化条件概率（即没有除以规范化因子的条件概率）。

解析：对于给定的标记序列 $y = (1, 2, 2)$ ，我们需要找出所有被激活（取值为 1）的特征函数，并将它们的权重相加，最后求指数。

- 转移特征 t_k 激活情况：

位置 $i = 2$ 时， $y_1 = 1, y_2 = 2$ ，激活特征 t_1 （此时权重 $\lambda_1 = 1$ ）。

位置 $i = 3$ 时， $y_2 = 2, y_3 = 2$ ，激活特征 t_5 （此时权重 $\lambda_5 = 0.2$ ）。

- 状态特征 s_l 激活情况：

位置 $i = 1$ 时， $y_1 = 1$ ，激活特征 s_1 （此时权重 $\mu_1 = 1$ ）。

位置 $i = 2$ 时， $y_2 = 2$ ，激活特征 s_2 （此时权重 $\mu_2 = 0.5$ ）。

位置 $i = 3$ 时， $y_3 = 2$ ，激活特征 s_4 （此时权重 $\mu_4 = 0.5$ ）。

特征权重总和 $W = \lambda_1 + \lambda_5 + \mu_1 + \mu_2 + \mu_4 = 1 + 0.2 + 1 + 0.5 + 0.5 = 3.2$ 。

因此，该标记序列的非规范化条件概率为 $P(y = (1, 2, 2)|x) \propto \exp(3.2)$ 。

5. 若上题中计算标记序列改为 $y = (y_1, y_2, y_3) = (2, 1, 2)$ ，求非规范化条件概率。

解析：此题为上题的变式，我们重新检查标记序列 $y = (2, 1, 2)$ 下激活的特征。

- 转移特征 t_k 激活情况：

位置 $i = 2$ 时， $y_1 = 2, y_2 = 1$ ，激活特征 t_4 （此时权重 $\lambda_4 = 1$ ）。

位置 $i = 3$ 时， $y_2 = 1, y_3 = 2$ ，激活特征 t_1 （此时权重 $\lambda_1 = 1$ ）。

- 状态特征 s_l 激活情况：

位置 $i = 1$ 时， $y_1 = 2$ ，激活特征 s_2 （此时权重 $\mu_2 = 0.5$ ）。

位置 $i = 2$ 时， $y_2 = 1$ ，激活特征 s_3 （此时权重 $\mu_3 = 0.8$ ）。

位置 $i = 3$ 时， $y_3 = 2$ ，激活特征 s_4 （此时权重 $\mu_4 = 0.5$ ）。

特征权重总和 $W = \lambda_4 + \lambda_1 + \mu_2 + \mu_3 + \mu_4 = 1 + 1 + 0.5 + 0.8 + 0.5 = 3.8$ 。

因此，该标记序列的非规范化条件概率为 $P(y = (2, 1, 2)|x) \propto \exp(3.8)$ 。

6. 对观测序列 $\mathbf{X} = \{x_1, x_2, x_3\}$ 进行词性（标签）标注，求解最优标注序列。已知标签集合 $\mathbf{Y} = \{A, B, C\}$ （3 类标签，模拟词性标注：A = 名词、B = 动词、C = 形容词），序列长度 $n = 3$ ，观测词 x_1, x_2, x_3 对应标注 y_1, y_2, y_3 。特征函数与对应权重定义如下：

$$\begin{aligned} f_1(y_i = A, x_i) &= 1, \quad \lambda_1 = 1.2; \\ f_2(y_i = B, x_i) &= 1, \quad \lambda_2 = 0.8; \\ f_3(y_i = C, x_i) &= 1, \quad \lambda_3 = 1.0; \\ f_4(y_{i-1} = A, y_i = A) &= 1, \quad \lambda_4 = 0.6; \\ f_5(y_{i-1} = A, y_i = B) &= 1, \quad \lambda_5 = 0.9; \\ f_6(y_{i-1} = A, y_i = C) &= 1, \quad \lambda_6 = 0.4; \\ f_7(y_{i-1} = B, y_i = A) &= 1, \quad \lambda_7 = 0.5; \\ f_8(y_{i-1} = B, y_i = B) &= 1, \quad \lambda_8 = 0.7; \\ f_9(y_{i-1} = B, y_i = C) &= 1, \quad \lambda_9 = 1.1; \\ f_{10}(y_{i-1} = C, y_i = A) &= 1, \quad \lambda_{10} = 0.3; \\ f_{11}(y_{i-1} = C, y_i = B) &= 1, \quad \lambda_{11} = 0.8; \\ f_{12}(y_{i-1} = C, y_i = C) &= 1, \quad \lambda_{12} = 0.6. \end{aligned}$$

解析：本题为 CRF 词性标注解码问题，目标求标注序列 $\mathbf{y} = (y_1, y_2, y_3)$ 使得全局得分

$$\text{score}(\mathbf{X}, \mathbf{y}) = \sum_{i=1}^3 \sum_{k=1}^3 \lambda_k f_k(y_i, x_i) + \sum_{i=2}^3 \sum_{k=4}^{12} \lambda_k f_k(y_{i-1}, y_i)$$

最大，采用维特比算法分三步递推：

解：初始化 $\delta_1(A) = 1.2, \delta_1(B) = 0.8, \delta_1(C) = 1.0$

递推：
 $(i=2)$
 $y_2 = A: \max \begin{cases} A \rightarrow A: 1.2 + 1.2 + 0.6 = 3.0 \\ B \rightarrow A: 0.8 + 1.2 + 0.5 = 2.5 \\ C \rightarrow A: 1.0 + 1.2 + 0.3 = 2.5 \end{cases} = 3.0$
 $y_2 = B: \max \begin{cases} A \rightarrow B: 1.2 + 0.8 + 0.9 = 2.9 \\ B \rightarrow B: 0.8 + 0.8 + 0.7 = 2.3 \\ C \rightarrow B: 1.0 + 0.8 + 0.8 = 2.6 \end{cases} = 2.9$
 $y_2 = C: \max \begin{cases} A \rightarrow C: 1.2 + 1.0 + 0.4 = 2.6 \\ B \rightarrow C: 0.8 + 1.0 + 1.1 = 2.9 \\ C \rightarrow C: 1.0 + 1.0 + 0.6 = 2.6 \end{cases} = 2.9$

递推：
 $(i=3)$
 $y_3 = A: \max \begin{cases} A \rightarrow A: 3.0 + 1.2 + 0.6 = 4.8 \\ B \rightarrow A: 2.9 + 1.2 + 0.5 = 4.6 \\ C \rightarrow A: 2.9 + 1.2 + 0.3 = 4.4 \end{cases} = 4.8$
 $y_3 = B: \max \begin{cases} A \rightarrow B: 3.0 + 0.8 + 0.9 = 4.7 \\ B \rightarrow B: 2.9 + 0.8 + 0.7 = 4.4 \\ C \rightarrow B: 2.9 + 0.8 + 0.8 = 4.5 \end{cases} = 4.7$
 $y_3 = C: \max \begin{cases} A \rightarrow C: 3.0 + 1.0 + 0.4 = 4.4 \\ B \rightarrow C: 2.9 + 1.0 + 1.1 = 5.0 \\ C \rightarrow C: 2.9 + 1.0 + 0.6 = 4.5 \end{cases} = 5.0$

回溯得： $(y_1, y_2, y_3) = (A, B, C)$ ，最大总得分为 5.0

第六讲 语言模型与语料库

语言模型 (Language Model) 用于刻画真实语言中词与词之间的组合规律, 表现为计算任意句子在真实世界中出现的概率。语言研究倾向于认为语言本身并非由随机抽取的单词序列构成, 词与词之间是有联系的, 语言模型正是刻画这种联系规律的模型。

6.1 本讲重点

1. 熟悉语言模型的概念;
2. 理解 N 元语法模型的参数估计方法及模型的简单应用方法;
3. 了解语言模型平滑的概念及原因;
4. 掌握语料库、语言知识库的概念定义;
5. 熟悉语料库类型的典型划分标准;
6. 熟悉 LDC 中文树库的概念及基本标注格式、标注符号的意义;
7. 熟悉 WordNet、HowNet 的概念与构建基本原理。

第一部分：语言模型

6.2 语言模型的定义 ★★——【2025·真题选择 T6】

语言模型用概率衡量句子的合理性。由链式规则 (chain rule):

$$P(S) = \prod_{i=1}^n P(w_i | w_1, \dots, w_{i-1})$$

其中 w_i 为统计基元 (字、词、短语等), $w_1, \dots, w_{i-1}$ 称为 w_i 的历史。但随历史长度增加, 不同历史数量呈指数级增长——若词汇表 $L = 5000$, 则 $m = 3$ 时的自由参数达 $L^3 = 1250$ 亿, 无法直接估计。

6.3 N-gram 模型 ★★★

N-gram 模型基于马尔可夫假设: 当前词的概率只依赖前 $n - 1$ 个词。

$$P(w_i | w_1, \dots, w_{i-1}) \approx P(w_i | w_{i-n+1}, \dots, w_{i-1})$$

Unigram ($n = 1$) 为 0 阶马尔可夫链,

Bigram ($n = 2$) 为 1 阶马尔可夫链,

Trigram ($n = 3$) 为 2 阶马尔可夫链。

最大似然估计 (MLE):

$$P_{\text{MLE}}(w_i | w_{i-n+1}, \dots, w_{i-1}) = \frac{C(w_{i-n+1}, \dots, w_i)}{C(w_{i-n+1}, \dots, w_{i-1})}$$

其中 $C(\cdot)$ 表示 N-gram 在语料中的出现频次。

例题 6-1: 假定训练语料如下:

[B] The cat is walking [E]

[B] The dog is swimming [E]

[B] The dog is running [E]

计算句子 The dog is walking 的概率。

解析: 首先, 转换为标准形式:

[B] The dog is walking [E]

用 2-gram 语言模型计算:

$$P(\text{The}|\text{[B]}) = \frac{c(\text{[B] The})}{c(\text{[B]})} = \frac{3}{3} = 1$$

$$P(\text{dog}|\text{The}) = \frac{c(\text{The dog})}{c(\text{The})} = \frac{2}{3}$$

$$P(\text{is}|\text{dog}) = \frac{c(\text{dog is})}{c(\text{dog})} = \frac{2}{2} = 1$$

$$P(\text{walking}|\text{is}) = \frac{c(\text{is walking})}{c(\text{is})} = \frac{1}{3}$$

$$\begin{aligned} &P(\text{[B] The dog is walking [E]}) \\ &= P(\text{[B]}) \times P(\text{The}|\text{[B]}) \times P(\text{dog}|\text{The}) \times P(\text{is}|\text{dog}) \times P(\text{walking}|\text{is}) \times P(\text{[E]}|\text{walking}) \\ &= 1 \times 1 \times \frac{2}{3} \times 1 \times \frac{1}{3} \times 1 = \frac{2}{9} \end{aligned}$$

例题 6-2: 给定语料

(1) "John read Moby Dick"

(2) "Mary read a different book"

(3) "She read a book by Cher"

计算句子 "John read a book" 的 Bigram 概率。

解析: 先在句首句尾分别添加 <s> 和 </s>, 统计二元频次:

- $C(\text{John} | \text{<s>}) = 1, C(\text{<s>}) = 3, P(\text{John} | \text{<s>}) = 1/3$
- $C(\text{read} | \text{John}) = 1, C(\text{John}) = 1, P(\text{read} | \text{John}) = 1$
- $C(\text{a} | \text{read}) = 2, C(\text{read}) = 3, P(\text{a} | \text{read}) = 2/3$
- $C(\text{book} | \text{a}) = 1, C(\text{a}) = 2, P(\text{book} | \text{a}) = 1/2$
- $C(\text{</s>} | \text{book}) = 1, C(\text{book}) = 2, P(\text{</s>} | \text{book}) = 1/2$

$$P(S) = \frac{1}{3} \times \frac{1}{1} \times \frac{2}{3} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{18} \approx 0.056$$

6.4 平滑技术 ★★

6.4.1 平滑技术的原因及概念

为什么需要平滑？

- N-gram 语言模型的参数估计中，无论采用多大的训练语料库，总是会存在大量零概率的情况，这与现实情况不符；
- N-gram 语言模型的参数估计采用的是最大似然估计，受限于训练语料库容量的限制，存在对非零概率放大的倾向。

什么是平滑？

为了让最大似然估计的结果更准确，降低高概率，提升低概率，尽量使概率分布趋于均匀，从而整体上让概率的估计结果更接近真实情况。

6.4.2 加法平滑法

Add-one 平滑 (Laplace 平滑): 将每个 N-gram 的计数加 1。其中 V 为词汇表大小。

$$P_{\text{add1}}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i) + 1}{C(w_{i-1}) + V}$$

例题 6-3: 假定训练语料如下：

[B] The cat is walking [E]

[B] The dog is swimming [E]

[B] The dog is running [E]

采用加一法计算 The walking is dog 的概率。

解析: 首先，将待计算的句子转换为包含起止符的标准形式：

[B] The walking is dog [E]

统计语料库中的无重复词汇构成的集合 V （词汇表不包含句子起止标记 [B] 和 [E]）：

$$V = \{The, cat, is, walking, dog, swimming, running\}$$

得出词汇表大小 $|V| = 7$ 。

统计相关单词在语料中出现的词频：

$$c([B]) = 3$$

$$c(The) = 3$$

$$c(walking) = 1$$

$$c(is) = 3$$

$$c(dog) = 2$$

根据加一平滑法公式

$$P(w_i|w_{i-1}) = \frac{c(w_{i-1}w_i) + 1}{c(w_{i-1}) + |V|}$$

分别计算各项条件概率：

$$P(The|[B]) = \frac{c([B]The) + 1}{c([B]) + |V|} = \frac{3 + 1}{3 + 7} = \frac{4}{10}$$

$$P(walking|The) = \frac{c(Thewalking) + 1}{c(The) + |V|} = \frac{0 + 1}{3 + 7} = \frac{1}{10}$$

$$P(is|walking) = \frac{c(walkingis) + 1}{c(walking) + |V|} = \frac{0 + 1}{1 + 7} = \frac{1}{8}$$

$$P(dog|is) = \frac{c(isdog) + 1}{c(is) + |V|} = \frac{2 + 1}{3 + 7} = \frac{3}{10}$$

$$P([E]|dog) = \frac{c(dog[E]) + 1}{c(dog) + |V|} = \frac{0 + 1}{2 + 7} = \frac{1}{9}$$

计算整句概率：

$$\begin{aligned} & P([B] The walking is dog [E]) \\ &= P(The|[B]) * P(walking|The) * P(is|walking) * P(dog|is) * P([E]|dog) \\ &= \frac{4}{10} * \frac{1}{10} * \frac{1}{8} * \frac{3}{10} * \frac{1}{9} \\ &= \frac{12}{72000} = \frac{1}{6000} \end{aligned}$$

例题 6-4：对例题 6-2 语料，词汇量 $|V| = 11$ 。用 Add-one 平滑重新计算句子”John read a book” 的 Bigram 概率，并与未平滑的结果比较。

解析：

$$P(\text{John} | <s>) = (1 + 1)/(3 + 11) = 2/14$$

$$P(\text{read} | \text{John}) = (1 + 1)/(1 + 11) = 2/12$$

$$P(\text{a} | \text{read}) = (2 + 1)/(3 + 11) = 3/14$$

$$P(\text{book} | \text{a}) = (1 + 1)/(2 + 11) = 2/13$$

$$P(</s> | \text{book}) = (1 + 1)/(2 + 11) = 2/13$$

$$P_{\text{add1}}(S) = \frac{2}{14} \times \frac{2}{12} \times \frac{3}{14} \times \frac{2}{13} \times \frac{2}{13} \approx 0.00003$$

平滑前概率为 $1/18 \approx 0.056$ ，平滑后大幅降低，这是因为将部分概率质量分配给了未出现的 N-gram。虽然该句子的概率变小了，但模型的整体鲁棒性得以提升，避免了零概率问题。

6.4.3 减值平滑法

基本思想：修改训练样本中事件的实际计数，使样本中（实际出现的）不同事件的概率之和小于 1，剩余的概率量分配给未见概率。

- Good-Turing 估计：用出现 $r + 1$ 次的 N-gram 数量来估计出现 r 次的 N-gram 的概率
- Katz Back-off（后备法）：对高频 N-gram 用 MLE，对低频或未出现的用低阶分布回退
- 绝对折扣法：从每个计数中减去固定折扣值
- 线性减值法：线性插值不同阶数的 N-gram

例题 6-5（Good-Turing 平滑）：假设要估计以 read 开始的 2-gram 概率，列出以 read 开始的所有 2-gram，并转化为频率信息。

r	n_r	r^*
1	2053	
2	458	
3	191	
4	107	
5	69	
6	48	
7	36	保持原来的计数

解析：根据 Good-Turing 平滑公式

$$r^* = (r + 1) \frac{n_{r+1}}{n_r}$$

代入计算得： r^* 分别为：0.446、1.25、2.24、3.22、4.17、5.25、7（保留）。

（补充）四种减值平滑法核心区别：

1. 减值逻辑不同
 - (a) 绝对减值：固定数值减值，与原计数无关；
 - (b) 线性减值：按比例减值，与原计数正相关；
 - (c) Good-Turing 法：通过频次分布动态修正计数，无固定减值参数；
 - (d) Katz 后退法：仅对高频项做同阶减值，低频项不做同阶减值。
2. 未出现事件处理不同：**Good-Turing**、**绝对减值**、**线性减值**均将腾出的概率在同阶所有未出现 N-gram 中平均分配；而 **Katz 后退法**对于未出现/低频事件不做同阶均分，直接退回到低阶模型估算概率。
3. 模型依赖不同：前三种方法仅依赖同阶 N-gram 的计数统计，无需低阶模型；Katz 后退法需要结合低阶 (n-1)gram 的统计结果，属于跨阶平滑。

第二部分：语料库与语言知识库

6.5 语料库的基本概念 ★★★

语料库 (Corpus): 系统收集、整理和存储的语言数据数据库, 为语言学研究提供实证基础。
语料库语言学 (Corpus Linguistics): 基于语料库进行语言研究的学科, 采用实证方法从真实语言数据中发现语言模式和规律。

6.6 语料库的类型 (划分标准) ★★

- 按内容构成和目的: 异质语料库、同质语料库、系统语料库、专用语料库
- 按语言种类: 单语、双语、多语
- 按时间维度: 共时语料库 (反映某一时期语言状态)、历时语料库 (追踪语言演变)
- 按标注: 生语料库 (未标注)、标注语料库 (按一定规范标注词性、句法、语义等)

6.7 LDC 中文树库 ★★——【2025 · 真题选择 T4】

LDC 中文树库 (LDC Chinese Treebank): 由美国语言数据联盟 (LDC) 发布的中文句法树库, 包含大量中文句子及其对应的句法结构标注。主要用于句法分析、依存分析等。

词性标签 (上图)、短语层级标签 (下图) 的含义及解析表

符号	含义	解析	符号	含义	解析
NN	普通名词	如 “苹果” “房间” “故事”	DEG	“的”	定语后的 “的”
NR	专有名词	如 “北京” “小明” “长城”	DER	“地”	状语后的 “地”
NT	时间名词	如 “今天” “明天” “去年”	DEC	“得”	补语前的 “得”
PN	代词	如 “我” “他” “我们” “这”	AS	体貌助词	“着” “了” “过” “去”
VV	动词	如 “吃” “看” “打扫” “旅行”	PU	标点符号	“。” “,” “?” “、”
VA	形容词	如 “美丽” “好” “感人” “干净”	SP	句末语气词	“吗” “呢” “啊”
AD	副词	如 “很” “慢慢” “飞快” “按时”	CS	连词	让步、条件连词, 如 “虽然” “只有”
P	介词	如 “在” “把” “从” “给”	CC	并列连词	如 “但” “和” “而且”
M	量词	如 “碗” “本” “个”	MD	情态动词	如 “能” “会” “应该” “才能”
CD	数词	如 “一” “三” “十”	DT	指示代词	如 “这” “那”
LC	方位词	如 “里” “外” “上” “下”			

符号	含义	解析
IP	句子	小句, 整个句子的最高层级
NP	名词短语	由名词、代词、数量词等构成
VP	动词短语	由动词、动词 + 宾语/补语等构成
PP	介词短语	介词 + 名词短语, 如 “在图书馆”
ADJP	形容词短语	由形容词、副词 + 形容词构成
ADVP	副词短语	由副词或副词性成分构成
QP	数量短语	数词 + 量词, 如 “一碗” “三个”
CLP	量词短语	单独量词或量词相关搭配
CP	“的” 字结构/定语从句结构	含小句 + “的”
DNP	“的” 字短语	名词短语 + “的”

例题 6-6: 利用上表进行分词、句法结构标注：“他还提出一系列具体措施的政策要点。”


解析: 分词标注:

他/PN 还/AD 提出/VV 一/CD 系列/M 具体/JJ 措施/NN 和/CC 政策/NN 要点/NN 。/PU

句法结构标注:

```
( IP ( NP-SBJ ( PN 他 ))
  ( VP ( ADVP ( AD 还 ))
    ( VP ( VV 提出 ))
      ( NP-OBJ ( QP ( CD 一)
        ( CLP ( M 系列 )))
        ( NP ( NP ( ADJP ( JJ 具体)
          ( NP ( NN 措施 )))
          ( CC 和)
          ( NP ( NN 政策 )
            ( NN 要点 ))))))))
  ( PU 。 ))
```

句法树结构可视化:



例题 6-7: 请分析下列句子，利用上表进行句法结构标注。

(1) 句子：今天天气很好。

```
(IP (NP (NT 今天))
  (NP (NN 天气))
  (VP (ADVP (AD 很))
    (ADJP (VA 好)))
  (PU。))
```

(2) 句子：美丽的花朵开放了。

```
(IP (NP
```



```

      (ADJP (VA 美丽))
      (DEG 的)
      (NP (NN 花朵)))
    (VP (VV 开放)
      (AS 了))
    (PU。))

```

(3) 句子：他在图书馆看书。

```

(IP
  (NP (PN 他))
  (VP
    (PP (P 在) (NP (NN 图书馆)))
    (VP (VV 看) (NP (NN 书))))
  )
(PU。))

```

6.8 典型语料库与知识库 ★★

6.8.1 WordNet

WordNet: 基于同义词集 (synset) 的词汇知识库 (普林斯顿大学, 面向英语)。每个 synset 代表一个概念, 通过语义关系 (上下位关系、同义关系、反义关系、部分—整体关系、继承关系等) 相互关联。以概念而非字母顺序组织, 试图反映人类词汇知识的心理表征。

6.8.2 知网 (HowNet)

知网 (HowNet): 以义原 (semeine) 为基本构建单位的汉语词汇知识库 (中科院计算所研发)。义原是最基本的、不易再分割的最小意义单位。词语通过其所包含的义原集合来定义, 义原之间通过 6 种关系互连。

HowNet 的构建原则:

1. NLP 系统需要知识库: NLP 系统最终需要更强大的知识库的支持;
2. 知识是一个系统: 知识是一个包含着各种概念与概念之间的关系, 以及概念的属性与属性之间的关系的系统;
3. 建立常识性知识库: 应首先建立一种可以被称为知识系统的常识性知识库, 以通用的概念为描述对象;
4. 知识工程师设计: 首先应由知识工程师来设计知识库的框架, 并建立常识性知识库的原型。

第三部分：神经网络语言模型（新增内容）

N-gram 模型面临严重的数据稀疏问题，且忽略了词与词之间的相似性，导致泛化能力不足。神经网络语言模型（NNLM）通过使用参数模型和分布式词语表示克服了上述问题。

6.9 NNLM 基本思想

分布式表示（Distributed Representation）：将每个词映射到一个低维实数向量（词向量/词嵌入），语义相近的词在向量空间中彼此靠近。

NNLM 用神经网络代替条件概率模型作为语言规律的建模框架，基于语料库进行参数估计。相比于 N-gram，NNLM 的优势在于：

- 泛化能力更强：语义相似的词可获得相似的预测结果
- 缓解数据稀疏：使用参数化模型而非计数模型
- 捕捉长距离依赖：可通过神经网络结构捕获更长的上下文信息

6.10 Transformer 与注意力机制

注意力机制（Attention）：模型在处理某个位置时，动态关注输入序列中其他相关位置，而非仅依赖局部窗口。核心计算为加权求和：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 Q 为查询向量， K 为键向量， V 为值向量。

多头注意力（Multi-Head Attention）：将多个注意力头的输出拼接在一起，使模型能从不同表示子空间同时关注信息，增强了模型表达能力。

6.11 GPT——生成式预训练模型

GPT（Generative Pre-Training）：基于单向 Transformer 的自回归语言模型。采用自左向右的生成方式，每个位置的表示只能关注左侧上下文，通过掩码自注意力（Masked Self-Attention）实现。

训练策略：

1. 预训练：在大规模无标注语料上学习通用的语言表示
2. 微调：在各下游任务上针对特定目标进行参数调整

6.12 BERT——双向编码器表示——【2025·真题选择 T20】

BERT (Bidirectional Encoder Representations from Transformers):

基于双向 **Transformer** 的预训练模型，通过两个预训练任务学习语言表示：

- **MLM** (Masked Language Model): 随机掩码部分输入词，让模型根据上下文预测被掩码的词
- **NSP** (Next Sentence Prediction): 预测两个句子是否连续 (在原始 BERT 中使用，后续研究如 RoBERTa 已证明其并非必需)

GPT 与 BERT 的关键区别: GPT 使用单向注意力 (每个位置只能看左侧上下文)，BERT 使用双向注意力 (同时看左右两侧上下文)。GPT 是自回归模型，适合文本生成；BERT 是自编码模型，适合文本理解。

6.13 评估指标

BLEU (Bilingual Evaluation Understudy): 基于 N-gram 精确率的机器翻译评价指标，衡量候选译文与参考译文的重叠程度。值越高表示翻译质量越好。

ROUGE (Recall-Oriented Understudy for Gisting Evaluation): 基于召回率的自动文摘评价指标，衡量生成摘要与参考摘要的重叠程度。

区别: BLEU 侧重精确率 (译文是否准确)，ROUGE 侧重召回率 (是否覆盖了所有关键信息)。二者常结合使用，以综合评估生成质量。

6.14 预训练模型的应用

神经网络语言模型广泛应用于中文分词、机器翻译、文本生成、问答系统、文档分类、信息抽取等 NLP 任务，已成为当前 NLP 技术的基础组件。

“预训练 + 微调”的范式极大地推动了 NLP 领域的发展。

6.15 课后习题

1. 下列关于 Katz 平滑与 Good-Turing 平滑的区别，说法正确的是 ()。
 - A. 两者都给未出现的 n-gram 均分概率
 - B. Katz 平滑给未出现的 n-gram 按低阶语言模型分布分配概率，Good-Turing 均分
 - C. Good-Turing 平滑需要后缀常数 α ，Katz 平滑不需要
 - D. 两者都不需要依赖低阶语言模型

解析：正确答案为 **B**。Good-Turing 平滑在估计未出现事件的整体概率 ($P_0 = N_1/N$) 后，是将这部分概率均分给所有未出现的 n-gram。而 Katz 平滑（回退模型，Back-off）更加精细，当高阶 n-gram 计数为 0 时，它会选择“回退”到低阶模型（例如从 Bigram 回退到 Unigram），并依据低阶语言模型的概率分布来按比例分配这些未出现词对的剩余概率，因而比单纯的均分更符合实际语言分布。

2. 若某前缀 w_i 对应的 Bigram 总出现次数 $C(w_i) = 80$ ，所有出现过的 Bigram 调整后频次总和为 8。则出现过的 Bigram 总概率和为（ ）。

A. 0.1 B. 0.08 C. 0.8 D. 1.0

解析：正确答案为 **A**。在古德-图灵（Good-Turing）或类似的平滑算法中，某一前缀 w_i 下所有事件的概率计算公式基于其调整后的频次。所有出现过的 Bigram 的概率之和，等于它们调整后的频次总和除以该前缀的总出现次数：

$$P(\text{已出现}) = \frac{\sum C^*(\text{已出现})}{C(w_i)} = \frac{8}{80} = 0.1$$

（剩余的 0.9 的概率空间将被预留并分配给所有未曾出现过的 Bigram）。

3. 【2025 · 真题简答 T1】请简要说明 WordNet？

解析：WordNet 是由普林斯顿大学团队开发的英语语义数据库，基于认知语言学理论构建词汇网络，将词语按语义而非字母顺序关联。其核心结构以同义词集合（synset）为基本单元，涵盖名词、动词、形容词和副词，通过上下位、整体部分等九类语义关系连接概念。

4. 【2025 · 真题简答 T2】请简述语言模型、N-gram 模型的概念？N-gram 模型构建后，为什么需要进行平滑？

答题技巧：原因类问题——为什么要改进 + 改进了有啥用？

解析：

- **语言模型：**NLP 的核心，用于预测文本中下一个词的概率。它基于大量文本数据学习语言的统计规律，能生成连贯文本或评估文本合理性。
- **N-gram 模型：**语言模型的一种，通过统计 n 个连续词的出现频率来预测下一个词。
- **原因：**避免零概率问题。训练数据中未出现的 N-gram，其概率会被计算为 0，导致模型处理未知序列时表现不佳。而采用平滑技术，可为未出现的 N-gram 分配小概率，提高模型稳健性。
- **（补充）平滑技术的作用：**平滑技术使 N-gram 模型能更合理地处理未知序列，提高在实际应用中的泛化能力和准确性。

5. 简述课件中的几种减值平滑法的原理和区别。（见 6.4.3，略）

6. 基于语料:

I read news every day.

I like English book.

We like read English news some time.

(1) 计算句子 “I like read English book.” 的概率?

(2) 使用 Add-one 平滑计算句子 “We read English book.” 的概率?

解析:【预处理与频次统计】 设句子边界符为 $\langle s \rangle$ (句首) 和 $\langle /s \rangle$ (句尾)。

唯一词汇表:

$$V = \{I, need, news, every, day, like, English, book, We, read, some, time\}$$

计入句尾符 $\langle /s \rangle$, 词汇表大小为: $|V| = 12$

根据语料库, 统计各相关项的绝对频次如下:

- 句子总数 (即句首符总数):

$$C(\langle s \rangle) = 3$$

- 历史前缀频次:

$$C(I) = 2, \quad C(\text{like}) = 2, \quad C(\text{read}) = 2,$$

$$C(\text{English}) = 2, \quad C(\text{We}) = 1, \quad C(\text{book}) = 1$$

- 二元语法频次:

$$C(\langle s \rangle I) = 2, \quad C(\langle s \rangle \text{We}) = 1, \quad C(I \text{ like}) = 1, \quad C(\text{like read}) = 1$$

- 二元语法频次:

$$C(\text{read English}) = 1, \quad C(\text{English book}) = 1,$$

$$C(\text{book} \langle /s \rangle) = 1, \quad C(\text{We read}) = 0$$

(1) 极大似然估计 (MLE) 计算

根据二元语法 (Bigram) 假设与链式法则, 该句子的概率计算公式为:

$$P = P(I | \langle s \rangle) \cdot P(\text{like} | I) \cdot P(\text{read} | \text{like}) \cdot P(\text{English} | \text{read}) \cdot P(\text{book} | \text{English}) \cdot P(\langle /s \rangle | \text{book})$$

依据极大似然估计公式 $P(w_i | w_{i-1}) = \frac{C(w_{i-1}w_i)}{C(w_{i-1})}$, 各因子计算如下:

$$P(I | \langle s \rangle) = \frac{C(\langle s \rangle I)}{C(\langle s \rangle)} = \frac{2}{3}$$

$$P(\text{like} | I) = \frac{C(I \text{ like})}{C(I)} = \frac{1}{2}$$

$$\begin{aligned}
P(\text{read} \mid \text{like}) &= \frac{C(\text{like read})}{C(\text{like})} = \frac{1}{2} \\
P(\text{English} \mid \text{read}) &= \frac{C(\text{read English})}{C(\text{read})} = \frac{1}{2} \quad (\text{注: 第一句为 read news}) \\
P(\text{book} \mid \text{English}) &= \frac{C(\text{English book})}{C(\text{English})} = \frac{1}{2} \\
P(\langle /s \rangle \mid \text{book}) &= \frac{C(\text{book} \langle /s \rangle)}{C(\text{book})} = \frac{1}{1} = 1
\end{aligned}$$

将上述条件概率累乘, 得到最终句子概率:

$$P = \frac{2}{3} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times 1 = \frac{2}{48} = \frac{1}{24}$$

(2) Add-one (加一) 平滑计算

加一平滑的条件概率计算公式为:

$$P_{\text{Add-1}}(w_i \mid w_{i-1}) = \frac{C(w_{i-1}w_i) + 1}{C(w_{i-1}) + |V|}$$

代入 $|V| = 12$, 对句子 “We read English book.” 的各项条件概率进行平滑建模:

$$\begin{aligned}
P(\text{We} \mid \langle s \rangle) &= \frac{C(\langle s \rangle \text{We}) + 1}{C(\langle s \rangle) + 12} = \frac{1 + 1}{3 + 12} = \frac{2}{15} \\
P(\text{read} \mid \text{We}) &= \frac{C(\text{We read}) + 1}{C(\text{We}) + 12} = \frac{0 + 1}{1 + 12} = \frac{1}{13} \\
P(\text{English} \mid \text{read}) &= \frac{C(\text{read English}) + 1}{C(\text{read}) + 12} = \frac{1 + 1}{2 + 12} = \frac{2}{14} = \frac{1}{7} \\
P(\text{book} \mid \text{English}) &= \frac{C(\text{English book}) + 1}{C(\text{English}) + 12} = \frac{1 + 1}{2 + 12} = \frac{2}{14} = \frac{1}{7} \\
P(\langle /s \rangle \mid \text{book}) &= \frac{C(\text{book} \langle /s \rangle) + 1}{C(\text{book}) + 12} = \frac{1 + 1}{1 + 12} = \frac{2}{13}
\end{aligned}$$

将平滑后的各项概率累乘, 得到最终句子概率:

$$P = \frac{2}{15} \times \frac{1}{13} \times \frac{1}{7} \times \frac{1}{7} \times \frac{2}{13} = \frac{4}{124215} \approx 3.22 \times 10^{-5}$$

第七讲 信息检索


7.1 本讲重点

1. 掌握信息检索的概念定义；
2. 掌握信息检索系统的一般框架；
3. 熟悉基于向量空间模型的信息检索系统；
4. 熟悉基于 LSI 模型的信息检索的基本原理。

7.2 信息检索概述 ★★★

信息检索 (Information Retrieval, IR): 指从大规模非结构化数据 (通常是文本) 集合中找出满足用户信息需求的资料的过程。可形式化描述为: 给定一个文档库 D 和一个表述需求信息的查询字段 $query$, 系统回复一个包含所需信息的文档有序列表 $[d_1, d_2, \dots]$ 。

★★★信息检索系统的一般框架:



1. **标引:** 建立统一的用户查询条件语句与候选查询文档的数学表示。
2. **相关度评估:** 计算标引后的“查询表达”与“候选文档表达”之间的相关度。
3. **文档排序:** 基于相关度等指标将候选文档按对用户查询的契合程度与重要程度合理排序。

7.3 信息检索基本模型

信息检索技术实现框架 (信息检索模型) 是系统中包含的核心逻辑、规则、算法等的统称。

7.3.1 布尔模型 (Boolean Model)

- **原理:** 最早且应用最广泛的模型。文档被表示为关键词的集合; 查询式被表示为关键词的布尔组合 (AND/OR/NOT), **优先级: NOT>AND>OR**
- **相关度评估:** 二值匹配。当且仅当文档能够满足布尔查询式时作为返回值。本质上不排序。
- **优点:** 查询式简单, 用户易上手; 非常高效; 具备一定的扩展性。
- **缺点:** 不支持部分匹配 (只能完全匹配); 很难基于检索过程对输出进行排序; 不考虑关键词权重 (出现 1 次与 n 次影响相同)。

例题 7-1: 给定查询式 Query, 下面哪一个文档会被检索到?

- Query = 病毒 AND (计算机 OR 电脑) AND NOT 医
- 文档集:

D1: 据报道**计算机病毒**最近猖獗

D2: 小王虽然是学**医**的, 但对研究**电脑病毒**也感兴趣...

D3: **计算机**程序发现了艾滋病**病毒**传播途径

解析: 本题考查布尔逻辑检索规则 (**优先级: NOT>AND>OR**), 逐一判定:

D1 包含「病毒」与「计算机」, 未出现「医」, 满足全部条件, 可被检索到;

D2 包含「病毒」与「电脑」, 但出现禁止词「医」, 被 NOT 逻辑排除, 无法被检索到;

D3 包含「病毒」与「计算机」, 未出现「医」, 满足全部条件, 可被检索到。

最终结论: D1、D3 会被检索到。

7.3.2 向量空间模型 (Vector Space Model, VSM) ★★

- **核心思想:** 把文本内容简化为高维线性空间中的向量。
- **关键概念:**
 - **文档 D (Document):** 泛指文档或文档中的一个片段。
 - **索引项 t (Term):** 能够代表文档内容特点的基本语言单位 (如字、词、短语、同义词集、语义概念等)。
 - **索引项权重 W_{t_k} (Term Weight):** 指索引项 t_k 代表文档 D 的能力的大小, 体现了该索引项在本文档中的重要程度, 最终文档 D 由 W_{t_k} 构成的向量来表示。
 - **相似度 S (Similarity):** 两个文档内容相关程度的大小 (常用 0-1 之间的数值来量化, 如余弦相似度), 在两个文档的向量表示基础上计算得出。
- **三个关键点:**
 1. **索引项的选择**——怎样确定文档中哪些词项是重要的词项
 - (1) 高频出现的词项;
 - (2) 与领域相关的词项;
 - (3) 相似的词项归并为同一个索引项可极大改善检索性能 (如: 计算机、电脑)
 2. **索引项的权重**——怎样确定一个词项在某个文档中的重要程度
 - **TF-IDF 加权:** 一种用于信息检索与信息抽取的常用加权技术; 通过综合考察索引项在当前文档中出现的频次以及索引项在整个文档集合中出现的频繁程度, 更为准确地评估索引项对于某一份文件的重要程度。——【2025·真题选择 T5】

$$tf_{ij} = \frac{n_{i,j}}{\sum_k n_{k,j}}$$

$$idf_i = \log \frac{|D|}{|\{j : t_i \in d_j\}|}$$

$$TF\text{-}IDF_{ij} = tf_{ij} \times idf_i$$

- $n_{i,j}$ 是该词在文件 d_j 中出现的次数，分母为文件 d_j 中所有词汇出现的次数总和；
- $|D|$ 是语料库中的文件总数， $|\{j : t_i \in d_j\}|$ 表示包含词语 t_i 的文件数目。

3. 相似度评价——怎样确定一个文档和一个查询式之间的相似度

$$\text{Inner Product: } \sum_{k=1}^t (d_{ik} \cdot q_k)$$

$$\text{Cosine 距离: } \frac{\sum_{k=1}^t (d_{ik} \cdot q_k)}{\sqrt{\sum_{k=1}^t d_{ik}^2 \cdot \sum_{k=1}^t q_k^2}}$$

$$\text{广义 Jaccard 系数: } \frac{\sum_{k=1}^t (d_{ik} \cdot q_k)}{\sum_{k=1}^t d_{ik}^2 + \sum_{k=1}^t q_k^2 - \sum_{k=1}^t (d_{ik} \cdot q_k)}$$

注： d_i 、 q_k 分别指文档 i 、文档 k 的向量表示

• 优点：

- 查询式无需写成布尔条件形式，更接近日常自然语言；
- 部分匹配策略使得查询条件可以更自由灵活；
- 利用索引项的权重来刻画文档，对文档的刻画更为细致；
- 根据索引项的分布特征来度量文档之间的相似度，相似度度量得更精确；
- 可根据相似度对输出结果进行排序。

• 不足：

- 索引项之间被默认为是相互独立的，这不符合客观实际，会一定程度影响效果；
- 一词多义、一义多词现象会严重影响检索效果。

7.3.3 语言模型与概率模型

- **语言模型**：为每个文档建立语言模型。查询式被看作是由文档语言模型抽样产生的样本，根据文档生成查询式的概率来对文档排序。
- **概率模型**：估计出给定查询时文档相关与不相关的概率 $P(R|D, Q)$ 与 $P(\bar{R}|D, Q)$ ，根据相对大小选取并排序。

7.4 LSI 模型 ★★

隐性语义索引 (Latent Semantic Indexing, LSI)：为解决传统模型中“一词多义”和“一义多词”带来的漏检和误检问题，LSI 利用奇异值分解 (SVD) 技术将“词项-文档”矩阵分解，通过引入“语义维度”建立词项与文档在低维空间中的潜在语义联系。

★★SVD 矩阵分解 (奇异值分解: $C = U\Sigma V^T$):

- C ：“词项-文档”原始矩阵。
- U ：“词项”表征矩阵，表示词项与各语义维度间的关系。
- V^T ：“文档”标引矩阵，表示文档与各语义维度间的关系。
- Σ ：奇异值对角矩阵，对角线上的奇异值模拟了各“语义维度”的重要性程度。

★★LSI 模型对于信息检索的优势：

- **原因一**：可以用奇异值来过滤次要的“语义维度”，起到滤除噪声的效果

若将不太重要的奇异值置为 0，可以去掉一些枝节信息而仅保留重要的信息，**枝节信息可能会使本来应该相似的对象不相似。**

如：鲜红色花朵的图像/红黑花朵的图像

如果通过将颜色相关的奇异值设置为 0 而忽略掉颜色信息，则将更容易看到两者的相似性。

- **原因二**：分解出语义层作为中介后，可将同义词用语义层联系起来

若文档 d_1 中只包含“计算机”，文档 d_2 中只包含“电脑”，用传统的基于词的表示模型， d_1 与 d_2 之间是不相似的，但因为“计算机”、“电脑”对应相同的语义，在 LSI 模型的 V^T 矩阵中， d_1 与 d_2 通过语义维度来表示后，两者之间却可能是高度相似的。

- **原因三**：分解出语义层的过程中，多义词的重要性被自动下降到几乎不起作用的程度

在 LSI 模型中，多义词因为和多种语义维度相关，最后会对语义维度定义基本上不起任何贡献，其作用会被自动降低甚至完全被忽视。

7.5 信息检索系统评测

常用评测指标:

- **Precision@N**: 前 N 个返回值中的正确率 (如 $P@10$, $P@20$)。
- **R-Precision**: 已知相关文档总数为 R, 计算检索结果前 R 篇属于相关文档的比例。
- **P-R 曲线** (Precision vs. Recall curve): 召回率为 0% 到 100% 变化时对应的正确率曲线。

主要评测活动: TREC (美国)、NTCIR (日本)、863 (中国)。

7.6 问答系统概述

问答系统: 允许用户以自然语言方式询问, 系统能从大量的异构数据中查找并总结出用户问题答案的新型信息检索系统。具有“自然语言方式提问”和“准确而简洁的答案”两大特点。

问答系统的类型:

基于大规模真实文本的问答系统	✓ 从预先建立的大规模真实文本语料库中找答案 ✓ 覆盖度受限
基于 Web 的问答系统	✓ 从网络 (Web) 中寻找提问的答案 ✓ 覆盖度高 ✓ 最新发展是社区问答系统
基于知识库的问答系统	✓ 从一个预先建立的结构化的知识库中找答案 ✓ 可以实现推理 ✓ 知识库构建困难
基于语言模型的理解式问答系统	✓ 语言模型是底层基础 ✓ 基于语言模型的理解能力预先学习大量的“问题-答案”材料 ✓ 基于语言模型阅读理解从 Web 中寻找到的问题答案相关材料 ✓ 利用模型的生成能力生成任意问题的答案

7.7 课后作业

1. 简述基于 VSM 信息检索技术框架的三个关键点。(详见 7.3.2)
2. LSI 模型应用于信息检索相对于基本的向量空间模型有哪些优势?(详见 7.4)
3. **【2025 · 真题简答 T6】**简述 LSI 模型中 C 、 U 、 V^T 、 Σ 四个矩阵的含义?(详见 7.4)
4. 简述问答系统的概念以及几种实现类型?(详见 7.6)

第八讲 词法分析

8.1 本讲重点

1. 熟悉汉语自动分词方法的分类，最大匹配法、最短路径法的原理；
2. 熟悉北大的中文词性标注集，词性标注方法的分类；
3. 了解字分类法的基本思想，命名实体识别的概念。

8.2 概述

NLP 系统：字符串 → 词法分析 → 句法分析 → 语义分析（对应接下来三讲内容）

词法分析（Morphological Analysis）：NLP 系统从接受到输入字符串开始，一直到对输入字符串进行句子层面的分析之前，对输入字符串进行的词一级处理统称为词法分析。

主要任务：汉语自动分词、英语形态还原、命名实体识别、词性标注

8.3 汉语自动分词及四大方法 ★★——【2025·真题选择 T8】

汉语自动分词：让计算机系统在汉语文本中的词与词之间自动加上边界标记。

例如：自然语言处理的期末考试要炸了 → 自然语言处理/ 的/ 期末考试/ 要/ 炸/ 了/


8.3.1 最大匹配法 ★★

最大匹配法：基于词典的机械切分法。未能被词典覆盖的就当作单字词（不能识别未登录词）。包括：正向最大匹配算法 (FMM)、逆向最大匹配算法 (BMM)、双向最大匹配算法 (Bi-MM)。

例题 8-1：分别使用 FMM、BMM 执行自动分词（汉语分词词典中最长单词的字数为 7）。

- 词典：研究，研究生，生物，物化，化学，科学家……（不完全展示，最长 7 字）
- 句子：他是研究生物化学的一位科学家。

解析：




8.3.2 最短路径法 ★★

最短路径法：基于词典的启发式切分法。构建词图并寻找最短路径，但同样不能有效识别未登录词。（最大匹配法、最短路径法**都认为词语数最少的切分方式就是最佳分词结果**）

例题 8-2：使用最短路径法执行自动分词：“他只会诊断一般的疾病”。

解析：



8.3.3 最大概率法

最大概率法：基于 N 元语法模型的分词法。基于概率最大化的思想选择最佳切分方式。

8.3.4 字分类法（序列标注法） ★

字分类法（机器学习分类/序列标注问题）：从头至尾对句子中每一个字进行词位分类。

- 基本思想：

将分词过程看作是字的分类问题。该方法认为，每个字在构造一个特定的词语时都占据着。一个确定的构词位置（即词位）。假定每个字只有 4 个词位：词首 (B)、词中 (M)、词尾 (E) 和单独成词 (S)，那么，每个字归属一特定的词位。

- 两点特殊性：

1. 从开头到末尾逐个对每一单元进行分类。
2. 仅基于待分类单元的上下游信息构建分类器。

- 解决序列标注问题的最佳模型：

HMM、CRF、SVM 分类模型、ANN 模型等。

8.4 命名实体识别 (NER) ★

命名实体识别 (Named Entity Recognition, NER): 识别文本中对实体的命名性指称, 具体来讲就是识别文本中的人名、地名、机构名、时间名等专有名词。

示例: 中国乒乓球男队总教练刘国梁出席了备战会议, 他指出了当前备战工作的重点。

- 实体: 刘国梁
- 指称: 中国乒乓球男队总教练 (名词性); 刘国梁 (命名性); 他 (代词性)。

8.5 词性标注

词性标注 (Part-of-Speech Tagging): 词性指词汇的基本语法属性, 通常用类别的方式来定义。词性标注是根据一个词在某个特定句子中的上下文, 为这个词标注正确的词性。

8.5.1 词性标记集

词性标记集 (POS TagSet) 就是标注时可选择的词性类别范围 (如: 动词 V、名词 N 等)。通常源自语言学分类, 但 NLP 倾向于更精细化。

常用的词性标注集有: 北大标注集、Brown 标注集、Penn Tree Bank 标注集、CLAWS 系统的 c5 标注集、LDC 的 CTB 标注集、中科院 ICTCLAS 词性标注集。

★★ **北大计算语言研究所的词性标注集: ——【2025·真题选择 T9】**

- 26 个基本词类代码, 74 个扩充代码, 标记集中共有 106 个代码。

26 个基本词类代码: 名词 (n)、时间词 (t)、处所词 (s)、方位词 (f)、数词 (m)、量词 (q)、区别词 (b)、代词 (r)、动词 (v)、形容词 (a)、状态词 (z)、副词 (d)、介词 (p)、连词 (c)、助词 (u)、语气词 (y)、叹词 (e)、拟声词 (o)、成语 (i)、习用语 (l)、简称 (j)、前接成分 (h)、后接成分 (k)、语素 (g)、非语素字 (x)、标点符号 (w)。

8.5.2 词性标注的主要方法 ★★

1. 基于规则的方法:

- 基于人工设计的规则: 如 TAGGIT 系统。
- 基于自动提取的规则: 如基于转换规则的错误驱动的机器学习方法 (获取初始自动标注结果 → 比较并提取候选规则 → 搜索有效规则调整结果 → 迭代)。

2. 基于统计的方法:

- 代表性方法: 基于 HMM 模型的词性标注方法。

- 需要解决三个问题：如何设计模型框架；如何训练模型；如何利用 Viterbi 算法进行解码标注。

8.6 课后作业

1. 【2025·真题简答 T3】简述基于字分类法的分词方法原理？（见 8.3.4）

解析：将分词过程看作是字的分类问题。该方法认为，每个字在构造一个特定的词语时都占据着。一个确定的构词位置（即词位）。假定每个字只有 4 个词位：词首 (B)、词中 (M)、词尾 (E) 和单独成词 (S)，那么，每个字归属一特定的词位。具体步骤如下：

- 字典准备：构建包含汉字及其词性的字典。
- 逐字扫描：按字切分句子，标注每个字的词性。
- 词性组合：将符合语法规则的相邻字组合成词。
- 优化调整：通过规则或统计模型优化分词结果。

优缺点：简单易实现；但对复杂句子或特殊词汇可能不够准确。

2. 简述命名实体识别的概念？（见 8.4）
3. 请列举北大版的词性标注集的基本词性代码？（见 8.5.2）
4. 请简述如何利用 HMM 建立词性标注器？

解析：包含三个核心步骤：

- **模型设计：**将词性序列作为隐藏状态序列，单词序列作为观测序列。
- **模型训练：**利用大规模已标注语料库，统计并计算出初始状态概率、词性间的状态转移概率以及词汇的发射概率。
- **标注解码：**给定新的待标注文本序列，利用 Viterbi 算法动态规划求解出全局概率最大的隐藏词性状态序列。

5. 请分别用正向最大匹配法、反向最大匹配法对以下句子进行分词？

- **词典：**自动化研究所、自动化、研究所、自动、研究、取得、成就、非常、常人、能干、干到
- **句子：**自动化研究所取得的成就非常人能干到

解析：

- **正向最大匹配法 (FMM)：**自动化研究所 / 取得 / 的 / 成就 / 非常 / 人 / 能干 / 到
- **反向最大匹配法 (BMM)：**自动化研究所 / 取得 / 的 / 成就 / 非 / 常人 / 能 / 干到

第九讲 句法分析

9.1 本讲重点

1. 掌握句法分析的概念定义、主要任务类型；
2. 掌握句法结构分析、句法分析树的概念定义；
3. 掌握基于规则的分析方法（CYK 分析算法）；
4. 熟悉基于 PCFG 的句法分析基本原理；
5. 了解浅层句法分析、BaseNP 的概念定义；
6. 了解依存句法理论、依存关系树的概念定义。

9.2 句法分析概述 ★★★——【2025·真题选择 T10】

句法分析 (Syntactic Parsing): 自然语言处理过程中限定于句子层面上的形式化分析，核心目标是确定**句子的句法结构**或句子词汇之间的**依存关系**。

特点: 分析对象是以整个句子为单位；仅从形式（语法）层面进行分析，而非语义层面。
句法分析的主要任务:



1. **句法结构分析（一般等价于完全句法分析）**: 判断输入的整体句子是否合乎语法规则，并确定出宏观的、完整的树状句法层级结构，输出句法分析树。
2. **浅层句法分析**: 不关注整体的长距离关联特征，仅关注局部区域内的语法属性，把句子拆解切分为多个相互独立的、底层的基本语块（如 Base NP、PP 等）。
3. **依存句法分析**: 以动词为句子的绝对中心，直接利用词汇与词汇之间的二元连边（支配者与被支配者的依存关系）来表达结构，突出词汇直接的关联特性。

9.3 句法结构分析（完全句法分析）

句法结构分析 (Syntactic Structure Parsing): 指对输入的单词序列（句子）判断其构成是否合乎给定的语法规则，以及确定出符合语法规则的句法结构。

9.3.1 句法分析树 ★★★

句法分析树 (Syntactic Parsing Tree): 用树状数据结构表示的句法结构。

从句子获得句法分析树需要哪些语言知识？**语法规则库 + 词典**


语法规则库常见术语：

S	句子 (Sentence)	SBV	主谓依存关系 (Subject-Verb)
VP	动词短语 (Verb Phrase)	VOB	动宾依存关系 (Verb-Object)
NP	名词短语 (Noun Phrase)	ATT	定语修饰关系 (Attribute)
PP	介词短语 (Prepositional Phrase)	DE	“的”字结构依存关系

例题 9-1：绘制句法分析树：The can can hold the water（第一个 can 意为“罐头”）

- 语法规则库： $S \rightarrow NP VP$ ； $NP \rightarrow art\ n$ ； $VP \rightarrow aux\ VP$ ； $VP \rightarrow v\ NP$
- 词典：the(art)；can(n,aux,v)；hold(v)；water(n)（其中 art 指冠词，aux 指助动词）

解析：



9.3.2 句法结构分析器的关键问题

- 语法规则库如何构建？——人工规则/统计（机器学习）
- 基于语法规则库的推理算法如何设计？——如 CYK 算法、Viterbi 算法

9.3.3 主要分析方法框架——【2025·真题选择 T11】


1. 基于人工规则的方法（下图左）

- 思想：**人工建立语法规则库（如 CFG）；根据对规则库的穷举式搜索推导出句法分析树。
- 优点：**原理简单，容易实现。
- 缺点：**规则有限时长句难以被分析；难找到最优结构；人工编制有主观性；工作量巨大。

2. 基于统计（机器学习）的方法（下图右）

- 思想：**使用从训练数据中学习得到的语法规则库定义语法特性；然后根据启发式搜索推导出句法分析树（如 PCFG 模型及其改进）。
- 优点：**降低了人工编制的工作量与主观性；学到的规则更符合语言客观实际；能寻找到最大概率的最优句法结构。

两种句法分析器的一般框架如下图所示，下面两小节将分别对这两种方法展开介绍。



9.3.4 CFG+CYK 算法——基于人工规则的分析方法 ★★★

CYK 算法 (Cocke-Younger-Kasami 算法): 一种用来对上下文无关文法 (CFG) 进行语法分析 (parsing) 的算法, 是基于动态规划思想设计的一种自底向上语法分析算法。

CFG (上下文无关文法) 通过一系列替换规则将非终结符翻译为句子词语。结合 CYK 算法, 可以在给定的 CFG 下, 采用自底向上的动态规划策略, 平行于对角线逐层搜索, 推导出合法的句法分析树。但在实际应用中, 纯 CFG 模型的拟合能力往往不足。


- 对文法进行 Chomsky 范式化 (乔姆斯基范式化):

$$A \rightarrow w \quad \text{或} \quad A \rightarrow BC \quad (\text{只能推单元终结符或二元非终结符, 别瞎搞!})$$

$$A, B, C \in V_N, \quad w \in V_T, \quad G = (V_N, V_T, P, S)$$

- 自下而上的分析方法
- 构造 $(n+1) \times (n+1)$ 识别矩阵, n 为输入句子长度。

假设输入句子 $x = w_1 w_2 \dots w_n$, w_i 为构成句子的单词, $n = |x|$ 。



识别矩阵的特征 (这你不得记住了???) :

- 是**方阵**, 对角线以下 (左下角) 全为 0
- 主对角线以上的元素由文法 G 的**非终结符**构成
- 主对角线上的元素由输入句子的**终结符 (单词)** 构成 (补充: 最左上角为 0)



识别矩阵构造——三大步骤（计算题可考!!!）：

1. 首先构造主对角线，令 $t_{0,0} = 0$ ，然后，从 $t_{1,1}$ 到 $t_{n,n}$ 在主对角线的位置上依次放入输入句子 x 的单词 w_i 。
2. 构造主对角线以上紧靠主对角线的元素 $t_{i,i+1}$ ，其中， $i = 0, 1, 2, \dots, n-1$ 。对于输入句子 $x = w_1 w_2 \dots w_n$ ，从 w_1 开始分析。

如果在文法 G 的产生式集中有一条规则： $A \rightarrow w_1$ ，则 $t_{0,1} = A$ 。

依此类推，如果有 $A \rightarrow w_{i+1}$ ，则 $t_{i,i+1} = A$ 。

即对于主对角线上的每一个终结符 w_i ，所有可能推导出它的非终结符写在它的右边主对角线以上的位置上。



3. 按平行于主对角线的方向，一层一层地向上填写矩阵的各个元素 $t_{i,j}$ ，其中， $i = 0, 1, \dots, n-d$ ， $j = d+i$ ， $d = 2, 3, \dots, n$ 。如果存在一个正整数 k ， $i+1 \leq k \leq j-1$ ，在文法 G 的规则集中有产生式 $A \rightarrow BC$ ，并且， $B \in t_{i,k}$ ， $C \in t_{k,j}$ ，那么，将 A 写到矩阵 $t_{i,j}$ 位置上。

判断句子 x 由文法 G 所产生的充要条件是： $t_{0,n} = S$ 。

例题 9-2：给定文法 $G(S)$ ：

- (1) $S \rightarrow PVP$ (2) $VP \rightarrow VV$ (3) $VP \rightarrow VP N$
 (4) $P \rightarrow \text{他}$ (5) $V \rightarrow \text{喜欢}$ (6) $V \rightarrow \text{读}$ (7) $N \rightarrow \text{书}$

请用 CYK 算法分析句子：他 喜欢 读 书


解析：

步骤 1：汉语分词和词性标注

他/P 喜欢/V 读/V 书/N 句子总长度 $n = 4$ 。

步骤 2：构造 CYK 识别矩阵，执行分析过程


CYK 算法基于乔姆斯基范式构造上三角识别矩阵，从短子串到长子串逐层推导填表：



- 子串 $l = 1$ (对角线): 根据终结符产生式, 主对角线以上元素分别填 P, V, V, N ;
- 子串 $l = 2$: 拆分区间匹配产生式, $[1, 3]$ 满足 $VP \rightarrow V V$, 填入 VP ;
- 子串 $l = 3$: 拆分 $[0, 3]$ 得到 $[0, 1] + [1, 3]$, 满足 $S \rightarrow P VP$, 此处填入 S 似乎推完了? 你瞎吗? 漏了一个“书”字! (此路不通!)
- 子串 $l = 3$ 另解: 改为拆分 $[1, 4]$ 得到 $[1, 3] + [3, 4]$, 满足 $VP \rightarrow VP N$, 填入 VP ;
- 子串 $l = 4$: 拆分整句区间 $[0, 4]$ 得到 $[0, 1] + [1, 4]$, 满足 $S \rightarrow P VP$, 顶层格子填入起始符号 S 。太好了这下完事了! 证明该句子可被文法接受。

步骤 3: 生成句法分析树

根据推导过程还原句法层级结构, 绘制得到如下分析树:



CYK 算法的评价:

- 优点: 简单易行, 执行效率高。
- 弱点: 必须对文法进行范式化处理; 无法区分歧义; CFG 模型的拟合能力不足。

9.3.5 概率上下文无关文法 (PCFG) —— 基于统计 (机器学习) 的分析方法 ★★

PCFG 模型：在 CFG 的基础上引入概率，基于规则的概率计算整棵语法树的概率，从而可以筛选出概率最大的最优句法树。包含三个基本问题：概率计算（内向算法等）；最优句法树搜索（采用动态规划思想改进的 CYK 算法 / Viterbi 算法）；参数学习（EM 算法）。

基于 PCFG+CYK 算法，采用动态规划思想，只保留每个跨度的最优（最大概率）组合方案，避免无必要的盲目搜索，大幅提高了长句分析效率。

- **特点：**PCFG（概率上下文无关文法）为文法中的每条产生式规则赋予了一个概率。一棵完整句法树的发生概率由推导出该树的所有节点规则概率连乘计算得到。
- **优势：**
 1. 大幅降低了人工编制规则的庞大工作量与主观性。
 2. 从真实训练数据中学习得到的概率语法规则，更加贴切语言的客观实际现象。
 3. 结合动态规划算法，模型能精准寻找到概率最大（全局最优）的句法树，有效解决了一句多树的切分歧义难题。

9.4 浅层句法分析 ★

浅层句法分析 (Shallow Parsing)：仅关注于局部区域范围内的语法属性，不关注远距离的语法关联特征。把句子拆解成多个相互独立的局部块（语块），并为独立局部块分类。

四大语块类型：基本名词短语 Base NP；动词词组 VG；介词短语 PP；副词短语 DP
当前主流方法之一：把局部语块识别（如 Base NP 的识别）转化为序列标注任务。

9.4.1 基本名词短语 (Base NP) ★

基本名词短语 (Base NP)：简单的、非嵌套的名词短语，不含有其他的子短语。也叫非递归的名词短语（内部不包含其他 NP 的底层 NP）。

特点：短语的中心语为名词；短语中不含其他子项短语，Base NP 之间结构上独立。

9.5 依存句法分析 ★


依存句法理论：认为动词是句子的中心，它只会支配其他成分而不受其他成分支配。摒弃了传统的短语层级，直接用“依存关系”（支配者 → 被支配者）描述句子“关联”特性。

依存树：用树表示的依存结构，树中子节点依存于该节点的父节点。

依存投射树：带有投射线的树结构，实线表示依存联结关系，位置低的成分依存于位置高的成分，虚线为投射线。

例题 9-3：绘制句子“北京是中国的首都”的依存树、依存投射树。

解析：



9.6 课后作业

- 1. 请比较说明句法结构分析、浅层句法分析、依存句法分析的概念？（见 9.2）
- 2. 【2025 · 真题简答 T4】简述术语含义：S、VP、NP、PP；SBV、VOB、ATT、DE

S	句子 (Sentence)	SBV	主谓依存关系 (Subject-Verb)
VP	动词短语 (Verb Phrase)	VOB	动宾依存关系 (Verb-Object)
NP	名词短语 (Noun Phrase)	ATT	定语修饰关系 (Attribute)
PP	介词短语 (Prepositional Phrase)	DE	“的”字结构依存关系

- 3. 请简要说明 PCFG 模型特点，及其进行句法分析的优势？（见 9.3.5）
- 4. 采用 CYK 算法进行句法结构分析（注意 Chomsky 范式化、多种结构树）：

• CFG 文法：

$$\begin{aligned} S &\rightarrow VC\ NP \mid VP\ Aux\ NP \\ VC &\rightarrow v\ a \mid VC\ utl \\ NP &\rightarrow n \mid NP\ Aux\ NP \mid NP\ NP \\ VP &\rightarrow VC\ NP \end{aligned}$$

$$v \rightarrow \text{咬} ; a \rightarrow \text{死} ; n \rightarrow \text{猎人} \mid \text{狗} ; utl \rightarrow \text{了} ; Aux \rightarrow \text{的}$$

• 句子：咬死了猎人的狗

解析：

步骤 1：文法转化为 Chomsky 范式（仅允许 $A \rightarrow BC$ 或 $A \rightarrow a$ ）

- 拆分三元产生式：新增非终结符 X ，令 $X \rightarrow Aux\ NP$ ，改写 S 、 NP 两式。
- 消除单元产生式：移除 $NP \rightarrow n$ ，直接添加终结符产生式 $NP \rightarrow \text{猎人}$ 、 $NP \rightarrow \text{狗}$ 。

新 CNF 文法的二元产生式：（为做题清晰，建议展开写，别惦记你那破一竖了）

$$\begin{aligned} S &\rightarrow VC NP \\ S &\rightarrow VP X \\ VC &\rightarrow v a \\ VC &\rightarrow VC utl \\ VP &\rightarrow VC NP \\ NP &\rightarrow NP X \\ NP &\rightarrow NP NP \\ X &\rightarrow Aux NP \end{aligned}$$

新 CNF 文法的单元终结符产生式：

$$v \rightarrow \text{咬}; a \rightarrow \text{死}; utl \rightarrow \text{了}; Aux \rightarrow \text{的}; NP \rightarrow \text{猎人}; NP \rightarrow \text{狗}$$

步骤 2：分词与序列标注

长度 $n = 6$ ，词性对应：咬 / v 、死 / a 、了 / utl 、猎人 / NP 、的 / Aux 、狗 / NP

步骤 3：构造 CYK 上三角识别矩阵

矩阵格子 (i, j) ($i < j$) 对应从第 $i + 1$ 到第 j 个词的子串，填入可推出该子串的非终结符；主对角线格子 (j, j) 填入对应终结符汉字。按子串长度从小到大逐层填表：

- 初始矩阵（长度 $l = 1$ ）：填入单个词对应的非终结符与汉字：

	0	1	2	3	4	5	6
0		v					
1		咬	a				
2			死	utl			
3				了	NP		
4					猎人	Aux	
5						的	NP
6							狗

- 长度 $l = 2$ ：两两组合匹配二元产生式：
 - $(0, 2)$ ： $v + a$ 匹配 $VC \rightarrow v a$ ，填入 VC
 - $(4, 6)$ ： $Aux + NP$ 匹配 $X \rightarrow Aux NP$ ，填入 X
 - 其余长度 2 子串无匹配产生式，集合为空。
- 长度 $l = 3$ ：拆分为 1+2 组合推导：

- (0,3): $VC + utl$ 匹配 $VC \rightarrow VC\ utl$, 填入 VC
- (3,6): $NP + X$ 匹配 $NP \rightarrow NP\ X$, 填入 NP
- 其余长度 3 子串无匹配产生式, 集合为空。
- 长度 $l = 4$: 拆分为 1+3、2+2 组合推导:
 - (0,4): $VC + NP$ 同时匹配 $S \rightarrow VC\ NP$ 与 $VP \rightarrow VC\ NP$, 填入 S, VP
 - 其余长度 4 子串无匹配产生式, 集合为空。
- 长度 $l = 5$: 所有拆分组合均无匹配产生式, 对应格子为空集。
- 最终矩阵 (长度 $l = 6$, 整句): 整句存在两条有效推导路径:
 - 拆分 $k = 3$: $VC + NP$ 匹配 $S \rightarrow VC\ NP$ 、 $VP \rightarrow VC\ NP$
 - 拆分 $k = 4$: $VP + X$ 匹配 $S \rightarrow VP\ X$


最终格子 (0,6) 包含起始符 S , 证明该句子符合文法; 且存在两条不同推导路径, 为歧义句。

	0	1	2	3	4	5	6
0		v	VC	VC	S, VP		S
1		咬	a				
2			死	utl			
3				了	NP		NP
4					猎人	Aux	X
5						的	NP
6							狗

步骤 4: 绘制两棵句法分析树


结构一: 动宾结构 (语义: 咬死了“猎人的狗”)

整体为述宾结构, 宾语是偏正短语“猎人的狗”:



结构二: 偏正结构 (语义: “咬死了猎人” 的狗)

整体为定中结构, 中心语是“狗”, 定语是述宾短语“咬死了猎人”:



5. **【2025 · 真题计算 T2】**采用 CYK 算法进行句法结构分析（注意 Chomsky 范式化）：
文法：

$$\begin{aligned}
 S &\rightarrow P VP \\
 VP &\rightarrow V VP \mid V N \mid V NP \mid VP CC VP \\
 P &\rightarrow \text{他} \\
 V &\rightarrow \text{喜欢} \mid \text{看} \mid \text{读} \\
 N &\rightarrow \text{历史} \mid \text{书} \mid \text{电影} \\
 CC &\rightarrow \text{和}
 \end{aligned}$$

句子：他喜欢看电影和读历史书

分词标注：他/P 喜欢/V 看/V 电影/N 和/CC 读/V 历史/N 书/N

解析：

步骤 1：文法转化为 Chomsky 范式（仅允许 $A \rightarrow BC$ 或 $A \rightarrow a$ ）

- 不是哥们，你们三个人挤一屋里干啥？滚出去!!!

令新增非终结符 $X \rightarrow CC VP$ ，将原三元产生式 $VP \rightarrow VP CC VP$ 改写为 $VP \rightarrow VP X$ 。

- 你先别急，NP 这玩意儿还能下崽 (?)!!!

根据 $VP \rightarrow V NP$ 的动宾结构，名词短语 NP 的基础产生式为 $NP \rightarrow N \mid N N$ ；其中 $NP \rightarrow N$ 为单元产生式，消除后直接将终结符赋给 NP ，即 $NP \rightarrow \text{历史} \mid \text{书} \mid \text{电影}$ ，保留二元产生式 $NP \rightarrow N N$ 。

- 新 CNF 文法的单元终结符产生式：不变
- 新 CNF 文法的二元产生式：

$$\begin{aligned}
 S &\rightarrow P VP \\
 VP &\rightarrow V VP \mid V N \mid V NP \mid VP X \\
 NP &\rightarrow N N \\
 X &\rightarrow CC VP
 \end{aligned}$$

步骤 2：分词与序列标注

长度 $n = 8$ ，对应：他 / P 、喜欢 / V 、看 / V 、电影 / N 、和 / CC 、读 / V 、历史 / N 、书 / N

步骤 3：构造 CYK 上三角识别矩阵

矩阵格子 (i, j) ($i < j$) 对应从第 $i + 1$ 到第 j 个词的子串，填入可推出该子串的非终结符；主对角线格子 (j, j) 填入对应终结符汉字。按子串长度从小到大逐层填表：

- 初始矩阵（长度 $l = 1$ ）：填入单个词对应的非终结符与汉字：

	0	1	2	3	4	5	6	7	8
0		P							
1		他	V						
2			喜欢	V					
3				看	N, NP				
4					电影	CC			
5						和	V		
6							读	N, NP	
7								历史	N, NP
8									书


- 长度 $l = 2$ ：两两组合匹配二元产生式：
 - (2, 4)： $V + N / V + NP$ 匹配 $VP \rightarrow V N$ 、 $VP \rightarrow V NP$ ，填入 VP
 - (5, 7)： $V + N / V + NP$ 匹配 $VP \rightarrow V N$ 、 $VP \rightarrow V NP$ ，填入 VP
 - (6, 8)： $N + N$ 匹配 $NP \rightarrow N N$ ，填入 NP
 - 其余长度 2 子串无匹配产生式，集合为空。
- 长度 $l = 3$ ：拆分为 1+2、2+1 组合推导：
 - (1, 4)： $V + VP$ 匹配 $VP \rightarrow V VP$ ，填入 VP
 - (4, 7)： $CC + VP$ 匹配 $X \rightarrow CC VP$ ，填入 X
 - (5, 8)： $V + NP$ 匹配 $VP \rightarrow V NP$ ，填入 VP
 - 其余长度 3 子串无匹配产生式，集合为空。
- 长度 $l = 4$ ：拆分为 1+3、2+2、3+1 组合推导：
 - (0, 4)： $P + VP$ 匹配 $S \rightarrow P VP$ ，填入 S
 - (4, 8)： $CC + VP$ 匹配 $X \rightarrow CC VP$ ，填入 X
 - 其余长度 4 子串无匹配产生式，集合为空。
- 长度 $l = 5$ ：拆分为多组组合推导：
 - (2, 7)： $VP + X$ 匹配 $VP \rightarrow VP X$ ，填入 VP
 - 其余长度 5 子串无匹配产生式，集合为空。

- 长度 $l = 6$: 拆分为多组组合推导:
 - (1,7): $V + VP$ 匹配 $VP \rightarrow V VP$, 填入 VP
 - (2,8): $VP + X$ 匹配 $VP \rightarrow VP X$, 填入 VP
 - 其余长度 6 子串无匹配产生式, 集合为空。
- 长度 $l = 7$: 拆分为多组组合推导:
 - (0,7): $P + VP$ 匹配 $S \rightarrow P VP$, 填入 S
 - (1,8): $V + VP$ 匹配 $VP \rightarrow V VP$, 填入 VP
 - 其余长度 7 子串无匹配产生式, 集合为空。
- 最终矩阵 (长度 $l = 8$, 整句): 整句拆分 $k = 1$: $P + VP$ 匹配 $S \rightarrow P VP$, 最终格子 (0,8) 包含起始符 S , 证明该句子符合文法。

	0	1	2	3	4	5	6	7	8
0		P			S			S	S
1		他	V		VP			VP	VP
2			喜欢	V	VP		VP		VP
3				看	N, NP				
4					电影	CC		X	X
5						和	V	VP	VP
6							读	N, NP	NP
7								历史	N, NP
8									书

步骤 4: 句法分析树

根据推导过程还原句法层级结构, 整句为主谓结构, 谓语部分为嵌套动宾 + 并列结构:



第十讲 语义分析

10.1 本讲重点

1. 熟悉语义分析的任务内容、划分方式；
2. 熟悉词义消歧的概念定义；
3. 熟悉词义消歧主要方法的分类；
4. 熟悉语义角色标注的概念定义；
5. 熟悉常见语义角色，了解中文语义角色标注语料库（CPB、CNB）的语义角色集合；
6. 了解语义角色标注方法的基本流程。

10.2 语义分析概述

★★ 语义分析：对输入的文本内容，在词法分析、句法分析的基础上，让计算机进一步识别出作者所表达的意义内涵。即建立计算模型，让计算机能通过计算识别出语言符号与背后客观世界的真实联系。

★★ 语义分析任务的类型划分：

- 按分析层面划分：
 - 词语层面：词义消歧
 - 句子层面：语义角色标注
 - 篇章层面：共指消解、话题结构分析
- 按理解深度划分：
 - 浅层语义分析：词义消歧、语义角色标注、共指消解、话题结构分析
 - 深层次语义推理：高阶文本理解、生成类推理

10.3 词义消歧

★★ 词义消歧：确定一个多义词在给定上下文语境中的具体含义。

词的多义现象分类：

1. 意义相关的多义（如：open 的“开着的”、“公开的”）
2. 意义无关的多义（如：bank 的“银行”、“河堤”）
3. 词性不同的多义（如：cook 的“煮”、“厨师”）

上下文信息的特点：邻近的上下文信息对于确定词性非常有效；相隔很远的实词对于确定词义往往更有效。

★★ 主要消歧方法分类:

1. 基于规则的方法: 人工抽取出词与词连用的限制规则, 利用这些规则进行消歧。
2. 基于有监督学习的方法:
 - 基于互信息: 基于标注语料, 使用互信息作为度量模型为多义词归纳上下文特征 (指示器), 帮助鉴别语义。
 - 基于贝叶斯分类器: 利用贝叶斯公式计算多义词在特定上下文中各义项的概率分布进行分类。
 - 基于最大熵: 将词的上下文作为特征信息, 利用最大熵模型对语义进行分类。
3. 基于词典的方法: ★★★
 - 基于词典中语义定义的消歧方法: 将词典中词条本身的定义作为判断其语义的条件。
 - 基于义类辞典的消歧方法: 确定多义词上下文词语的语义类状况, 通过统计共现的语义类规律来确定多义词在此语境中的词义。
 - 基于双语词典的消歧方法: 利用第二种语言的语料库, 统计对应不同词义的翻译词与上下文词的同现频次, 同现频次显著高者即为消歧结果。

10.4 语义角色标注——【2025·真题选择 T13】

★★ 语义角色标注 (SRL): 以句子的谓词为中心, 研究句子中各成分与谓词之间的关系, 并用语义角色来描述区分它们之间的关系。语义角色指句子中与谓词具有“格”关系的成分。

需要标注的语义角色: 指**体词** (名词、代词等) 和**谓词** (动词) 之间的**及物性关系**, 如动作和施事者、动作和受事者、动作和结果、动作和工具等关系。常见的格 (及物性关系) 如下:

- (1) 施事格 (Agentive): 动作的发生者。
- (2) 工具格 (Instrumental): 对动作或状态而言作为某种因素而牵涉到的无生命的力量或客体。
- (3) 承受格 (Dative): 由动词确定的动作或状态所影响的有生物。如: *He is tall.*
- (4) 使成格 (Factitive): 由动词确定的动作或状态所形成的客体或有生物。或理解为: 动词意义的一部分的客体或有生物。如: *John dreamed a dream about Mary.*
- (5) 方位格 (Locative): 由动词确定的动作或状态的处所或空间方位。如: *He is in the house.*
- (6) 客体格 (Objective): 由动词确定的动作或状态所影响的事物。如: *He bought a book.*
- (7) 受益格 (Benefactive): 由动词确定的动作为之服务的有生命的对象。如: *He sang a song for Mary.*
- (8) 源点格 (Source): 由动词确定的动作所作用到的事物的来源或发生位置变化过程中的起始位置。如: *He bought a book from Mary.*
- (9) 终点格 (Goal): 由动词确定的动作所作用到的事物的终点或发生位置变化过程中的终端位置。如: *I sold a car to Mary.*
- (10) 伴随格 (Comitative): 由动词确定的与施事共同完成动作的伴随者。如: *He sang a song with Mary.*


★ 中文 PropBank 语义角色体系：

中文语义角色标注的语料库主要有 **Chinese PropBank (CPB)** 和 **Chinese NomBank (CNB)**。它们都是在中文树库 (Chinese Treebank) 的句法成分中加入了人工标注的语义角色信息。也把语义角色分为两类：

- (1) **核心语义角色**：ARG0, ..., ARG4, 如 ARG0 表示动作的施事者, ARG1 表示受事者；
- (2) **起修饰作用的辅助性角色**：其角色标签都以 ARGM 开头, 如下表。

语义角色	角色描述	语义角色	角色描述	语义角色	角色描述
ARG0	施事者	ARGM-ADV	状语	ARGM-MNR	方式
ARG1	受事者	ARGM-BNF	受益者	ARGM-PRP	目的
ARG2	范围或程度	ARGM-CND	条件	ARGM-TMP	时间
ARG3	动作起点	ARGM-DIR	方向	ARGM-TPC	主题
ARG4	动作结束点	ARGM-LOC	地点	ARGM-PRD	次谓词

★ 语义角色标注的基本流程：



★ 主要标注方法及核心差异：

1. **基于短语结构树的标注方法**：基于句法结构分析的结果（句法结构树）进行标注。
标注对象为短语，特征信息主要从句法结构树中抽取。
2. **基于依存关系树的标注方法**：基于句子依存关系分析的结果（依存树）进行标注。
标注对象为词语，特征信息主要从依存树中抽取。
3. **基于浅层句法语块的标注方法**：基于浅层句法分析的结果（语块序列）进行标注。

10.5 课后作业

1. 简述词义消歧的概念？目前主要的词义消歧方法分为哪几类？

解析：概念：确定一个多义词在给定上下文语境中的具体含义。

主要分类：基于规则的方法、基于有监督学习的方法、基于词典的方法。

2. 【2025·真题简答 T5】基于词典的词义消歧有哪几种类型，分别简述其原理？

解析：主要分为三种：

- 基于词典中语义定义的消歧方法：将词典中词条本身的定义作为判断其语义的条件。
- 基于义类辞典的消歧方法：确定多义词上下文词语的语义类状况，通过统计共现的语义类规律来确定多义词在此语境中的词义。
- 基于双语词典的消歧方法：利用第二种语言的语料库，统计对应不同词义的翻译词与上下文词的同现频次，同现频次显著高者即为消歧结果。

3. 简述语义角色标注的概念？自然语言处理中常用有哪些语义角色？

解析：概念：以句子的谓词为中心，研究句子中各成分与谓词之间的关系，并用语义角色来描述区分它们之间的关系。

常用的语义角色源自动词的“格”框架，主要包括：动作和施事者、受事者、结果、工具等关系。

4. 简述基于短语结构树与基于依存关系树的语义角色标注方法之间的核心差异？

解析：核心差异在于标注对象和特征来源不同：


- 基于短语结构树的方法：标注对象为**短语**，特征信息主要从**句法结构树**中抽取。
- 基于依存关系树的方法：标注对象为**词语**，特征信息主要从**依存句法树**中抽取。

第十一讲 预训练词向量（新增内容）

文本表示是自然语言处理中最基础、最本质的问题——如何让计算机理解并处理自然语言文本。词的表示方法大体经历了从独热（One-hot）表示，到分布式表示，再到词向量（Word Embedding）三个阶段。在此基础上，预训练词向量又经历了从静态（一词一向量）到动态（根据上下文生成向量）的演进，标志着词表示技术从浅层语义理解迈向更深层次的语义理解。

11.1 基础概念

11.1.1 NLP 技术的发展过程 ★★



自然语言处理技术经历了四次范式变迁：

- **小规模专家系统（1950~1990）**
- **语料库统计模型（1990~2010）**：使用离散的语言符号来表示词（如近义词：{土豆, 马铃薯}，褒义词：{好, 喜欢}，否定词：{不, 没有}）。
- **深度学习模型（2010~2017）**：把词语表示成低维的稠密向量。
- **大规模预训练模型（2018~ 至今）**：确立了“预训练 (Pre-train) + 精调 (Fine-tune)”的自然语言处理新范式。

示例：“土豆非常好吃。”的情感倾向性识别


- **基于专家系统/规则**：如果出现褒义词“好”“喜欢”等，则结果为褒义；如果出现“不”，则结果倾向性取反。
- **基于统计模型（离散表示）**：使用离散、高维稀疏的向量表示词。例如，维度为词表大小，仅在对索引位置为 1：
 - 土豆：[0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, ...]
 - 马铃薯：[0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, ...]

11.1.2 文本表示问题

文本表示：将人类的自然语言文本，转化为计算机能够理解和处理的数字形式（如向量）的过程。它是连接原始文本与 NLP 模型之间的核心桥梁，让机器具备了“读懂”文字的基础能力。

- **模型的基石**：分类、翻译、问答、生成等所有 NLP 核心任务，都建立在高质量的文本表示之上，它是模型理解语言的起点。
- **效果的关键**：文本表示质量直接决定模型性能上限。优秀的表示能精准捕捉语义、语法和上下文信息，反之则会限制模型的表达与推理能力。
- **分类**：
 - **词语表示 (Word Representation)**：研究对单个词语进行向量化表示的方法，是文本表示的基础单元，也是理解语言最小语义颗粒的关键。
 - **整文表示 (Text Representation)**：将句子、段落或文档转化为向量，通常基于词语表示构建，用于处理更长文本的整体语义理解任务。

11.2 传统的词表示模型 ★★



11.2.1 词的离散表示：One-hot 模型

One-hot 模型：核心原理是给每个词分配一个唯一的“数字身份证”。为词汇表中的每个词分配一个唯一的索引，索引表现为一个稀疏向量，向量中仅对应索引位置为 1，其余全为 0。

- **特征空间特点**：每个词向量都是正交的，向量长度恒为 1。结构简单、易于实现。
- **编码映射示例**：设词汇表 $V = \{\text{苹果}, \text{香蕉}, \text{橙子}, \dots\}$ ，则“苹果”映射为 $[1, 0, 0]$ ，“香蕉”映射为 $[0, 1, 0]$ ，“橙子”映射为 $[0, 0, 1]$ 。
- **缺陷**：容易造成维度灾难，且词向量之间完全正交，无法体现词与词之间的语义相似度。

11.2.2 词的分布表示

分布语义假设 (Distributional semantic hypothesis)：词的含义可由其上下文词的分布进行表示。“A word is characterized by the company it keeps.”（词如其伴）——理论核心在于：两个词的语义相似度由其上下文环境的相似度决定。

分布词向量：用在语料库中统计得到的上下文信息来表示词的语义。语义相似度通过计算向量相似度获得。但从原始语料库中直接简单统计得到的分布词向量仍然存在高维稀疏、语义精确性不高的问题。

代表性模型：

1. LSA (Latent Semantic Analysis) 模型:

- 目标: 降低稀疏性; 反映高阶共现关系。
- 方式: 利用奇异值分解 (SVD) 实现矩阵降维。

2. HAL (Hyperspace Analogue to Language) 模型:

- 实现机制: 设定固定大小的滑动窗口扫描语料, 窗口内的上下文词根据与中心词的距离获得权重 (距离越近权重越高), 并将权重累加到词-词共现矩阵中。
- 模型产出: 高维的加权词语共现矩阵。
- 优势: 完全自动化构建; 原理直观。
- 局限: 维度高且稀疏; 共现矩阵不对称增加计算成本; 简单的线性加权语义表达能力有限。

11.3 预训练静态词向量

11.3.1 词的嵌入表示 (分布式表示)

针对分布表示高维稀疏等缺点, 提出了词的分布式表示。

词嵌入 (Word Embedding / 分布式表示): 使用低维、稠密、连续的向量表示词。通过“自监督学习”方法学习得到词向量 (效果显著优于直接的统计方法)。可分为**预训练静态词向量**和**预训练动态词向量**两类。

预训练静态词向量的分类:

- 基于神经网络语言模型的词向量 (FF-NNLM, RNNLM)。
- 基于局部上下文预测模型的词向量 (Word2vec 中的 CBOW 模型和 Skip-gram 模型)。
- 基于全局词频统计模型的词向量 (GloVe 模型)。

11.3.2 基于神经网络语言模型的静态词向量

- **FF-NNLM (基于前馈神经网络):** 根据前 $n - 1$ 个词 (历史) 预测当前词。通过在词向量矩阵 E 中查找表获得词的向量表示。词向量训练伴随神经网络训练过程, 通过梯度下降迭代优化词向量矩阵 E 。缺点: 语言模型训练中, “历史” 的长度不可变。
- **RNNLM (基于循环神经网络):** 根据完整的“历史”对当前词进行预测。缺点: 受“语言模型”的约束, 只利用了“历史”信息来训练词向量模型, 未利用下文信息。

11.3.3 Word2vec 词向量 ★★——【2025·真题选择 T19】

设计相对语言模型网络更简单的神经网络, 以对局部上下文的共现规律预测为目标, 训练出词向量模型。

- **CBOW 模型**：根据周围词（上下文）预测中间词。上下文表示采用周围词向量取平均。
- **Skip-Gram 模型**：**根据中间词（目标词）独立地预测周围词（上下文）。**
- **负采样 (Negative Sampling) ★★**：
 - **要解决的问题**：利用 Softmax 对目标词进行预测时，当词表较大且计算资源有限时，概率（归一化）计算效率极低。
 - **解决方式**：将多分类转化为对“(词，上下文)”进行二元分类（1 表示在给定上下文内共现，0 表示不共现）。通过“换词”构造少量负例，极大提升了训练速度。

11.3.4 GloVe 词向量

GloVe (Global Vectors for Word Representation)：结合了全局信息和局部上下文窗口信息的优势。先统计出全局的“词-上下文”共现信息，然后利用回归预测构建词的共现矩阵，隐式地实现矩阵分解，学习出低维的词向量。

11.3.5 词向量的评价

- **内部任务评价方法**：词义相似度计算、词类比关系计算。
- **外部任务评价方法**：知识图谱补全、推荐系统等下游任务。

11.4 预训练动态词向量

11.4.1 动态词向量

- **静态词向量的问题**：假设一个词由唯一的词向量表示。很多词包含多种语义信息，静态词向量无法解决“一词多义”现象。
- **动态词向量的思想**：词向量应根据其所处的上下文不同而动态生成、发生改变。完美解决一词多义问题。

11.4.2 ELMo 词向量

ELMo (Embeddings from Language Models)：利用两个 LSTM 网络分别训练一个前向的语言模型和一个后向的语言模型；采用字符组合作为整个神经网络的输入；对神经网络不同层次的输出向量进行加权平均，得到最终的词向量。

ELMo 为何更有效？输入新句子时，每个单词能得到对应的 3 个 Embedding：

1. 最底层：单词的基础 Word Embedding。
2. 第一层双向 LSTM：这层编码单词的**句法信息**更多一些。
3. 第二层双向 LSTM：这层编码单词的**语义信息**更多一些。

ELMo 的特点:

- **动态（上下文相关）**：词的表示由当前上下文决定。
- **鲁棒**：使用字符级输入，对未登录词具有强鲁棒性。
- **层次**：为下游任务提供了较大的使用自由度。

11.4.3 小结：静态词向量 vs. 动态词向量 ★★★

- **静态词向量 (Word2Vec / GloVe):**
 - **核心**：一词一向量，向量固定与上下文无关。
 - **特性**：轻量高效，基于浅层模型，训练和推理速度极快，但无法处理一词多义。
 - **类比**：像一本固定释义的纸质字典。
- **动态词向量 (ELMo / BERT):**
 - **核心**：一词多向量，向量随上下文动态生成。
 - **特性**：深层复杂，基于深层双向神经网络，语义理解更透彻，但计算开销与推理成本更高。
 - **类比**：像一位能读懂语境的聪明读者。

11.5 课后作业

1. 简述 NLP 从基于统计机器学习过渡到当前基于预训练模型的发展过程，以及过程中各阶段的核心特征？

解析：自然语言处理技术经历了四次范式变迁：

- **小规模专家系统（1950~1990）**：依赖人工制定的专家规则系统。
- **语料库统计模型（1990~2010）**：核心特征是使用离散的语言符号（如 One-hot 等高维稀疏向量）来表示词，通过大量统计方法进行学习。
- **深度学习模型（2010~2017）**：核心特征是把词语表示成低维的稠密连续向量，能够较好地提取特征。
- **大规模预训练模型（2018~ 至今）**：确立了“预训练 (Pre-train) + 精调 (Fine-tune)”的新范式。

2. 简述词表示模型的发展过程，以及不同过程的代表性模型？

解析：词表示模型的发展经历了三个主要阶段：

- **离散表示**：为每个词分配唯一的索引数字身份证，表现为高维、稀疏的向量。代表模型：One-hot 模型。
- **分布表示**：基于分布语义假设，利用词在语料库中的上下文共现信息来统计表示词义。代表模型：LSA 模型、HAL 模型。

- **嵌入表示（分布式表示）**：使用低维、稠密、连续的向量表示词，通过自监督学习获得。可分为：
 - **预训练静态词向量**：代表模型有 NNLM、RNNLM、Word2vec (包含 CBOW 和 Skip-gram) 和 GloVe。
 - **预训练动态词向量**：代表模型有 ELMo、BERT、GPT 等。

3. 简述静态词向量与动态词向量之间的核心差异，以及各自的优劣势？

解析：

- **核心差异**：静态词向量是“一词一向量”，向量固定且与上下文无关；动态词向量是“一词多向量”，词向量会根据其所处的上下文语境动态生成并改变。
- **静态词向量优劣势**：优势在于模型浅层、轻量高效，训练和推理速度极快；劣势在于无法处理“一词多义”现象，同一词在不同语境下的向量完全相同，语义表达单一。
- **动态词向量优劣势**：优势在于具备强大的上下文感知能力，完美解决“一词多义”难题，捕捉语境对词义的微妙影响，语义理解更透彻；劣势在于基于深层复杂神经网络（如 LSTM/Transformer），模型庞大，计算开销与推理成本更高。

4. 在 Word2vec 模型中为什么需要采用负采样技术？

解析：在利用 Softmax 对目标词进行预测时，如果词汇表非常庞大且计算资源有限，每一次迭代都需要在整个词表上计算概率（归一化），计算效率会极其低下。负采样技术通过将复杂的“多分类预测”转化为对“(词，上下文)”是否共现的“二分类问题”（1 表示共现，0 表示不共现），并通过“换词”构造少量负例。这样每次只需要更新正负样本对应的少量参数，极大提升了训练速度。

End.

<https://github.com/Jaserrr/Intelligent-ST-Wiki>

大学本科四年最后一场考试的复习就到此结束了。

这本讲义也很庆幸能与你见面，陪你走完最后一场考试。

或许心有不舍，不妨昂首向前，迈向更高的舞台，展现更卓越的自我！